2023年2月7日　@電気通信大学
修士論文発表会

Bayesian fused lasso regression modeling for binary data via horseshoe prior

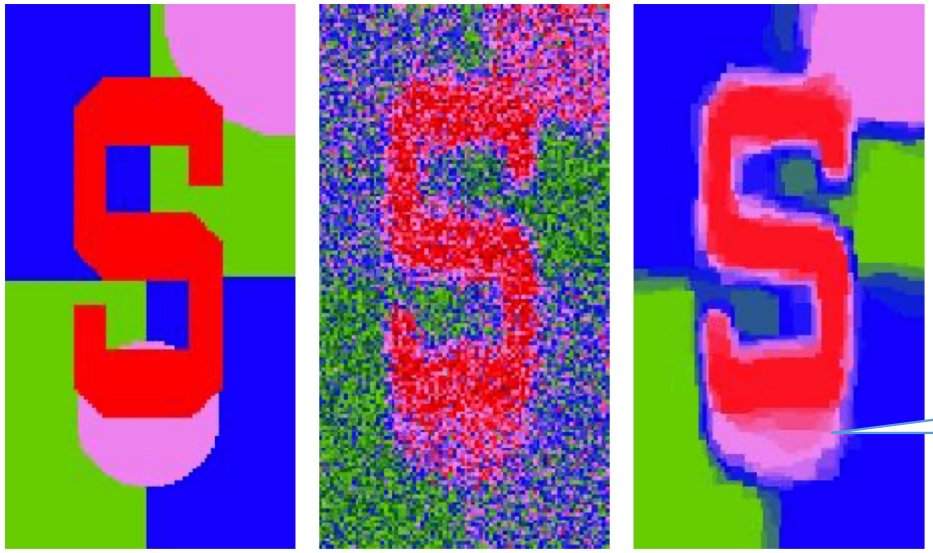
学籍番号 2131047 情報・ネットワーク工学専攻
情報数理工学プログラム　植野研究室
書川 侑子

目次

1. 研究の目的
   - グループ構造を持つデータ
   - 回帰係数の併合
2. 提案手法
   - 馬蹄事前分布に基づくベイジアン連結lassoを用いたロジスティック回帰モデル
3. 実験と結果
   - 数値実験
   - 結果
4. まとめ

グループ構造を持つデータ①

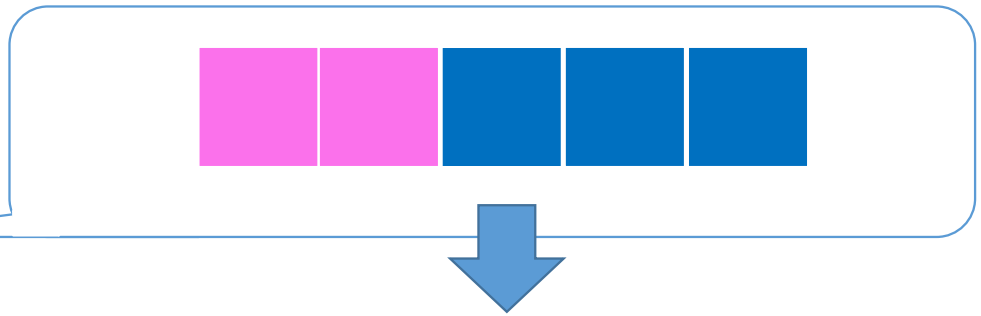
例: ノイズが入った画像から元の画像を予測したい
→各ピクセルの値を予測



(a) Original　(b) Noisy　(c) Denoised

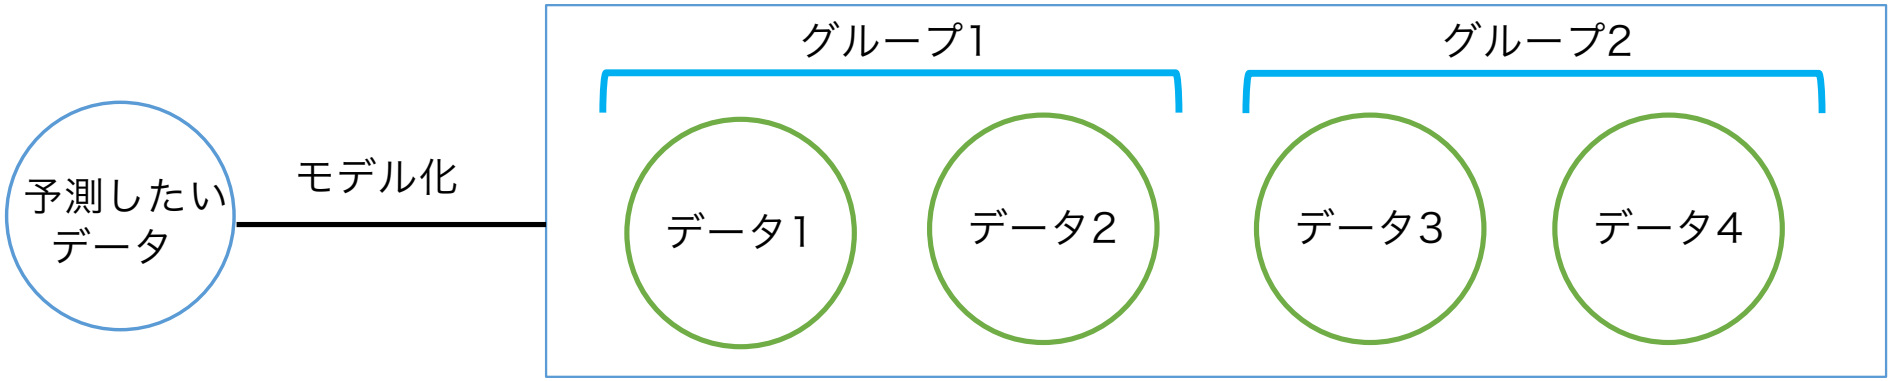
(Tibshirani et al., 2011)

隣り合うピクセルは同じ色(値)を持つ傾向にある



データにグループ構造がある
同じグループはまとめたい

グループ構造を持つデータ②



グループを自動でまとめるモデル

予測したいデータが連続値 例: 画像のノイズ除去 時系列データのトレンド推定	線形回帰モデル Tibshirani et al. (2005) Kakikawa et al. (2022)
予測したいデータが二値 (0,1) 例: 画像の分類 病気の診断	ロジスティック回帰モデル Yu et al. (2015) 本研究

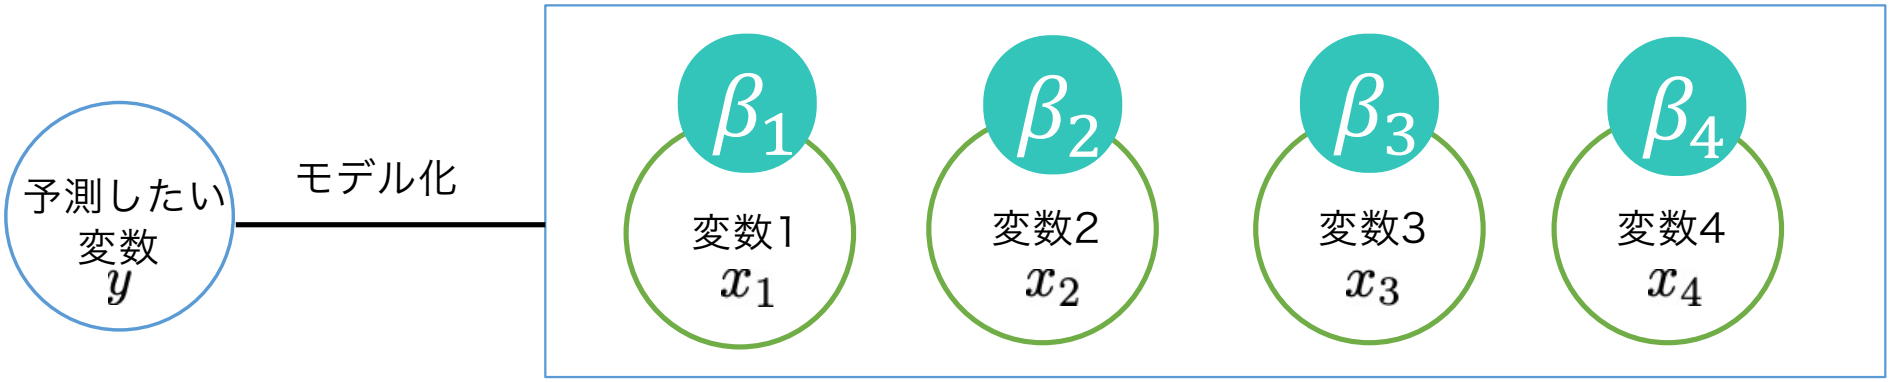
回帰係数の併合①

ロジスティック回帰モデル

目的変数 $y_1, y_2, \ldots, y_n \in \{0, 1\}$　　p次元説明変数ベクトル　$\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_n$

$$\Pr(y_i = 1 | \boldsymbol{x}_i) = \frac{e^{\beta_0 + \boldsymbol{x}_i^T \boldsymbol{\beta}}}{1 + e^{\beta_0 + \boldsymbol{x}_i^T \boldsymbol{\beta}}}, \quad i = 1, \ldots, n$$

・ 切片項 β_0，回帰係数ベクトル $\boldsymbol{\beta} = (\beta_1, \beta_2, \ldots, \beta_p)^T$



回帰係数の併合②

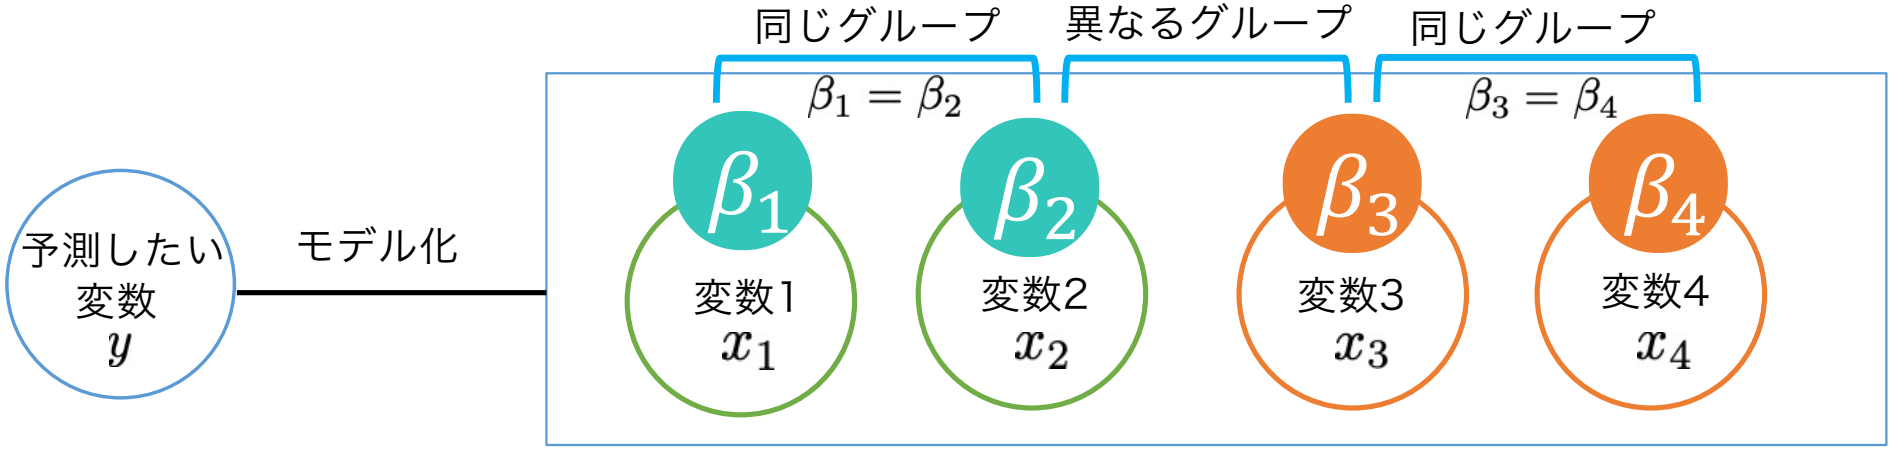
連結 lasso を用いたロジスティック回帰モデル (Yu et al., 2015)

$$\hat{\boldsymbol{\beta}} = \arg\max_{\boldsymbol{\beta}} \left\{ \log f(\boldsymbol{y}|\boldsymbol{X};\boldsymbol{\beta},\beta_0) - \lambda_1 \sum_{j=1}^{p} |\beta_j| - \lambda_2 \sum_{j=1}^{p} |\beta_j - \beta_{j-1}| \right\}$$

ロジスティック回帰モデルの対数尤度

変数選択

回帰係数の併合
(変数をグループ化)



回帰係数の併合③

ベイジアン連結 lasso を用いたロジスティック回帰モデル (Betancourt et al., 2017)

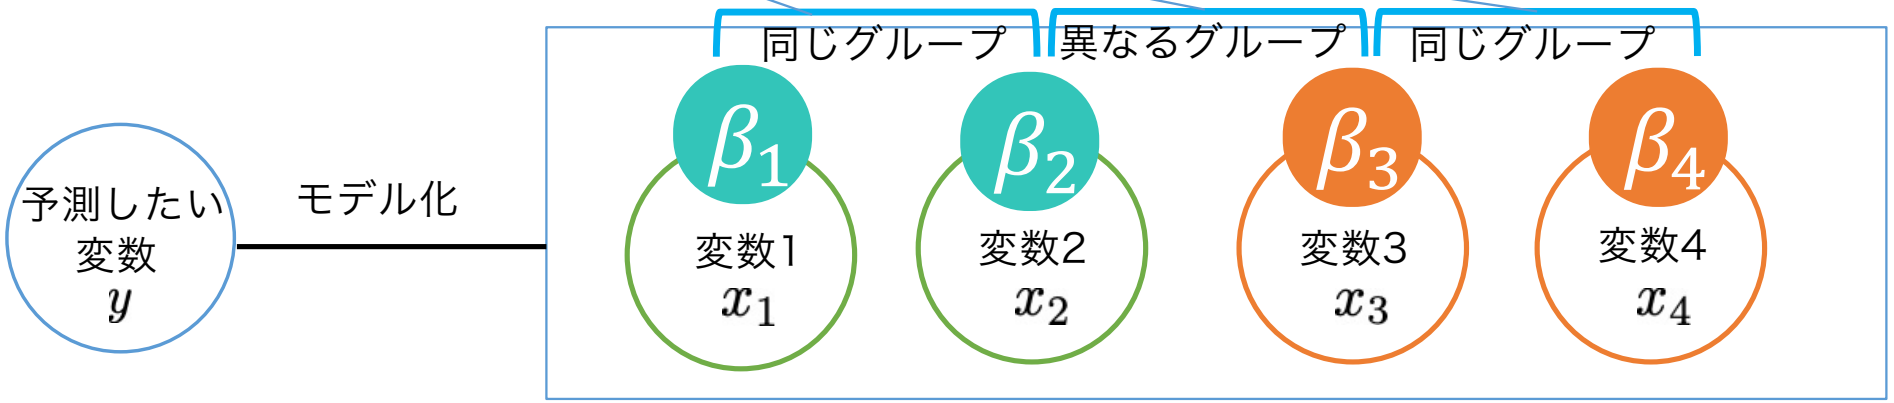
$$y_i|\boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0 \sim \text{Binom}\left(1, \frac{1}{1+e^{-(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})}}\right),$$

$$\beta_j \sim \text{Laplace}(\lambda_1),$$

$$\beta_j - \beta_{j-1} \sim \text{Laplace}(\lambda_2)$$

回帰係数の併合

- Binom (a, b) : 二項分布
- Laplace (λ) : ラプラス分布



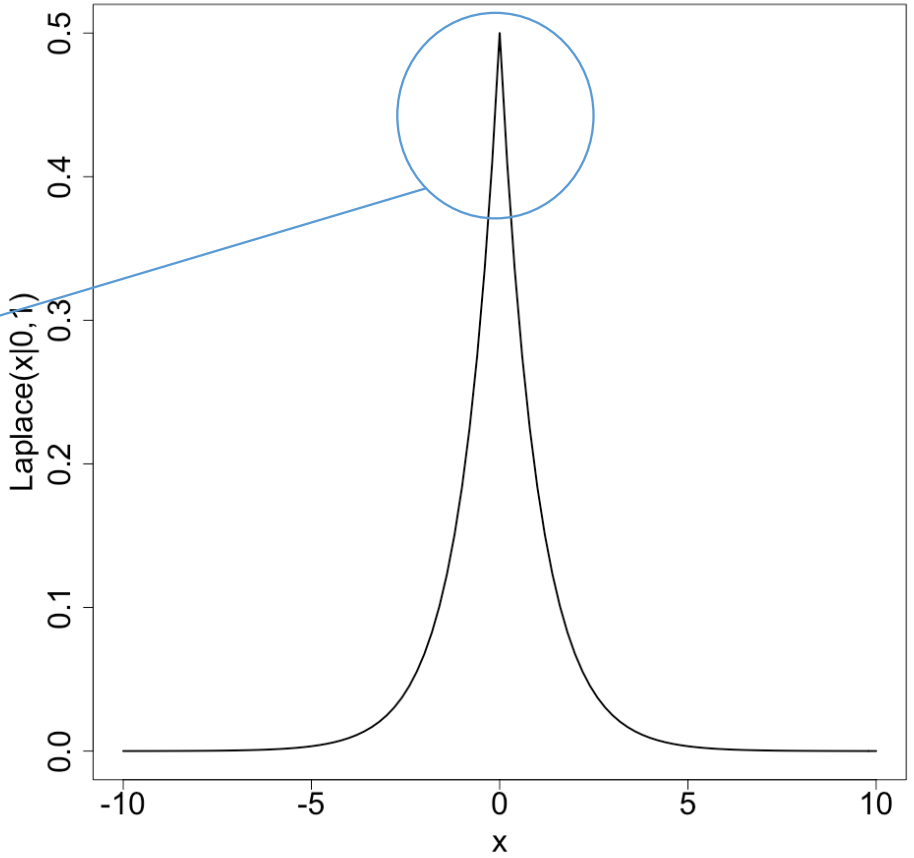
回帰係数の併合④

ラプラス分布

$$\mathrm{Laplace}(x|\mu, b) = \frac{1}{2b}\exp\left(-\frac{|x-\mu|}{b}\right)$$

同じグループの
回帰係数は類似
→**差を縮小**



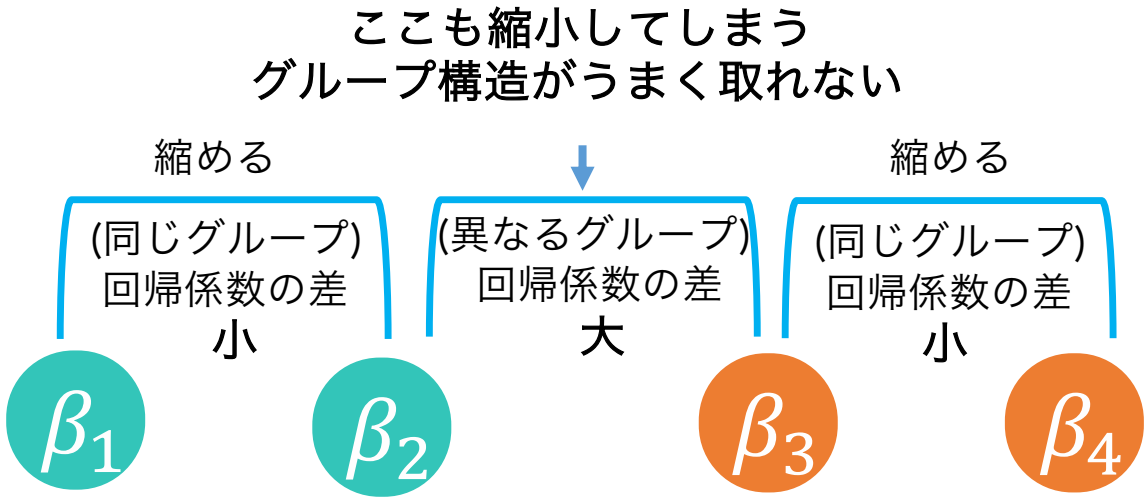


縦軸: 確率密度関数　　横軸: 確率変数の値

問題点と解決策

ベイジアン連結 lasso を用いたロジスティック回帰モデル

ラプラス分布を使う方法: 回帰係数の差を過剰に縮小する恐れ



本研究

馬蹄事前分布 (Carvalho et al., 2010) を用いる

差をなくすべき部分は縮小しつつ、過度な縮小は抑える

馬蹄事前分布を用いた手法

回帰係数β_jに対する馬蹄事前分布を用いたロジスティック回帰モデル
(Makalic and Schmidt, 2015)

$$y_i|\boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0 \sim \text{Binom}\left(1, \frac{e^{\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta}}}{1+e^{\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta}}}\right),$$

変数選択項

$$\beta_j|\tau^2 \sim \text{N}(0, \lambda_j^2\tau^2),$$
$$\lambda_j \sim \text{C}^+(0,1),$$
$$\tau \sim \text{C}^+(0,1)$$

馬蹄事前分布

$C^+(0,a)(a>0)$:半コーシー分布

提案手法①

馬蹄事前分布に基づくベイジアン連結 lasso を用いた
ロジスティック回帰モデル

$$y_i|\boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0 \sim \mathrm{Binom}\left(1, \frac{1}{1+e^{-(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})}}\right),$$

変数選択項

$$\beta_j \sim \mathrm{Laplace}(\lambda_1),$$

ラプラス分布

回帰係数の併合項
(グループ化)

$$\beta_j - \beta_{j-1}|\tilde{\lambda}_j^2, \tilde{\tau}^2 \sim \mathrm{N}(0, \tilde{\lambda}_j^2\tilde{\tau}^2),$$
$$\tilde{\lambda}_j \sim \mathrm{C}^+(0,1),$$
$$\tilde{\tau} \sim \mathrm{C}^+(0,1)$$

馬蹄事前分布

馬蹄事前分布

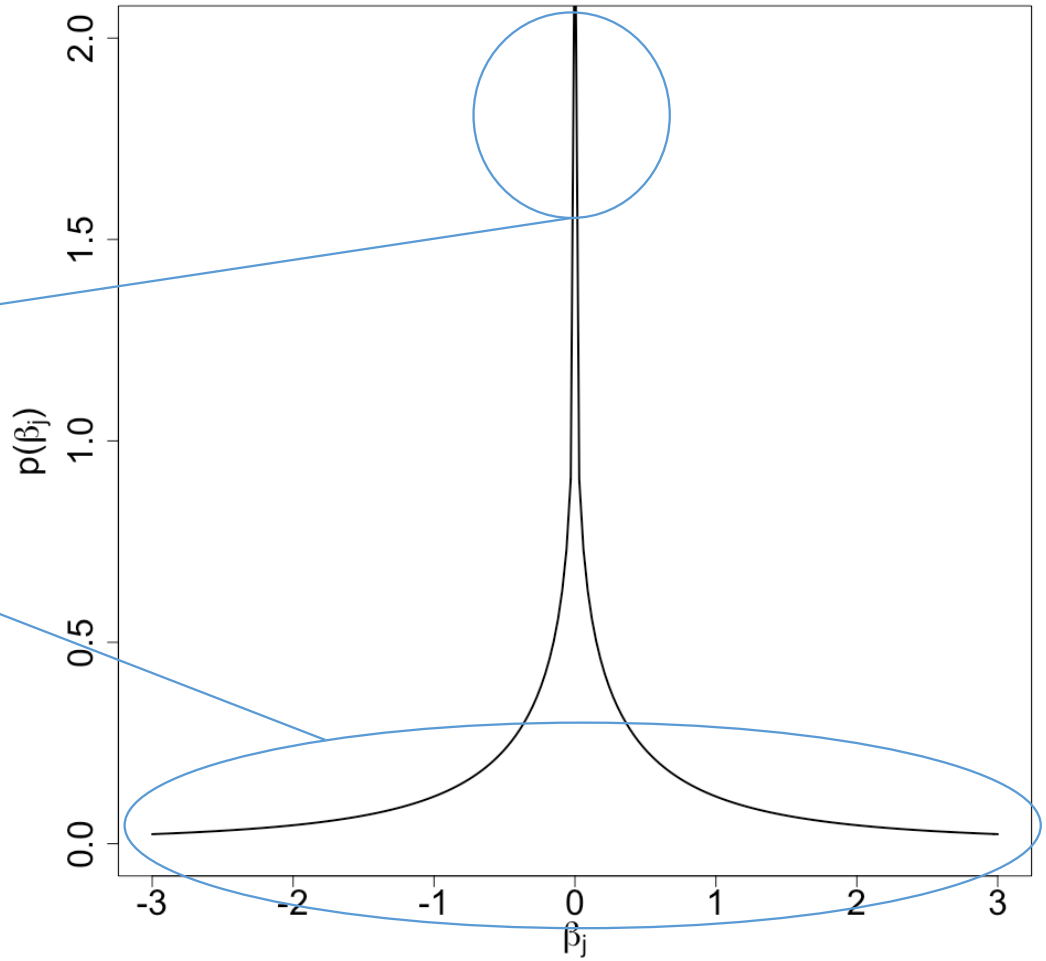
馬蹄事前分布

$$p(\beta_j) = \int_0^\infty \frac{1}{\sqrt{2\pi\lambda^2}} \exp\left(-\frac{\beta_j^2}{2\lambda^2}\right) \frac{2}{\pi(1+\lambda^2)} d\lambda$$

(同じグループ)
回帰係数の差
小

(異なるグループ)
回帰係数の差
大

β_1 β_2 β_3



縦軸: 確率密度関数$p(\beta_j)$ 横軸: 確率変数の値

提案手法②

階層表現による事前分布の書き換え

Pólya-Gamma 分布に従う
潜在変数 ω_i を用いた
尤度の表現 (Polson et al., 2013)

$$y_i|\boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0, \omega_i \sim \text{Binom}\left(1, \frac{1}{1+e^{-(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})}}\right),$$

$$\omega_i \sim \text{PG}(1, 0),$$

正規尺度混合
(Andrews and Mallows, 1974)

$$\beta_j|\tau_j^2 \sim \text{N}(0, \tau_j^2),$$

$$\tau_j^2 \sim \text{EXP}\left(\frac{\lambda_1^2}{2}\right),$$

ラプラス分布

半コーシー分布の階層表現
(Wand et al., 2011)

$$\beta_j - \beta_{j-1}|\tilde{\lambda}_j^2, \tilde{\tau}^2 \sim \text{N}(0, \tilde{\lambda}_j^2\tilde{\tau}^2),$$

$$\tilde{\tau}^2|\xi \sim \text{IG}\left(\frac{1}{2}, \frac{1}{\xi}\right)$$

$$\tilde{\lambda}_j^2|\nu_j \sim \text{IG}\left(\frac{1}{2}, \frac{1}{\nu_j}\right)$$

馬蹄事前分布

$$\xi, \nu_j \sim \text{IG}\left(\frac{1}{2}, 1\right)$$

・IG(a, b) :逆ガンマ分布

数値実験①

真のモデル $\Pr(y_i^* = 1|\boldsymbol{x}_i) = \dfrac{e^{\beta_0^* + \boldsymbol{x}_i^T \boldsymbol{\beta}^*}}{1 + e^{\beta_0^* + \boldsymbol{x}_i^T \boldsymbol{\beta}^*}}, \quad i = 1, \ldots, n$

- 説明変数ベクトル $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_n, \boldsymbol{x}_i \sim \mathrm{N}(\mathbf{0}_p, \boldsymbol{\Sigma}), \Sigma_{i,j} = \begin{cases} 1 & (i = j) \\ \rho & (i \neq j) \end{cases}$
- 回帰係数 $\boldsymbol{\beta}^* = (\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T, (-\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T$
- サンプルサイズ $n = 100, 300,\ \rho = 0.0, 0.5^{|i-j|}$
- MCMC の反復回数は5,000回 (burn in: 2,000回)
- シミュレーション回数は100回

数値実験②

比較手法

1.連結 lasso + ロジスティック回帰 (LFL)

2.ベイジアン連結 lasso + ロジスティック回帰 (LBFL)

・回帰係数、回帰係数の差: ラプラス分布

3.提案手法 (LBFH)

馬蹄事前分布によるベイジアン連結 lasso + ロジスティック回帰

・回帰係数: ラプラス分布、回帰係数の差: 馬蹄事前分布

数値実験③

平均二乗誤差 (MSE)

$$\mathrm{MSE} = \frac{1}{100}\sum_{k=1}^{100}(\hat{\boldsymbol{\beta}}^{(k)} - \boldsymbol{\beta}^*)^T(\hat{\boldsymbol{\beta}}^{(k)} - \boldsymbol{\beta}^*)$$

回帰係数の推定値と真のモデルの回帰係数の差を捉える

負の対数尤度 (EL)

$$\mathrm{EL} = \frac{1}{100}\sum_{k=1}^{100}\left\{-\frac{1}{1000}\sum_{j=1}^{1000}\left[y_j^{\dagger(k)}(\boldsymbol{x}_j^{\dagger(k)^T}\hat{\boldsymbol{\beta}}^{(k)} + \hat{\beta}_0^{(k)}) - \log\{1+\exp(\hat{\boldsymbol{\beta}}^{(k)} + \hat{\beta}_0^{(k)})\}\right]\right\}$$

予測精度を捉える

$y_j^{\dagger}, \boldsymbol{x}_j^{\dagger}$はテストデータ

➡ どちらも小さい方が良いモデルであることを示す

数値実験④

$\boldsymbol{\beta}^* = (\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T$ の場合

		$\rho = 0.0$		$\rho = 0.5^{\lvert i-j \rvert}$	
		MSE (sd)	EL (sd)	MSE (sd)	EL (sd)
$n = 100$	LFL	**1.568 (0.782)**	42.240 (3.555)	**1.633 (0.839)**	31.328 (3.405)
	LBFL	2.565 (1.812)	46.178 (4.701)	3.270 (1.927)	34.972 (4.982)
	LBFH	1.726 (0.773)	**41.123 (2.427)**	1.724 (0.708)	**31.096 (2.697)**
$n = 300$	LFL	0.508 (0.236)	111.35 (3.061)	0.739 (0.455)	82.938 (3.266)
	LBFL	0.719 (0.474)	114.24 (3.831)	1.249 (0.849)	85.797 (3.876)
	LBFH	**0.376 (0.195)**	**109.09 (2.134)**	**0.557 (0.276)**	**81.692 (2.421)**

数値実験⑤

$\boldsymbol{\beta}^* = (-\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T$ の場合

		$\rho = 0.0$		$\rho = 0.5^{\lvert i-j \rvert}$	
		MSE (sd)	EL (sd)	MSE (sd)	EL (sd)
$n = 100$	LFL	**1.635** (1.135)	42.629 (5.366)	1.805 (1.058)	32.078 (3.566)
	LBFL	2.442 (1.512)	46.719 (6.028)	2.640 (1.286)	34.666 (3.875)
	LBFH	1.645 (0.746)	**41.193 (2.900)**	**1.768 (0.606)**	**31.380 (2.155)**
$n = 300$	LFL	0.509 (0.268)	112.08 (3.617)	0.768(0.662)	83.892(3.885)
	LBFL	0.736 (0.349)	115.01 (3.694)	1.286 (0.742)	87.082 (4.065)
	LBFH	**0.381(0.244)**	**109.67 (2.768)**	**0.533 (0.272)**	**82.594 (2.793)**

数値実験⑥

$$\mathrm{MSE}_{\mathrm{diff}} = \frac{1}{100}\sum_{k=1}^{100}\left[\sum_{j=1}^{p-1}\left\{(\hat{\beta}_{j+1}^{(k)} - \hat{\beta}_{j}^{(k)}) - (\beta_{j+1}^{*} - \beta_{j}^{*})\right\}^2\right]$$

0 0 1 0 ...

回帰係数の差が取れている？

例: $\boldsymbol{\beta} = (1,1,1,0,0,0,1,1,1)^T$

$\boldsymbol{\beta}^* = (\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T$ の場合

		$\rho = 0.0$	$\rho = 0.5^{\lvert i-j \rvert}$
		$\mathrm{MSE}_{\mathrm{diff}}$ (sd)	$\mathrm{MSE}_{\mathrm{diff}}$ (sd)
$n = 100$	LFL	1.867 (1.270)	2.176 (1.561)
	LBFL	3.351 (1.732)	4.856 (2.160)
	LBFH	**1.300 (0.508)**	**1.693 (0.539)**

		$\rho = 0.0$	$\rho = 0.5^{\lvert i-j \rvert}$
		$\mathrm{MSE}_{\mathrm{diff}}$ (sd)	$\mathrm{MSE}_{\mathrm{diff}}$ (sd)
$n = 300$	LFL	0.621 (0.371)	1.230 (0.986)
	LBFL	1.054 (0.476)	2.327 (1.204)
	LBFH	**0.322 (0.212)**	**0.780 (0.439)**

数値実験⑦

$$\mathrm{MSE}_{\mathrm{diff}} = \frac{1}{100}\sum_{k=1}^{100}\left[\sum_{j=1}^{p-1}\left\{(\hat{\beta}_{j+1}^{(k)} - \hat{\beta}_{j}^{(k)}) - (\beta_{j+1}^{*} - \beta_{j}^{*})\right\}^2\right]$$

0 0 1 0 ...

回帰係数の差が取れている？

例: $\boldsymbol{\beta} = (1,1,1,0,0,0,1,1,1)^T$

$\beta^* = (-\mathbf{1.0}_5^T, \mathbf{0.0}_5^T, \mathbf{1.0}_5^T, \mathbf{0.0}_5^T)^T$の場合

		$\rho = 0.0$	$\rho = 0.5^{\lvert i-j\rvert}$
		$\mathrm{MSE}_{\mathrm{diff}}$ (sd)	$\mathrm{MSE}_{\mathrm{diff}}$ (sd)
$n = 100$	LFL	1.914 (1.818)	2.569 (2.586)
	LBFL	3.400 (1.910)	4.300 (2.201)
	LBFH	**1.242 (0.569)**	**1.660 (0.467)**

		$\rho = 0.0$	$\rho = 0.5^{\lvert i-j\rvert}$
		$\mathrm{MSE}_{\mathrm{diff}}$ (sd)	$\mathrm{MSE}_{\mathrm{diff}}$ (sd)
$n = 300$	LFL	0.655 (0.468)	1.221 (1.123)
	LBFL	1.067 (0.498)	2.331 (1.127)
	LBFH	**0.324 (0.243)**	**0.722 (0.439)**

まとめ

従来の手法

回帰係数の差を過剰に縮小する恐れがある

→ データのグループ構造を把握できない可能性

本研究

馬蹄事前分布によるベイジアン連結 lasso を用いたロジスティックモデル

✓事前分布の階層表現によりギブスサンプリングを実現

✓グループ構造の把握 + より高い予測性能

今後の課題

- MCMCアルゴリズムの高速化
- 変数のグループ化のための客観的な指標の開発

研究業績

学術論文

Kakikawa, Y., Shimamura, K., and Kawano, S. (2022). Bayesian Fused Lasso Modeling via Horseshoe Prior. arXiv preprint, arXiv:2201.08053. (投稿中)

研究発表

国際学会 1件
国内学会・シンポジウム 10件

受賞歴

2022年度統計関連学会連合大会コンペティション講演 優秀報告賞 (2022/9/8)

参考文献①

Tibshirani, R. J., & Taylor, J. (2011). The solution path of the generalized lasso. The annals of statistics, 39(3), 1335-1371.

Kyung, M., Gill, J., Ghosh, M., and Casella, G. (2010). Penalized regression, standard errors, and Bayesian lassos. Bayesian Analysis, 5(2), 369–411.

Kakikawa, Y., Shimamura, K., & Kawano, S. (2022). Bayesian fused lasso modeling via horseshoe prior. arXiv preprint arXiv:2201.08053.

Yu, D., Lee, S. J., Lee, W. J., Kim, S. C., Lim, J., & Kwon, S. W. (2015). Classification of spectral data using fused lasso logistic regression. Chemometrics and Intelligent Laboratory Systems, 142, 70-77.

Betancourt, B., Rodríguez, A., & Boyd, N. (2017). Bayesian fused lasso regression for dynamic binary networks. Journal of Computational and Graphical Statistics, 26(4), 840-850.

Makalic, E. and Schmidt, D. F. (2015). A simple sampler for the horseshoe estimator.IEEE Signal Processing Letters, 23(1), 179–182.

参考文献②

Polson, N. G., Scott, J. G., & Windle, J. (2013). Bayesian inference for logistic models using Pólya–Gamma latent variables. Journal of the American statistical Association, 108(504), 1339-1349.

Andrews, D. F. and Mallows, C. L. (1974). Scale mixtures of normal distributions. Journal of the Royal Statistical Society: Series B (Methodological), 36(1), 99–102.

Wand, M. P., Ormerod, J. T., Padoan, S. A., and Fru ̈hwirth, R. (2011). Mean field variational Bayes for elaborate distributions. Bayesian Analysis, 6(4), 847–900.

ロジスティック回帰モデルにおける尤度の表現

回帰係数$\boldsymbol{\beta}$のベイズ推定 (Polson et al., 2013)

$p(\boldsymbol{\beta}|\boldsymbol{y}, \beta_0, \boldsymbol{X})$ 回帰係数の事後分布

$$\propto \underbrace{p(\boldsymbol{\beta})}_{\text{回帰係数の事前分布}} \times \underbrace{\left[\prod_{i=1}^{n} \frac{(e^{\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta}})^{y_i}}{1+e^{\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta}}}\right]}_{\text{尤度関数}} \rightarrow 2^{-1}e^{\kappa_i(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})} \int_0^\infty e^{-\frac{w_i(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})^2}{2}} \mathrm{PG}(w_i \mid 1,0)dw_i$$

PG $(w_i|b,c)$: Pólya-Gamma分布

事後分布を単純な形に

$$p(\boldsymbol{\beta}|\boldsymbol{y}, \beta_0, \boldsymbol{X}, \boldsymbol{w}) \propto p(\boldsymbol{\beta})e^{-\frac{1}{2}(z-\boldsymbol{X}\boldsymbol{\beta})^T\boldsymbol{\Omega}(z-\boldsymbol{X}\boldsymbol{\beta})}$$

$$\begin{cases} \kappa_i = y_i - 1/2 \\ z = (\kappa_1/\omega_1, \kappa_2/\omega_2, \ldots, \kappa_n/\omega_n) \\ \boldsymbol{\Omega} = \mathrm{diag}(\omega_1, \omega_2, \ldots, \omega_n) \\ \boldsymbol{y} = (\boldsymbol{y}_1, \boldsymbol{y}_2, \ldots, \boldsymbol{y}_n)^T \\ \boldsymbol{X} = (\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_n)^T \end{cases}$$

馬蹄事前分布によるベイジアン連結lasso回帰を用いたロジスティック回帰モデル

$$
\begin{aligned}
y_i|\boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0, \omega_i &\sim \mathrm{Binom}\left(1, \frac{1}{1+e^{-(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})}}\right), \\
\omega_i &\sim \mathrm{PG}(1,0), \\
\beta_j &\sim \mathrm{Laplace}(\lambda_1), \\
\beta_j - \beta_{j-1}|\tilde{\lambda}_j^2, \tilde{\tau}^2 &\sim \mathrm{N}(0, \tilde{\lambda}_j^2\tilde{\tau}^2), \\
\tilde{\lambda}_j &\sim \mathrm{C}^+(0,1), \\
\tilde{\tau} &\sim \mathrm{C}^+(0,1), \\
\lambda_1^2 &\sim \mathrm{Ga}(r_1, \delta_1)
\end{aligned}
$$

回帰係数の併合

正規尺度混合 (Andrews and Mallows,1974)

$$\mathrm{Laplace}(x|\lambda) = \frac{\lambda}{2}\exp\left(-\lambda|x|\right)$$

$$= \int_0^\infty \frac{1}{\sqrt{2\pi\tau^2}}\exp\left(-\frac{x^2}{2\tau^2}\right)\frac{\lambda^2}{2}\exp\left(-\frac{\lambda^2}{2}\tau^2\right)d\tau^2$$

正規分布　　指数分布

$$y_i|\boldsymbol{x}_i,\boldsymbol{\beta},\beta_0,\omega_i \sim \mathrm{Binom}\left(1,\frac{1}{1+e^{-(\beta_0+\boldsymbol{x}_i^T\boldsymbol{\beta})}}\right),$$

$$\beta_j \sim \mathrm{Laplace}(\lambda_1),$$

$$\beta_j - \beta_{j-1}|\mathrm{Laplace}(\lambda_2)$$

正規尺度混合

$$\beta_j|\tau_j^2 \sim \mathrm{N}\left(0,\tau_j^2\right),$$

$$\tau_j^2 \sim \mathrm{EXP}\left(\frac{\lambda_1^2}{2}\right),$$

$$\beta_j - \beta_{j-1}|\tilde{\tau}_j^2 \sim \mathrm{N}\left(0,\tilde{\tau}_j^2\right),$$

$$\tilde{\tau}_j^2 \sim \mathrm{EXP}\left(\frac{\lambda_2^2}{2}\right)$$

EXP(λ_1): 指数分布

馬蹄事前分布によるベイジアン連結lasso回帰を用いたロジスティック回帰モデル

完全条件付き分布

$$\boldsymbol{\beta} \mid \boldsymbol{y}, \boldsymbol{X}, \beta_0, \tau_1^2, \ldots, \tau_p^2, \tilde{\tau}^2, \lambda_2^2, \ldots, \lambda_p^2, w_1, w_2, \ldots, w_n \sim \mathrm{N}_p(\boldsymbol{A}^{-1}\boldsymbol{X}^T\boldsymbol{W}(\boldsymbol{z} - \beta_0\boldsymbol{1}), \boldsymbol{A}^{-1})$$

$$\boldsymbol{A} = \boldsymbol{X}^T\boldsymbol{W}\boldsymbol{X} + \boldsymbol{\Sigma}_{\boldsymbol{\beta}}^{-1},$$

$$w_i \mid \boldsymbol{x}_i, \boldsymbol{\beta}, \beta_0 \sim \mathrm{PG}(1, \beta_0 + \boldsymbol{x}_i^T\boldsymbol{\beta}),$$

$$\frac{1}{\tau_j^2} \mid \beta_j, \tilde{\lambda}_1^2 \sim \mathrm{IGauss}\left(\sqrt{\frac{\tilde{\lambda}_1^2}{\beta_j^2}}, \tilde{\lambda}_1^2\right),$$

$$\tilde{\lambda}_1^2 \mid \tau_1^2, \ldots, \tau_p^2 \sim \mathrm{Ga}\left(p + r_1, \frac{1}{2}\sum_{j=1}^p \tau_j^2 + \delta_1\right),$$

$$\tilde{\tau}^2 \mid \beta_1, \ldots, \beta_p, \lambda_2^2, \ldots, \lambda_p^2, \xi \sim \mathrm{IG}\left(\frac{p}{2}, \frac{1}{2}\sum_{j=2}^p \frac{(\beta_j - \beta_{j-1})^2}{\lambda_j^2} + \frac{1}{\xi}\right),$$

$$\lambda_j^2 \mid \beta_j, \beta_{j-1}, \tilde{\tau}^2, \nu_j \sim \mathrm{IG}\left(1, \frac{(\beta_j - \beta_{j-1})^2}{2\tilde{\tau}^2} + \frac{1}{\nu_j}\right),$$

$$\nu_j \mid \lambda_j^2 \sim \mathrm{IG}\left(1, \frac{1}{\lambda_j^2} + 1\right),$$

$$\xi \mid \tilde{\tau}^2 \sim \mathrm{IG}\left(1, \frac{1}{\tilde{\tau}^2} + 1\right),$$

$$\beta_0 \mid \boldsymbol{y}, \boldsymbol{X}, \tau_1^2, \ldots, \tau_p^2, \tilde{\tau}^2, \lambda_2^2, \ldots, \lambda_p^2, w_1, w_2, \ldots, w_n \sim \mathrm{N}\left(\frac{1}{S}\sum_{i=1}^n v_i, \frac{1}{S}\right),$$

$$v_i = (\boldsymbol{z} - \boldsymbol{X}\boldsymbol{\beta}) \odot \boldsymbol{W},$$

$$S = \sum_{i=1}^n w_i.$$

提案手法1-①

馬蹄事前分布に基づくベイジアン連結 lasso 回帰モデル

$$\boldsymbol{y}|\boldsymbol{X},\boldsymbol{\beta},\sigma^2 \sim \mathrm{N}_n(\boldsymbol{X}\boldsymbol{\beta},\sigma^2\boldsymbol{I}_n),$$

変数選択項

$$\frac{\beta_j}{\sqrt{\sigma^2}}|\sigma^2, \sim \mathrm{Laplace}(\lambda_1),$$

ラプラス分布

回帰係数の併合項
(グループ化)

$$\beta_j - \beta_{j-1}|\tilde{\lambda}_j^2,\tilde{\tau}^2,\sigma^2 \sim \mathrm{N}(0,\tilde{\lambda}_j^2\tilde{\tau}^2\sigma^2),$$
$$\tilde{\lambda}_j \sim \mathrm{C}^+(0,1),$$
$$\tilde{\tau} \sim \mathrm{C}^+(0,1),$$

馬蹄事前分布

$$\sigma^2 \sim \mathrm{IG}\left(\frac{\nu_0}{2},\frac{\eta_0}{2}\right),$$
$$\lambda_1^2 \sim \mathrm{Ga}(\mathrm{r}_1,\delta_1)$$

・$\mathrm{IG}(\frac{\nu_0}{2},\frac{\eta_0}{2})$: 逆ガンマ分布
・$\mathrm{Ga}(r_1,\delta_1)$: ガンマ分布

提案手法1-②

正規尺度混合(Andrews and Mallows,1974)、
半コーシー分布の階層表現 (Wand et al., 2011)を使うと

$$\boldsymbol{y}|\boldsymbol{X},\boldsymbol{\beta},\sigma^2 \sim \mathrm{N}_n(\boldsymbol{X}\boldsymbol{\beta},\sigma^2\boldsymbol{I}_n),$$

正規尺度混合
(Andrews and Mallows, 1974)

$$\beta_j|\sigma^2,\tau_j^2 \sim \mathrm{N}(0,\sigma^2\tau_j^2),$$

$$\tau_j^2 \sim \mathrm{EXP}\left(\frac{\lambda_1^2}{2}\right),$$

ラプラス分布

半コーシー分布の階層表現
(Wand et al., 2011)

$$\beta_j - \beta_{j-1}|\tilde{\lambda}_j^2,\tilde{\tau}^2,\sigma^2, \sim \mathrm{N}(0,\tilde{\lambda}_j^2\tilde{\tau}^2\sigma^2),$$

$$\tilde{\tau}^2|\xi \sim \mathrm{IG}\left(\frac{1}{2},\frac{1}{\xi}\right),$$

$$\tilde{\lambda}_j^2|\nu_j \sim \mathrm{IG}\left(\frac{1}{2},\frac{1}{\nu_j}\right),$$

$$\xi,\nu_j \sim \mathrm{IG}\left(\frac{1}{2},1\right),$$

馬蹄事前分布

$$\sigma^2 \sim \mathrm{IG}\left(\frac{\nu_0}{2},\frac{\eta_0}{2}\right)$$

馬蹄事前分布に基づくベイジアン連結lasso回帰モデル①

完全条件付き分布

$$\boldsymbol{\beta}|\boldsymbol{y},\boldsymbol{X},\sigma^2,\tau_1^2,\cdots,\tau_p^2,\tilde{\tau}^2,\tilde{\lambda}_2^2,\cdots,\tilde{\lambda}_p^2,\nu_2,\cdots,\nu_p,\xi \sim \mathrm{N}_p(\boldsymbol{A}^{-1}\boldsymbol{X}^T\boldsymbol{y},\sigma^2\boldsymbol{A}^{-1})$$

$$\boldsymbol{A}=\boldsymbol{X}^T\boldsymbol{X}+\boldsymbol{\Sigma}_{\boldsymbol{\beta}}^{-1}$$

$$\sigma^2|\boldsymbol{y},\boldsymbol{X},\boldsymbol{\beta},\tau_1^2,\cdots,\tau_p^2,\tilde{\tau}^2,\tilde{\lambda}_2^2,\cdots,\tilde{\lambda}_p^2,\nu_2,\cdots,\nu_p,\xi \sim \mathrm{IG}\left(\frac{n_1}{2},\frac{s_1}{2}\right)$$

$$(n_1=n+2p-1+\nu_0, s_1=||\boldsymbol{y}-\boldsymbol{X}\boldsymbol{\beta}||_2^2+\boldsymbol{\beta}^T\Sigma_{\boldsymbol{\beta}}^{-1}\boldsymbol{\beta}+\eta_0)$$

$$\frac{1}{\tau_j^2}|\beta_j,\sigma^2,\lambda_1 \sim \mathrm{IGauss}\left(\sqrt{\frac{\sigma^2\lambda_1^2}{\beta_j^2}},\lambda_1^2\right)$$

$$\tilde{\tau}^2|\beta_j,\beta_{j-1},\sigma^2,\tilde{\lambda}_j^2,\xi \sim \mathrm{IG}\left(\frac{p}{2},\frac{1}{2\sigma^2}\left(\sum_{j=2}^{p}\frac{(\beta_j-\beta_{j-1})^2}{\lambda_j^2}\right)+\frac{1}{\xi}\right)$$

$$\tilde{\lambda}_j^2|\beta_j,\beta_{j-1},\sigma^2,\tilde{\tau}^2,\nu_j \sim \mathrm{IG}\left(1,\frac{(\beta_j-\beta_{j-1})^2}{2\sigma^2\tilde{\tau}^2}+\frac{1}{\nu_j}\right)(j=2,\ldots,p)$$

$$\nu_j|\tilde{\lambda}_j^2 \sim \mathrm{IG}\left(1,\frac{1}{\tilde{\lambda}_j^2}+1\right)(j=2,\ldots,p)$$

$$\xi|\tilde{\tau}^2 \sim \mathrm{IG}\left(1,\frac{1}{\tilde{\tau}^2}+1\right)$$

IGauss (a,b): 逆ガウス分布

馬蹄事前分布に基づくベイジアン連結lasso回帰モデル②

$$
\Sigma_{\boldsymbol{\beta}}^{-1} = \begin{pmatrix}
\frac{1}{\tau_1^2} + \frac{1}{\tilde{\lambda}_2^2\tilde{\tau}^2} & -\frac{1}{\tilde{\lambda}_2^2\tilde{\tau}^2} & 0 & \cdots & 0 & 0 \\
-\frac{1}{\tilde{\lambda}_2^2\tilde{\tau}^2} & \frac{1}{\tau_2^2} + \frac{1}{\tilde{\lambda}_2^2\tilde{\tau}^2} + \frac{1}{\tilde{\lambda}_3^2\tilde{\tau}^2} & -\frac{1}{\tilde{\lambda}_3^2\tilde{\tau}^2} & \cdots & 0 & 0 \\
0 & -\frac{1}{\tilde{\lambda}_3^2\tilde{\tau}^2} & \frac{1}{\tau_3^2} + \frac{1}{\tilde{\lambda}_3^2\tilde{\tau}^2} + \frac{1}{\tilde{\lambda}_4^2\tilde{\tau}^2} & \cdots & 0 & 0 \\
\vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\
0 & 0 & 0 & \cdots & \frac{1}{\tau_{p-1}^2} + \frac{1}{\tilde{\lambda}_{p-1}^2\tilde{\tau}^2} + \frac{1}{\tilde{\lambda}_p^2\tilde{\tau}^2} & -\frac{1}{\tilde{\lambda}_p^2\tilde{\tau}^2} \\
0 & 0 & 0 & \cdots & -\frac{1}{\tilde{\lambda}_p^2\tilde{\tau}^2} & \frac{1}{\tau_p^2} + \frac{1}{\tilde{\lambda}_p^2\tilde{\tau}^2}
\end{pmatrix}
$$

提案手法1-③

馬蹄事前分布によるベイジアン HORSES

$$\boldsymbol{y}|\boldsymbol{X},\boldsymbol{\beta},\sigma^2 \sim \mathrm{N}_n(\boldsymbol{X}\boldsymbol{\beta},\sigma^2\boldsymbol{I}_n)$$

変数選択項

$$\frac{\beta_j}{\sqrt{\sigma^2}} \mid \sigma^2 \sim \mathrm{Laplace}(\lambda_1),$$

ラプラス分布

変数の
グループ化項

$$\beta_j - \beta_k \mid \tilde{\lambda}^2_{j,k}, \sigma^2 \sim \mathrm{N}\left(0, \tilde{\lambda}^2_{j,k}\tilde{\tau}^2\sigma^2\right),$$

$$\tilde{\lambda}^2_{j,k} \sim \mathrm{C}^+(0,1),$$

馬蹄事前分布

$$\sigma^2 \sim \mathrm{IG}\left(\frac{\nu_0}{2}, \frac{\eta_0}{2}\right),$$

$$\lambda_1^2 \sim \mathrm{Ga}(\mathrm{r}_1, \delta_1)$$

事前分布の階層表現を用いてギブスサンプリングを構成

馬蹄事前分布に基づくベイジアンHORSES

完全条件付き分布

$$\boldsymbol{\beta} \mid \boldsymbol{y}, \boldsymbol{X}, \sigma^2, \tau_1^2, \ldots, \tau_p^2, \tilde{\tau}^2, \lambda_{1,2}^2, \ldots, \lambda_{p-1,p}^2 \sim \mathrm{N}_p(\boldsymbol{A}^{-1}\boldsymbol{X}^T\boldsymbol{y}, \sigma^2\boldsymbol{A}^{-1}),$$
$$\boldsymbol{A} = \boldsymbol{X}^T\boldsymbol{X} + \boldsymbol{B}^{-1},$$

$$\sigma^2 \mid \boldsymbol{y}, \boldsymbol{X}, \boldsymbol{\beta}, \tau_1^2, \ldots, \tau_p^2, \tilde{\tau}^2, \lambda_{1,2}^2, \ldots, \lambda_{p-1,p}^2 \sim \mathrm{IG}\left(\frac{n_1}{2}, \frac{s_1}{2}\right),$$
$$n_1 = n + p(p+1)/2 + \nu_0,$$
$$s_1 = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^T(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}) + \boldsymbol{\beta}^T\boldsymbol{B}^{-1}\boldsymbol{\beta} + \eta_0,$$

$$\frac{1}{\tau_j^2} \mid \beta_j, \sigma^2, \tilde{\lambda}_1^2 \sim \mathrm{IGauss}\left(\sqrt{\frac{\sigma^2\tilde{\lambda}_1^2}{\beta_j^2}}, \tilde{\lambda}_1^2\right),$$

$$\tilde{\lambda}_1^2 \mid \tau_1^2, \ldots, \tau_p^2 \sim \mathrm{Ga}\left(p + r_1, \frac{1}{2}\sum_{j=1}^{p}\tau_j^2 + \delta_1\right),$$

$$\lambda_{j,k}^2 \mid \beta_j, \beta_k, \sigma^2, \tilde{\tau}^2, \nu_{j,k} \sim \mathrm{IG}\left(1, \frac{(\beta_j - \beta_k)^2}{2\sigma^2\tilde{\tau}^2} + \frac{1}{\nu_{j,k}}\right),$$

$$\nu_{j,k} \mid \lambda_{j,k}^2 \sim \mathrm{IG}\left(1, \frac{1}{\lambda_{j,k}^2} + 1\right).$$

$$\left(\boldsymbol{B}^{-1}{}_{(i,j)} = \begin{cases} \dfrac{1}{\tau_j^2} + \dfrac{1}{\tilde{\tau}^2}\displaystyle\sum_{l \neq i}\frac{1}{\lambda_{i,l}^2}, & (i = j), \\ -\dfrac{1}{\lambda_{i,j}^2}, & (i \neq j). \end{cases}\right)$$

実データ解析①

アパラシアン山脈の土壌データ (Bondell and Reich, 2008)

・目的変数 $\boldsymbol{y}$:土地に生えている植物の種類で表される森林の多様性

・説明変数 $\boldsymbol{X}$: 500 m^2の土地における15 種類の土壌特性× 20区画分

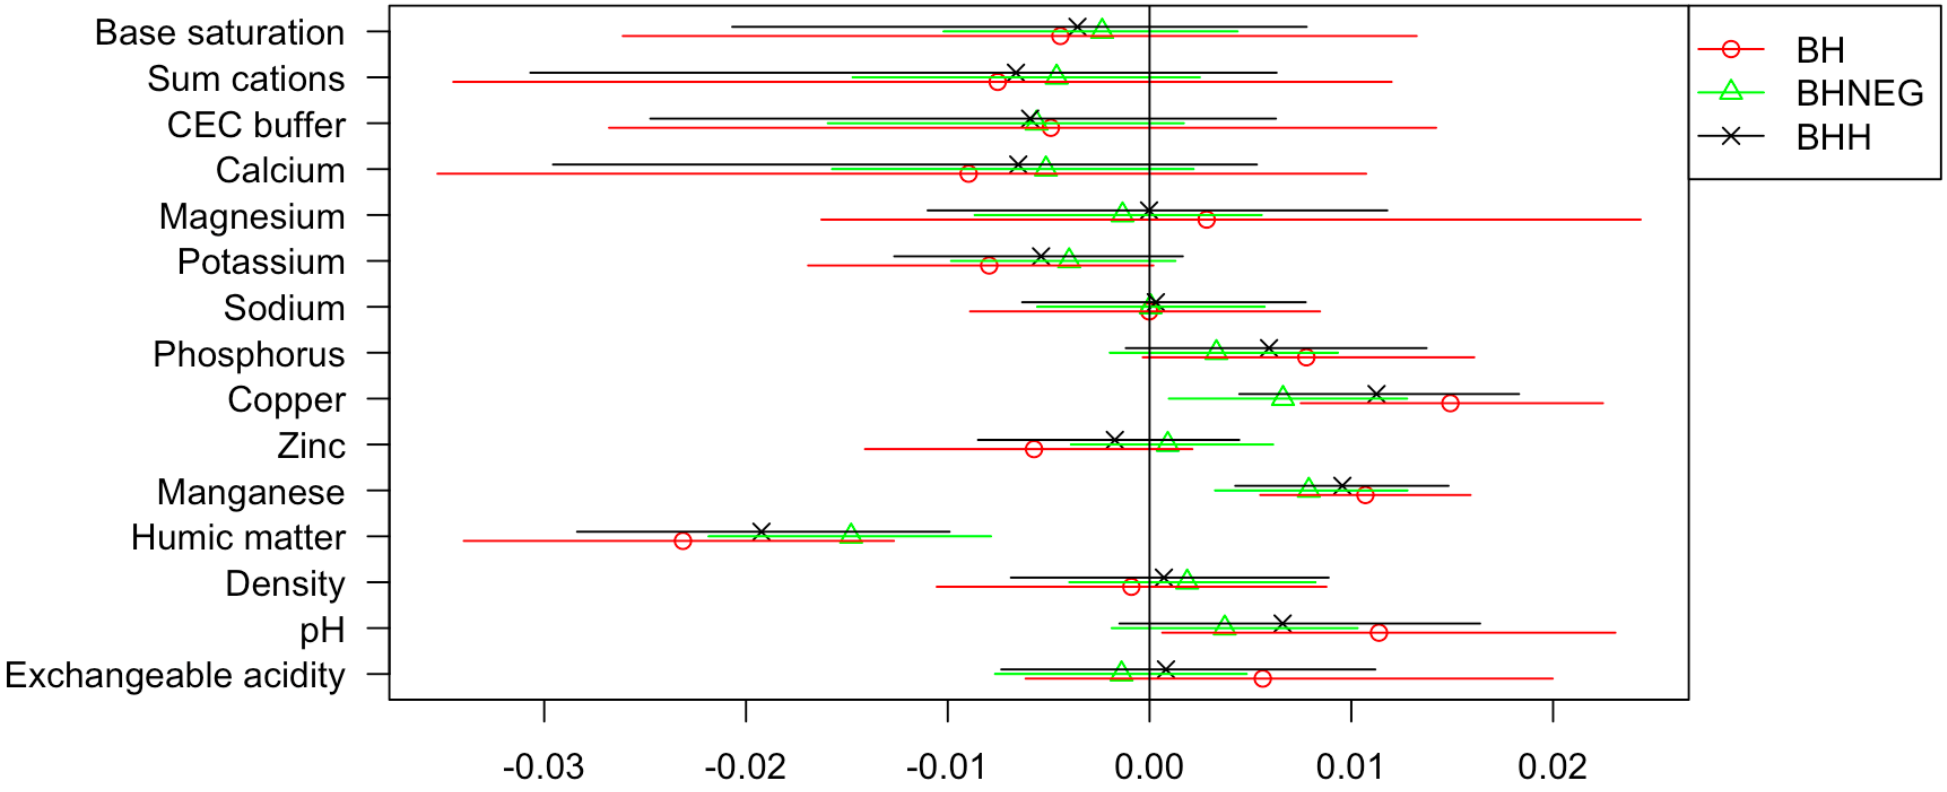
比較手法

ベイジアンHORSES (BH), NEG分布に基づくベイジアンHORSES (BFNEG) vs. 馬蹄事前分布に基づくベイジアンHORSES (BHH)

表: クロス・バリデーション値

	BH	BHNEG	BHH
CV (sd)	0.000685 (0.000807)	0.000618 (0.000852)	0.000652 (0.000839)

実データ解析②



線：回帰係数の推定値の95%信用区間

○、△、×：回帰係数の推定値の事後平均

馬蹄事前分布(縮小係数)②

縮小係数

$$p(\kappa_j|\tau,\sigma) = \frac{1}{\pi}\frac{\sigma^{-1}\tau\sqrt{n}}{(n\sigma^{-2}\tau^2-1)\kappa_j+1}\frac{1}{\sqrt{\kappa_j}\sqrt{1-\kappa_j}}$$

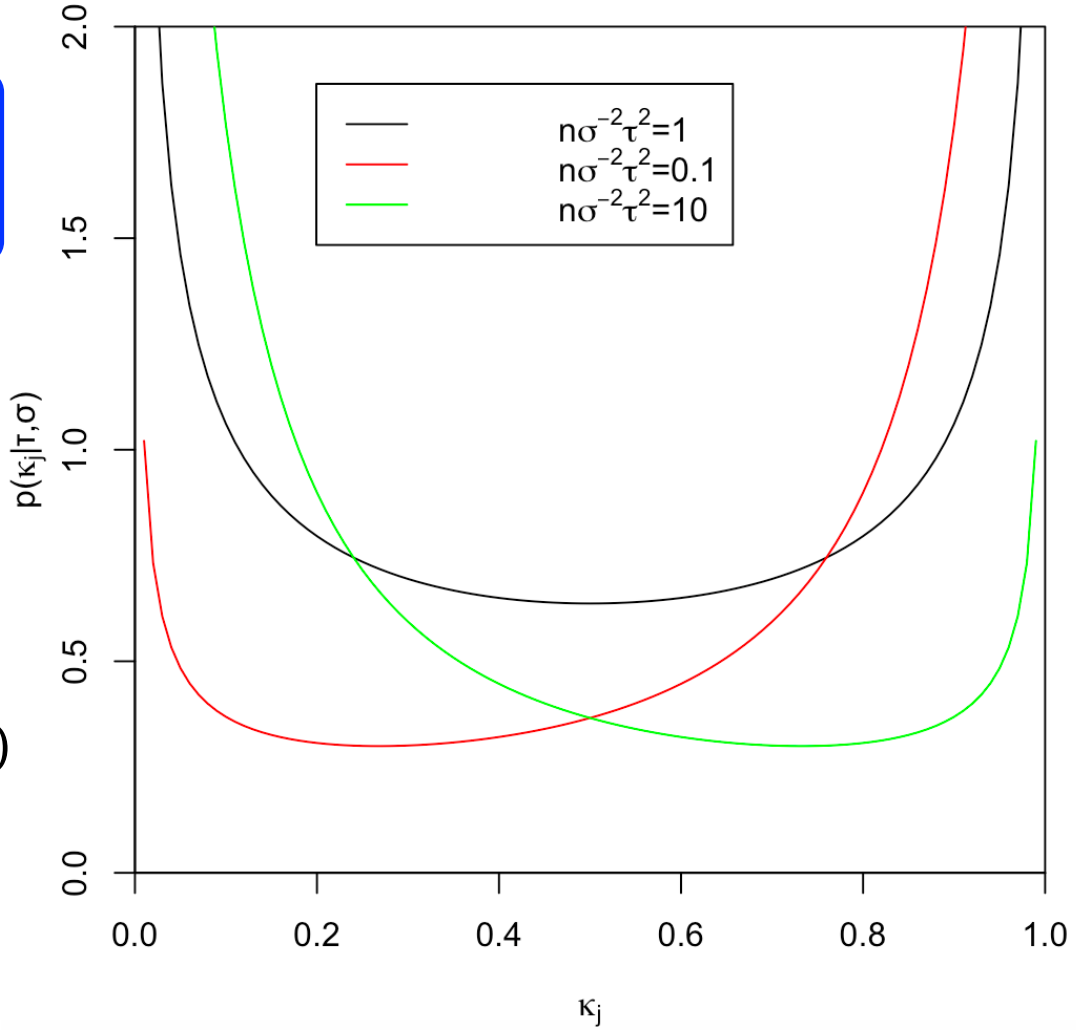
馬蹄の形

↓

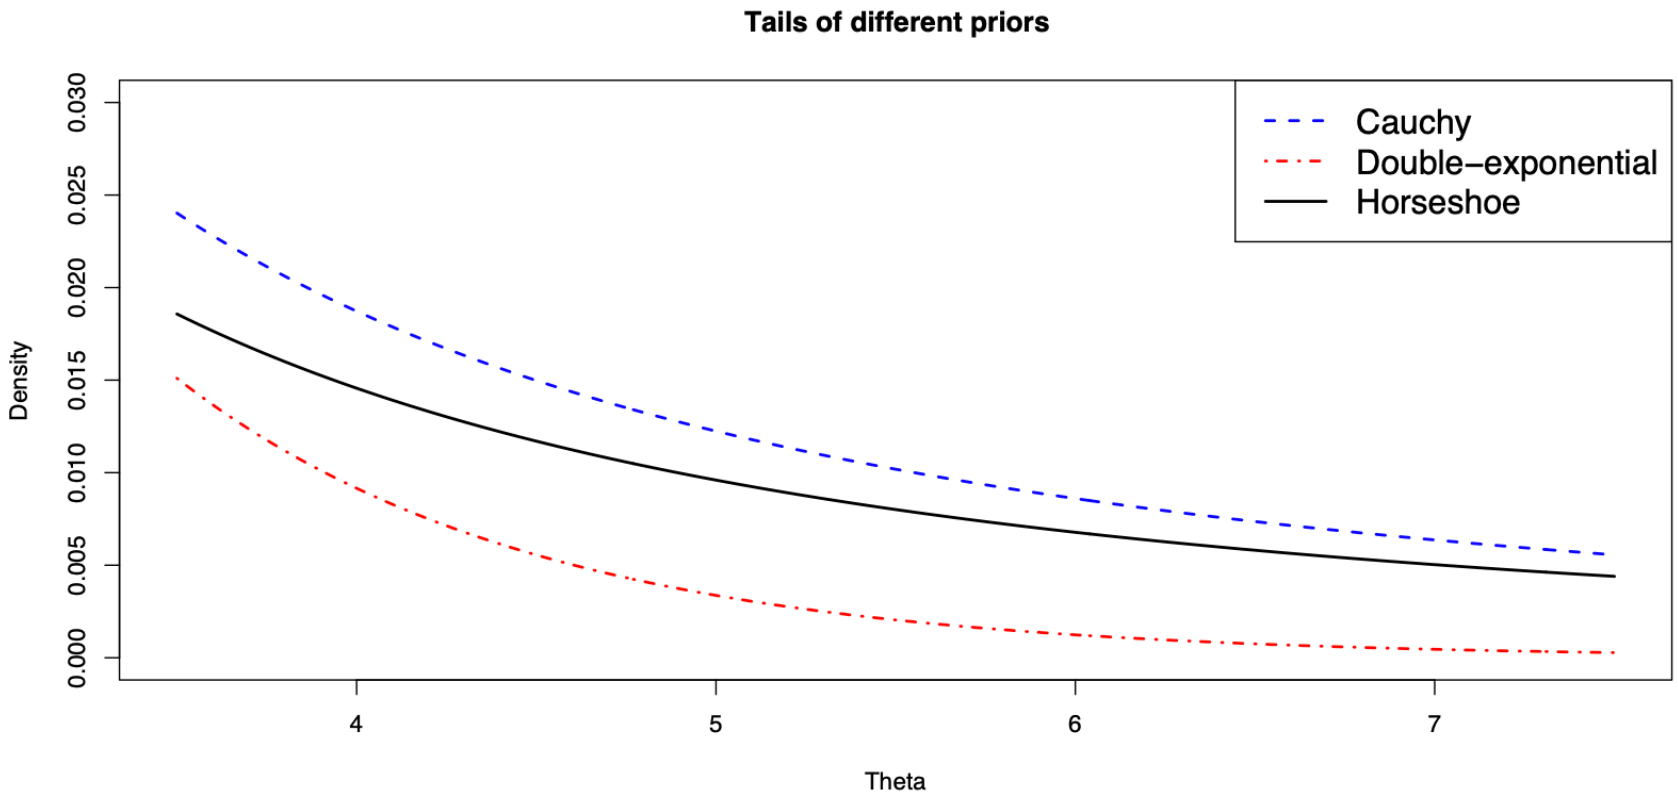
馬蹄事前分布

縦軸:確率密度関数$p(\kappa_j|\tau,\sigma)$

横軸:確率変数κ_jの値



裾の厚さ



(Carvalho et al., 2010)