令和 5 年 2 月 7 日

情報・ネットワーク工学専攻　修士論文発表会予稿

回帰係数の併合を伴う関連ベクトルマシンの構築

情報数理工学プログラム　2131020　西山悠研究室　稲垣良祐

1　はじめに

近年の計算機性能の向上に伴い，多種多様なデータが蓄積され，その活用が進められている．データを活用するためには，統計学や機械学習によるデータ解析技術が必要不可欠であるが，その中でも回帰分析は基礎的かつ重要である．

解析するデータの中には，アレイ CGH データ (array comparative genomic hybridization data) のように回帰係数が連続して同じ値を持つ部分，回帰係数の差が大きく異なる値を持つ部分に分けることができるものがある．上記に述べた構造を有するデータを分析する手法としては，変数併合を促す連結 lasso (Tibshirani et al., 2005) や，そのベイズ版であるベイズ型連結 lasso (Kyung et al., 2010) などを挙げることができる．これらの手法では隣り合った回帰係数の差を 0 に縮小推定することで，変数併合を実現している．しかし，連結 lasso やベイズ型連結 lasso では，非 0 と推定される回帰係数の差の部分を過度に縮小推定してしまうという問題点を有している．

本論文では，ベイズ型 lasso より裾の厚い事前分布を持った関連ベクトルマシン (Tipping, 2001) に着目し，変数併合を行うことが可能な連結 lasso 型の関連ベクトルマシンを提案する．

2　関連ベクトルマシン

関連ベクトルマシン (relevance vector machine: RVM) とは，カーネル法の考え方を用いることで柔軟な分析を行うことができるベイズモデルの一つである．関連ベクトルマシンは，不要な回帰係数の値を 0 と推定するスパース性を持っている．

関連ベクトルマシンでは，次式を用いて説明変数と目的変数をモデリングする．

$$\boldsymbol{y} = \boldsymbol{\Phi}\boldsymbol{\beta} + \boldsymbol{\epsilon}. \tag{2.1}$$

ここで，$\boldsymbol{y} = (y_1, \cdots, y_n)^T$ は n 次元の目的変数ベクトル，$\boldsymbol{\Phi}$ は $n \times n$ 型のグラム行列，$\boldsymbol{\beta}$ は n 次元の回帰係数ベクトル，$\boldsymbol{\epsilon}$ は n 次元の誤差ベクトルである．また，$\boldsymbol{\epsilon}$ は多変量正規分布 $\mathcal{N}_n(\boldsymbol{0}, \sigma^2 I_n)$ に従うと仮定する．ただし，σ^2 は誤差分散であり，I_n は $n \times n$ 型の単位行列である．

関連ベクトルマシンでは，ベイズ的手法を用いて回帰係数 $\boldsymbol{\beta}$ の推測を行う．尤度関数は次式で書くことができる．

$$p(\boldsymbol{y} \mid \boldsymbol{\Phi}, \boldsymbol{\beta}, \sigma^2) = \mathcal{N}_n(\boldsymbol{y} \mid \boldsymbol{\Phi}\boldsymbol{\beta}, \sigma^2 I_n). \tag{2.2}$$

また，各パラメータの事前分布は以下のとおり設定する．

$$\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) = \prod_{i=1}^{n} \mathcal{N}(\beta_i \mid \boldsymbol{0}, \alpha_i^{-1}), \tag{2.3}$$

$$\pi(\boldsymbol{\alpha} \mid a, b) = \prod_{i=1}^{n} \mathrm{Gamma}(\alpha_i \mid a, b), \tag{2.4}$$

$$\pi(1/\sigma^2 \mid c, d) = \mathrm{Gamma}(1/\sigma^2 \mid c, d). \tag{2.5}$$

ここで，a, b, c, d は調整パラメータである．関連ベクトルマシンの事後分布は、第二種最尤法 (Berger, 1985) やギブス・サンプリングにより計算できる．

3　L_1 型スパース推定法

3.1　連結 lasso

連結 lasso は，次式を最小化することで回帰係数の併合を行う．

$$E(\boldsymbol{\beta}) = \frac{1}{2}(\boldsymbol{y} - X\boldsymbol{\beta})^T(\boldsymbol{y} - X\boldsymbol{\beta}) + \lambda_1 \sum_{i=1}^{p} |\beta_i| + \lambda_2 \sum_{i=2}^{p} |\beta_i - \beta_{i-1}|. \tag{3.1}$$

ただし，X は $n \times p$ 型の計画行列，λ_1, λ_2 は正の値をとる正則化パラメータである．正則化項の $\lambda_1 \sum_{i=1}^{p} |\beta_i|$，$\lambda_2 \sum_{i=2}^{p} |\beta_i - \beta_{i-1}|$ は，隣り合った回帰係数の差を 0 に縮小する働きを持つ．

3.2　ベイズ型連結 lasso (BFL)

Kyung et al. (2010) では，連結 lasso のベイズ版であるベイズ型連結 lasso を提案している．回帰係数ベクトル $\boldsymbol{\beta}$ の事前分布に

$$\pi(\boldsymbol{\beta} \mid \sigma^2, \lambda_1, \lambda_2) = \prod_{i=1}^{p} \mathrm{Laplace}(\beta_i \mid 0, 2\lambda_1/\sigma) \times \prod_{i=1}^{p-1} \mathrm{Laplace}(\beta_{i+1} - \beta_i \mid 0, 2\lambda_2/\sigma) \tag{3.2}$$

を設定することでベイズ型連結 lasso を構築する．

4　提案手法

提案手法では，関連ベクトルマシンの各パラメータの事前分布を以下のとおりに設定することで，回

帰係数の併合を実現する．

$$\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) = \prod_{i=1}^{n} \mathcal{N}(\beta_i \mid 0, (\lambda_1 \alpha_i)^{-1}) \times \prod_{i=1}^{n-1} \mathcal{N}(\beta_{i+1} - \beta_i \mid 0, (\lambda_2 \alpha_i')^{-1}), \tag{4.1}$$

$$\pi(\boldsymbol{\alpha} \mid \eta, \nu) = \prod_{i=1}^{n} \mathrm{Gamma}(\alpha_i \mid \eta/2, \nu/2), \tag{4.2}$$

$$\pi(\boldsymbol{\alpha}' \mid \eta', \nu') = \prod_{i=1}^{p-1} \mathrm{Gamma}(\alpha_i' \mid \eta'/2, \nu'/2), \tag{4.3}$$

$$\pi(1/\sigma^2 \mid c, d) = \mathrm{Gamma}(1/\sigma^2 \mid c, d). \tag{4.4}$$

ただし，$\nu, \eta, \nu', \eta', c, d, \lambda_1, \lambda_2$ は調整パラメータである．事後分布は，ギブス・サンプリングを用いて計算する．

5　数値実験

5.1　モンテカルロ・シミュレーション

真のモデルとして，以下の線形モデルを考えた．

$$\boldsymbol{y} = X\boldsymbol{\beta}^* + \boldsymbol{\epsilon}. \tag{5.1}$$

ただし，$\boldsymbol{\beta}^*$ は p 次元の真の回帰係数ベクトルであり，$\boldsymbol{\epsilon}$ は多変量正規分布 $\mathcal{N}_n(\mathbf{0}_n, \sigma^2 I_n)$ に従う誤差ベクトルとした．また，$n \times p$ 型の計画行列 X の行ベクトル $\boldsymbol{x}_i$ は各々独立に多変量正規分布 $\mathcal{N}_p(\mathbf{0}_p, \Sigma)$ に従うものとした．

真のモデルの設定は，$p = 20, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_1^*$ or $\boldsymbol{\beta}_2^*$, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$ とした．ただし，$\boldsymbol{\beta}_1^* = (\mathbf{0}_5^T, \mathbf{1}_5^T, \mathbf{0}_5^T, \mathbf{1}_5^T)^T, \boldsymbol{\beta}_2^* = (\mathbf{0}_5^T, \mathbf{2}_5^T, \mathbf{0}_5^T, \mathbf{2}_5^T)^T$ である．

実験結果は，Table 1 のとおりとなった．この結果から，$\sigma = 0.5$ の場合には提案手法はいずれの指標でもベイズ型連結 lasso より小さい値となっている．このことから，分散が比較的小さい場合，提案手法の推定精度はベイズ型連結 lasso と比べて改善されていることがわかる．

5.2　実データへの適用

アレイ CGH データを用いて，提案手法とベイズ型連結 lasso の比較を行った．ここでは，提案手法とベイズ型連結 lasso のモデルとして以下を設定した．

$$\boldsymbol{y} = \boldsymbol{\beta} + \boldsymbol{\epsilon}. \tag{5.2}$$

推定結果は Fig. 1 のとおりとなった．提案手法はベイズ型連結 lasso の隣り合う回帰係数の差を 0 と推定するという性質を保ちながら，非 0 と推定される回帰係数に対して過度な縮小は招かないことがわかる．

Table1: モンテカルロ・シミュレーションの結果．sd は標準偏差を表す．BFL と提案手法のうち評価指標の値が小さい方を太字で示した．

			MSE (sd)	$\mathrm{MSE}_{\mathrm{diff}}$ (sd)	PSE (sd)
$\sigma = 0.5$	$\boldsymbol{\beta}_1^*$	BFL	0.353 (0.215)	0.236 (0.162)	0.550 (0.445)
		提案手法	**0.200 (0.105)**	**0.067 (0.070)**	**0.248 (0.176)**
	$\boldsymbol{\beta}_2^*$	BFL	0.471 (0.335)	0.314 (0.245)	0.903 (1.143)
		提案手法	**0.460 (0.239)**	**0.152 (0.139)**	**0.648 (0.788)**
$\sigma = 1.5$	$\boldsymbol{\beta}_1^*$	BFL	**1.044 (0.547)**	**0.547 (0.431)**	**0.770 (0.425)**
		提案手法	2.784 (1.406)	0.803 (0.704)	1.617 (0.761)
	$\boldsymbol{\beta}_2^*$	BFL	**1.273 (0.651)**	0.902 (0.664)	**1.288 (0.932)**
		提案手法	3.402 (1.256)	**0.887 (0.700)**	2.339 (0.974)

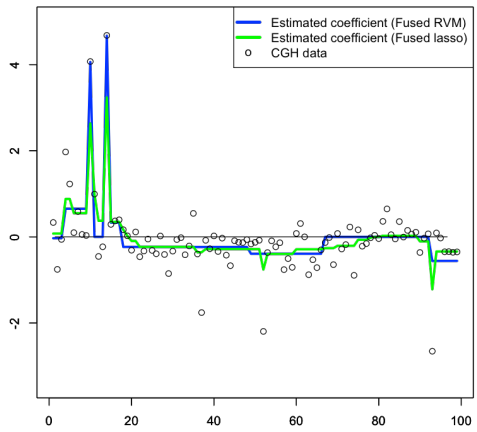


Figure1: 提案手法およびベイズ型連結 lasso による，アレイ CGH データを用いた推定結果．青線が提案手法により推定された曲線，緑線がベイズ型連結 lasso により推定された曲線．

6　まとめ

本論文では，回帰係数の併合を伴う関連ベクトルマシンを提案した．モンテカルロ・シミュレーションや実データへの適用を通して，予測精度や推定精度の観点から提案手法の有効性を検証した．今後の課題としては，計算時間削減のために第二種最尤法による推定を行うことや，分散が大きいデータに対しての分析性能の向上を図ることが考えられる．

参考文献

Berger, J. O. (1985). *Statistical Decision Theory and Bayesian Analysis (Second Ed.)*. Springer.

Kyung, M., Gill J., Ghosh, M., Casella, G. (2010). Penalized regression, standard errors, and Bayesian Lassos. *Bayesian Analysis*, **5**, 369–412.

Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., Knight, K. (2005). Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society Series B*, **67**, 91–108.

Tipping, M. E. (2001). Sparse Bayesian learning and the relevance vector machine. *Journal of Machine Learning Research*, **1**, 211–244