令和四年度 修士論文

# 回帰係数の併合を伴う
# 関連ベクトルマシンの構築

2023 年 3 月 7 日

電気通信大学 大学院情報理工学研究科
情報・ネットワーク工学専攻
情報数理工学プログラム
学籍番号 2131020
稲垣 良祐

主任指導教員 西山 悠 准教授
指導教員 宇都 雅輝 准教授

# 目 次

**1 はじめに** **4**

**2 関連ベクトルマシン** **6**

2.1 関連ベクトルマシンのモデルと事前分布 . . . . . 6

2.2 関連ベクトルマシンの推定アルゴリズム . . . . . 7

2.2.1 第二種最尤法によるアルゴリズム . . . . . 7

2.2.2 MCMC 法によるアルゴリズム . . . . . 9

2.3 関連ベクトルマシンのスパース性 . . . . . 10

2.3.1 周辺尤度最大化による説明 . . . . . 11

2.3.2 ベイズ的観点による説明 . . . . . 12

2.3.3 実際の推定による確認 . . . . . 13

**3 $L_1$ 型スパース推定法** **14**

3.1 Lasso . . . . . 14

3.1.1 Lasso のスパース性 . . . . . 15

3.2 ベイズ型 lasso . . . . . 16

3.3 連結 lasso . . . . . 18

3.4 ベイズ型連結 lasso . . . . . 19

3.4.1 ベイズ型連結 lasso のスパース性 . . . . . 20

**4 提案手法** **22**

4.1 事前分布 . . . . . 22

4.2 完全条件付き分布と推定アルゴリズム . . . . . 23

4.3 ラプラス事前分布との比較 . . . . . 25

**5 数値実験** **27**

5.1 モンテカルロ・シミュレーション . . . . . 27

5.2 実データへの適用 . . . . . 32

**6 まとめと今後の課題** **35**

**A ギブス・サンプリング** **37**

**B　混合法** **38**

# 1　はじめに

近年の計算機性能の向上に伴い，多種多様なデータが蓄積され，その活用が進められている．データを活用するためには，統計学や機械学習によるデータ解析技術が必要不可欠であるが，その中でも回帰分析は基礎的かつ重要である．

解析するデータの中には，回帰係数が連続して同じ値を持つ部分，回帰係数の差が大きく異なる値を持つ部分に分けることができるものがある．このような構造を有するデータの例としては，アレイ CGH データ (array comparative genomic hybridization data) を挙げることができる．アレイ CGH データとは，2 種類の細胞（例えばがん細胞と正常細胞）の間でゲノムのコピー回数の比較を行ったデータであり，その分析によりゲノムのコピー数の増減を伴うゲノム上の異常を検出することができ，臨床医療において応用されている（山本，2010）．

上記に述べた構造を有するデータを分析する手法としては，変数併合を促す連結 lasso (Tibshirani et al., 2005) や，そのベイズ版であるベイズ型連結 lasso (Kyung et al., 2010) などを挙げることができる．これらの手法では隣り合った回帰係数の差を 0 に縮小推定することで，変数併合を実現している．また，Lasso (Tibshirani, 1996) や ベイズ型 lasso (Park and Casella, 2008) に見られるように回帰係数を 0 に縮小推定する機能も有している．Tibshirani and Wang (2008) では，先に紹介したアレイ CGH データに連結 lasso を適用し，有用な情報の抽出を試みている．しかし，連結 lasso やベイズ型連結 lasso では，非 0 と推定される回帰係数の差の部分を過度に縮小推定してしまうという問題点を有している．

本論文では，ベイズ型 lasso より裾の厚い事前分布を持った関連ベクトルマシン (Tipping, 2001) に着目し，変数併合を行うことが可能な連結 lasso 型の関連ベクトルマシンを提案する．本モデルの提案によって，非 0 と推定される回帰係数の差の部分の過度な縮小推定を抑えることができる．

関連ベクトルマシンの推定には，通常，対数周辺尤度関数をハイパーパラメータに関して最大化する第二種最尤法 (Berger, 1985) を用いる．しかし，第二種最尤法では対数周辺尤度関数の停留点を求めなくてはならない．停留点の計算は一般に煩雑になるため，場合によっては解析的に解けないという問題がある．そのため，第二種最尤法による推定は難しいことが多い．そこで，Fokoué et al. (2010) では，階層ベイズモデルを用いて関連ベクトルマシンをマルコフ連鎖モンテカルロ法 (Markov

chain Monte Carlo method: MCMC 法) による推定方法を提案している．この方法は推定に時間を要する代わりに簡便な計算でモデルを構築することができる．本論文では，Fokoué et al. (2010) に従い，MCMC 法による推定法を提案する．

本論文の構成は以下のとおりである．第 2 節では関連ベクトルマシンについて，そのモデルの構築と推定手法について述べる．第 3 節ではベイズ型連結 lasso について，そのモデルの構築と推定手法を述べる．第 4 節では提案手法について，既存手法との差異やその推定手法を述べる．第 5 節では人工データおよび実データを用いて提案手法の有効性について比較および検証する．第 6 節では本論文のまとめおよび今後の課題について述べる．

# 2　関連ベクトルマシン

関連ベクトルマシン (relevance vector machine: RVM) とは，カーネル法の考え方を用いることで柔軟な分析を行うことができるベイズモデルの一つである．関連ベクトルマシンは，不要な回帰係数の値を 0 と推定するスパース性を持っている．このため，0 と推定された部分を無視することで大規模な行列の演算を回避でき，高速な予測が可能であるという利点がある．関連ベクトルマシンには分類問題に対するものと回帰問題に対するものの 2 種類があるが，本論文では特に回帰問題に対する関連ベクトルマシンについて扱う．

本節では，関連ベクトルマシンの概要と推定方法，並びにスパース性が生じる要因について述べる．

## 2.1　関連ベクトルマシンのモデルと事前分布

いま，$p$ 次元ベクトル $\boldsymbol{x}_i$ を説明変数，1 次元の $y_i$ を目的変数とする $n$ 個のデータの組 $\{(\boldsymbol{x}_i, y_i) : i = 1, \cdots, n\}$ が得られているとする．関連ベクトルマシンでは，次式を用いて説明変数と目的変数をモデリングする．

$$\boldsymbol{y} = \boldsymbol{\Phi}\boldsymbol{\beta} + \boldsymbol{\epsilon}. \tag{2.1}$$

ここで，$\boldsymbol{y} = (y_1, \cdots, y_n)^T$ は $n$ 次元の目的変数ベクトル，$\boldsymbol{\Phi}$ は $n \times n$ 型のグラム行列，$\boldsymbol{\beta}$ は $n$ 次元の回帰係数ベクトル，$\boldsymbol{\epsilon}$ は $n$ 次元の誤差ベクトルである．また，$\boldsymbol{\epsilon}$ は多変量正規分布 $\mathcal{N}_n(\boldsymbol{0}, \sigma^2 I_n)$ に従うと仮定する．ただし，$\sigma^2$ は誤差分散であり，$I_n$ は $n \times n$ 型の単位行列である．グラム行列とは，カーネル関数 $K(\cdot, \cdot)$ の値を並べたものであり，具体的には以下で書くことができる行列である．

$$\boldsymbol{\Phi} = \begin{bmatrix} K(\boldsymbol{x}_1, \boldsymbol{x}_1) & K(\boldsymbol{x}_1, \boldsymbol{x}_2) & \cdots & K(\boldsymbol{x}_1, \boldsymbol{x}_n) \\ K(\boldsymbol{x}_2, \boldsymbol{x}_1) & K(\boldsymbol{x}_2, \boldsymbol{x}_2) & \cdots & K(\boldsymbol{x}_2, \boldsymbol{x}_n) \\ \vdots & \vdots & \ddots & \vdots \\ K(\boldsymbol{x}_n, \boldsymbol{x}_1) & K(\boldsymbol{x}_n, \boldsymbol{x}_2) & \cdots & K(\boldsymbol{x}_n, \boldsymbol{x}_n) \end{bmatrix}. \tag{2.2}$$

カーネル関数とは，ヒルベルト空間と呼ばれるベクトル空間上での内積の計算となる，グラム行列が正定値行列となるなどといった性質を持った関数である．本論文

では，調整パラメータ $r$ を用いて次式で表されるガウシアンカーネルを用いる．

$$K(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2r^2}\right). \tag{2.3}$$

カーネル関数やグラム行列の詳細な性質については，赤穂 (2008) を参照されたい．

関連ベクトルマシンでは，ベイズ的手法を用いて (2.1) 式の回帰係数 $\boldsymbol{\beta}$ の推測を行う．このとき，尤度関数は次式で書くことができる．

$$p(\boldsymbol{y} \mid \boldsymbol{\Phi}, \boldsymbol{\beta}, \sigma^2) = \mathcal{N}_n(\boldsymbol{y} \mid \boldsymbol{\Phi}\boldsymbol{\beta}, \sigma^2 I_n). \tag{2.4}$$

また，各パラメータの事前分布は以下のとおり設定する．

$$\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) = \prod_{i=1}^{n} \mathcal{N}(\beta_i \mid \mathbf{0}, \alpha_i^{-1}), \tag{2.5}$$

$$\pi(\boldsymbol{\alpha} \mid a, b) = \prod_{i=1}^{n} \mathrm{Gamma}(\alpha_i \mid a, b), \tag{2.6}$$

$$\pi(1/\sigma^2 \mid c, d) = \mathrm{Gamma}(1/\sigma^2 \mid c, d). \tag{2.7}$$

ここで，$\mathrm{Gamma}(\cdot \mid \cdot, \cdot)$ はガンマ分布であり，その確率密度関数は形状パラメータ $a$，尺度パラメータ $b$ を用いて次式のとおり表される．

$$\mathrm{Gamma}(x \mid a, b) = \frac{b^a}{\Gamma(a)} x^{a-1} \exp\left(-bx\right). \tag{2.8}$$

ただし，$\Gamma(\cdot)$ はガンマ関数である．

## 2.2 関連ベクトルマシンの推定アルゴリズム

本項では，関連ベクトルマシンを推定する方法として，第二種最尤法による方法，MCMC 法による方法について述べる．

### 2.2.1 第二種最尤法によるアルゴリズム

Tipping (2001) では，第二種最尤法を用いて事後分布の計算を行っている．第二種最尤法によるアルゴリズムは，周辺尤度関数（実際の計算においては対数周辺尤

度関数）のハイパーパラメータに関する最大化問題を直接解くため，比較的高速にモデルの推定を行うことができるという特徴がある．

第二種最尤法では，(2.4) 式の尤度関数を $\boldsymbol{\beta}$ で周辺化した周辺尤度関数をハイパーパラメータ $\boldsymbol{\alpha}$ と $1/\sigma^2$ に関して最大化する．ここで，周辺尤度関数は，

$$\begin{aligned} p(\boldsymbol{\beta} \mid \boldsymbol{\alpha}, \sigma^2) &= \int p(\boldsymbol{y} \mid \boldsymbol{\Phi}, \boldsymbol{\beta}, \sigma^2) \pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) \mathrm{d}\boldsymbol{\beta} \\ &= \frac{1}{(2\pi)^{n/2} |\sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T|^{-1}} \exp\left\{ -\frac{1}{2} \boldsymbol{y} (\sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T)^{-1} \boldsymbol{y} \right\} \\ &= \mathcal{N}_n(\boldsymbol{y} \mid \boldsymbol{0}, \sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T) \end{aligned} \tag{2.9}$$

である．ただし，$\boldsymbol{A} = \mathrm{diag}(\alpha_1, \ldots, \alpha_n)$ である．この最大化問題は通常の最尤法と同じく対数周辺尤度関数の最大化に帰着されるため，次式の対数周辺尤度関数を考える．

$$\begin{aligned} \ln p(\boldsymbol{\beta} \mid \boldsymbol{\alpha}, \sigma^2) &= \ln \mathcal{N}_n(\boldsymbol{y} \mid \boldsymbol{0}, \sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T) \\ &= -\frac{1}{2} \left\{ n \ln(2\pi) + \ln |\sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T| + \boldsymbol{y} (\sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T)^{-1} \boldsymbol{y} \right\}. \end{aligned} \tag{2.10}$$

この対数周辺尤度関数をハイパーパラメータ $\boldsymbol{\alpha}$ と $1/\sigma^2$ に関して最大化するため，それぞれのハイパーパラメータで微分して 0 とおく．その方程式を解くことで，次のハイパーパラメータの更新式が得られる．

$$\alpha_i^{\mathrm{new}} = \frac{\gamma_i}{m_i^2}, \tag{2.11}$$

$$(\sigma^2)^{\mathrm{new}} = \frac{|\boldsymbol{y} - \boldsymbol{\Phi} \boldsymbol{m}|^2}{N - \sum_i \gamma_i}. \tag{2.12}$$

ただし，

$$\boldsymbol{m} = \frac{1}{\sigma^2} \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \boldsymbol{y}, \tag{2.13}$$

$$\boldsymbol{\Sigma} = \left( A + \frac{1}{\sigma^2} \boldsymbol{\Phi}^T \boldsymbol{\Phi} \right)^{-1}, \tag{2.14}$$

$$\gamma_i = 1 - \alpha_i \Sigma_{ii} \tag{2.15}$$

である．以上のことから，第二種最尤法による関連ベクトルマシンのハイパーパラメータは，Algorithm 1 で推定できる．

**Algorithm 1** 第二種最尤法による RVM のハイパーパラメータ推定

**while** 更新量が十分に小さくなるまで **do**
$\alpha_i$ を $\frac{\gamma_i}{m_i^2}$ で更新する．
$\sigma^2$ を $\frac{|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{m}|^2}{N-\sum_i \gamma_i}$ で更新する．

ベイズの定理を用いることで，回帰係数ベクトルの事後分布は推定したハイパーパラメータ $\boldsymbol{\alpha}, \sigma^2$ を用いて次のとおり計算できる．

$$
\begin{aligned}
p(\boldsymbol{\beta} \mid \boldsymbol{y}, \boldsymbol{\Phi}, \boldsymbol{\alpha}, \sigma^2) &\propto p(\boldsymbol{y} \mid \boldsymbol{\Phi}, \boldsymbol{\beta}, \sigma^2)\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) \\
&\propto \exp\left\{-\frac{1}{2}(\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta})^T\sigma^{-2}I_n(\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta})\right\}\exp\left(\boldsymbol{\beta}^T\boldsymbol{A}\boldsymbol{\beta}\right) \\
&= \exp\left[-\frac{1}{2}\left\{(\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta})^T\sigma^{-2}I_n(\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta})\right\}+\boldsymbol{\beta}^T\boldsymbol{A}\boldsymbol{\beta}\right] \\
&= \exp\left[-\frac{1}{2}\left\{\sigma^{-2}(\boldsymbol{y}^T\boldsymbol{y}-\boldsymbol{y}^T\boldsymbol{\Phi}\boldsymbol{\beta}-\boldsymbol{\beta}^T\boldsymbol{\Phi}^T\boldsymbol{y}+\boldsymbol{\beta}^T\boldsymbol{\Phi}^T\boldsymbol{\Phi}\boldsymbol{\beta})+\boldsymbol{\beta}^TA\boldsymbol{\beta}\right\}\right] \\
&\propto \exp\Bigg\{-\frac{1}{2}\boldsymbol{\beta}(\boldsymbol{A}+\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi})\boldsymbol{\beta} \\
&\qquad\qquad +\boldsymbol{\beta}^T\boldsymbol{\Phi}(\boldsymbol{A}+\boldsymbol{\beta}\boldsymbol{\Phi}^T\boldsymbol{\Phi})\sigma^{-2}(\boldsymbol{A}+\boldsymbol{\beta}\boldsymbol{\Phi}^T\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}\Bigg\} \\
&\propto \exp\left\{-\frac{1}{2}(\boldsymbol{\beta}-\boldsymbol{m})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{\beta}-\boldsymbol{m})\right\} \\
&\propto \mathcal{N}_n(\boldsymbol{\beta} \mid \boldsymbol{m}, \boldsymbol{\Sigma}).
\end{aligned}
\tag{2.16}
$$

### 2.2.2 MCMC 法によるアルゴリズム

第二種最尤法によるアルゴリズムは高速な推定が可能である一方で，モデルを拡張する際に計算が煩雑もしくは解析的な計算が不可能となってしまう．これに対して Fokoué et al. (2010) では，各パラメータの事後分布を MCMC 法に基づくアルゴリズムにより推定する方法を提案している．この方法はモデルの構築に必要な計算が簡便なため，モデルの拡張を容易に行うことができる．本項では，Fokoué et al. (2010) で提案されたギブス・サンプリングにより，回帰係数の事後分布を推定する方法について述べる．ギブス・サンプリングとは，完全条件付き分布と呼ばれる分

布からのサンプリングを繰り返すことにより，事後分布からのサンプリングを行うアルゴリズムである．ギブス・サンプリングの詳細については，付録 A を参照されたい．

完全条件付き分布は，尤度関数と事前分布のうち，各パラメータに関するものの積を取ることで以下のとおり求められる．

$$\boldsymbol{\beta} \mid \sigma^2, \boldsymbol{\Psi}, \boldsymbol{y} \sim \mathcal{N}_{n+1}\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}, (\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\right), \tag{2.17}$$

$$\alpha_j \mid \boldsymbol{\beta}, \sigma^{-2}, \boldsymbol{y} \sim \text{Gamma}\left(a + \frac{1}{2}, b + \frac{1}{2}\beta_j\right), \tag{2.18}$$

$$\sigma^{-2} \mid \boldsymbol{\beta}, \boldsymbol{\Psi}, \boldsymbol{y} \sim \text{Gamma}\left(c_0 + \frac{n}{2}, d_0 + \frac{1}{2}\|\boldsymbol{\Phi}\boldsymbol{\beta} - \boldsymbol{y}\|\right). \tag{2.19}$$

以上の完全条件付き分布を用いて，各パラメータのサンプリングは Algorithm 2 により行うことができる．

**Algorithm 2** ギブス・サンプリングによる RVM の事後分布推定

ハイパーパラメータ $a, b, c_0, d_0$ を決める．
反復回数 $m$ を定める．
**for** $i = 1, 2, \cdots, m$ **do**
　$\boldsymbol{\beta}$ を $\mathcal{N}_n\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}, (\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\right)$ からサンプリングする．
　$\sigma^{-2}$ を $\text{Gamma}\left(c_0 + \frac{n}{2}, d_0 + \frac{1}{2}\|\boldsymbol{\Phi}\boldsymbol{\beta} - \boldsymbol{y}\|\right)$ からサンプリングする．
　**for** $j = 1, 2, \cdots, n$ **do**
　　$\alpha_j$ を $\text{Gamma}\left(a + \frac{1}{2}, b + \frac{1}{2}\beta_j\right)$ からサンプリングする．

ギブス・サンプリングでは，$i$ 番目のサンプルは $i \to \infty$ のときに厳密に事後分布からのサンプリングとなる．実際の計算では予め定めた十分大きい回数までのサンプルを捨て，それ以降のサンプルのみを用いることで近似的に事後分布からのサンプリングを行う．この実際に用いないサンプリングの期間を稼働検査期間（burn-in）と呼ぶ．

## 2.3　関連ベクトルマシンのスパース性

関連ベクトルマシンにより推定された回帰係数ベクトルは，その多くの成分が 0 となる．本項では，その理由について周辺尤度最大化の観点およびベイズ的観点か

ら述べる．また，実際に関連ベクトルマシンによる推定を行うことで，スパース性を確認する．

### 2.3.1 周辺尤度最大化による説明

Bishop (2006) では，関連ベクトルマシンのスパース性を，周辺尤度を $\alpha_i$ に関して最大化する方法で説明している．(2.9) 式の周辺尤度関数の分散共分散行列を $\boldsymbol{C}$ とする．つまり，

$$\boldsymbol{C} = \sigma^2 I_n + \boldsymbol{\Phi} \boldsymbol{A}^{-1} \boldsymbol{\Phi}^T \tag{2.20}$$

である．$\boldsymbol{C}$ において，$\alpha_i$ に関する項を分離すると，

$$\begin{aligned} \boldsymbol{C} &= \sigma^2 I_n + \sum_{j \neq i} \alpha_j^{-1} \boldsymbol{\phi}_j^T \boldsymbol{\phi}_j + \alpha_i^{-1} \boldsymbol{\phi}_i^T \boldsymbol{\phi}_i \\ &= \boldsymbol{C}_{-i} + \alpha_i^{-1} \boldsymbol{\phi}_i^T \boldsymbol{\phi}_i \end{aligned} \tag{2.21}$$

となる．ただし，$\boldsymbol{\phi}_i$ は $\boldsymbol{\Phi}$ の第 $i$ 列の列ベクトルであり，$\boldsymbol{C}_{-i}$ は $\boldsymbol{C}$ から $\alpha_i$ に関する項をすべて取り除いたものである．

ここで，(2.10) 式の対数周辺尤度関数の $\alpha_i$ による偏微分は次式で表されることが知られている．

$$\frac{\partial \ln p(\boldsymbol{\beta} \mid \boldsymbol{\alpha}, \sigma^2)}{\partial \alpha_i} = \frac{\alpha_i^{-1} s_i^2 - (q_i^2 - s_i)}{2(\alpha_i + s_i)^2}. \tag{2.22}$$

ただし，$s_i$ は $\boldsymbol{\phi}_i$ の疎性パラメータ，$q_i$ は $\boldsymbol{\phi}_i$ の品質パラメータと呼ばれる値で，次式で定義される．

$$s_i = \boldsymbol{\phi}_i^T \boldsymbol{C}_{-i}^{-1} \boldsymbol{\phi}_i, \tag{2.23}$$

$$q_i = \boldsymbol{\phi}_i^T \boldsymbol{C}_{-i}^{-1} \boldsymbol{y}. \tag{2.24}$$

$\alpha_i \geq 0$ であることに注意すると，$q_i^2 \leq s_i$ の場合には，対数周辺尤度関数を最大にする $\alpha_i$ は無限大となることがわかる．無限大となる $\alpha_i$ に対応する $\beta_i$ の事後分布は，平均と分散がともに 0 となる．そのため，関連ベクトルマシンはスパース性を示す．

### 2.3.2　ベイズ的観点による説明

精度パラメータを与えた下での回帰係数ベクトル $\boldsymbol{\beta}$ の事前分布は，(2.5) 式のとおり正規分布である．一方，その精度パラメータ（分散パラメータの逆数）の事前分布には (2.6) 式のとおりガンマ分布である．これより，$\boldsymbol{\beta}$ の事前分布は正規分布とは異なる分布となる．具体的には，以下の計算により Student-$t$ 分布に類似する分布になることが知られている．

$$\begin{aligned}\pi(\boldsymbol{\beta} \mid a, b) &= \int \pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha})\pi(\boldsymbol{\alpha} \mid a, b)\mathrm{d}\boldsymbol{\alpha} \\ &= \frac{b^a \Gamma(a + 1/2)}{\sqrt{2\pi}\Gamma(a)}(b + \beta_i^2/2)^{-(a+1/2)} \\ &=: \mathrm{RVMprior}(\boldsymbol{\beta} \mid a, b). \end{aligned} \tag{2.25}$$

この分布は，Fig. 1 に示すとおり，パラメータ $a, b$ をうまく設定することで確率質量のうち多くを 0 付近に集中させることができる．そのため，ほとんどの回帰係数を 0 にするという事前情報を持った事前分布として捉えることができる．具体的には，パラメータ $b$ を 0 に近い値とすることでこのような特性を持たせることができる．また，この分布のパラメータ $a$ は確率密度関数の核の指数部分であるので，分布の裾の厚さを調整するパラメータとなっている．

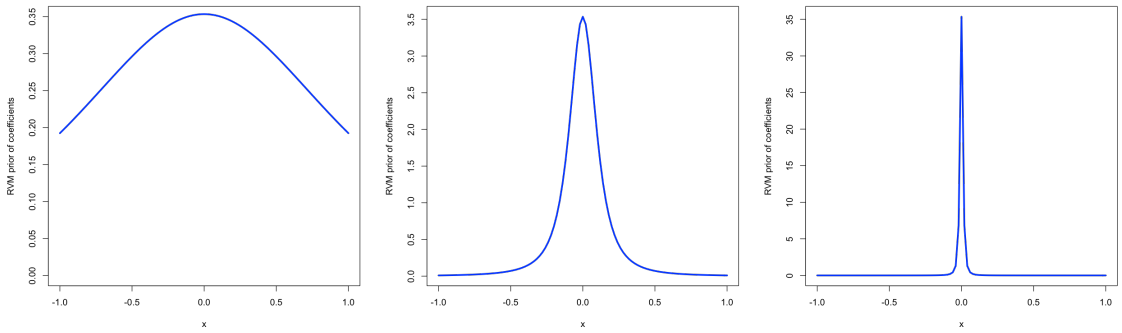



Fig. 1: 関連ベクトルマシンの回帰係数の事前分布．縦軸のスケールはそれぞれ異なるので注意されたい．(左) $a = 1, b = 1$ のとき．(中) $a = 1, b = 0.01$ のとき．(右) $a = 1, b = 0.0001$ のとき．

### 2.3.3 実際の推定による確認

真の関数 $y = \sin \pi x$ に対して，以下の式に従いデータ $\{(x_i, y_i) : i = 1, \cdots, 100\}$ を発生させた．ただし，説明変数の次元数は $p = 1$ である．

$$x_i \sim U(x_i \mid -1, 1), \tag{2.26}$$

$$y_i \sim \mathcal{N}(y_i \mid \sin \pi x_i, 0.4^2). \tag{2.27}$$

以上により発生させたデータに対して，関連ベクトルマシンを用いて真の関数の推測を行った．推定アルゴリズムには，MCMC 法によるものを用いた．ハイパーパラメータは，$a = 1, b = 1/999, c_0 = 10, d_0 = 2 \times 10^{-5}$ とした．MCMC の繰り返し回数は 5000 回で，そのうち 1000 回を burn-in として除外し 4000 回分をパラメータ推定に用いた．推定結果は，回帰係数の事後平均を用いて求めた．

結果は Fig. 2 のとおりとなった．この結果から，回帰係数が 4 つを除いて 0 となっていることがわかる．そのため，新たに得られたデータに対する予測には非 0 の部分のみを抜き出した $4 \times 4$ の行列を計算すればよく，高速な予測が可能となっていることがわかる．

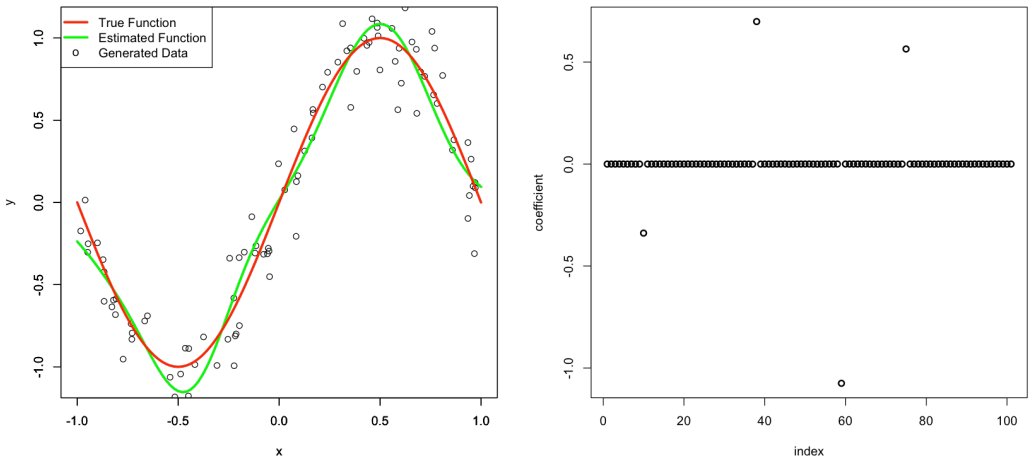



Fig. 2: 関連ベクトルマシンによる回帰分析の例．(左) 真の関数からノイズを伴って観測されたデータを用いた推定．赤線が真の関数，緑線が関連ベクトルマシンにより推定された関数，黒丸が観測されたデータ．(右) 関連ベクトルマシンにより推定された回帰係数の事後平均値のプロット．4 つの回帰係数を除いて 0 と推定されていることがわかる．

# 3　$L_1$ 型スパース推定法

本節では，Lasso および連結 lasso について述べ，それぞれのベイズ型についても述べる．

## 3.1　Lasso

Lasso (Tibshirani, 1996) は，変数選択を目的として提案された線形回帰の正則化手法である．多くの回帰係数を完全に 0 と推定する性質を有しているため，非 0 と推定された回帰係数を選択することができる．

関連ベクトルマシンのときと同様に，$p$ 次元ベクトル $\boldsymbol{x}_i$ を説明変数，1 次元の $y_i$ を目的変数とする $n$ 個のデータの組 $\{(\boldsymbol{x}_i, y_i) : i = 1, \cdots, n\}$ が得られているとする．このとき，Lasso では次の線形モデルを用いて説明変数と目的変数をモデリングする．

$$\boldsymbol{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon}. \tag{3.1}$$

ただし，$\boldsymbol{y} = (y_1, \cdots, y_n)^T$ は $p$ 次元の目的変数ベクトル，$X$ は $n \times p$ 型の $\boldsymbol{x}_i$ を行ベクトルとして持つ計画行列，$\boldsymbol{\beta}$ は $p$ 次元の回帰係数ベクトル，$\boldsymbol{\epsilon}$ は $n$ 次元の誤差ベクトルである．また，$\boldsymbol{\epsilon}$ 多変量正規分布 $\mathcal{N}_n(\mathbf{0}, \sigma^2 I_n)$ に従うと仮定する．

最小二乗法では，2 乗誤差の最小化により回帰係数ベクトル $\boldsymbol{\beta}$ の推定を行うが，Lasso では 2 乗誤差に回帰係数の $L_1$ ノルムを正則化項として加えたものの最小化により $\boldsymbol{\beta}$ を推定する．つまり，以下の関数の最小化で $\boldsymbol{\beta}$ の推定を行う．

$$E(\boldsymbol{\beta}) = \frac{1}{2}(\boldsymbol{y} - X\boldsymbol{\beta})^T(\boldsymbol{y} - X\boldsymbol{\beta}) + \lambda \sum_{i=1}^{p} |\beta_i|. \tag{3.2}$$

ここで，$\lambda\ (> 0)$ は正則化パラメータと呼ばれる調整パラメータであり，正則化の強さを調整する働きを持つ．

(3.2) 式の最小化は，正則化項に微分不可能な点を含むため，解析的に求めることができない．そのため，数値的に最小化を行うアルゴリズムとして，Fu (1998) による shooting 法や Efron et al. (2004) による LARS (least angle regression) などが提案されている．

### 3.1.1 Lasso のスパース性

Lasso は関連ベクトルマシンと同様に，回帰係数ベクトルの各成分を完全に 0 と推定する性質を有する．ここでは，その理由について述べる．

(3.2) 式の最小化問題は，ラグランジュの未定乗数法を用いることにより以下の制約付き最小化問題に変形できることが知られている (Tibshirani, 1996)．

$$\begin{aligned} &\text{minimize} && \frac{1}{2}\left\{(\boldsymbol{y}-X\boldsymbol{\beta})^T(\boldsymbol{y}-X\boldsymbol{\beta})\right\} \\ &\text{subject to} && \sum_{j=1}^{p}|\beta_j| \leq \eta \end{aligned} \tag{3.3}$$

ただし，$\eta$ はラグランジュの未定乗数法によって決まる正の定数である．$p=2$ のとき，最小二乗推定値と Lasso 推定値の関係を図式化すると Fig. 3 のとおりとなる．ここで，Lasso 推定値 $\hat{\boldsymbol{\beta}}_{\text{Lasso}}$ は最小二乗推定値 $\hat{\boldsymbol{\beta}}_{\text{OLS}}$ から二乗誤差の楕円を徐々に大きくしていき，最初に制約条件の示すひし形と当たる点になっている．そのため，$\hat{\boldsymbol{\beta}}_{\text{Lasso}}$ は制約条件の角の部分になりやすく，回帰係数の値を 0 と推定する．

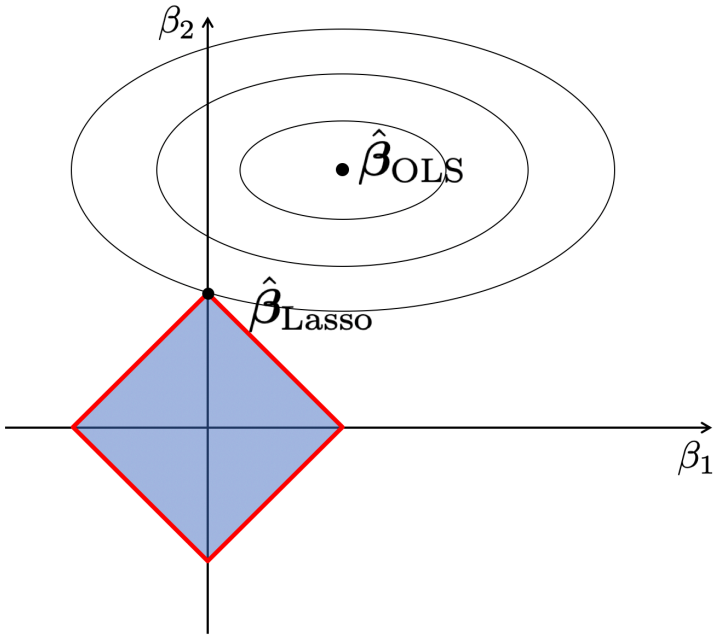



Fig. 3: 2 次元のときの Lasso 推定値の図式化．$\hat{\boldsymbol{\beta}}_{\text{OLS}}$ は最小二乗推定値，$\hat{\boldsymbol{\beta}}_{\text{Lasso}}$ は Lasso 推定値，楕円は二乗誤差の等高線，中央のひし形は (3.3) 式の制約条件．この場合，Lasso 推定値の $\beta_1$ が 0 と推定されている．

## 3.2 ベイズ型 lasso

Tibshirani (1996) では，(3.2) 式の正則化を用いた Lasso の推定値は，回帰係数毎に独立したラプラス分布を事前分布に用いた回帰モデルの事後モードと一致することが示されている．つまり，回帰係数ベクトルの事前分布に次式を設定した回帰の事後モードが Lasso 推定値と一致する．

$$\begin{aligned}\pi(\boldsymbol{\beta} \mid \sigma^2, \lambda_1, \lambda_2) &= \prod_{i=1}^{p} \mathrm{Laplace}(\beta_i \mid 0, 2\lambda/\sigma) \\ &\propto \prod_{i=1}^{p} \exp\left(-\frac{\lambda}{\sigma}|\beta_i|\right). \end{aligned} \tag{3.4}$$

(3.4) 式を事前分布とした場合，ギブス・サンプリング等の効率的なサンプリングアルゴリズムを構成することは難しい．そこで，Park and Casella (2008) では混合法を用いてラプラス分布の階層ベイズモデルを考えることで，ギブス・サンプリングを実行できるベイズ型 lasso と呼ばれる方法を提案している．混合法については付録 B を参照されたい．

Andrews and Mallows (1974) は，ラプラス分布は指数分布と正規分布からなる階層表現で表すことができることを示している．つまり，ラプラス分布は以下のように指数分布と正規分布の畳み込み積で書くことができる．

$$\begin{aligned}\mathrm{Laplace}(x \mid 0, \lambda) &= \frac{\lambda}{2}\exp\left(-\lambda|x|\right) \\ &= \int_0^\infty \frac{1}{\sqrt{2\pi s}}\exp\left(-\frac{x^2}{2s}\right) \times \frac{\lambda^2}{2}\exp\left(-\frac{\lambda^2 s}{2}\right)\mathrm{d}s \\ &= \int_0^\infty \mathcal{N}(x \mid 0, s)\mathrm{Exp}(s \mid \lambda^2)\mathrm{d}s. \end{aligned} \tag{3.5}$$

このとき，ラプラス分布からのサンプリングは混合法を用いて，Algorithm 3 により実行することができる．

**Algorithm 3** 混合法によるラプラス分布からのサンプリング

$s$ を $\mathrm{Exp}(\lambda^2)$ からサンプリングする．
$x$ を $\mathcal{N}(0, s)$ からサンプリングする．

以上より，ベイズ型 lasso は回帰係数の条件付き事前分布に正規分布を，回帰係数の分散の事前分布に指数分布を設定する階層ベイズモデルとして構成すれば良いこ

とがわかる．さらに，誤差分散 $\sigma^2$ に逆ガンマ分布を設定する．つまり，

$$\pi(\sigma^2 \mid \nu_0, \eta_0) = \frac{{\eta_0}^{\nu_0}}{\Gamma(\nu_0)} x^{-(\nu_0-1)} \exp\left(-\frac{\eta_0}{\sigma^2}\right) \tag{3.6}$$

$$=: \text{inverted Gamma } (\sigma^2 \mid \nu_0, \eta_0) \tag{3.7}$$

と設定する．また，尤度関数は次式で書くことができる．

$$p(\boldsymbol{y} \mid X, \boldsymbol{\beta}, \sigma^2) = \mathcal{N}_n(\boldsymbol{y} \mid X\boldsymbol{\beta}, \sigma^2 I_n). \tag{3.8}$$

このとき，完全条件付き分布は以下のとおりとなる．

$$\begin{aligned}
\boldsymbol{\beta} \mid \boldsymbol{y}, X, \sigma^2, \tau_1^2, \cdots, \tau_p^2 &\sim \mathcal{N}_p(A^{-1}X^T\boldsymbol{y}, \sigma^2 A^{-1}), \\
&A = X^TX + B^{-1}, B = \text{diag}(\tau_1^2, \cdots, \tau_p^2), \qquad (3.9) \\
\sigma^2 \mid \boldsymbol{y}, X, \boldsymbol{\beta}, \tau_1^2, \cdots, \tau_p^2 &\sim \text{inverted Gamma } \left(\frac{n_1}{2}, \frac{s_1}{2}\right), \\
&n_1 = n + p + \nu_0, \\
&s_1 = (\boldsymbol{y} - X\boldsymbol{\beta})^T(\boldsymbol{y} - X\boldsymbol{\beta}) + \boldsymbol{\beta}^T B^{-1}\boldsymbol{\beta} + \eta_0, \qquad (3.10) \\
\frac{1}{\tau_j^2} \mid \beta_j, \sigma^2, \lambda &= \text{inverse Gaussian } \left(\frac{\sigma\lambda}{\beta_j}, \lambda^2\right), j = 1, \cdots, p. \qquad (3.11)
\end{aligned}$$

ここで，inverse Gaussian $(\cdot, \cdot)$ は逆ガウス分布であり，その確率密度関数はパラメータ $\mu, \phi$ を用いて以下で表される．

$$\text{inverse Gaussian } (x \mid \mu, \phi) = \sqrt{\frac{1}{2\pi\phi x^3}} \exp\left\{-\frac{(x-\mu)^2}{2\mu^2\phi x}\right\}. \tag{3.12}$$

したがって，ベイズ型 lasso のギブス・サンプリングは，Algorithm 4 にまとめることができる．

**Algorithm 4** ギブス・サンプリングによるベイズ型 lasso の事後分布推定

ハイパーパラメータ $\lambda, \nu_0, \eta_0$ を決める．
反復回数 $m$ を定める．
**for** $i = 1, 2, \cdots, m$ **do**
　$\boldsymbol{\beta}$ を $\mathcal{N}_p(A^{-1}X^T\boldsymbol{y}, \sigma^2 A^{-1})$ からサンプリングする．ただし，$A = X^TX + B^{-1}, B = \mathrm{diag}(\tau_1^2, \cdots, \tau_p^2)$.
　$\sigma^2$ を inverted Gamma $\left(\frac{n_1}{2}, \frac{s_1}{2}\right)$ からサンプリングする．ただし，$n_1 = n + p + \nu_0, s_1 = (\boldsymbol{y} - X\boldsymbol{\beta})^T(\boldsymbol{y} - X\boldsymbol{\beta}) + \boldsymbol{\beta}^T B^{-1}\boldsymbol{\beta} + \eta_0$.
　**for** $j = 1, 2, \cdots, n$ **do**
　　$1/\tau_j^2$ を inverse Gaussian $\left(\frac{\sigma\lambda}{\beta_j}, \lambda^2\right)$ からサンプリングする．

## 3.3 連結 lasso

連結 lasso (Tibshirani et al., 2005) は，(3.2) 式に隣り合った回帰係数の差の $L_1$ ノルムを正則化項として加えて回帰係数パラメータを推定する方法である．つまり，次式を最小化する．

$$E(\boldsymbol{\beta}) = \frac{1}{2}(\boldsymbol{y} - X\boldsymbol{\beta})^T(\boldsymbol{y} - X\boldsymbol{\beta}) + \lambda_1 \sum_{i=1}^{p} |\beta_i| + \lambda_2 \sum_{i=2}^{p} |\beta_i - \beta_{i-1}|. \tag{3.13}$$

ただし，$\lambda_1, \lambda_2$ は正の値をとる正則化パラメータである．ここで追加した正則化項は，Lasso の正則化項と同様，隣り合った回帰係数の差を 0 に縮小する働きを持つ．

(3.13) 式の最小化も，Lasso と同様に正則化項に微分可能でない点を含むため，計算アルゴリズムに従って推定値を求める必要がある．Tibshirani et al. (2005) では，Gill et al. (1997) による SQOPT と呼ばれる FORTRAN のパッケージを用いて最小化する方法と，座標降下法で最小化する方法が提案されている．

## 3.4 ベイズ型連結 lasso

Kyung et al. (2010) では，連結 lasso のベイズ版であるベイズ型連結 lasso を提案している．すなわち，回帰係数ベクトル $\boldsymbol{\beta}$ の事前分布に

$$\begin{aligned}\pi(\boldsymbol{\beta} \mid \sigma^2, \lambda_1, \lambda_2) &= \prod_{i=1}^{p} \text{Laplace}(\beta_i \mid 0, 2\lambda_1/\sigma) \prod_{i=1}^{p-1} \text{Laplace}(\beta_{i+1} - \beta_i \mid 0, 2\lambda_2/\sigma) \\ &\propto \prod_{i=1}^{p} \exp\left(-\frac{\lambda_1}{\sigma}|\beta_i|\right) \prod_{i=1}^{p-1} \exp\left(-\frac{\lambda_2}{\sigma}|\beta_{i+1} - \beta_i|\right) \end{aligned} \tag{3.14}$$

を設定することでベイズ型連結 lasso を構築する．ラプラス分布の階層表現を用いて完全条件付き分布を計算すると，以下のとおりとなる．

$$\boldsymbol{\beta} \mid X, \boldsymbol{y}, \sigma^2, \tau_i, \omega_i \sim \mathcal{N}_n\left(\left(X^T X + \Sigma_\beta^{-1}\right)^{-1} X^T \boldsymbol{y}, \sigma^2 \left(X^T X + \Sigma_\beta^{-1}\right)\right), \tag{3.15}$$

$$\sigma^2 \mid X, \boldsymbol{\beta}, \boldsymbol{y}, \tau_i, \omega_i \sim \text{inverted Gamma}\left(\frac{n-1+p}{2}, \frac{1}{2}(y - X\boldsymbol{\beta})^T(y - X\boldsymbol{\beta}) + \frac{1}{2}\boldsymbol{\beta}^T \Sigma^{-1} \boldsymbol{\beta}\right), \tag{3.16}$$

$$1/\tau_j^2 \mid X, \boldsymbol{\beta}, \boldsymbol{y}, \sigma^2, \omega_i \sim \text{inverse Gaussian}\left(\frac{\lambda_1 \sigma}{\beta_i}, \lambda_1^2\right), \tag{3.17}$$

$$1/\omega_j^2 \mid X, \boldsymbol{\beta}, \boldsymbol{y}, \sigma^2, \tau_i \sim \text{inverse Gaussian}\left(\frac{\lambda_2 \sigma}{\beta_{i+1} - \beta_i}, \lambda_2^2\right). \tag{3.18}$$

ここで，$\Sigma_\beta^{-1}$ は次式で表される三重対角行列である．

$$\Sigma_\beta^{-1} = \begin{bmatrix} \frac{1}{\tau_1^2} + \frac{1}{\omega_1^2} & -\frac{1}{\omega_1^2} & 0 & \cdots & \cdots & 0 \\ -\frac{1}{\omega_1^2} & \frac{1}{\tau_2^2} + \frac{1}{\omega_1^2} + \frac{1}{\omega_2^2} & -\frac{1}{\omega_2^2} & \ddots & \ddots & \vdots \\ 0 & -\frac{1}{\omega_2^2} & \frac{1}{\tau_3^2} + \frac{2}{\omega_1^2} + \frac{1}{\omega_3^2} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & \frac{1}{\tau_{p-1}^2} + \frac{1}{\omega_{p-2}^2} + \frac{1}{\omega_{p-1}^2} & -\frac{1}{\omega_{p-1}^2} \\ 0 & \cdots & \cdots & 0 & -\frac{1}{\omega_{p-1}^2} & \frac{1}{\tau_p^2} + \frac{1}{\omega_{p-1}^2} \end{bmatrix}$$

以上より，ベイズ型連結 lasso のギブス・サンプリングは，Algorithm 5 にまとめることができる．

**Algorithm 5** ギブス・サンプリングによるベイズ型連結 lasso の事後分布推定

ハイパーパラメータ $\sigma, \lambda_1, \lambda_2$ を決める．
反復回数 $m$ を定める．
**for** $i = 1, 2, \cdots, m$ **do**
　$\boldsymbol{\beta}$ を $\mathcal{N}_n\left(\left(X^TX + \Sigma_\beta^{-1}\right)^{-1} X^T\boldsymbol{y}, \sigma^2\left(X^TX + \Sigma_\beta^{-1}\right)\right)$ からサンプリングする．
　$\sigma^2$ を inverted Gamma $\left(\frac{n-1+p}{2}, \frac{1}{2}(y - X\boldsymbol{\beta})^T(y - X\boldsymbol{\beta}) + \frac{1}{2}\boldsymbol{\beta}^T\Sigma^{-1}\boldsymbol{\beta}\right)$ からサンプリングする．
　**for** $j = 1, 2, \cdots, n$ **do**
　　$1/\tau_j^2$ を inverse Gaussian $\left(\frac{\lambda_1\sigma}{\beta_i}, \lambda_1^2\right)$ からサンプリングする．
　　$1/\omega_j^2$ を inverse Gaussian $\left(\frac{\lambda_2\sigma}{\beta_{i+1}-\beta_i}, \lambda_2^2\right)$ からサンプリングする．

### 3.4.1　ベイズ型連結 lasso のスパース性

Kyung et al. (2010) によれば，(3.13) 式の正則化による連結 lasso とベイズ型連結 lasso が対応しているため，ベイズ型連結 lasso についてもスパース性を持つと述べられている．本項では，これに加えてベイズ的観点からベイズ型連結 lasso が持つスパース性について述べる．

ベイズ型連結 lasso の回帰係数ベクトルの事前分布は，(3.14) 式のとおりラプラス分布を設定している．ここで，ラプラス分布の確率密度関数は Fig. 4 のような形をしており，確率質量のうち多くが 0 付近に集中している．つまり，関連ベクトルマシンの事前分布と同様，回帰係数や隣り合った回帰係数の差のうち多くが 0 付近にあるという情報を事前分布を通してモデルに仮定している．このため，ラプラス事前分布は回帰係数および隣り合った回帰係数の差を 0 に縮小推定するような働きをしている．関連ベクトルマシンの事前分布との差異については，4.3 節で詳述する．ベイズ型連結 lasso では，正則化パラメータ $\lambda_1, \lambda_2$ を大きくすることが，連結 lasso における正則化項の働きを強めてスパース性を強くすることに対応している．それは (3.14) 式における $\lambda_1, \lambda_2$ を大きくすると，$|\beta_i|$ や $|\beta_{i+1} - \beta_i|$ の係数が大きくなるために分布が急峻となることからもわかる．

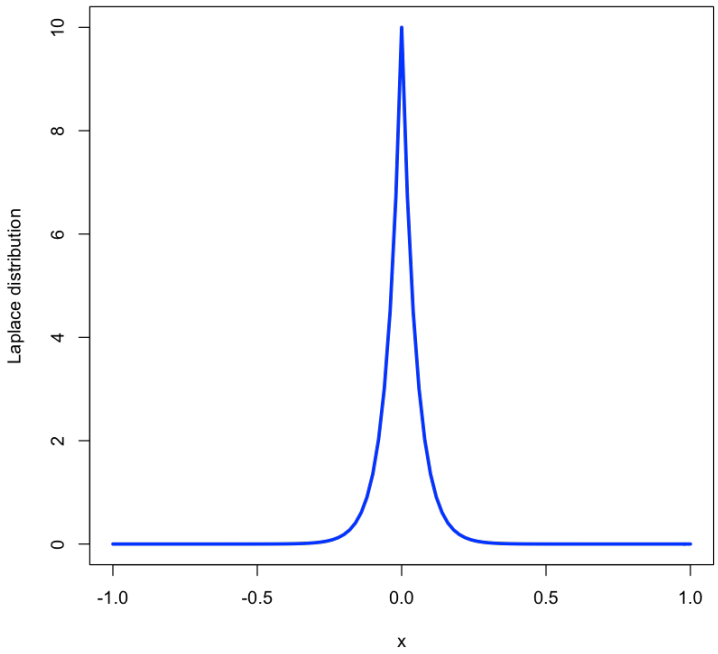



Fig. 4: ラプラス分布（Laplace$(0, 0.05)$）の確率密度関数のプロット.

# 4　提案手法

本節では，ベイズ型連結 lasso の考えに基づき，回帰係数の併合を行うことが可能な関連ベクトルマシンを提案する．また，提案モデル内に含まれるパラメータを推定するために，MCMC 法に基づく計算アルゴリズムを提案する．

## 4.1　事前分布

尤度関数には，関連ベクトルマシンと同様の (2.4) 式，もしくは Lasso と同様の (3.8) 式を用いる．どちらの尤度関数を用いても，以下の議論は同様である．ここでは，関連ベクトルマシンと同様のものを用いて議論を進める．

各パラメータの事前分布は，以下のとおりに設定する．

$$\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) = \prod_{i=1}^{n} \mathcal{N}(\beta_i \mid 0, (\lambda_1 \alpha_i)^{-1}) \prod_{i=1}^{n-1} \mathcal{N}(\beta_{i+1} - \beta_i \mid 0, (\lambda_2 \alpha_i')^{-1}), \tag{4.1}$$

$$\pi(\boldsymbol{\alpha} \mid \eta, \nu) = \prod_{i=1}^{n} \mathrm{Gamma}(\alpha_i \mid \eta/2, \nu/2), \tag{4.2}$$

$$\pi(\boldsymbol{\alpha}' \mid \eta', \nu') = \prod_{i=1}^{p-1} \mathrm{Gamma}(\alpha_i' \mid \eta'/2, \nu'/2), \tag{4.3}$$

$$\pi(1/\sigma^2 \mid c, d) = \mathrm{Gamma}(1/\sigma^2 \mid c, d). \tag{4.4}$$

(4.1) 式の回帰係数ベクトル $\boldsymbol{\beta}$ の事前分布に，隣り合った回帰係数の差についても正規分布を設定している点が，2 節で述べた関連ベクトルマシンと異なる点である．この部分についても精度パラメータの事前分布をガンマ分布にすることで，隣り合った回帰係数の差の事前分布は (2.25) 式が確率密度関数である分布となる．そのため，提案手法の隣り合った回帰係数の差に関しても関連ベクトルマシンの回帰係数と同様に 0 への縮小推定が促進される．

ここで，(4.1) 式の回帰係数ベクトルの事前分布は正規分布どうしの積なので，次

のように一つの多変量正規分布で書くことができる．

$$
\begin{aligned}
\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) &\propto \prod_{j=1}^{n} \mathcal{N}(\beta_j \mid 0, 1/\sqrt{\lambda_1 \alpha_j}) \prod_{j=1}^{n-1} \mathcal{N}(\beta_j - \beta_{j+1} \mid 0, 1/\sqrt{\lambda_2 \alpha'_j}) \\
&\propto \prod_{j=1}^{n} \exp\left(-\frac{\beta_j^2}{2(\sqrt{\lambda_1 \alpha_j})^{-2}}\right) \prod_{j=1}^{n-1} \exp\left(-\frac{(\beta_j - \beta_{j+1})^2}{2(\sqrt{\lambda_2 \alpha'_j})^{-2}}\right) \\
&= \exp\{-\lambda_1/2 \left(\alpha_1 \beta_1^2 + \alpha_2 \beta_2^2 + \cdots + \alpha_n \beta_n^2\right) \\
&\quad - \lambda_2/2\{\alpha'_1(\beta_1^2 - 2\beta_1\beta_2 + \beta_2^2) + \alpha'_2(\beta_2^2 - 2\beta_2\beta_3 + \beta_3^2) \\
&\quad - \cdots - \alpha'_{n-1}(\beta_{n-1}^2 - 2\beta_{n-1}\beta_n + \beta_n^2)\}\} \\
&= \exp\left(-\frac{1}{2}\boldsymbol{\beta}^T \boldsymbol{\Psi}^{-1} \boldsymbol{\beta}\right) \\
&\propto \mathcal{N}_n(\mathbf{0}, \boldsymbol{\Psi}).
\end{aligned} \tag{4.5}
$$

ただし，分散共分散行列 $\boldsymbol{\Psi}$ は，その逆行列が次式の三重対角行列で与えられる $n \times n$ 行列である．

$$
\boldsymbol{\Psi}^{-1} =
\begin{bmatrix}
\lambda_1\alpha_1 + \lambda_2\alpha'_1 & -\lambda_2\alpha'_1 & 0 & \cdots & \cdots & 0 \\
-\lambda_2\alpha'_1 & \lambda_1\alpha_2 + \lambda_2\alpha'_1 + \lambda_2\alpha'_2 & -\lambda_2\alpha'_2 & \ddots & \ddots & \vdots \\
0 & -\lambda_2\alpha'_2 & \lambda_1\alpha_3 + \lambda_2\alpha'_2 + \lambda_2\alpha'_3 & \ddots & \ddots & \vdots \\
\vdots & \ddots & \ddots & \ddots & \ddots & 0 \\
\vdots & \ddots & \ddots & \ddots & \lambda_1\alpha_{,i-1} + \lambda_2\alpha'_{i-2} + \lambda_2\alpha'_{i-1} & -\lambda_2\alpha'_{i-1} \\
0 & \cdots & \cdots & 0 & -\lambda_2\alpha'_{i-1} & \lambda_1\alpha_i + \lambda_2\alpha'_{i-1}
\end{bmatrix}.
\tag{4.6}
$$

## 4.2 完全条件付き分布と推定アルゴリズム

2.2.2 項で説明した MCMC 法による関連ベクトルマシンの推定アルゴリズムを拡張することで，提案手法の推定アルゴリズムを導出する．

提案手法では，ギブス・サンプリングを用いて事後分布の推定を行う．そのため，各パラメータについて完全条件付き分布が必要となる．以下の計算により，完全条件付き分布を求めることができる．

$$
\begin{aligned}
\pi(\boldsymbol{\beta}|\boldsymbol{\Phi},\boldsymbol{\beta},\sigma^2,\boldsymbol{\alpha},\boldsymbol{\alpha}') &\propto \mathcal{N}_n(\boldsymbol{y}|\boldsymbol{\Phi}\boldsymbol{\beta},\sigma^2 I_n)\times\mathcal{N}_n(\boldsymbol{\beta}|\mathbf{0},\boldsymbol{\Psi}) \\
&\propto \frac{1}{\sqrt{(2\pi\sigma^2)^n}}\exp\left(-\frac{1}{2}\frac{\|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{\sigma^2}\right)\times\exp\left(\frac{1}{2}\boldsymbol{\beta}^T\boldsymbol{\Psi}^{-1}\boldsymbol{\beta}\right) \\
&\propto \mathcal{N}_n\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi}+\boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y},(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi}+\boldsymbol{\Psi})^{-1}\right), \qquad (4.7)
\end{aligned}
$$

$$
\begin{aligned}
\pi(1/\sigma^2|a,b,\boldsymbol{y},\boldsymbol{\Psi},\boldsymbol{\beta}) &\propto \mathcal{N}_n(\boldsymbol{y}|\boldsymbol{\Phi}\boldsymbol{\beta},\sigma^2 I_n)\times\mathrm{Gamma}(1/\sigma^2|a,b) \\
&\propto \frac{1}{\sqrt{(2\pi\sigma^2)^n}}\exp\left(-\frac{1}{2}\frac{\|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{\sigma^2}\right)\times(1/\sigma^2)^{a-1}\exp(-b/\sigma^2) \\
&\propto (1/\sigma^2)^{a+n/2-1}\exp\left\{-(1/\sigma^2)\left(b+\frac{\|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{2}\right)\right\} \\
&\propto \mathrm{Gamma}\left(a+\frac{n}{2},b+\frac{\|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{2}\right), \qquad (4.8)
\end{aligned}
$$

$$
\begin{aligned}
\pi(\alpha_i|\nu,\eta,\lambda_1,\beta_i) &\propto \mathcal{N}(\beta_i|0,1/\sqrt{\lambda_1\alpha_i})\times\mathrm{Gamma}(\nu/2,\eta/2) \\
&\propto \sqrt{\frac{\lambda_1\alpha_1}{2\pi}}\exp\left(-\frac{\beta_j^2}{2(\sqrt{\lambda_1\alpha_j})^{-2}}\right)\times(\alpha_i)^{\nu/2-1}\exp(-\alpha_i\cdot\eta/2) \\
&\propto (\alpha_i)^{(\nu+1)/2-1}\exp\left\{-\frac{1}{2}\left(\beta_i^2\lambda_1+\eta\right)\alpha_i\right\} \\
&\propto \mathrm{Gamma}\left(\frac{\nu+1}{2},\frac{1}{2}\left(\beta_i^2\lambda_1+\eta\right)\right), \qquad (4.9)
\end{aligned}
$$

$$
\begin{aligned}
\pi(\alpha_i'|\nu',\eta',\lambda_1,\lambda_2,\beta_i,\beta_{i+1}) &\propto \mathcal{N}(\beta_j-\beta_{j+1}|0,1/\sqrt{\lambda_2\alpha_i'})\times\mathrm{Gamma}(\nu'/2,\eta'/2) \\
&\propto \sqrt{\frac{\lambda_2\alpha_i'}{2\pi}}\exp\left(-\frac{(\beta_j-\beta_{j+1})^2}{2(\sqrt{\lambda_2\alpha_j'})^{-2}}\right)\times(\alpha_i')^{\nu'/2-1}\exp(-\alpha_i'\cdot\eta'/2) \\
&\propto (\alpha_i')^{(\nu'+1)/2-1}\exp\left\{-\frac{1}{2}\left((\beta_j-\beta_{j+1})^2\lambda_2+\eta'\right)\alpha_i'\right\} \\
&\propto \mathrm{Gamma}\left(\frac{\nu'+1}{2},\frac{1}{2}\left\{(\beta_j-\beta_{j+1})^2\lambda_2+\eta'\right\}\right). \qquad (4.10)
\end{aligned}
$$

この完全条件付き分布を用いると，ギブス・サンプリングを用いた事後分布の推定アルゴリズムは Algorithm 6 のとおりとなる．

**Algorithm 6** ギブス・サンプリングによる提案手法の事後分布推定

ハイパーパラメータ $\lambda_1, \lambda_2, a, b, \eta, \nu, \eta', \nu'$ を決める．
反復回数 $m$ を定める．
**for** $i = 1, 2, \cdots, m$ **do**
  $\boldsymbol{\beta}$ を $\mathcal{N}_n\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}, (\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\right)$ からサンプリングする．
  $\sigma^{-2}$ を $\mathrm{Gamma}\left(a + \frac{n}{2}, b + \frac{\|\boldsymbol{y} - \boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{2}\right)$ からサンプリングする．
  **for** $j = 1, 2, \cdots, n$ **do**
    $\alpha_j$ を $\mathrm{Gamma}\left(\frac{\nu+1}{2}, \frac{1}{2}\left(\beta_i^2\lambda_1 + \eta\right)\right)$ からサンプリングする．
    $\alpha'_j$ を $\mathrm{Gamma}\left(\frac{\nu'+1}{2}, \frac{1}{2}\left\{(\beta_j - \beta_{j+1})^2\lambda_2 + \eta'\right\}\right)$ からサンプリングする．

## 4.3 ラプラス事前分布との比較

前述のとおり，回帰係数の事前分布に関連ベクトルマシンと提案手法ではStudent-$t$ 分布に類似した分布を，ベイズ型連結 lasso ではラプラス分布を設定している．本項では，2 つの分布の裾の厚さの違いについて論じ，スパース性の違いについて検討する．

裾の厚さを検討するために，確率密度関数の比の極限について考える．つまり，

$$\lim_{\beta\to\infty} \frac{\mathrm{RVMprior}(\beta \mid a, b)}{\mathrm{Laplace}(\beta \mid 0, \lambda)} = \lim_{\beta\to\infty} \frac{\frac{b^a\Gamma(a+1/2)}{\sqrt{2\pi}\Gamma(a)}(b + \beta^2/2)^{-(a+1/2)}}{\frac{\lambda}{2}\exp\left(-\lambda|\beta|\right)} \tag{4.11}$$

が有限値に収束するならば分子のほうが速く 0 に収束し，無限大に発散するならば分母のほうが速く 0 に収束する．実際には，この極限は $a$ が有限値ならば無限大に発散する．つまり，分母の確率分布すなわちベイズ型連結 lasso の事前分布のほうが速く 0 に収束する．そのため，ラプラス事前分布は関連ベクトルマシンの事前分布より裾が薄いといえる．また，以下の計算により，$[-0.5, 0.5]$ より外側の裾の部分を取る事前確率は関連ベクトルマシンの事前分布の方が高いことがわかる．

$$1 - \int_{-0.5}^{0.5} \mathrm{RVMprior}(\beta \mid 0.1, 10^{-5})\mathrm{d}\beta \simeq 0.344, \tag{4.12}$$

$$1 - \int_{-0.5}^{0.5} \mathrm{Laplace}(\beta \mid 0, 0.025)\mathrm{d}\beta \simeq 2.06 \times 10^{-9}. \tag{4.13}$$

ただし，それぞれの確率密度関数のプロットは Fig. 5 のとおりとなっている．また，$\beta = 0$ での確率密度関数の値がほぼ同じとなるようにパラメータを調整している．

以上の議論より，関連ベクトルマシンの事前分布はラプラス分布よりも裾が厚い

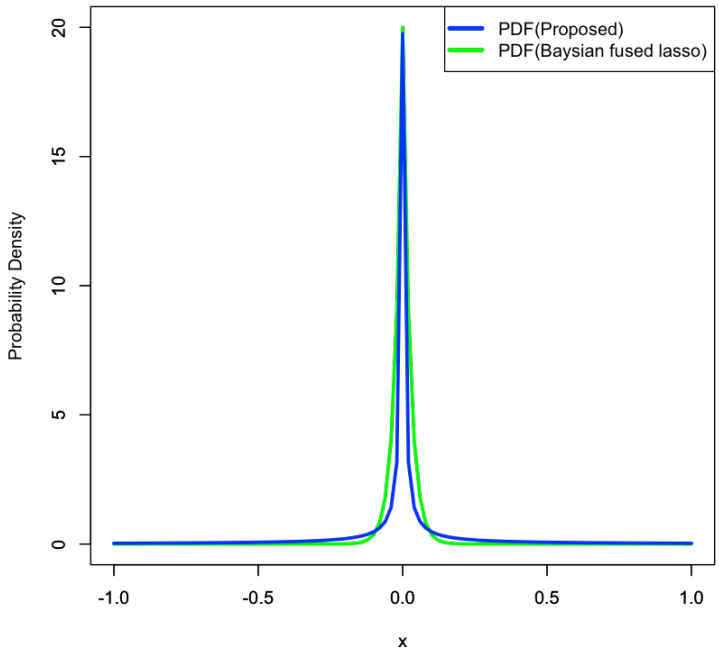



Fig. 5: (4.12) 式および (4.13) 式の被積分関数のプロット．青線が RVMprior($\beta \mid 0.1, 10^{-5}$)，緑線が Laplace($\beta \mid 0, 0.025$).

と言える．そのため，提案手法の事前分布はスパース性を保ち，ベイズ型連結 lasso より非 0 の回帰係数に対しては過度な縮小を起こさない.

# 5　数値実験

本節では人工データおよび実データを用いて，提案手法と既存手法であるベイズ型連結 lasso (BFL) の比較を行う．

## 5.1　モンテカルロ・シミュレーション

本項では，モンテカルロ・シミュレーションを通して提案手法とベイズ型連結 lasso (BFL) の比較を行う．

真のモデルとして，以下の線形モデルを考えた．

$$\boldsymbol{y} = X\boldsymbol{\beta}^* + \boldsymbol{\epsilon}. \tag{5.1}$$

ただし，$\boldsymbol{\beta}^*$ は $p$ 次元の真の回帰係数ベクトルであり，$\boldsymbol{\epsilon}$ は多変量正規分布 $\mathcal{N}_n(\mathbf{0}_n, \sigma^2 I_n)$ に従う誤差ベクトルとした．また，$n \times p$ 型の計画行列 $X$ の行ベクトル $\boldsymbol{x}_i$ は各々独立に多変量正規分布 $\mathcal{N}_p(\mathbf{0}_p, \Sigma)$ に従うものとした．

真のモデルの設定には，以下の 6 種類を用いた．

**Case 1** $p = 20, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_1^*$ or $\boldsymbol{\beta}_2^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

**Case 2** $p = 20, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_1^*$ or $\boldsymbol{\beta}_2^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

**Case 3** $p = 50, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_3^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

**Case 4** $p = 50, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_3^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

**Case 5** $p = 50, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_4^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

**Case 6** $p = 50, n = 50$, $\boldsymbol{\beta}^* = \boldsymbol{\beta}_4^*$, $\sigma = 0.5$ or $1.5$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

ただし，$\boldsymbol{\beta}_1^* = (\mathbf{0}_5^T, \mathbf{1}_5^T, \mathbf{0}_5^T, \mathbf{1}_5^T)^T, \boldsymbol{\beta}_2^* = (\mathbf{0}_5^T, \mathbf{2}_5^T, \mathbf{0}_5^T, \mathbf{2}_5^T)^T, \boldsymbol{\beta}_3^* = (\mathbf{3}_5^T, \mathbf{-1.5}_5^T, \mathbf{1}_5^T, \mathbf{2}_5^T, \mathbf{0}_{30}^T)^T$

である．$\boldsymbol{\beta}_4^*$ は $\boldsymbol{\beta}_3^*$ に対して，次の変更を加えたものとした．

$$(\beta_4^*)_i = \begin{cases} 5 & (i = 2), \\ 3 & (i = 33), \\ -3 & (i = 7, 20, 42), \\ (\beta_3^*)_i & (\text{others}). \end{cases} \tag{5.2}$$

ここで，$(\beta_3^*)_i$ は $\boldsymbol{\beta}_3^*$ の $i$ 番目の要素，$(\beta_4^*)_i$ は $\boldsymbol{\beta}_4^*$ の $i$ 番目の要素を表す．以上の真の回帰係数をプロットすると，Fig. 6 のとおりとなる．

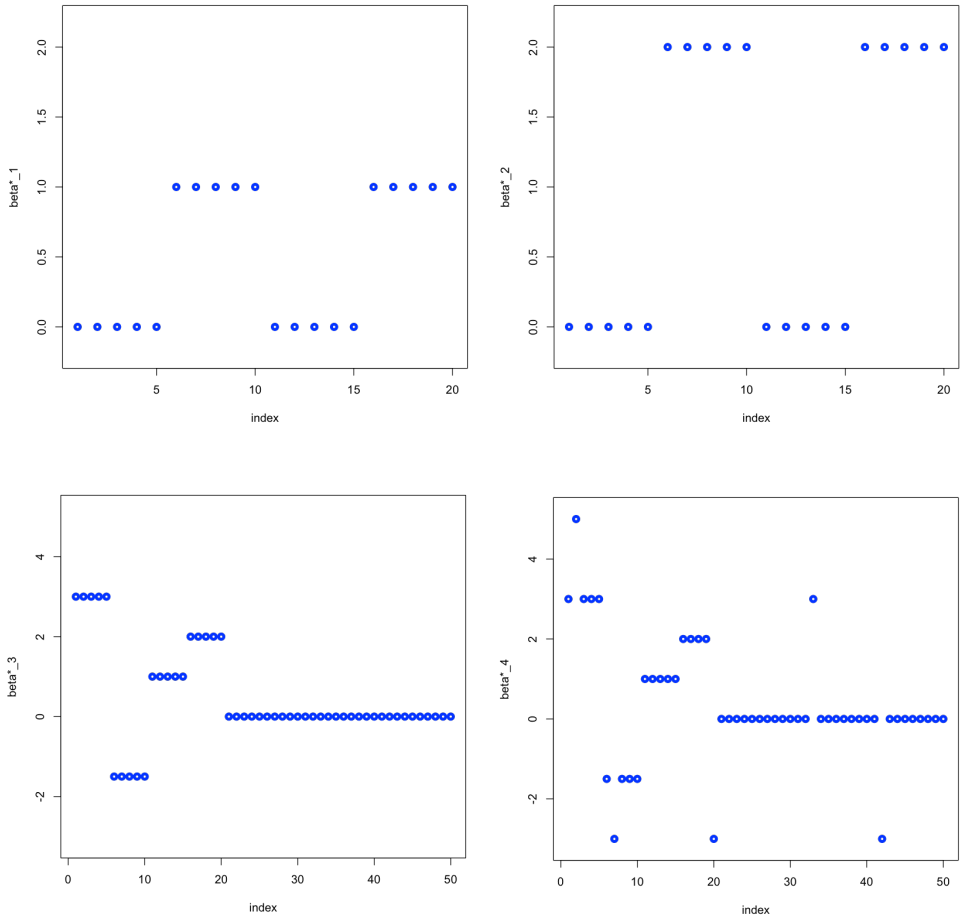



Fig. 6: 真の回帰係数のプロット．横軸は回帰係数の順番，縦軸は回帰係数の値．(左上) $\boldsymbol{\beta}_1^*$ のプロット．(右上) $\boldsymbol{\beta}_2^*$ のプロット．(左下) $\boldsymbol{\beta}_3^*$ のプロット．(右下) $\boldsymbol{\beta}_4^*$ のプロット．

提案手法とベイズ型連結 lasso の MCMC の繰り返し回数は 5000 回で，そのうち 1000 回を burn-in として除外し 4000 回分をパラメータ推定に用いた．ハイパーパラメータについては，WAIC (Watanabe, 2010) を最小化するように決定した．評価指標には，次式で定義される平均二乗誤差（mean squared error: MSE），予測二乗誤差（predict squared error: PSE）を用いた．これに加えて Case 1 から Case 4 までは $\mathrm{MSE}_{\mathrm{diff}}$ を，Case 5 と Case 6 には $\mathrm{MSE}_{\mathrm{spike}}$ を用いた．

$$\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})^T(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)}), \tag{5.3}$$

$$\mathrm{PSE} = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})^T\Sigma(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)}), \tag{5.4}$$

$$\mathrm{MSE}_{\mathrm{diff}} = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\beta}^*_{\mathrm{diff}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{diff}})^T(\boldsymbol{\beta}^*_{\mathrm{diff}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{diff}}), \tag{5.5}$$

$$\mathrm{MSE}_{\mathrm{spike}} = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\beta}^*_{\mathrm{spike}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{spike}})^T(\boldsymbol{\beta}^*_{\mathrm{spike}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{spike}}). \tag{5.6}$$

ここで，$\hat{\boldsymbol{\beta}}^{(i)}$ は $i$ 番目のデータセット $\mathcal{D}_i$ を用いて推定された回帰係数ベクトルの事後平均，$\boldsymbol{\beta}^*_{\mathrm{diff}}$ は真の回帰係数の隣り合ったものの差が非 0 の部分の回帰係数の差分を取ったものであり，例えば Case 1 のときは次式で書くことができる．

$$\boldsymbol{\beta}^*_{\mathrm{diff}} = (\beta^*_6 - \beta^*_5, \beta^*_{11} - \beta^*_{10}, \beta^*_{16} - \beta^*_{15})^T. \tag{5.7}$$

また，$\hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{diff}}$ についても $\boldsymbol{\beta}^*_{\mathrm{diff}}$ と同様，推定された $i$ 番目の回帰係数において隣り合ったものの差が非 0 の部分の回帰係数の差分を取ったものである．さらに，$\hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{spike}}$ と $\boldsymbol{\beta}^*_{\mathrm{spike}}$ は，具体的に次式で書くことができる．

$$\boldsymbol{\beta}^*_{\mathrm{spike}} = (\beta^*_2, \beta^*_7, \beta^*_{20}, \beta^*_{33}, \beta^*_{42})^T, \tag{5.8}$$

$$\hat{\boldsymbol{\beta}}_{\mathrm{spike}} = (\hat{\beta}_2, \hat{\beta}_7, \hat{\beta}_{20}, \hat{\beta}_{33}, \hat{\beta}_{42})^T. \tag{5.9}$$

実験結果は，Case 1 が Table 1，Case 2 が Table 2，Case 3 と Case 4 が Table 3 のとおりとなった．これらの結果から，$\sigma = 0.5$ の場合には提案手法はいずれの指標でもベイズ型連結 lasso より小さい値となっている．このことから，分散が比較的小さい場合，提案手法の推定精度はベイズ型連結 lasso と比べて改善されていることが

わかる．特に $\mathrm{MSE}_{\mathrm{diff}}$ についてはベイズ型連結 lasso の半分程度かそれを下回っており，大きく改善している．これは提案手法ではベイズ型連結 lasso より裾の厚い事前分布を用いることにより，隣り合った回帰係数の差が非 0 に推定されることが要因であると考えられる．一方で $\sigma = 1.5$ の場合には，提案手法はほとんどの指標でベイズ型連結 lasso より値が大きくなっている．そのため，提案手法は分散が比較的大きい場合には推定精度が悪くなっていると言える．これは提案手法は事前分布の裾が厚いため，真の構造から離れたデータに大きく影響されてしまったためであると考えられる．

また，Case 5 と Case 6 の結果は Table 4 のとおりとなった．Case 1 から Case 4 と同様，$\sigma$ が小さいときには提案手法の方が評価指標の値が小さいが，$\sigma$ が大きいときにはベイズ型連結 lasso の方が評価指標の値が小さいという結果になっている．これも Case 1 から Case 4 と同様であり，提案手法はデータの分散に対するロバスト性が低いことがわかる．

Table 1: Case 1 の結果．sd は標準偏差を表す．BFL と提案手法のうち評価指標の値が小さい方を太字で示した．

| | | $\sigma = 0.5$ | | | $\sigma = 1.5$ | | |
|---|---|---|---|---|---|---|---|
| | | MSE (sd) | $\mathrm{MSE}_{\mathrm{diff}}$ (sd) | PSE (sd) | MSE (sd) | $\mathrm{MSE}_{\mathrm{diff}}$ (sd) | PSE (sd) |
| $\beta_1^*$ | BFL | 0.353 (0.215) | 0.236 (0.162) | 0.550 (0.445) | **1.044 (0.547)** | **0.547 (0.431)** | **0.770 (0.425)** |
| | 提案手法 | **0.200 (0.105)** | **0.067 (0.070)** | **0.248 (0.176)** | 2.784 (1.406) | 0.803 (0.704) | 1.617 (0.761) |
| $\beta_2^*$ | BFL | 0.471 (0.335) | 0.314 (0.245) | 0.903 (1.143) | **1.273 (0.651)** | 0.902 (0.664) | **1.288 (0.932)** |
| | 提案手法 | **0.460 (0.239)** | **0.152 (0.139)** | **0.648 (0.788)** | 3.402 (1.256) | **0.887 (0.700)** | 2.339 (0.974) |

Table 2: Case 2 の結果．sd は標準偏差を表す．BFL と提案手法のうち評価指標の値が小さい方を太字で示した．

| | | $\sigma = 0.5$ | | | $\sigma = 1.5$ | | |
|---|---|---|---|---|---|---|---|
| | | MSE (sd) | $\text{MSE}_{\text{diff}}$ (sd) | PSE (sd) | MSE (sd) | $\text{MSE}_{\text{diff}}$ (sd) | PSE (sd) |
| $\boldsymbol{\beta}_1^*$ | BFL | 0.292 (0.191) | 0.159 (0.112) | 0.550 (0.387) | **0.489 (0.353)** | **0.429 (0.374)** | **0.630 (0.487)** |
| | 提案手法 | **0.176 (0.103)** | **0.067 (0.066)** | **0.183 (0.123)** | 2.708 (1.528) | 1.149 (1.028) | 1.701 (0.920) |
| $\boldsymbol{\beta}_2^*$ | BFL | 0.573 (0.302) | 0.287 (0.189) | 1.044 (0.604) | **0.705 (0.375)** | **0.537 (0.407)** | **0.977 (0.552)** |
| | 提案手法 | **0.498 (0.240)** | **0.174 (0.155)** | **0.603 (0.342)** | 3.069 (1.200) | 1.408 (1.088) | 2.145 (0.772) |

Table 3: Case 3 および Case 4 の結果．sd は標準偏差を表す．BFL と提案手法のうち評価指標の値が小さい方を太字で示した．

| | | $\sigma = 0.5$ | | | $\sigma = 1.5$ | | |
|---|---|---|---|---|---|---|---|
| | | MSE (sd) | $\text{MSE}_{\text{diff}}$ (sd) | PSE (sd) | MSE (sd) | $\text{MSE}_{\text{diff}}$ (sd) | PSE (sd) |
| Case 3 | BFL | 1.552 (0.772) | 0.522 (0.499) | 1.883 (1.846) | **20.129 (11.358)** | **4.367 (3.583)** | **11.281 (5.992)** |
| | 提案手法 | **1.429 (0.928)** | **0.439 (0.407)** | **1.820 (1.831)** | 34.598 (28.950) | 6.773 (6.369) | 18.592 (14.704) |
| Case 4 | BFL | 1.174 (0.443) | 0.440 (0.450) | 1.331 (0.643) | **15.213 (8.878)** | **4.085 (3.160)** | **10.715 (5.820)** |
| | 提案手法 | **1.083 (0.431)** | **0.386 (0.414)** | **1.195 (0.577)** | 25.431 (20.031) | 6.390 (5.987) | 17.017 (13.965) |

Table 4: Case 5 および Case 6 の結果．sd は標準偏差を表す．BFL と提案手法のうち評価指標の値が小さい方を太字で示した．

| | | $\sigma = 0.5$ | | | $\sigma = 1.5$ | | |
|---|---|---|---|---|---|---|---|
| | | MSE (sd) | $\text{MSE}_{\text{spike}}$ (sd) | PSE (sd) | MSE (sd) | $\text{MSE}_{\text{spike}}$ (sd) | PSE (sd) |
| Case 5 | BFL | 2.629 (1.277) | 0.974 (0.728) | 2.122 (1.498) | **26.713 (16.724)** | **3.776 (2.938)** | **14.637 (8.634)** |
| | 提案手法 | **2.376 (4.046)** | **0.791 (0.539)** | **1.983 (2.378)** | 66.805 (58.556) | 7.718 (7.499) | 34.856 (29.614) |
| Case 6 | BFL | 2.012 (0.836) | 0.795 (0.594) | 1.947 (0.750) | **18.653 (10.311)** | **3.054 (2.080)** | **12.754 (6.289)** |
| | 提案手法 | **1.896 (2.635)** | **0.697 (0.596)** | **1.823 (1.625)** | 41.831 (37.682) | 5.844 (9.371) | 26.856 (22.608) |

## 5.2　実データへの適用

1 節で紹介したアレイ CGH データを用いて，提案手法とベイズ型連結 lasso の比較を行った．アレイ CGH データは R のパッケージ `cghFLasso` より利用可能であるものを用いた．このデータは 990 次元のベクトルとなっており，プロットすると Fig. 7 のとおりとなっている．

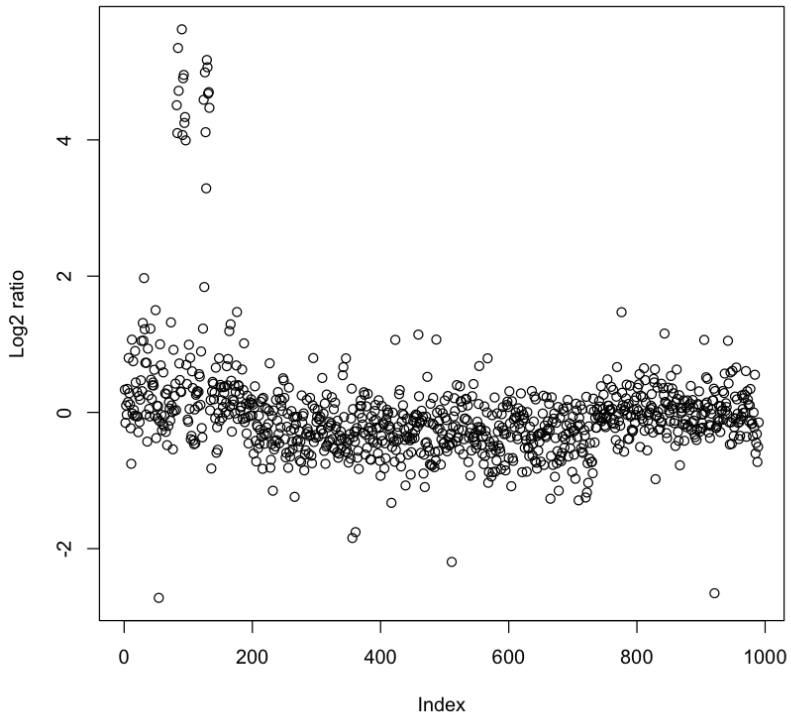



Fig. 7: アレイ CGH データのプロット．横軸は遺伝子の順序，縦軸は遺伝子コピー数の比の対数．

ここでは，提案手法とベイズ型連結 lasso のモデルとして以下を設定した．

$$\boldsymbol{y} = \boldsymbol{\beta} + \boldsymbol{\epsilon}. \tag{5.10}$$

これは (2.1) 式のグラム行列や (3.1) 式の計画行列を単位行列としたものに対応しており，アレイ CGH データの値が $\boldsymbol{y}$ に対応している．つまり，ここでは $n = 990$ となっていることに注意する．$\boldsymbol{\beta}$ によってアレイ CGH データの平滑化値を捉えることを試みる．

本解析でもモンテカルロ・シミュレーションのときと同様に，提案手法とベイズ型連結 lasso の MCMC の繰り返し回数は 5000 回で，そのうち 1000 回を burn-in として除外し 4000 回分をパラメータ推定に用いた．推定結果は，事後平均によって求めた．なお，計算時間が膨大になることを抑えるため，データは 10 次元ごとに抜き出した 99 次元のベクトルとして用いた．つまり，$n = 99$ である．

推定結果は Fig. 8 のとおりとなった．図中左方の大きく外れている部分について，提案手法では推定値とアレイ CGH データの値が非常に近くなっている．一方で，ベイズ型連結 lasso の推定値は提案手法の推定値と比べて 0 方向に縮小されていることがわかる．これは，提案手法においては事後確率質量のうちほとんどがこの部分の隣り合う回帰係数の差を非 0 と推定するところに分布しているが，ベイズ型連結 lasso の事後確率質量の多くがこの部分の隣り合う回帰係数の差を 0 と推定するように分布していることを示唆している．また，中央や右方部分では，提案手法の推定値はベイズ型連結 lasso の推定値と比べて隣り合う回帰係数の差を 0 と推定している部分が多くなっている．以上のことから，提案手法はベイズ型連結 lasso の隣り合う回帰係数の差を 0 と推定するという性質を保ちながら，非 0 と推定される回帰係数に対して過度な縮小は招かないことがわかる．

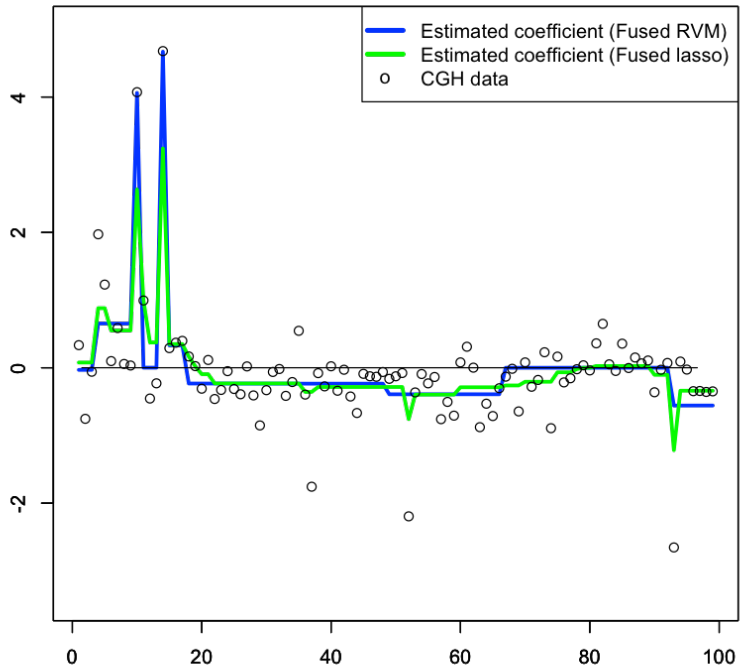



Fig. 8: 提案手法およびベイズ型連結 lasso による推定結果．青線が提案手法により推定された値，緑線がベイズ型連結 lasso により推定された値.

# 6　まとめと今後の課題

本論文では，回帰係数の併合を伴う関連ベクトルマシンを提案した．パラメータの推測はベイズ理論に基づき行い，ギブス・サンプリングによる推定アルゴリズムを構築した．モンテカルロ・シミュレーションや実データへの適用を通して，予測精度や推定精度の観点から提案手法の有効性を検証した．

今後の課題としては，計算時間削減のために第二種最尤法による推定を行うことや，分散が大きいデータに対しての分析性能の向上を図ることが考えられる．また，別の実データへの適用，さらなるシミュレーション実験を行うことで提案手法の特徴を分析することも検討する必要がある．

# 謝辞

本研究を進めるにあたり，主任指導教員の西山悠准教授，指導教員の宇都雅輝准教授，九州大学大学院数理学研究院の川野秀一教授には懇切丁寧な指導と多大なる助言を頂きましたことに深く感謝を申し上げます．また，同研究室の皆様，特に博士後期課程の岡崎彰良さんには研究を進めるにあたり多くのアドバイスを頂きました．深く御礼申し上げます．

# 付録

## A　ギブス・サンプリング

ギブス・サンプリングとは，確率分布 $\pi(\boldsymbol{x})$ に従う $\boldsymbol{x}$ のサンプリングを，$\boldsymbol{x}$ を $k$ 個のブロック $\boldsymbol{x} = (\boldsymbol{x}_1, \cdots, \boldsymbol{x}_k)$ に分割して行う方法である (古澄, 2015)．具体的には，各 $\boldsymbol{x}_i$ を完全条件付き分布と呼ばれる確率分布 $\pi(\boldsymbol{x}_i \mid \boldsymbol{x}_1, \cdots, \boldsymbol{x}_{i-1}, \boldsymbol{x}_{i+1}, \cdots, \boldsymbol{x}_k) = \pi(\boldsymbol{x}_i \mid \boldsymbol{x}_{-i})$ からのサンプリングを繰り返す．すなわち，Algorithm 7 を実行することで $\boldsymbol{x}$ のサンプリングを行う．

**Algorithm 7** ギブス・サンプリング

初期値 $\boldsymbol{x}^{(0)} = (\boldsymbol{x}_1^{(0)}, \cdots, \boldsymbol{x}_k^{(0)})$ を定める．
**for** $t = 0, 1, \cdots$ **do**
　$\boldsymbol{x}_1^{(t+1)}$ を $\pi(\boldsymbol{x}_1 \mid \boldsymbol{x}_2^{(t)}, \cdots, \boldsymbol{x}_k^{(t)})$ からサンプリングする．
　$\boldsymbol{x}_2^{(t+1)}$ を $\pi(\boldsymbol{x}_2 \mid \boldsymbol{x}_1^{(t+1)}, \boldsymbol{x}_3^{(t)}, \cdots, \boldsymbol{x}_k^{(t)})$ からサンプリングする．
　$\vdots$
　$\boldsymbol{x}_k^{(t+1)}$ を $\pi(\boldsymbol{x}_1 \mid \boldsymbol{x}_1^{(t+1)}, \cdots, \boldsymbol{x}_{k-1}^{(t+1)})$ からサンプリングする．

ギブス・サンプリングを実際に適用する場合，例えばモデルのパラメータが $a, b, \boldsymbol{c}$ であるときには，$\boldsymbol{x} = (a, b, \boldsymbol{c})$ とする．このとき，$\boldsymbol{x}_1 = a, \boldsymbol{x}_2 = b, \boldsymbol{x}_3 = \boldsymbol{c}$ としてギブス・サンプリングを構築することが多い．

ここで得られたサンプルは，多くの場合で $t \to \infty$ のときに $\pi(\boldsymbol{x})$ からのサンプリングとなっている．$t \to \infty$ のときに $\pi(\boldsymbol{x})$ からのサンプリングとなる詳細な条件については，古澄 (2015), Chan(1993), Roberts and Smith (1994) を参照されたい．

# B　混合法

混合法とは，ある確率密度関数 $\pi(x)$ が

$$\pi(x) = \int p(x \mid y) w(y) \mathrm{d}y$$

という階層表現で表されるとき，Algorithm 8 で $\pi(x)$ からサンプリングを行う方法である．また，$\pi(x)$ のように確率関数または確率密度関数の畳み込み積で表される確率分布を混合分布と呼ぶ (古澄, 2015).

**Algorithm 8** 混合法

$y$ を $w(y)$ からサンプリングする.
$y$ を $p(x \mid y)$ からサンプリングする.

# 参考文献


赤穂昭太郎 (2008). カーネル多変量解析 - 非線形データ解析の新しい展開. 岩波書店.

Berger, J. O. (1985). *Statistical Decision Theory and Bayesian Analysis (Second Ed.)*. Springer.

Bishop, M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Chan, K. S. (1993). Asymptotic behavior of the Gibbs sampler. *Journal of the American Statistical Association*, **88**, 320–326.

Efron, B., Hastie, T., Johnstone, I., Tibshirani, R. (2004). Least Angle Regression. *The Annals of Statistics*, **32**, 407–451

Fokoué, E., Sun, D., Goel, P. (2010). Fully Bayesian analysis of the relevance vector machine with an extended hierarchical prior structure. *Statistical Methodology*, **8**, 83–96.

Fu, W. J. (1998). Penalized regressions: The bridge versus the Lasso, *Journal of Computational and Graphical Statistics*, **7**, 397–416.

Gill, P. E., Murray, W., Saunders, M. A. (1997) Users guide for SQOPT 5.3: a Fortran package for large-scale linear and quadratic programming. *Technical Report NA 97-4*. University of California, San Diego.

古澄英雄 (2015). ベイズ計算統計学. 朝倉書店.

Kyung, M., Gill J., Ghosh, M., Casella, G. (2010). Penalized regression, standard errors, and Bayesian Lassos. *Bayesian Analysis*, **5**, 369–412.

Park, T., Casella, G. (2008). The Bayesian Lasso, *Journal of the American Statistical Association*, **103**, 681–686.

Roberts, G. O., Smith, A. F. M. (1994). Simple conditions for the convergence of the Gibbs sampler and Metropolis-Hastings algorithms. *Stochastic Processes and their Applications*, **49**, 207–216.

Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society*, **58**, 267–288.

Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., Knight, K. (2005). Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society Series B,* **67**, 91–108.

Tibshirani, R., Wang, P. (2008). Spatial smoothing and hot spot detection for CGH data using the fused lasso. *Biostatistics*, **8**, 18–29.

Tipping, M. E. (2001). Sparse Bayesian learning and the relevance vector machine. *Journal of Machine Learning Research*, **1**, 211–244

山本俊至 (2010). アレイ CGH 法によるデジタル染色体解析の進歩と臨床応用. 脳と発達, **42**, 138–143.

Watanabe, S. (2010). Asymptotic equivalence of Bayes cross validation and widely applicable information criterion in singular learning theory. *Journal of Machine Learning Research*, **11**, 3571–3594.