回帰係数の併合を伴う関連ベクトルマシンの構築

情報・ネットワーク工学専攻 情報数理工学プログラム 西山研究室
稲垣 良祐
学籍番号: 2131020

2023/02/07

研究背景

- 回帰係数が連続して同じ値を持つ部分，隣り合う回帰係数の差が大きく異なる値を持つ部分に分けることができるデータ（例：アレイ CGH データ，Tibshirani and Wang, 2008）.
- 解析手法としてベイズ型連結 lasso (Kyung et al., 2010)

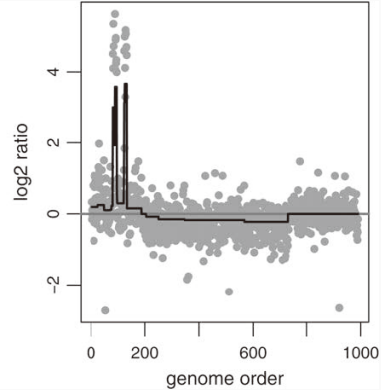


Fig. 1: アレイ CGH データの例 (Tibshirani and Wang, 2008)

提案手法の概要

- ベイズ型連結 lasso では，回帰係数 β の事前分布にラプラス分布を設定．

$$\pi(\boldsymbol{\beta} \mid \sigma^2, \lambda_1, \lambda_2) = \prod_{i=1}^{p} \mathrm{Laplace}(\beta_i \mid 0, 2\lambda_1/\sigma) \prod_{i=1}^{p-1} \mathrm{Laplace}(\beta_{i+1} - \beta_i \mid 0, 2\lambda_2/\sigma)$$
$$\propto \prod_{i=1}^{p} \exp\left(-\frac{\lambda_1}{\sigma}|\beta_i|\right) \prod_{i=1}^{p-1} \exp\left(-\frac{\lambda_2}{\sigma}|\beta_{i+1} - \beta_i|\right)$$

  $\Rightarrow$ 過剰に縮小推定

- 提案手法では，より裾の厚い分布を設定することで過剰な縮小を抑える．
  $\Rightarrow$ 関連ベクトルマシン (Tipping, 2001) の事前分布に着目．

既存手法: 関連ベクトルマシン (Tipping, 2001)

モデルは以下.

$$\boldsymbol{y} = \boldsymbol{\Phi}\boldsymbol{\beta} + \boldsymbol{\epsilon}.$$

$\boldsymbol{y} \in \mathbb{R}^n$:目的変数ベクトル

$\boldsymbol{\Phi} \in \mathbb{R}^{n \times n}$:グラム行列

$\boldsymbol{\beta} \in \mathbb{R}^n$:回帰係数ベクトル

$\boldsymbol{\epsilon} \in \mathbb{R}^n$:誤差ベクトル（正規分布にしたがう）

→回帰係数 $\boldsymbol{\beta}$ を推定

既存手法: 関連ベクトルマシン (Tipping, 2001)

RVM の尤度関数と事前分布は，

$$
\begin{aligned}
p(\boldsymbol{y}|\boldsymbol{\Phi}, \boldsymbol{\beta}, \sigma^2) &= \mathcal{N}_n(\boldsymbol{y}|\boldsymbol{\Phi}\boldsymbol{\beta}, \sigma^2 I_n) \\
\pi(\boldsymbol{\beta}|\boldsymbol{\alpha}) &= \prod_{i=1}^{n} \mathcal{N}(\beta_i|0, \alpha_i^{-1}) \\
\pi(\boldsymbol{\alpha}|a, b) &= \prod_{i=1}^{n} \mathrm{Gamma}(\alpha_i|a, b) \\
\pi(1/\sigma^2|c, d) &= \mathrm{Gamma}(1/\sigma^2|c, d).
\end{aligned}
$$

既存手法: 関連ベクトルマシン (Tipping, 2001)

回帰係数 $\boldsymbol{\beta}$ の事前分布は Student-t 分布に類似する分布になる.

$$
\begin{aligned}
\pi(\boldsymbol{\beta} \mid a, b) &= \int \pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) \pi(\boldsymbol{\alpha} \mid a, b) \mathrm{d}\boldsymbol{\alpha} \\
&= \frac{b^a \Gamma(a + 1/2)}{\sqrt{2\pi}\Gamma(a)} (b + \beta_i^2/2)^{-(a+1/2)} \\
&=: \mathrm{RVMprior}(\boldsymbol{\beta} \mid a, b).
\end{aligned}
$$

既存手法: 関連ベクトルマシン (Tipping, 2001)

RVMprior はパラメータ設定で尖った形になる．→ 0 への推定を促進．

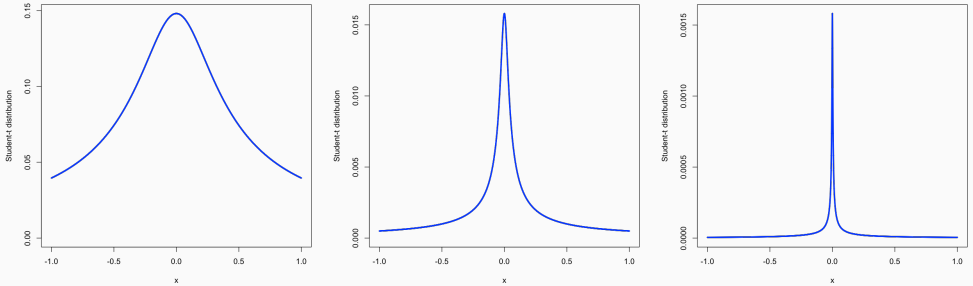


Fig. 2: 関連ベクトルマシンの回帰係数の事前分布．縦軸のスケールはそれぞれ異なるので注意されたい．(左) $a = 1, b = 1$ のとき．(中) $a = 1, b = 0.01$ のとき．(右) $a = 1, b = 0.0001$ のとき．

既存手法: RVM のギブスサンプリングによる推定 (Fokoué et al., 2010)

各パラメータの事後分布は，ギブスサンプリングにより計算できる．

RVM の推定アルゴリズム

1. $(a, b), (c, d)$ を決める
2. 以下を繰り返す
   1. $\boldsymbol{\beta}$ を $\mathcal{N}_n\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}, (\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi} + \boldsymbol{\Psi})^{-1}\right)$ からサンプリングする．
   2. σ^{-2} を $\mathrm{Gamma}\left(c_0 + \frac{n}{2}, d_0 + \frac{1}{2}\|\boldsymbol{\Phi}\boldsymbol{\beta} - \boldsymbol{y}\|\right)$ からサンプリングする．
   3. for $j = 1, 2, \cdots, n$
      1. α_j を $\mathrm{Gamma}\left(a + \frac{1}{2}, b + \frac{1}{2}w_j\right)$ からサンプリングする．
3. 必要なサンプル数が集まれば終了

既存手法: ベイズ型連結 lasso (Kyung et al., 2010)

Lasso (Tibshirani, 1996): L_1 正則化でスパース推定を行う.

連結 lasso (Tibshirani et al., 2005): 回帰係数の差にもスパース性を導入→同じ値が連続する構造を捉える.

連結 lasso をベイズモデルにしたものがベイズ型連結 lasso.

既存手法: ベイズ型連結 lasso (Kyung et al., 2010)

回帰係数 β の事前分布を以下のように設定（λ_1, λ_2 は正則化パラメータ）.

$$\pi(\boldsymbol{\beta}|\sigma^2, \lambda_1, \lambda_2) \propto \exp\left(-\frac{\lambda_1}{\sigma} \sum_{j=1}^{p} |\beta_j| - \frac{\lambda_2}{\sigma} \sum_{j=1}^{p-1} |\beta_{j+1} - \beta_j| \right)$$

既存手法: ベイズ型連結 lasso (Kyung et al., 2010)

事前分布のラプラス分布は 0 付近で尖った形→ 0 への推定を促進.

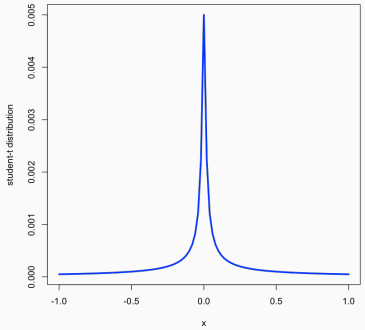


Fig. 3: ラプラス分布の確率密度関数

既存手法: ベイズ型連結 lasso (Kyung et al., 2010)

各パラメータの事後分布は，ギブスサンプリングにより計算できる．

ベイズ型連結 lasso の推定アルゴリズム

1. $(a, b), (c, d)$ を決める
2. 以下を繰り返す
   1. β を $\mathcal{N}_n\left(\left(X^T X + \Sigma_\beta^{-1}\right)^{-1} X^T y, \sigma^2\left(X^T X + \Sigma_\beta^{-1}\right)\right)$ からサンプリングする．
   2. $1/\tau_j^{-2}$ を inverted Gamma $\left(\frac{n-1+p}{2}, \frac{1}{2}(y - X\beta)^T(y - X\beta) + \frac{1}{2}\beta^T\Sigma^{-1}\right)\beta$ からサンプリングする．
   3. for $j = 1, 2, \cdots, n$
      1. $1/\tau_j^{-2}$ を inverse Gaussian $\left(\sqrt{\frac{\lambda_1^2\sigma^2}{\beta_j^2}}, \lambda_1^2\right)$ からサンプリングする．
      2. $1/\omega_j^{-2}$ を inverse Gaussian $\left(\sqrt{\frac{\lambda_2^2\sigma^2}{(\beta_{j+1} - \beta_j)^2}}, \lambda_2^2\right)$ からサンプリングする．
3. 必要なサンプル数が集まれば終了

提案手法：事前分布

提案手法では，隣り合った回帰係数の差も 0 に推定するような事前分布を設定する．

$$\pi(\boldsymbol{\beta} \mid \boldsymbol{\alpha}) = \prod_{i=1}^{n} \mathcal{N}(\beta_i \mid 0, (\lambda_1 \alpha_i)^{-1}) \prod_{i=1}^{n-1} \mathcal{N}(\beta_{i+1} - \beta_i | 0, (\lambda_2 \alpha_i')^{-1})$$
$$= \mathcal{N}_n(\boldsymbol{\beta} \mid 0, \boldsymbol{\Psi}) \quad \text{（一つの多変量正規分布で書ける）}$$

$$\boldsymbol{\Psi}^{-1} = \begin{bmatrix} \lambda_1\alpha_1 + \lambda_2\alpha_1' & -\lambda_2\alpha_1' & 0 & \cdots & \cdots & 0 \\ -\lambda_2\alpha_1' & \lambda_1\alpha_2 + \lambda_2\alpha_1' + \lambda_2\alpha_2' & -\lambda_2\alpha_2' & \ddots & \ddots & \vdots \\ 0 & -\lambda_2\alpha_2' & \lambda_1\alpha_3 + \lambda_2\alpha_2' + \lambda_2\alpha_3' & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & \lambda_1\alpha_{,i-1} + \lambda_2\alpha_{i-2}' + \lambda_2\alpha_{i-1}' & -\lambda_2\alpha_{i-1}' \\ 0 & \cdots & \cdots & 0 & -\lambda_2\alpha_{i-1}' & \lambda_1\alpha_i + \lambda_2\alpha_{i-1}' \end{bmatrix}$$

その他の事前分布については既存の RVM と同様.

$$
\begin{aligned}
p(\boldsymbol{y}|X, \boldsymbol{\beta}, \sigma^2) &= \mathcal{N}_n(\boldsymbol{y}|X\boldsymbol{\beta}, \sigma^2 I_n) \\
\pi(\boldsymbol{\alpha}|\eta, \nu) &= \prod_{i=1}^{p} \mathrm{Gamma}(\alpha_i|\eta/2, \nu/2) \\
\pi(\boldsymbol{\alpha}'|\eta', \nu') &= \prod_{i=1}^{p-1} \mathrm{Gamma}(\alpha_i'|\eta'/2, \nu'/2) \\
\pi(1/\sigma^2|a, b) &= \mathrm{Gamma}(1/\sigma^2|a, b).
\end{aligned}
$$

提案手法：事前分布

β_i と $\beta_{i+1} - \beta_i$ の事前分布に RVM の事前分布を設定．

$$1 - \int_{-0.5}^{0.5} \mathrm{RVMprior}(\beta \mid 0.1, 10^{-5}) \mathrm{d}\beta \simeq 0.344,$$

$$1 - \int_{-0.5}^{0.5} \mathrm{Laplace}(\beta \mid 0, 0.025) \mathrm{d}\beta \simeq 2.06 \times 10^{-9}.$$

$\Rightarrow$ RVMprior のほうが裾が厚い（過剰な縮小を起こさない）

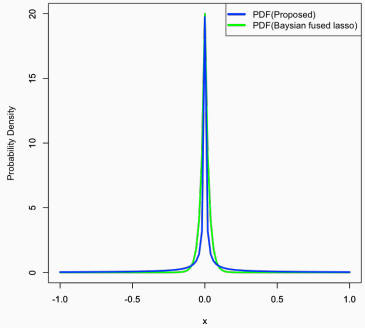


Fig. 4: 事前分布の被積分関数のプロット．青線が $\mathrm{RVMprior}(\beta \mid 0.1, 10^{-5})$，緑線が $\mathrm{Laplace}(\beta \mid 0, 0.025)$．

提案手法: 推定アルゴリズム

既存の RVM と同様，ギブスサンプリングにより推定できる．

提案手法の推定アルゴリズム

1. $\lambda_1, \lambda_2, a, b, \eta, \nu, \eta', \nu'$ を決める
2. 以下を繰り返す
   1. β を $\mathcal{N}_n\left(\sigma^{-2}(\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi}+\boldsymbol{\Psi})^{-1}\boldsymbol{\Phi}^T\boldsymbol{y}, (\sigma^{-2}\boldsymbol{\Phi}^T\boldsymbol{\Phi}+\boldsymbol{\Psi})^{-1}\right)$ からサンプリングする．
   2. σ^{-2} を $\mathrm{Gamma}\left(a+\frac{n}{2}, b+\frac{\|\boldsymbol{y}-\boldsymbol{\Phi}\boldsymbol{\beta}\|^2}{2}\right)$ からサンプリングする．
   3. for $j = 1, 2, \cdots, n$
      1. α_j を $\mathrm{Gamma}\left(\frac{\nu+1}{2}, \frac{1}{2}\left(\beta_i^2\lambda_1+\eta\right)\right)$ からサンプリングする．
      2. α_j' を $\mathrm{Gamma}\left(\frac{\nu'+1}{2}, \frac{1}{2}\left\{(\beta_j-\beta_{j+1})^2\lambda_2+\eta'\right\}\right)$ からサンプリングする．
3. 必要なサンプル数が集まれば終了

数値実験

以下の 2 つを行った.

- モンテカルロ・シミュレーション
- 実データへの適用 (アレイ CGH データ)

$$\boldsymbol{y} = X\boldsymbol{\beta}^* + \boldsymbol{\epsilon}$$

X : 行ベクトルが $\boldsymbol{x}_i \in \mathbb{R}^p (i = 1, \cdots, n)$ の $n \times p$ 計画行列

$\boldsymbol{x}_i \sim \mathcal{N}_p(0_p, \Sigma)$

$\boldsymbol{\beta}^*$: 真の回帰係数（p 次元）

$\boldsymbol{\epsilon}$: $\mathcal{N}_n(0_n, \sigma^2 \boldsymbol{I}_n)$

モンテカルロ・シミュレーション

シミュレーションの設定は以下の通り．

Case 1 $p = 20, n = 50$, $\beta^* = \beta_1^*$ or β_2^*, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

Case 2 $p = 20, n = 50$, $\beta^* = \beta_1^*$ or β_2^*, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

Case 3 $p = 50, n = 50$, $\beta^* = \beta_3^*$, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

Case 4 $p = 50, n = 50$, $\beta^* = \beta_3^*$, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

Case 5 $p = 50, n = 50$, $\beta^* = \beta_4^*$, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5 (i \neq j)$

Case 6 $p = 50, n = 50$, $\beta^* = \beta_4^*$, $\sigma = 0.5$ or 1.5, $\Sigma_{ii} = 1$, $\Sigma_{ij} = 0.5^{|i-j|} (i \neq j)$

ギブスサンプリングのサンプル数は 5000（最初の 1000 サンプルを burn-in として 4000 サンプルを使用）．

ベイズ型連結 lasso（BFL）と提案手法を比較．

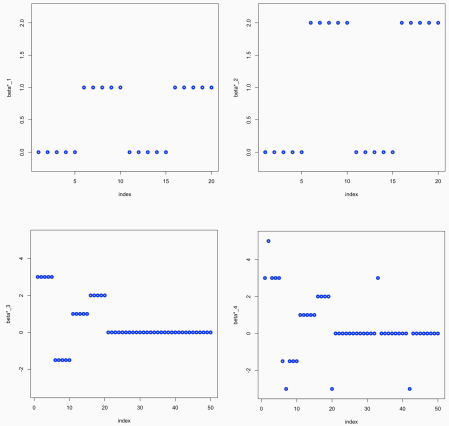


Fig. 5: 真の回帰係数のプロット．横軸は回帰係数の順番，縦軸は回帰係数の値．(左上) β_1^* のプロット．(右上) β_2^* のプロット．(左下) β_3^* のプロット．(右下) β_4^* のプロット．

モンテカルロ・シミュレーション

MSE，PSE，$\mathrm{MSE}_{\mathrm{diff}}$ の 3 種で評価（$\mathrm{MSE}_{\mathrm{diff}}$ は case 1〜4 のみ）．100 回シミュレーションを行った．

$$\mathrm{MSE} = \frac{1}{100}\sum_{i=1}^{100}(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})^T(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})$$

$$\mathrm{PSE} = \frac{1}{100}\sum_{i=1}^{100}(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})^T\Sigma(\boldsymbol{\beta}^* - \hat{\boldsymbol{\beta}}^{(i)})$$

$$\mathrm{MSE}_{\mathrm{diff}} = \frac{1}{100}\sum_{i=1}^{100}(\boldsymbol{\beta}^*_{\mathrm{diff}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{diff}})^T(\boldsymbol{\beta}^*_{\mathrm{diff}} - \hat{\boldsymbol{\beta}}^{(i)}_{\mathrm{diff}})$$

$\boldsymbol{\beta}_{\mathrm{diff}}$: 隣り合う真の回帰係数の差が非ゼロの部分のみを抜き出したもの

Table 1: Case 1 の結果．sd は標準偏差を表す．

		$\sigma = 0.5$			$\sigma = 1.5$		
		MSE (sd)	MSE_{diff} (sd)	PSE (sd)	MSE (sd)	MSE_{diff} (sd)	PSE (sd)
β_1^*	BFL	0.353 (0.215)	0.236 (0.162)	0.550 (0.445)	**1.044 (0.547)**	**0.547 (0.431)**	**0.770 (0.425)**
	提案手法	**0.200 (0.105)**	**0.067 (0.070)**	**0.248 (0.176)**	2.784 (1.406)	0.803 (0.704)	1.617 (0.761)
β_2^*	BFL	0.471 (0.335)	0.314 (0.245)	0.903 (1.143)	**1.273 (0.651)**	0.902 (0.664)	**1.288 (0.932)**
	提案手法	**0.460 (0.239)**	**0.152 (0.139)**	**0.648 (0.788)**	3.402 (1.256)	**0.887 (0.700)**	2.339 (0.974)

Table 2: Case 2 の結果．sd は標準偏差を表す．

		$\sigma = 0.5$			$\sigma = 1.5$		
		MSE (sd)	MSE_{diff} (sd)	PSE (sd)	MSE (sd)	MSE_{diff} (sd)	PSE (sd)
β_1^*	BFL	0.292 (0.191)	0.159 (0.112)	0.550 (0.387)	**0.489 (0.353)**	**0.429 (0.374)**	**0.630 (0.487)**
	提案手法	**0.176 (0.103)**	**0.067 (0.066)**	**0.183 (0.123)**	2.708 (1.528)	1.149 (1.028)	1.701 (0.920)
β_2^*	BFL	0.573 (0.302)	0.287 (0.189)	1.044 (0.604)	**0.705 (0.375)**	**0.537 (0.407)**	**0.977 (0.552)**
	提案手法	**0.498 (0.240)**	**0.174 (0.155)**	**0.603 (0.342)**	3.069 (1.200)	1.408 (1.088)	2.145 (0.772)

Table 3: Case 3 および Case 4 の結果．sd は標準偏差を表す．

		$\sigma = 0.5$			$\sigma = 1.5$		
		MSE (sd)	MSE_{diff} (sd)	PSE (sd)	MSE (sd)	MSE_{diff} (sd)	PSE (sd)
Case 3	BFL	1.552 (0.772)	0.522 (0.499)	1.883 (1.846)	**20.129 (11.358)**	**4.367 (3.583)**	**11.281 (5.992)**
	提案手法	**1.429 (0.928)**	**0.439 (0.407)**	**1.820 (1.831)**	34.598 (28.950)	6.773 (6.369)	18.592 (14.704)
Case 4	BFL	1.174 (0.443)	0.440 (0.450)	1.331 (0.643)	**15.213 (8.878)**	**4.085 (3.160)**	**10.715 (5.820)**
	提案手法	**1.083 (0.431)**	**0.386 (0.414)**	**1.195 (0.577)**	25.431 (20.031)	6.390 (5.987)	17.017 (13.965)

Table 4: Case 5 および Case 6 の結果．sd は標準偏差を表す．

		$\sigma = 0.5$		$\sigma = 1.5$	
		MSE (sd)	PSE (sd)	MSE (sd)	PSE (sd)
Case 5	BFL	2.629 (1.277)	2.122 (1.498)	**26.713 (16.724)**	**14.637 (8.634)**
	提案手法	**2.376 (4.046)**	**1.983 (2.378)**	66.805 (58.556)	34.856 (29.614)
Case 6	BFL	2.012 (0.836)	1.947 (0.750)	**18.653 (10.311)**	**12.754 (6.289)**
	提案手法	**1.896 (2.635)**	**1.823 (1.625)**	41.831 (37.682)	26.856 (22.608)

モンテカルロ・シミュレーション:考察

- 提案手法は分散が小さいときには評価指標の値が小さくなっている
  - 提案手法の目的が達成されている
- 分散が大きいときには評価指標の値が大きくなっている
  - 事前分布の裾の厚さが原因
  - 真の構造から離れたデータに大きく影響されている

実データへの適用 (アレイ CGH データ)

- アレイ CGH データ: 遺伝子のコピー数の増加，減少を示すデータ．
- 990 ゲノムのうち、10 ゲノムごとに抜き出して解析（$n = 99$）
- モデルは $\mathbf{y} = \beta + \epsilon$（$X$ に単位行列）．
- ベイズ型連結 lasso と提案手法を比較．
- ギブスサンプリングのサンプル数は 5000（最初の 1000 サンプルを burn-in として 4000 サンプルを使用）．
- ハイパーパラメータは $\lambda_1 = 1, \lambda_2 = 4, a = 1, b = 1/999, \nu = 1, \nu' = 10, \eta = 10^{-5}, \eta' = 10^{-5}$．

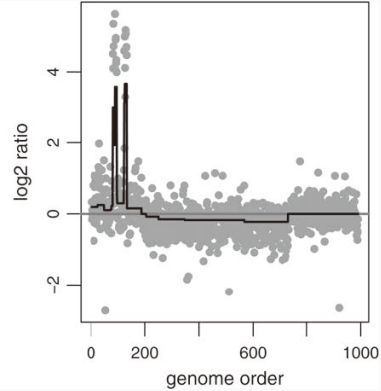


Fig. 6: アレイ CGH データのプロット (Tibshirani and Wang, 2008)

実データへの適用 (アレイ CGH データ)

- 青線：提案手法
- 緑線：ベイズ型連結 lasso
- 白丸：アレイ CGH データの点

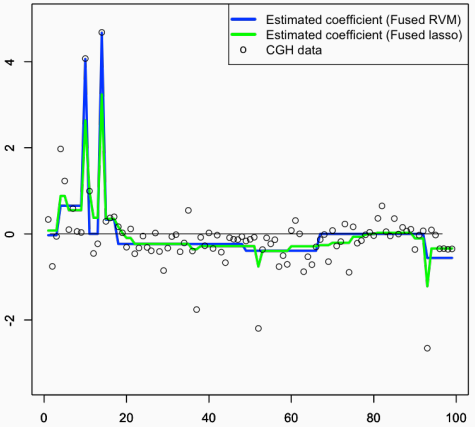


Fig. 7: 推定された回帰係数のプロット

実データへの適用 (アレイ CGH データ)

- 図中左方の大きく外れている部分
  - 提案手法：推定値とアレイ CGH データの値が非常に近い
  - ベイズ型連結 lasso：0 方向に縮小されている
  - ⇒ 過剰な縮小を招かない
- 中央や右方部分
  - 提案手法：ベイズ型連結 lasso と比べて隣り合う回帰係数の差を 0 と推定している部分が多い

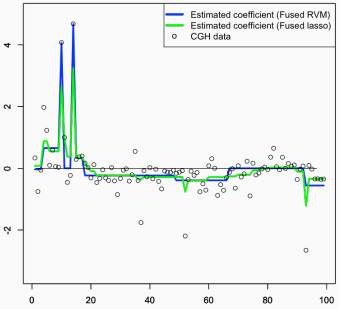


Fig. 7: 推定された回帰係数のプロット

まとめ・今後の展望

- 回帰係数の併合を伴う関連ベクトルマシンを提案した.
- 予測精度や推定精度の観点から提案手法の有効性を検証した.
- 今後の展望
  - 分散が大きいデータに対しての分析性能の向上
  - 第二種最尤法による推定
  - 他の実データを用いた解析やさらなるシミュレーションで特徴の分析

参考文献

- Fokoué, E., Sun, D., and Goel, P. (2010). Fully Bayesian analysis of the relevance vector machine with an extended hierarchical prior structure. *Statistical Methodology*, 83–96.
- Kyung, M., Gill J., Ghosh, M. and Casella, G. (2010). Penalized Regression, Standard Errors, and Bayesian Lassos. *Bayesian Analysis*, **5**, 369–412.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society*. **58**, 267–288.
- Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., Knight, K. (2005). Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society*. **67**, 91–108.
- Tibshirani, R. and Wang, P. (2008). Spatial smoothing and hot spot detection for CGH data using the fused lasso. *Biostatistics*, **8**, 18–29.
- Tipping, M. E. (2001). Sparse Bayesian Learning and the Relevance Vector Machine. *Journal of Machine Learning Reserch*, **1**, 211–244.