令和 6 年 2 月 5 日

情報・ネットワーク工学専攻　修士論文発表会予稿

スパース主成分分析に対する Knockoff 法を用いた偽発見率制御

情報数理工学プログラム　2231136　植野真臣研究室　星野菜南子

1　はじめに

スパース主成分分析 (Zou and Xue, 2018) は，互いに相関のある多次元データに対して，データの解釈に不要な主成分負荷量の値をちょうど 0 に推定し，重要な主成分負荷量のみを選択する手法である．選択される主成分負荷量の個数は，調整パラメータの値によって変化する．そのため，調整パラメータの値の選択がそのモデリング過程において本質となる．

Barber and Candès (2015) は lasso (Tibshirani, 1996) に関して，偽発見率 (False Discovery Rate: FDR) (Benjamini and Hochberg, 1995) を設定値以下に抑えながら適切な正則化パラメータを決定する Knockoff 法を提案した．しかし，Knockoff 法の主成分分析への拡張はいまだ発展途上である．

本発表では，Knockoff 法をスパース主成分分析に拡張することで，スパース主成分分析の調整パラメータを選択する手法を提案する．Knockoff 法を実行する際に必要な Knockoff 変数の作成については，標本相関が t 分布にしたがう条件 (Fisher, 1915) を利用する．数値実験を通して提案手法の有効性を検証する．

2　スパース主成分分析

いま，n 個の中心化された p 次元データ $\{\boldsymbol{x}_i; i = 1, \ldots, n\}$ が得られているとする．SCoTLASS (Jolliffe et al., 2003) による第 k 主成分 $(k = 1, \ldots, p)$ の主成分負荷量 $\boldsymbol{v}_k = (v_{k1}, \ldots, v_{kp})^T$ は，次の最大化問題

$$\arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T S \boldsymbol{v}_k \text{ subject to } \|\boldsymbol{v}_k\|_2 = 1, \quad \boldsymbol{v}_j^T \boldsymbol{v}_k = 0,\ \|\boldsymbol{v}_k\|_1 \le c,\ j = 1, \ldots, k-1,$$

により得られる．ここで，$S = \frac{1}{n}\sum_{i=1}^n \boldsymbol{x}_i \boldsymbol{x}_i^T$ は標本分散共分散行列，c $(1 \le c \le \sqrt{p})$ は調整パラメータである．制約に L_1 ノルムを加えることで，多くの主成分負荷量の値が 0 とスパース推定される．

3　多重比較法

FDR は，多重比較法における評価基準の一つである．いま，第 k 主成分の主成分負荷量 $\boldsymbol{v}_k$ に関する帰無仮説 $H_{0,kj}$ と対立仮説 $H_{1,kj}$ を

$$H_{0,kj} : v_{kj} = 0 \quad \text{vs.} \quad H_{1,kj} : v_{kj} \neq 0, \quad j = 1, \ldots, p,$$

と設定する．推定した主成分負荷量 $\hat{\boldsymbol{v}}_k$ を棄却した個数を $R(c)$ とし，$R(c)$ のうち帰無仮説が正しい個数を $V(c)$，対立仮説が正しい個数を $S(c)$ とする．$R(c)$ における $V(c)$ の割合に対する期待値をとると，FDR が算出される．また，検出力は FDR と共に用いる場合が多い評価基準である．対立仮説が正しい個数を B とおくと，検出力は B における $S(c)$ の割合である．

4　提案手法

lasso に対して FDR を設定値以下に抑える正則化パラメータの決定方法を Knockoff 法と呼ぶ．本発表では，Knockoff 法をスパース主成分分析に拡張し，スパース主成分分析内に含まれる調整パラメータの選択方法を提案する．

第 k 主成分における調整パラメータの導出手順を次節により順に説明する．

4.1　Knockoff 変数 $\tilde{\boldsymbol{x}}_i$ の作成

オリジナル行列 $X = (\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n)^T$ の標本相関行列 $\{C_{ij},\ i, j = 1, \ldots, p\}$ に関して，母集団の相関係数が 0 という帰無仮説の下では，

$$R_{ij} = \frac{C_{ij}}{\sqrt{(1 - C_{ij}^2)/(n-2)}},\ i, j = 1, \ldots, p,$$

が自由度 $n-2$ の t 分布にしたがう (Fisher, 1915)．これより，Knockoff 相関行列を

$$\tilde{C}_{ij} = \begin{cases} 1, & i = j, \\ \frac{R_{ij}}{\sqrt{n-2+R_{ij}^2}}, & i \neq j, \end{cases} \quad i, j = 1, \ldots, p, \tag{4.1}$$

と定める．(4.1) 式から，p 次元 Knockoff 変数 $\{\tilde{\boldsymbol{x}}_i; i = 1, \ldots, n\}$ を乱数を用いて発生させ，Knockoff 行列 $\tilde{X} = (\tilde{\boldsymbol{x}}_1, \ldots, \tilde{\boldsymbol{x}}_n)^T$ にまとめる．

4.2　統計量 $\boldsymbol{W}_k$ の導出

X と $\tilde{X}$ を結合した $n \times 2p$ 行列に対し，SCoTLASS の近似解を求める SPC (Witten et al., 2009)

$$\hat{\boldsymbol{v}}_k(c) = \arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T [X, \tilde{X}]^T [X, \tilde{X}] \boldsymbol{v}_k \quad \text{subject to } \|\boldsymbol{v}_k\|_2^2 \le 1,\ \|\boldsymbol{v}_k\|_1 \le c,$$

を実行し，統計量 W_{kj} を次式のように計算する．

$$W_{kj} = Z_{kj} \wedge \tilde{Z}_{kj} \cdot \mathrm{sign}(Z_{kj} - \tilde{Z}_{kj}),\ j = 1, \ldots, p.$$

ここで，Z_{kj}，$\tilde{Z}_{kj}$ はそれぞれ $Z_{kj} = \inf\{c : \hat{v}_{kj}(c) \neq 0\}$，$\tilde{Z}_{kj} = \inf\{c : \hat{v}_{k(j+p)}(c) \neq 0\}$ であり，$\mathrm{sign}(\cdot)$ は符号関数を表す．また，$a \wedge b = \min\{a, b\}$ である．W_{kj} は X と $\tilde{X}$ を比較した際に，主成分への寄与がより大きい主成分負荷量の調整パラメータの値を選択し，それがどちらの場合かを符号で区別している．

4.3 しきい値 T_k の導出

$\boldsymbol{W}_k$ を用いた次式

$$T_k = \max\left\{ t \in \mathcal{W}_k : \frac{1 + \#\{j : -t \le W_{kj} < 0\}}{\#\{j : 0 < W_j \le t\} \vee 1} \le q \right\},$$

により，しきい値 T_k を計算する．ここで，$\mathcal{W}_k$ は $\{|W_{kj}| : j = 1, \ldots, p\}$ から 0 を除いた集合であり，q $(0 \le q \le 1)$ は事前に設定した FDR 制御値である．

4.4 変数の選択，および調整パラメータ c の導出

$0 < W_{kj} \le T_k$ を満たす添字番号集合が，FDR 制御において選択された主成分負荷量の変数番号集合であるため，調整パラメータの範囲が求まる．

5 数値実験

人工データ $X = (\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n)^T$ を，$\boldsymbol{x}_i \sim N(\boldsymbol{0}, \Sigma)$ に従って発生させた．ここで，分散共分散行列は $\Sigma = P\Lambda P^T$ とした．$P = (\boldsymbol{p}_1, \ldots, \boldsymbol{p}_{15})^T$ は固有ベクトルであり，$\dot{\boldsymbol{p}}_1, \ldots, \dot{\boldsymbol{p}}_{15}$ を以下のように設定したあと，直交化させた．

$$\begin{aligned}
\dot{\boldsymbol{p}}_1 &= (1,1,0,1,0,1,1,0,0,0,0,0,0,0,0)^T, \\
\dot{\boldsymbol{p}}_2 &= (0,0,0,0,0,0,0,1,1,1,0,1,0,1,0)^T, \\
\dot{\boldsymbol{p}}_3 &= (0,0,0,0,0,0,0,0,0,0,0,1,0,1,0,1)^T, \\
\dot{\boldsymbol{p}}_4, &\ldots, \dot{\boldsymbol{p}}_{15} \sim N(2,1).
\end{aligned}$$

Λ は固有値を対角成分に持つ行列

$$\Lambda = \mathrm{diag}(A, 5, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1),$$

とし，A は $\{20, 50\}$ と設定した．サンプルサイズ n は $\{200, 500\}$ を考え，FDR 制御値 q は 0.2 とした．

次に，Knockoff 法を 1 回実行して fdp を算出した．しかし，Knockoff 変数は乱数を用いて作成するため，fdp を算出する過程を 100 回繰り返すことで得られる fdp の期待値を FDP とした．この操作を 100 回実行し，FDR を計算した．以上の操作を第 1 主成分から第 3 主成分まで実行し，その結果を表 1 から表 3 にまとめた．括弧には標準偏差を記載した．

第 1 主成分の FDR は，すべての設定において FDR 制御値である 0.2 を下回ったため，FDR 制御が可能であることが分かる．しかし，第 2 主成分の $\{A = 50, n = 500\}$ の設定と第 3 主成分の FDR は 0.2 を上回った．これは，固有値の値が小さく，また固有値の差が小さいため，FDR 制御が難しいことが考えられる．また，検出力に関して，第 1 主成分と第 2 主成分の検出力は 1 であったが，第 3 主成分では値が小さくなった．こちらも固有値の値の大きさが関係していると考えられる．一方，既存手法の BH 法は，すべての設定で 0.2 を大きく上回ったため，FDR 制御が不可能であることが分かる．

Table1: 第 1 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.1807 (0.06727)	0.1735 (0.05748)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.3225 (0.2084)	0.3518 (0.1906)
		検出力	0.984 (0.1160)	1 (0)
$n = 500$	提案手法	FDR	0.1780 (0.06173)	0.1871 (0.06809)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.3198 (0.1847)	0.2986 (0.1792)
		検出力	1 (0)	1 (0)

Table2: 第 2 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.1978 (0.05684)	0.1932 (0.06882)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.4578 (0.1475)	0.4921 (0.1194)
		検出力	0.996 (0.02814)	1 (0)
$n = 500$	提案手法	FDR	0.1982 (0.06126)	0.2061 (0.06083)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.5095 (0.1062)	0.4782 (0.1138)
		検出力	1 (0)	1 (0)

Table3: 第 3 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.5583 (0.1170)	0.5769 (0.1036)
		検出力	0.6598 (0.1583)	0.6778 (0.1339)
	BH 法	FDR	0.4612 (0.1461)	0.5392 (0.1105)
		検出力	0.976 (0.07670)	0.9820 (0.07018)
$n = 500$	提案手法	FDR	0.2155 (0.1085)	0.2074 (0.08062)
		検出力	0.9822 (0.05408)	0.9902 (0.03526)
	BH 法	FDR	0.5709 (0.07207)	0.5813 (0.07957)
		検出力	1 (0)	1 (0)

6 まとめ

本発表では，Knockoff 法をスパース主成分分析に拡張し，スパース主成分分析に含まれる調整パラメータの選択方法を提案した．数値実験では，固有値の値が大きいことや他の主成分の固有値との差が大きい場合に，提案手法が FDR を制御できることが分かった．

参考文献

Barber, R. F. and Candès, E. (2015). Controlling the false discovery rate via knockoffs. *Ann. Stat.*, **43**(5), 2055–2085.

Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *J. R. Stat. Soc., B*, **57**(1), 289–300.

Fisher, R. (1915). Frequency distribution of the values of the correlation coeffcient in samples from an indenitely large population. *Biometrika*, **10**(4), 507–521.

Jolliffe, I. T., Trendafilov, N. T., and Uddin, M. (2003). A modified principal component technique based on the lasso. *J. Comput. Graph. Stat.*, **12**(13), 531–547.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *J. R. Stat. Soc., B*, **58**(1), 267–288.

Witten, D. M., Tibshirani, R., and Hastie, T. (2009). A penalized matrix decomposition, with applications to sparse principal components and canonical correlation analysis. *Biostatistics*, **10**(3), 515–534.

Zou, H. and Xue, L. (2018). A selective overview of sparse principal component analysis. *Proc. IEEE*, **106**(8), 1311–1320.