修 士 論 文 の 和 文 要 旨

研究科・専攻	大学院　情報理工学研究科　　情報・ネットワーク工学専攻　博士前期課程		
氏　　名	星野菜南子	学籍番号	2231136
論 文 題 目	スパース主成分分析に対する Knockoff 法を用いた偽発見率制御		

要　旨

近年，観測された大規模データにおける解析技術の発展が著しく，多方面分野での実用が期待されている．主成分分析 (principal component analysis; PCA) (Jollife, 2002) はその解析技術の一つであり，観測された互いに相関のある多次元データに対して，データの持つ情報をできるだけ損なわずに，もとの変数をその線型結合により新たな変数へと縮約する手法である．もとの変数を線形結合する際の重みを主成分負荷量といい，その値の大小により重要な変数が選択される．

スパース主成分分析 (Zou and Xue, 2018) は，データの解釈に不要な主成分負荷量の値をちょうど0にスパース推定する手法であり，通常の主成分分析よりもデータの解釈が容易となる．また，スパース主成分分析は調整パラメータを含んでおり，主成分負荷量の選択度合いと推定精度の2点の釣り合いを調節する働きを持つ．したがって，調整パラメータの決定は重要であり，その決定には，調整パラメータの値と推定精度の関係を測る評価指標が必要である．

評価指標の一つに偽発見率 (False Discovery Rate: FDR) (Benjamini and Hochberg, 1995) がある．Barber and Candes (2015) は線形回帰モデルの推定方法の一つである lasso (Tibshirani, 1996) に関して，「回帰係数の値が0である」という帰無仮説のもと，FDRをあらかじめ設定した値以下に抑えながら適切な正則化パラメータの値を決定するKnockoff法を提案した．Knockoff法は交換可能性を成立させることでFDR制御を可能とする手法であり，これを満たすような条件として説明変数を模倣した Knockoff 変数の作成が必要となる．しかし，Knockoff法の主成分分析への拡張は発展途上である．

本論文では，Knockoff法をスパース主成分分析に拡張することで，FDR制御の観点からスパース主成分分析内の調整パラメータを選択する手法を提案する．交換可能性を成立させるために必要なKnockoff 変数については，標本相関がt分布にしたがう条件(Fisher, 1915) を利用することにより作成する．数値実験の結果，固有値の値が大きく他の主成分の固有値との差が大きい数値設定では，提案手法は既存手法よりも正確にFDR制御を行うことができた．

令和五年度　修士論文

スパース主成分分析に対する Knockoff 法を用いた偽発見率制御

電気通信大学 大学院情報理工学研究科
情報・ネットワーク工学専攻 情報数理工学プログラム
学籍番号 2231136
星野 菜南子

主任指導教員 植野真臣 教授
指導教員 宇都雅輝 准教授

提出年月日　2024 年 1 月 28 日

目 次

1 はじめに **4**

2 主成分分析 **6**

2.1 主成分分析の構成 6

2.2 スパース主成分分析 7

2.2.1 SCoTLASS 7

2.2.2 アルゴリズム 8

3 多重比較法 **11**

3.1 偽発見率 11

3.2 検出力 12

4 線形回帰モデルにおける Knockoff 法による FDR 制御 **14**

4.1 lasso 14

4.2 lasso に対する FDR 16

4.3 Knockoff 法による正則化パラメータの決定 16

4.3.1 Knockoff 変数 $\tilde{\boldsymbol{x}}_j$ の作成 17

4.3.2 統計量 $\boldsymbol{W}$ の導出 18

4.3.3 しきい値 T の導出 19

4.3.4 変数の選択，および正則化パラメータ λ の導出 20

5 提案手法 **21**

5.1 Knockoff 変数 $\tilde{\boldsymbol{x}}_j$ の作成 21

5.2 統計量 $\boldsymbol{W}_k$ の導出 22

5.3 しきい値 T_k の導出 23

5.4 変数の選択，および調整パラメータ c の導出 27

6 数値実験 **28**

6.1 実験設定 28

6.2 BH 法 29

6.3 実験結果 29

7　まとめ **32**

付録 **34**

A　(2.2) 式の $\boldsymbol{v}_k^T S \boldsymbol{v}_k$ の導出 **34**

B　線形回帰モデルにおける Knockoff 法の証明 **34**

i　交換可能性の証明 34

ii　(4.22) 式による FDR 制御の証明 37

C　ガウシアングラフィカルモデルにおける Knockoff 法の交換可能性 **38**

i　Knockoff 手順 38

ii　交換可能性の証明 42

D　モンテカルロ p 値の計算方法 **43**

1　はじめに

近年，観測された大規模データにおける解析技術の発展が著しく，多方面分野での実用が期待されている．主成分分析 (principal component analysis; PCA) (Jolliffe, 2002) はその解析技術の一つであり，観測された互いに相関のある多次元データを，データの持つ情報をできるだけ損なわずに，もとの変数をその線型結合により新たな変数へと縮約する手法である．このとき，もとの変数を線形結合する際の重みを主成分負荷量といい，その重みからなるベクトルを主成分という．解釈が困難な多次元のデータを少数の主成分に縮約することができるため，主成分分析は主にデータを要約する目的で使用される．主成分負荷量の値が大きいほど，対応するもとの変数は主成分に強く寄与すると考えられることから，主成分負荷量の値の大小により，主成分に寄与する重要な変数を解釈することができる．しかし，データに含まれる変数の次元が大きくなるにつれ，検討すべき主成分負荷量の個数が多くなるため，適切な解釈が難しくなる．

スパース主成分分析 (Zou and Xue, 2018) は，変数選択とパラメータ推定を同時に行う，スパース推定という分野に属される手法である．これはデータの解釈に不要な主成分負荷量の値をちょうど 0 に推定し，重要な主成分負荷量を選択するため，通常の主成分分析よりもデータの解釈が容易となるという特徴がある．また，スパース主成分分析は調整パラメータを含んでおり，このパラメータは，主成分負荷量の選択度合いと推定精度の 2 点の釣り合いを調節する働きを持つ．したがって，調整パラメータの決定は重要であり，その決定には，調整パラメータの値と推定精度の関係を測る評価指標が必要である．

評価指標の一つに偽発見率 (False Discovery Rate: FDR) (Benjamini and Hochberg, 1995) がある．FDR は複数の検定を同時に行う際に，多重比較法により第一種の過誤を制御するための指標として導入された．FDR を制御することで棄却域の範囲を調整し，検定の多重性を緩和する．FDR を用いた多重比較法には，BH 法 (Benjamini and Hochberg, 1995) や BY 法 (Benjamini and Yekutieli, 2001) など数多くある．

一方，線形回帰モデルの推定方法の一つである lasso (Tibshirani, 1996) において，多重比較法の視点を持って回帰係数を推定したい場合は，「回帰係数の値が 0 である」という帰無仮説を回帰係数の次元の数だけ用意する．Barber and Candès (2015) は lasso を多重比較法として捉え，FDR をあらかじめ設定した値以下に抑えるという

意味で，適切な正則化パラメータの値を決定する Knockoff 法を提案した．Knockoff 法は，交換可能性という性質を成立させることにより FDR 制御を可能とする手法であり，これを満たすような条件として説明変数を模倣した Knockoff 変数の作成が必要となる．Knockoff 法は lasso だけでなく，隠れマルコフモデル (Sesia et al., 2019) や深層生成モデル (Romano et al., 2019) など様々な手法に拡張されているが，主成分分析への拡張はいまだ発展途上である．

本論文では，Knockoff 法をスパース主成分分析に拡張することで，FDR 制御の観点からスパース主成分分析内の調整パラメータを選択する手法を提案する．スパース主成分分析は主成分負荷量が従う帰無分布が明らかでないことや，帰無仮説が互いに負の相関を持つ場合があるため，BH 法や BY 法を用いて FDR 制御を実行することは難しい．しかし，Knockoff 法では帰無分布が既知である必要はなく，また，帰無仮説に条件を設ける必要はないため，これらの問題を解決する．交換可能性を成立させるために必要な Knockoff 変数については，標本相関が t 分布にしたがう条件 (Fisher, 1915) を利用することにより作成する．また，スパース主成分分析を実際に計算する際は，SCoTLASS (Jolliffe et al., 2003) の近似解を効率的に求める SPC (Witten et al., 2009) を用いる．

本論文の構成は次の通りである．第 2 節では主成分分析について述べた後，スパース主成分分析の一種である SCoTLASS について説明し，その計算アルゴリズムである SPC を紹介する．第 3 節では FDR と検出力について述べ，第 4 節では線形回帰モデルにおける Knockoff 法について説明する．第 5 節では提案手法であるスパース主成分分析における Knockoff 法について述べたあと，続く第 6 節では提案手法の有効性を数値実験を通して検証する．最後に，第 7 節では本論文のまとめと今後の課題を述べる．

2　主成分分析

主成分分析 (principal component analysis; PCA) (Jolliffe, 2002) は，観測された互いに相関のある多次元データに関して，データの持つ情報をできるだけ失わずに，もとの変数の線形結合で表される新たな変数へ要約する手法である．観測データの次元数より少ない変数へ要約することにより，次元の縮小や重要な特徴量の抽出といった，複雑なデータ構造を視覚的に捉えることも可能である．

本節では主成分分析の構成方法について説明したあとに，主成分分析にスパース性を持たせたスパース主成分分析について述べる．最後にスパース主成分分析の一種である SCoTLASS に着目し，その概要と計算アルゴリズムを述べる．

2.1　主成分分析の構成

いま，n 個の p 次元データ $\{\boldsymbol{x}_i; i = 1, \ldots, n\}$ が得られているとする．ここで，$\boldsymbol{x}_i = (x_{i1}, \ldots, x_{ip})^T$ であり，あらかじめ $\boldsymbol{x}_i$ は中心化されているとする．これらの得られた観測データを，次の線型結合

$$y_{ki} = \boldsymbol{v}_k^T \boldsymbol{x}_i \quad i = 1, \ldots, n,\ k = 1, \ldots, p, \tag{2.1}$$

で表した p 本の直線へ射影することを考える．ここで，$y_{k1}, \ldots, y_{kn}$ は主成分得点，$\boldsymbol{v}_k = (v_{k1}, \ldots, v_{kp})^T$ は主成分負荷量である．また，主成分負荷量の重みからなる直線を主成分という．主成分得点のばらつきが大きくなるように主成分を射影すると，データ間の分離がより明白になる．すなわち，データの情報量を多く持ちながら損失を最小限に抑える．したがって，主成分得点の分散が最大となるような主成分を求めることができれば，データ情報の本質を効率的に捉えることができる．ここで，(2.1) 式の分散が k $(1 \leq k \leq p)$ 番目に大きいときの主成分を第 k 主成分と呼ぶ．例えば，(2.1) 式の分散が最大となるときの主成分は第 1 主成分，2 番目に大きいときの主成分は第 2 主成分である．

主成分を特定するためには主成分負荷量 $\boldsymbol{v}_k$ を推定する必要がある．第 k 主成分の主成分負荷量は，次の最大化問題

$$\arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T S \boldsymbol{v}_k \quad \text{subject to } \|\boldsymbol{v}_k\|_2 = 1,\ \boldsymbol{v}_j^T \boldsymbol{v}_k = 0,\ j = 1, \ldots, k-1, \tag{2.2}$$

により得られる．ここで，$S = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{x}_i \boldsymbol{x}_i^T$ は標本分散共分散行列である．$\boldsymbol{v}_k^T S \boldsymbol{v}_k$ は (2.1) 式の分散を意味するが，その導出方法については付録 A を参照されたい．また，$\|\boldsymbol{v}_k\|_2 = 1$ は $\|\boldsymbol{v}_k\|_2 \to +\infty$ により $\boldsymbol{v}_k^T S \boldsymbol{v}_k$ が発散することを防ぐ制約条件である．また，$\boldsymbol{v}_j^T \boldsymbol{v}_k = 0$ の制約条件は，第 k 主成分と第 j $(< k)$ 主成分が直交することを意味する．これは第 j 成分まで得られた情報は第 k 主成分では取り出されず，第 j 主成分まで得られなかった情報は第 k 主成分で補うことができるため，異なる主成分同士で重複なく情報を得ることができる．

2.2 スパース主成分分析

高次元データに主成分分析を適用したとき，個々の主成分を構成する主成分負荷量の個数が多くなるため，主成分の特徴を明確に示すことが難しい．この問題を解決する方法として，スパース主成分分析 (Zou and Xue, 2018) がある．スパース主成分分析は SPCA (Zou et al., 2006) など，様々な手法が提案されているが，本論文では SCoTLASS (Simplified Component Technique LASSO) (Jolliffe et al., 2003) を紹介する．

2.2.1 SCoTLASS

SCoTLASS (Jolliffe et al., 2003) による第 k 主成分の主成分負荷量は，次の最大化問題

$$\arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T S \boldsymbol{v}_k \quad \text{subject to } \|\boldsymbol{v}_k\|_2 = 1,\ \boldsymbol{v}_j^T \boldsymbol{v}_k = 0,\ \|\boldsymbol{v}_k\|_1 \le c,\ j = 1, \ldots, k-1, \quad (2.3)$$

により得られる．ここで，c $(1 \le c \le \sqrt{p})$ は調整パラメータである．(2.2) 式の制約に L_1 ノルムを加えることで，多くの主成分負荷量の値が 0 と推定されるスパース性を持つ．

調整パラメータ c の値を大きくすると 0 と推定される主成分負荷量の個数が少なくなり，c の値を小さくすると 0 と推定される主成分負荷量の個数が多くなる．さらに，主成分負荷量は値が大きいほど主成分に強く寄与することから，主成分負荷量の構造を疎にさせることで重要な主成分負荷量だけを取り出すことができる．したがって，通常の主成分分析よりもデータの解釈が容易になることが期待される．

2.2.2 アルゴリズム

Jolliffe et al. (2003) は SCoTLASS の解を導出する手法として，射影勾配アルゴリズム (Trendafilov and Jolliffe, 2006) を用いたが，射影勾配アルゴリズムは次元が大きいほど計算速度が遅くなることが知られている (Jolliffe et al., 2003; Zou et al., 2006)．そこで，本論文では SCoTLASS の近似解を効率的に求める SPC (sparse principal components) (Witten et al., 2009) を紹介する．SPC は，特異値分解の特異値ベクトルにスパース性を導入した PMD (penalized matrix decomposition) を拡張することにより得られる手法である．

まず，PMD について説明する．第 l 因子 ($l = 1, \ldots, p$) に関して，PMD は次式の最大化問題

$$\arg\max_{\boldsymbol{u}_l, \boldsymbol{v}_l} \boldsymbol{u}_l^T X \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{u}_l\|_2^2 \leq 1,\ \|\boldsymbol{v}_l\|_2^2 \leq 1,\ P_1(\boldsymbol{u}_l) \leq c_1,\ P_2(\boldsymbol{v}_l) \leq c_2, \tag{2.4}$$

により定式化される．ここで，$\boldsymbol{u}_l$ は行列 X の左特異値ベクトル，$\boldsymbol{v}_l$ は右特異値ベクトル，c_1 (> 0)，c_2 (> 0) は調整パラメータである．$P_1(\cdot)$，$P_2(\cdot)$ は正則化項であり，これらに lasso (Tibshirani, 1996) や fused lasso (Tibshirani et al., 2005) を用いることで，特異値ベクトルにスパース性を持たせることができる．正則化項については第 4 章で述べる．

いま，$\boldsymbol{v}_l$ を固定すると，(2.4) 式は次の最大化問題に書きかえられる．

$$\arg\max_{\boldsymbol{u}_l} \boldsymbol{u}_l^T X \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{u}_l\|_2^2 \leq 1,\ P_1(\boldsymbol{u}_l) \leq c_1. \tag{2.5}$$

(2.5) 式は Karush-Kuhn-Tucker 条件を満たすことが知られているため (Boyd and Lieven, 2004)，(2.5) 式は (2.4) 式の $\boldsymbol{u}_l$ を導出することができる．$\boldsymbol{u}_l$ を固定した場合も同様である．したがって，$\boldsymbol{v}_l$ を固定した場合の最大化問題 (2.5) と $\boldsymbol{u}_l$ を固定した場合の最大化問題を，収束条件を満たすまで反復すれば，第 l 因子における PMD の解を求めることができる．さらに，PMD を各因子ごとに計算すれば複数の因子に関しても解が求まる．PMD を計算するアルゴリズムは Algorithm 1 のようにまとめることができる．

Algorithm 1 L 個 $(1 \leq L \leq p)$ の因子における PMD の計算アルゴリズム

1: $X^1 = X$ とする．
2: **for all** $l = 1, \ldots, L$ **do**
3: $\|\boldsymbol{v}_l\|_2^2 = 1$ を満たすような $\boldsymbol{v}_l$ の初期値を設定する．
4: $\boldsymbol{u}_l$ を次のように更新する．
$$\boldsymbol{u}_l \leftarrow \arg\max_{\boldsymbol{u}_l} \boldsymbol{u}_l^T X^l \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{u}_l\|_2^2 \leq 1,\ P_1(\boldsymbol{u}_l) \leq c_1.$$
5: $\boldsymbol{v}_l$ を次のように更新する．
$$\boldsymbol{v}_l \leftarrow \arg\max_{\boldsymbol{v}_l} \boldsymbol{u}_l^T X^l \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{v}_l\|_2^2 \leq 1,\ P_2(\boldsymbol{v}_l) \leq c_2.$$
6: 収束条件を満たすまで手順 4，5 を繰り返す．
7: X^l を次のように更新する．ただし，$d_l = \boldsymbol{u}_l^T X^l \boldsymbol{v}_l$ である．
$$X^{l+1} \leftarrow X^l - d_l \boldsymbol{u}_l \boldsymbol{v}_l^T.$$
8: $\boldsymbol{U} = (\boldsymbol{u}_1, \ldots, \boldsymbol{u}_L)^T$，$\boldsymbol{V} = (\boldsymbol{v}_1, \ldots, \boldsymbol{v}_L)^T$，$\boldsymbol{D} = (d_1, \ldots, d_L)^T$ を返す．

次に，SPC について述べる．SPC は PMD(2.4) にある $\boldsymbol{u}_l$ の制約を $\|\boldsymbol{u}_l\|_2^2 \leq 1$ のみに緩和し，$P_2(\cdot)$ を L_1 ノルムに設定した次の最大化問題として定式化される．

$$\arg\max_{\boldsymbol{u}_l, \boldsymbol{v}_l} \boldsymbol{u}_l^T X \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{u}_l\|_2^2 \leq 1,\ \|\boldsymbol{v}_l\|_2^2 \leq 1,\ \|\boldsymbol{v}_l\|_1 \leq c_2. \tag{2.6}$$

ここで，$\boldsymbol{u}_l = \frac{X\boldsymbol{v}_l}{\|X\boldsymbol{v}_l\|_2}$ とおくと，(2.6) 式は

$$\arg\max_{\boldsymbol{v}_l} \boldsymbol{v}_l^T X^T X \boldsymbol{v}_l \quad \text{subject to } \|\boldsymbol{v}_l\|_2^2 \leq 1,\ \|\boldsymbol{v}_l\|_1 \leq c_2, \tag{2.7}$$

と変形され，これは第 1 主成分における SCoTLASS (2.3) の制約を緩めて近似した最適化問題を表す．また，第 2 主成分以降に関して，(2.6) 式は直交性の制約を持たない．しかし，SPC を拡張することで直交性に似た条件を設ける手法により，SCoTLASS の解を求めることができ，さらに，拡張しない場合でも寄与率が高くなる．詳細は Jolliffe et al. (2003) を参照されたい．SPC を用いて SCoTLASS を計算するアルゴリズムは Algorithm 2 のようにまとめることができる．

Algorithm 2 SPC による第 K $(1 \leq K \leq p)$ 主成分における SCoTLASS を計算するアルゴリズム

1: $(X^TX)^1 = X^TX$ とする.
2: **for all** $k = 1, \ldots, K$ **do**
3: $\|\boldsymbol{v}_k\|_2^2 = 1$ を満たすような $\boldsymbol{v}_k$ の初期値を設定する.
4: $\boldsymbol{u}_k = \frac{X\boldsymbol{v}_k}{\|X\boldsymbol{v}_k\|_2}$ とする.
5: $\boldsymbol{v}_k$ を次のように更新する.
$$\boldsymbol{v}_k \leftarrow \arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T (X^TX)^k \boldsymbol{v}_k \quad \text{subject to } \|\boldsymbol{v}_k\|_2^2 \leq 1,\ \|\boldsymbol{v}_k\|_1 \leq c_2.$$
6: 収束条件を満たすまで手順 4，5 を繰り返す.
7: $(X^TX)^k$ を次のように更新する．ただし，$d_k = \boldsymbol{u}_k^T (X^TX)^k \boldsymbol{v}_k$ である.
$$(X^TX)^{k+1} \leftarrow (X^TX)^k - d_k \boldsymbol{u}_k \boldsymbol{v}_k^T.$$
8: $\boldsymbol{V} = (\boldsymbol{v}_1, \ldots, \boldsymbol{v}_K)^T$ を返す.

3　多重比較法

まず，スパース主成分分析の第 k 主成分 $(k = 1, \ldots, p)$ における主成分負荷量を $\boldsymbol{v}_k = (v_{k1}, \ldots, v_{kp})^T$ とする．v_{kj} に関する帰無仮説 $H_{0,kj}$ を

$$H_{0,kj} : v_{kj} = 0, \quad j = 1, \ldots, p, \tag{3.1}$$

と設定すると，対立仮説 $H_{1,kj}$ は $v_{kj} \neq 0$ と表せる．

この場合のように帰無仮説が複数あるときは，あらかじめ有意水準を決めて個々に検定を行うと全体としての有位水準が大きくなるため，第一種の過誤の確率が大きくなる「多重性の問題」が発生する．第一種の過誤とは，帰無仮説が真であるにも関わらず棄却することである．この多重性の問題を考慮した方法に多重比較法があり，全体としての有意水準を取り入れて検定することで棄却域の調整を行う．

偽発見率 (False Discovery Rate: FDR) は多重比較法における全体を評価するために必要な基準の一つであり，FDR を制御する手法は BH 法 (Benjamini and Hochberg, 1995) や BY 法 (Benjamini and Yekutieli, 2001) など，数多くある．

本節ではスパース主成分分析を例に，FDR の構成と，FDR と共に使用される場合が多い評価基準の検出力について述べる．

3.1　偽発見率

まず，得られたデータに対してスパース主成分分析を行い，推定された第 k 主成分の主成分負荷量を $\hat{\boldsymbol{v}}_k$ とする．次に，真の主成分負荷量 $\boldsymbol{v}_k$ のうち，非 0 となる主成分負荷量の添字集合を $\mathcal{A}$ とする．すなわち，$\mathcal{A} \equiv \{j : v_{kj} \neq 0\}$ であり，その補集合は $\mathcal{A}^c \equiv \{j : v_{kj} = 0\}$ である．スパース主成分分析により $\hat{\boldsymbol{v}}_k$ を求め，棄却した帰無仮説の個数，すなわち $\hat{v}_k \neq 0$ と推定された個数を $R(c)$ とする．$R(c)$ のうち真の主成分負荷量の値が 0 であるものの個数を $V(c)$，非 0 であるものの個数を $S(c)$ と定義する．すなわち，$R(c) = V(c) + S(c)$ である．また，前節で述べた通り，スパース主成分分析を行うと調整パラメータ c の値によって主成分負荷量の値が変化する．それに伴い，R，V，S の値も変動するため，本論文ではこれらの引数に c を導入している．

以上をまとめると

$$
\begin{aligned}
R(c) &\equiv \#\{j : \hat{v}_{kj} \neq 0\}, \\
V(c) &\equiv \#\{j : \hat{v}_{kj} \neq 0 \text{ and } j \in \mathcal{A}^c\}, \\
S(c) &\equiv \#\{j : \hat{v}_{kj} \neq 0 \text{ and } j \in \mathcal{A}\},
\end{aligned}
\tag{3.2}
$$

と表せる．ここで，$\#\{j : A\}$ は条件 A を満たす変数の添字番号の個数を表す．また，(3.2) 式の関係を表 1 にまとめている．Benjamini and Hochberg (1995) は上記の定義を用いて次に述べる偽発見率 (False Discovery Rate: FDR) を導入した．棄却した帰無仮説 $R(c)$ のうち，誤って棄却された個数 $V(c)$ の割合を FDP (False Discovery Proportion) といい，その期待値が FDR である．すなわち，以下のように定義される．

$$
\mathrm{FDP}(c) = \frac{V(c)}{R(c) \vee 1}, \tag{3.3}
$$

$$
\mathrm{FDR}(c) = E\left[\mathrm{FDR}(c)\right]. \tag{3.4}
$$

ここで，$a \vee b = \max\{a, b\}$ である．

なお，本稿では，各主成分ごとに FDR を導出することとする．

3.2 検出力

まず，$\mathcal{A}$ に含まれる要素の個数を B とする．また，$\mathcal{A}$ のうち，棄却しなかった帰無仮説の個数を $T(c)$ とする．すなわち，

$$
B \equiv \#\{j : j \in \mathcal{A}\}, \tag{3.5}
$$

$$
T(c) \equiv \#\{j : \hat{v}_{kj} = 0 \text{ and } j \in \mathcal{A}\}, \tag{3.6}
$$

と表し，これらの関係を表 1 にまとめている．検出力は，対立仮説が正しい B のうち，正しく棄却される個数 $S(c)$ の割合と定義される．すなわち，以下の式で表される．

$$
\text{検出力} = \frac{S(c)}{B}. \tag{3.7}
$$

Table 1: FDR と検出力を構成する変数の関係

		真の状態		
		$v_{kj} \neq 0$	$v_{kj} = 0$	計
推定結果	$\hat{v}_{kj} \neq 0$	$S(c)$	$V(c)$	$R(c)$
	$\hat{v}_{kj} = 0$	$T(c)$		
	計	B		

4　線形回帰モデルにおける Knockoff 法による FDR 制御

Barber and Candès (2015) は，lasso に対して FDR を設定値以下に抑える正則化パラメータの決定方法を提案し，この方法を Knockoff 法と名付けた．本節では，線形回帰モデルにおける正則化法について説明した後，lasso の概要を述べる．次に，lasso の場合の FDR の表現方法，および Knockoff 法により FDR 制御を行う手順を説明する．

4.1　lasso

いま，n 個の目的変数 $\boldsymbol{y} = (y_1, \ldots, y_n)^T$ と，p 次元説明変数 $\{\boldsymbol{x}_i; i = 1, \ldots, n\}$ に対し，これらの組 $\{(y_i, \boldsymbol{x}_i); i = 1, \ldots, n\}$ が独立に与えられているとする．ここで，$\boldsymbol{x}_i = (x_{i1}, \ldots, x_{ip})^T$ である．また，次のように目的変数は中心化，説明変数は標準化されているとする．

$$\frac{1}{n}\sum_{i=1}^{n} y_i = 0, \quad \frac{1}{n}\sum_{i=1}^{n} x_{ij} = 0, \quad \frac{1}{n}\sum_{i=1}^{n} x_{ij}^2 = 1, \quad j = 1, \ldots, p. \tag{4.1}$$

次に，これらの目的変数と説明変数の関係を，線形回帰モデル

$$\boldsymbol{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \tag{4.2}$$

で捉えることとする．ここで，$\boldsymbol{\beta} = (\beta_1, \ldots, \beta_p)^T$ は回帰係数とよばれるパラメータである．$\boldsymbol{\varepsilon} = (\varepsilon_1, \ldots, \varepsilon_n)^T$ は観測誤差であり，各要素が独立に $N(0, \sigma^2)$ にしたがうと仮定する．説明変数は $X = (\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n)^T$ の行列でまとめる．

線形回帰モデルにおける最小二乗法では，(4.2) 式における誤差の二乗和

$$S(\boldsymbol{\beta}) = \|\boldsymbol{\varepsilon}\|_2^2 = \|\boldsymbol{y} - X\boldsymbol{\beta}\|_2^2, \tag{4.3}$$

を最小とするモデルをデータに対する当てはまりの良いモデルと考える．(4.3) 式を

最小とする $\boldsymbol{\beta}$ については，(4.3) 式を $\boldsymbol{\beta}$ について偏微分し，正規方程式

$$\frac{\partial S(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2X^T(\boldsymbol{y} - X\boldsymbol{\beta}) = \mathbf{0}, \tag{4.4}$$

を解くことで，$\boldsymbol{\beta}$ の最小 2 乗推定量

$$\widehat{\boldsymbol{\beta}} = \left(X^T X\right)^{-1} X^T \boldsymbol{y}, \tag{4.5}$$

が求まる．

しかし，説明変数間の相関が非常に高いときや，$p > n$ の場合は，逆行列 $(X^T X)^{-1}$ が計算できないため，(4.5) 式により最小二乗推定量を求めることはできない．さらに，推定されたモデルが現在のデータに対してはよい当てはまりを示すが，将来のデータに対しては予測精度が劣る過適合が生じることがある．

その解決方法に，正則化法がある．正則化法は $S(\boldsymbol{\beta})$ と正則化項 $R(\boldsymbol{\beta})$ の和の最小化問題

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} S(\boldsymbol{\beta}) + \lambda R(\boldsymbol{\beta}) \right\}, \tag{4.6}$$

の解を求める方法である．ここで，$\lambda\ (> 0)$ は正則化パラメータである．正則化項を導入することでデータへの過適合を防ぎ，正則化パラメータを選択することで正則化項の効果を調節することができる．これより，正則化法は安定した推定量を導くことができる．

lasso は正則化法による線形回帰モデルの回帰係数の推定方法の一つであり，(4.6) 式の正則化項を $\boldsymbol{\beta}$ の L_1 ノルムとした

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \|\boldsymbol{y} - X\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_1 \right\}, \tag{4.7}$$

で表される．lasso では回帰係数の推定値の一部が 0 となるため，目的変数に影響を及ぼすパラメータのみが抽出される．λ の値が大きくなると 0 と推定される回帰係数の個数が多くなり，小さくなると 0 と推定される回帰係数の個数が少なくなる．したがって，正則化パラメータには「変数選択の度合い」と「観測データへの当てはまり」の 2 点の釣り合いを調節する働きを持つ．

4.2 lasso に対する FDR

まず，$\boldsymbol{\beta}$ に関して帰無仮説を

$$H_{0,j} : \beta_j = 0 \quad j = 1, \ldots, p, \tag{4.8}$$

と設定すると，対立仮説 $H_{1,j}$ は $\beta_j \neq 0$ と表せる．得られたデータに対して lasso を行い，推定された回帰係数を $\hat{\boldsymbol{\beta}}$ とする．次に，$\mathcal{A}$，$\mathcal{A}^c$ は，3.1 節と同様の形式を用いると

$$\mathcal{A} \equiv \{j : \beta_j \neq 0\}, \tag{4.9}$$

$$\mathcal{A}^c \equiv \{j : \beta_j = 0\}, \tag{4.10}$$

と表されるため，R，V，S は

$$\begin{aligned} R(\lambda) &\equiv \#\{j : \hat{\beta}_j \neq 0\}, \\ V(\lambda) &\equiv \#\{j : \hat{\beta}_j \neq 0 \text{ and } j \in \mathcal{A}^c\}, \\ S(\lambda) &\equiv \#\{j : \hat{\beta}_j \neq 0 \text{ and } j \in \mathcal{A}\}, \end{aligned} \tag{4.11}$$

と定義される．lasso 推定を行うと正則化パラメータ λ によって回帰係数の値が変化し，さらに R，V，S の値も変動するため，スパース主成分分析の場合と同様に R，V，S の引数に λ を導入している．以上より，lasso における FDR は

$$\mathrm{FDP}(\lambda) = \frac{V(\lambda)}{R(\lambda) \vee 1}, \tag{4.12}$$

$$\mathrm{FDR}(\lambda) = E\left[\mathrm{FDR}(\lambda)\right], \tag{4.13}$$

と表記される．

4.3 Knockoff 法による正則化パラメータの決定

Knockoff 法による正則化パラメータの導出に関しては次の 4 つの手順で構成される．

1. Knockoff 変数 $\tilde{\boldsymbol{x}}_i$ の作成

2. 統計量 $\boldsymbol{W}$ の導出

3. しきい値 T の導出

4. 変数の選択，および正則化パラメータ λ の導出

次の項で各手順の詳細を説明する．

4.3.1 Knockoff 変数 $\tilde{\boldsymbol{x}}_i$ の作成

まず，$\boldsymbol{x}_i$ に関して Knockoff 変数 $\tilde{\boldsymbol{x}}_i$ を作成する．ただし，$\tilde{\boldsymbol{x}}_i = (\tilde{x}_{i1}, \ldots, \tilde{x}_{ip})^T$ であり，Knockoff 変数を $\tilde{X} = (\tilde{\boldsymbol{x}}_1, \ldots, \tilde{\boldsymbol{x}}_n)^T$ の Knockoff 行列でまとめる．Kncokoff 変数，Knockoff 行列と区別をつけるため，この章より観測データの $\boldsymbol{x}_i$ をオリジナル変数，X をオリジナル行列と呼ぶこととする．

Knockoff 行列は次の条件を満たす必要がある．

$$\tilde{X}^T \tilde{X} = X^T X, \tag{4.14}$$

$$X^T \tilde{X} = X^T X - \mathrm{diag}\{\boldsymbol{s}\}. \tag{4.15}$$

ここで，$\boldsymbol{s}$ は p 次元非負ベクトルである．(4.14) 式はオリジナル変数と Knockoff 変数の分散共分散行列が等しいことを意味する．(4.15) 式は $X^T \tilde{X}$ の非対角成分に関しては，オリジナル変数の分散共分散行列と等しいことを意味する．また，対角成分に関しては，オリジナル変数と Knockoff 変数の分散共分散行列の値が 0 に非常に近い，すなわち，オリジナル変数と Knockoff 変数の相関が最小であることを意味する．$\boldsymbol{s}$ の値を大きくすると (4.15) 式の右辺の値が小さくなることから，オリジナル変数と Knockoff 変数を直交させた上で最大値をとるような値を $\boldsymbol{s}$ として採用する．例えば，半正定値計画問題 (Boyd and Lieven, 2004) を用いて $\boldsymbol{s}$ を決定する方法がある．このように，オリジナル変数を使用しながら Knockoff 変数を作成するため，両者の構造は似ているが，目的変数 $\boldsymbol{y}$ を用いて作成していないため，Knockoff 変数と目的変数は独立となる．

(4.14)，(4.15) 式の条件を満たすような Knockoff 変数の作成方法の一つは，次式で表される．

$$\tilde{X} = X(\mathrm{I} - \Sigma^{-1}\mathrm{diag}\{\boldsymbol{s}\}) + \tilde{\boldsymbol{U}}\boldsymbol{C}. \tag{4.16}$$

ここで，$\tilde{\boldsymbol{U}}$ は $\tilde{\boldsymbol{U}}^T X = \boldsymbol{0}$ を満たす $n \times p$ 直交行列である．$\boldsymbol{C}$ は $\boldsymbol{C}^T\boldsymbol{C} = 2\mathrm{diag}\{\boldsymbol{s}\} - \mathrm{diag}\{\boldsymbol{s}\}\Sigma^{-1}\mathrm{diag}\{\boldsymbol{s}\}$ を満たす行列で，コレスキー分解により計算される．(4.16) 式の詳細に関しては Barber and Candès (2015) を参照されたい．

4.3.2 統計量 W の導出

まず，オリジナル変数と Knockoff 変数を結合した $n \times 2p$ 行列で lasso 推定を行う．すなわち，次の最小化問題

$$\hat{\boldsymbol{\beta}}(\lambda) = \arg\min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \left\| \boldsymbol{y} - [X, \tilde{X}]\boldsymbol{\beta} \right\|_2^2 + \lambda \left\| \boldsymbol{\beta} \right\|_1 \right\}, \tag{4.17}$$

を解くことにより，$2p$ 次元の推定した回帰係数ベクトル $\hat{\boldsymbol{\beta}}(\lambda)$ を得る．このように，オリジナル変数と Knockoff 変数をまとめた形で推定を行うことで，次の性質を得ることができる．オリジナル変数の回帰係数 β_j $(j = 1, \ldots, p)$ と Knockoff 変数の回帰係数 β_{j+p} を比較したとき，

- β_j が目的変数 $\boldsymbol{y}$ に寄与する場合，β_j が優先的に選択される．
- β_j が目的変数 $\boldsymbol{y}$ に寄与しない場合，β_j と β_{j+p} のどちらが優先的に選択されるかは等確率で起こる．

この性質は，Knockoff 変数を作成した際に，同じ添字番号同士のオリジナル変数と Knockoff 変数はできるだけ無関係となるように設定したため，上記の場合分けを行うことができる．

上記の性質を正則化パラメータ λ を用いた形で表す．まず，$\hat{\beta}_j$ の値が非 0 と推定される正則化パラメータの値のうち，最大値を Z_j とする．これを回帰係数の添字番号 j $(j = 1, \ldots, p)$ ごとに行う．β_{j+p} についても同様に行い，$\tilde{Z}_j$ とする．このとき，Z_j，$\tilde{Z}_j$ は次の式で表される．

$$\begin{aligned} Z_j &= \sup\left\{ \lambda : \hat{\beta}_j(\lambda) \neq 0 \right\}, \\ \tilde{Z}_j &= \sup\left\{ \lambda : \hat{\beta}_{j+p}(\lambda) \neq 0 \right\}, \end{aligned} \quad j = 1, \ldots, p. \tag{4.18}$$

次に，Z_j，$\tilde{Z}_j$ を比較した結果を新たに統計量 W_j $(j = 1, \ldots, p)$ に取り入れる．オリジナル変数の正則化パラメータ Z_j の値が大きい場合は $W_j = Z_j$ とし，Knockoff 変

数の正則化パラメータ $\tilde{Z}_j$ の値が大きい場合は $W_j = -\tilde{Z}_j$ とする．すなわち，

$$W_j = Z_j \vee \tilde{Z}_j \cdot \mathrm{sign}(Z_j - \tilde{Z}_j), \quad j = 1, \ldots, p, \tag{4.19}$$

である．ここで，sign(·) は

$$\mathrm{sign}(a) = \begin{cases} a, & a > 0, \\ 0, & a = 0, \\ -a, & a < 0, \end{cases} \tag{4.20}$$

で定義される符号関数である．

統計量 $W_1, \ldots, W_p$ をベクトル化したものを p 次元ベクトル $\boldsymbol{W} = (W_1, \ldots, W_p)^T$ でまとめて表すと，$\boldsymbol{W}$ はオリジナル変数と Knockoff 変数を比較した際に，目的変数への寄与がより大きい回帰係数の正則化パラメータの値を選択し，それがオリジナル変数の場合であるか Knockoff 変数の場合であるかを符号で区別している．

4.3.3 しきい値 T の導出

$\boldsymbol{W}$ で表される次式

$$T = \min \left\{ t \in \mathcal{W} : \frac{1 + \#\{j : W_j \leq -t\}}{\#\{j : W_j \geq t\} \vee 1} \leq q \right\}, \tag{4.21}$$

によりしきい値 T を計算する．ただし，$\mathcal{W} = \{|W_j| : j = 1, \ldots, p\} \setminus \{0\}$ であり，$\setminus\{a\}$ は集合から a を除くことを意味する．q $(0 \leq q \leq 1)$ は事前に設定した FDR 制御値である．

(4.21) 式は交換可能性という性質が成立した場合に限り FDR 制御が実行可能，つまり

$$E\left[\frac{\#\{j : \beta_j = 0 \text{ and } j \in \hat{S}\}}{\#\{j : j \in \hat{S}\} \vee 1} \right] \leq q, \tag{4.22}$$

となることが知られている．ただし，$\hat{S}$ は $W_j \geq T$ を満たす添字番号集合である．ここで，線形回帰モデルにおける交換可能性とは，帰無仮説が正しい回帰係数の添字番号，すなわち，真の回帰係数の値が 0 である添字番号に対して，統計量 W_j の値

が t 以上である分布と $-t$ 以下である分布が等しい性質のことである．すなわち，

$$\#\{j : j \in \mathcal{A}^c \text{ and } W_j \geq t\} \stackrel{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } W_j \leq -t\}. \tag{4.23}$$

が成り立つことである．ここで，記号 $\stackrel{d}{=}$ は両辺の分布が等しいことを表す記号である．Knockoff 変数 $\tilde{\boldsymbol{x}}_i$ と統計量 $\boldsymbol{W}$ を用いることで交換可能性が成立する．交換可能性の証明と，統計量 $\boldsymbol{W}$ を用いた (4.22) 式により FDR 制御が可能であることの証明に関しては，付録 B を参照されたい．

4.3.4　変数の選択，および正則化パラメータ λ の導出

最後に，$W_j \geq T$ を満たす添字番号集合 $\hat{S}$ を取り出す．$\hat{S}$ が FDR 制御を行った際に選択された回帰係数の変数番号集合となるため，正則化パラメータの範囲を算出することができる．

5　提案手法

前節で述べたKnockoff法は，Dai and Zheng (2023)，Romano et al. (2019)，Sesia et al. (2019) など線形回帰モデル以外にも拡張されている．しかし，主成分分析への拡張はいまだ発展途上である．そこで，本論文ではKnockoff法をスパース主成分分析に拡張することで，FDR制御の観点からスパース主成分分析に含まれる調整パラメータの選択方法を提案する．

Knockoff法による，第 k $(1 \leq k \leq p)$ 主成分における調整パラメータの導出手順は次の通りである．

1. Knockoff変数 $\tilde{\boldsymbol{x}}_i$ の作成
2. 統計量 $\boldsymbol{W}_k$ の導出
3. しきい値 T_k の導出
4. 変数の選択，および調整パラメータ c の導出

次の節で手順の詳細を追う．

5.1　Knockoff変数 $\tilde{\boldsymbol{x}}_i$ の作成

オリジナル変数 $\boldsymbol{x}_i$ に関してKnockoff変数 $\tilde{\boldsymbol{x}}_i$ を作成する．ただし，$\tilde{\boldsymbol{x}}_i = (\tilde{x}_{i1}, \ldots, \tilde{x}_{ip})^T$ であり，Knockoff変数を $\tilde{X} = (\tilde{\boldsymbol{x}}_1, \ldots, \tilde{\boldsymbol{x}}_n)^T$ のKnockoff行列でまとめる．

まず，オリジナル行列 X の標本相関行列

$$C_{ij} = \frac{\sum_{l=1}^{n} x_{li} x_{lj}}{\sqrt{\sum_{l=1}^{n} x_{li}^2} \sqrt{\sum_{l=1}^{n} x_{lj}^2}}, \quad i, j = 1, \ldots, p, \tag{5.1}$$

に関して，母集団の相関係数が0という帰無仮説の下では，以下の値 R_{ij}

$$R_{ij} = \frac{C_{ij}}{\sqrt{(1 - C_{ij}^2)/(n-2)}}, \quad i, j = 1, \ldots, p, \tag{5.2}$$

が自由度 $n-2$ の t 分布にしたがうことが知られている (Fisher, 1915)．これより，Knockoff 相関行列を

$$\tilde{C}_{ij} = \begin{cases} 1, & i = j, \\ \frac{R_{ij}}{\sqrt{n-2+R_{ij}^2}}, & i \neq j, \end{cases} \qquad i, j = 1, \ldots, p, \tag{5.3}$$

と定める．非対角成分に関しては R_{ij} を標本相関行列 C_{ij} について解いたものであり，対角成分は 1 に設定する．この Knockoff 相関行列から Knockoff 変数を乱数を用いて発生させる．Knockoff 相関行列の導出方法は，ガウシアングラフィカルモデルに対する Knockoff 法 (Yu et al., 2021) に基づいており，Yu et al. (2021) の研究の詳細は付録 C を参照されたい．

5.2 統計量 W_k の導出

まず，第 k 主成分の主成分負荷量 $\boldsymbol{v}_k$ において，オリジナル変数と Knockoff 変数を結合した $n \times 2p$ 行列に対し，SPC を用いて SCoTLASS を計算する．すなわち，次の最大化問題

$$\hat{\boldsymbol{v}}_k(c) = \arg\max_{\boldsymbol{v}_k} \boldsymbol{v}_k^T [X, \tilde{X}]^T [X, \tilde{X}] \boldsymbol{v}_k \quad \text{subject to } \|\boldsymbol{v}_k\|_2^2 \leq 1,\ \|\boldsymbol{v}_k\|_1 \leq c, \tag{5.4}$$

を解くことにより，$2p$ 次元の主成分負荷量 $\hat{\boldsymbol{v}}_k(c)$ の推定値が得られる．(5.4) 式の形で SCoTLASS を行うことで，線形回帰モデルの場合と同様，次の性質を得ることができる．オリジナル変数の主成分負荷量 v_{kj} $(j = 1, \ldots, p)$ と Knockoff 変数の回帰係数 $v_{k(j+p)}$ を比較したとき，

- v_{kj} が第 k 主成分に寄与する場合，v_{kj} が優先的に選択される．
- v_{kj} が第 k 主成分に寄与しない場合，v_{kj} と $v_{k(j+p)}$ のどちらが優先的に選択されるかは等確率で起こる．

Knockoff 相関行列はオリジナル相関行列を使用せず作成したため，両者の構造は無関係である．したがって上記の性質を持つことができる．

上記の性質を調整パラメータ c を用いた形で表す．まず，v_{kj} の値が非 0 となる調整パラメータのうち，最小値を Z_{kj} とする．これを主成分負荷量の添字番号 j $(j =$

$1, \ldots, p)$ ごとに行う．$v_{k(j+p)}$ についても同様に行い，$\tilde{Z}_{kj}$ とする．このとき，Z_{kj}，$\tilde{Z}_{kj}$ は次の式でまとめられる．

$$\begin{aligned} Z_{kj} &= \inf\left\{c : \hat{v}_{kj}(c) \neq 0\right\}, \\ \tilde{Z}_{kj} &= \inf\left\{c : \hat{v}_{k(j+p)}(c) \neq 0\right\}, \end{aligned} \qquad j = 1, \ldots, p. \tag{5.5}$$

次に，Z_{kj}，$\tilde{Z}_{kj}$ を比較し，オリジナル変数の調整パラメータ Z_{kj} の値が小さい場合は $W_{kj} = Z_{kj}$ とし，Knockoff 変数の調整パラメータ $\tilde{Z}_{kj}$ の値が小さい場合は $W_{kj} = -\tilde{Z}_{kj}$ とする．調整パラメータの値の大きさと，主成分負荷量の値が非 0 となる数の関係が，線形回帰モデルの場合と逆であるため，線形回帰モデルでは統計量 (4.19) に正則化パラメータの最大値を用いたが，提案手法では統計量に調整パラメータの最小値を用いていることに注意されたい．以上をまとめると，次式で表される．

$$W_{kj} = Z_{kj} \wedge \tilde{Z}_{kj} \cdot \mathrm{sign}(Z_{kj} - \tilde{Z}_{kj}), \quad j = 1, \ldots, p. \tag{5.6}$$

ただし，$a \wedge b = \min\{a, b\}$ である．

以上より，$\boldsymbol{W}_k = (W_{k1}, \ldots, W_{kp})^T$ を導出することができる．

5.3 しきい値 T_k の導出

$\boldsymbol{W}_k$ を用いた次式

$$T_k = \max\left\{t \in \mathcal{W}_k : \frac{1 + \#\left\{j : -t \leq W_{kj} < 0\right\}}{\#\left\{j : 0 < W_j \leq t\right\} \vee 1} \leq q\right\}, \tag{5.7}$$

により，しきい値 T_k を計算する．ここで，$\mathcal{W}_k = \{|W_{kj}| : j = 1, \ldots, p\} \setminus \{0\}$ であり，q $(0 \leq q \leq 1)$ はあらかじめ設定した FDR 制御値である．(5.7) 式は交換可能性が成立した場合に限り FDR 制御が実行可能，つまり

$$E\left[\frac{\#\{j : v_{kj} = 0 \text{ and } j \in \hat{S}\}}{\#\{j : j \in \hat{S}\} \vee 1}\right] \leq q, \tag{5.8}$$

となることが知られている．ただし，$\hat{S}$ は $0 < W_{kj} \leq T_k$ を満たす添字番号集合である．

まず，スパース主成分分析においては交換可能性が満たされ，次の定理にまとめられる．

Theorem 1. スパース主成分分析においては交換可能性が満たされる．つまり，帰無仮説が正しい主成分負荷量の添字番号，すなわち，真の主成分負荷量の値が 0 である添字番号に対して，統計量の値が 0 以上 t 以下である分布と $-t$ 以上 0 以下である分布は等しい．数式で表すと

$$\#\{j : j \in \mathcal{A}^c \text{ and } 0 < W_{kj} \leq t\} \stackrel{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } -t \leq W_{kj} < 0\}, \tag{5.9}$$

となる．

Proof. まず，$\boldsymbol{W}_k$ が持つ性質について述べる．いま，$v_{kj} = 0$ を満たす添字番号集合 S に関して，C_{ij} と $\tilde{C}_{ij}$ $(i, j \in S)$ の位置を交換して計算された統計量を $\boldsymbol{W}_{k,swap(S)}$ とおく．このとき，$\boldsymbol{W}_{k,swap(S)}$ は W_{kj} の正負が逆になる反対称性の性質がある．すなわち，$\boldsymbol{W}_{k,swap(S)}$ は次式で表される．

$$\boldsymbol{W}_{k,swap(S)} = (W_{k1}\epsilon_{k1}, \ldots, W_{kp}\epsilon_{kp}), \quad \epsilon_{kj} = \begin{cases} +1 & j \notin S, \\ -1 & j \in S, \end{cases} \quad j = 1, \ldots, p. \tag{5.10}$$

$\boldsymbol{W}_k$ が反対称性を持つように (5.5) 式を設定しているため，この性質は明らかである．

次に，Knockoff 相関行列を作成することにより次の補題が成り立つ．

Lemma 1. $v_{kj} = 0$ を満たす任意の要素番号集合 S に対して，

$$(W_{k,swap(S)})_j \stackrel{d}{=} W_{kj}, \tag{5.11}$$

が成り立つ．

Proof. まず，$v_{kj} = 0$ の条件下では, (5.3) 式より,

$$C_{ij} \stackrel{d}{=} \tilde{C}_{ij}, \tag{5.12}$$

であり，この分布の同等性は (5.4) 式のスパース主成分分析でも成り立つことが分かる．したがって，(5.5) 式においても (5.12) 式の等価性は成り立つため，$Z_{kj} \stackrel{d}{=} \tilde{Z}_{kj}$ が成立する．同様に，$\text{sign}(Z_{kj} - \tilde{Z}_{kj}) \stackrel{d}{=} \text{sign}(\tilde{Z}_{kj} - Z_{kj})$ であり，$Z_{kj} \wedge \tilde{Z}_{kj}$ と $\tilde{Z}_{kj} \wedge Z_{kj}$

の値は明らかに等しいので,

$$(W_{k,swap(S)})_j \overset{d}{=} W_{kj}, \tag{5.13}$$

が成立する. □

この補題は，オリジナル変数と Knockoff 変数のうち，同じ添字番号である場所を交換しても統計量の分布は変わらないことを意味している.

以上の統計量の性質と補題より，$v_{kj} = 0$ を満たす任意の添え字番号集合 S に関して,

$$W_{kj} = (W_{k,swap(S)})_{kj} \overset{d}{=} -W_{kj}, \tag{5.14}$$

が成立する．(5.14) 式の最左辺と最右辺の関係は, $\#\{j : j \in \mathcal{A}^c \text{ and } 0 < W_{kj} \leq t\} \overset{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } -t \leq W_{kj} < 0\}$ と同じ意味である. □

次に，(5.8) 式が FDR 制御可能である理由を説明する．はじめに，p 値を用いた形式で多重比較法を行うと FDR 制御が可能であることを証明する．次に，この証明を Knockoff 法と関連付けることで，(5.8) 式が FDR 制御可能であることを示す．最後に，(5.7) 式が FDR 制御における棄却限界値であることを述べる.

まず，帰無仮説 $H_{0,kj}$ $(j = 1, \ldots, p)$ に関して p 値を p_{kj} $(j = 1, \ldots, p)$ と設定する．帰無仮説が正しい場合の p 値は一様分布にしたがうことが知られており，また，これらは互いに独立であるとする．次に，多重比較法を行うにあたり必要なしきい値を

$$\hat{m} = \max\left\{ m \in M : \frac{1 + \#\{j : j \leq m \text{ and } p_{kj} > c\}}{\#\{j : j \leq m \text{ and } p_{kj} \leq c\} \vee 1} \leq \frac{1-c}{c}\, q \right\}, \tag{5.15}$$

と定義する．ここで，c $(0 < c < 1)$ は任意の値をとり，$M \subset \{1, \ldots, p\}$ である．$\hat{m}$ は p 値の棄却域の上限値と対応している．$p_{kj} \leq c$ かつ，$j \leq \hat{m}$ を満たす帰無仮説 $H_{0,kj}$ を棄却するとき,

$$E\left[\frac{\#\{j : v_{kj} = 0 \text{ and } j \leq \hat{m} \text{ and } p_{kj} \leq c\}}{\#\{j : j \leq \hat{m} \text{ and } p_{kj} \leq c\} \vee 1} \right] \leq q, \tag{5.16}$$

が成立する．(5.16) 式は，あらかじめ設定した値 q で FDR 制御が可能であることを意味する．これは，Storey et al. (2004) の BH 法がマルチンゲール理論の側面から

FDR 制御が可能であることに由来し，詳細は Barber and Candès (2015) を参照されたい．

次に，(5.16) 式の左辺が Knockoff 法で表現可能であることを示す．まず，値が非 0 である統計量 $\boldsymbol{W}_k$ の個数を m $(\leq p)$ とし，これを絶対値の昇順に並べたものを $W'_{k1}, \ldots, W'_{km}$ と設定する．すなわち，

$$0 < |W'_{k1}| \leq \ldots \leq |W'_{km}|, \tag{5.17}$$

である．次に，p 値を以下のように設定する．

$$p_{kj} = \begin{cases} \dfrac{1}{2}, & W'_{kj} > 0, \\ 1, & W'_{kj} < 0, \end{cases} \qquad j = 1, \ldots, m. \tag{5.18}$$

このとき，帰無仮説が正しい場合において，すなわち，$v_{kj} = 0$ において

$$\Pr\left\{p_{kj} = \frac{1}{2}\right\} = \Pr\left\{p_{kj} = 1\right\} = \frac{1}{2}, \tag{5.19}$$

が成り立つ．ここで，$\Pr\{a\}$ は，a の条件が成立する確率を表す．これは，(5.18) 式を用いて (5.9) 式の交換可能性を p 値を含んだ形に言い換えたものである．したがって，帰無仮説が正しい p 値は一様分布にしたがい，互いに独立である．これは統計量 W_{kj} においても同様であるため，Knockoff 法の場合でも FDR 制御が可能である．

最後に，p 値の棄却域の上限を表す (5.15) 式の $\hat{m}$ が，(5.7) 式のしきい値 T_k と同値であることを示す．まず，(5.15) 式に $c = \frac{1}{2}$ を代入すると

$$\hat{m} = \max\left\{m \in M : \frac{1 + \#\{j : j \leq m \text{ and } p_{kj} > \frac{1}{2}\}}{\#\{j : j \leq m \text{ and } p_{kj} \leq \frac{1}{2}\} \vee 1} \leq q\right\}, \tag{5.20}$$

と表せる．これを，(5.18) 式を使用して統計量 W_{kj} を含む形式で表すと

$$\hat{m} = \max\left\{m \in M : \frac{1 + \#\{j : j \leq m \text{ and } W'_{kj} < 0\}}{\#\{j : j \leq m \text{ and } W'_{kj} > 0\} \vee 1} \leq q\right\}, \tag{5.21}$$

である．ここで，(5.17) 式を考慮すると，$j \leq m$ のとき，$|W'_{kj}| \leq |W'_{km}|$ であるため，$W'_{kj} < 0$ は $-|W'_m| \leq W'_{kj} < 0$ と同値であり，$W_{kj} > 0$ は $0 < |W'_{kj}| \leq |W'_m|$ と同値

であることが分かる．したがって，(5.21) 式は

$$\hat{m} = \max\left\{ m \in M : \frac{1 + \#\{j : -|W'_m| \leq W'_{kj} < 0\}}{\#\{j : 0 < |W'_{kj}| \leq |W'_m|\} \vee 1} \leq q \right\}, \tag{5.22}$$

と書き換えられる．(5.22) 式の不等式を満たす m の最大値を求めることは，(5.22) 式の不等式を満たす $|W'_m|$ の最大値を求めること，すなわち (5.7) 式を計算することである．

5.4 変数の選択，および調整パラメータ c の導出

最後に，$0 < W_{kj} \leq T_k$ を満たす添字番号集合 $\hat{S}$ を取り出す．$\hat{S}$ が FDR 制御を行った際に選択された主成分負荷量の変数番号集合となるため，調整パラメータの範囲を算出することができる．

6　数値実験

本節では，人工データによるシミュレーションにより提案手法の有効性を検証する．提案手法と BH 法 (Benjamini and Hochberg, 1995) により FDR と検出力をそれぞれ求め比較する．

6.1　実験設定

人工データ $X = (\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n)^T$ を，$\boldsymbol{x}_i \sim N(\boldsymbol{0}, \Sigma)$ に従って発生させた．ここで，分散共分散行列 Σ は

$$\Sigma = P \Lambda P^T \tag{6.1}$$

とした．なお，$P = (\boldsymbol{p}_1, \ldots, \boldsymbol{p}_{15})^T$ は固有ベクトルであり，$\dot{\boldsymbol{p}}_1, \ldots, \dot{\boldsymbol{p}}_{15}$ を以下のように設定したあと，グラムシュミット直交化法により直交ベクトルとした．

$$\dot{\boldsymbol{p}}_1 = (1,1,0,1,0,1,1,0,0,0,0,0,0,0,0)^T, \tag{6.2}$$

$$\dot{\boldsymbol{p}}_2 = (0,0,0,0,0,0,0,1,1,1,0,1,0,1,0)^T, \tag{6.3}$$

$$\dot{\boldsymbol{p}}_3 = (0,0,0,0,0,0,0,0,0,0,1,0,1,0,1)^T, \tag{6.4}$$

$$\dot{\boldsymbol{p}}_4, \ldots, \dot{\boldsymbol{p}}_{15} \sim N(2,1). \tag{6.5}$$

Λ は固有値を対角成分に持つ行列であり，以下のように設定した．

$$\Lambda \quad = \quad \mathrm{diag}(A, 5, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1). \tag{6.6}$$

A は $\{20, 50\}$ の値を取るものとした．また，サンプルサイズ n は $\{200, 500\}$ の 2 種類を考え，FDR 制御値 q は 0.2 とした．

以上の数値設定のもと，Knockoff 法を 1 回実行し，非 0 と推定された主成分負荷量の変数番号集合 $\hat{S}$ を取り出して fdp を算出した．しかし，(5.3) 式の Knockoff 行列の非対角成分は乱数を用いて作成されるため，fdp を算出する過程を 100 回繰り返すことで fdp の期待値を求めた．この値を (3.3) 式の FDP とした．この操作をさらに 100 回実行することで得られる FDP の期待値を FDR とした．以上の操作を第

1 主成分から第 3 主成分まで，各主成分ごとに実行し，FDR と検出力の期待値を求めた．

6.2 BH 法

比較手法として，BH 法 (Benjamini and Hochberg, 1995) を用いた．BH 法を適用するためには p 値を計算する必要がある．そこで，本論文では，はじめに尤度比検定統計量に基づいたモンテカルロ検定を実行して，モンテカルロ p 値 p_{kj} $(k = 1, 2, 3,\ j = 1, \ldots, p)$ を求めた．次に，得られたモンテカルロ p 値を用いて BH 法を実行し，棄却された添字番号集合から FDP を得た．最後に，FDP を計算する過程を 100 回繰り返し，FDP の期待値である FDR を計算した．モンテカルロ検定の詳細は，例えば汪金芳 and 桜井裕仁 (2011) を，また，モンテカルロ p 値の具体的な計算方法については，付録 D を参照されたい．

6.3 実験結果

実験結果は表 2 から表 4 のようになった．

Table 2: 第 1 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.1807 (0.06727)	0.1735 (0.05748)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.3225 (0.2084)	0.3518 (0.1906)
		検出力	0.984 (0.1160)	1 (0)
$n = 500$	提案手法	FDR	0.1780 (0.06173)	0.1871 (0.06809)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.3198 (0.1847)	0.2986 (0.1792)
		検出力	1 (0)	1 (0)

Table 3: 第 2 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.1978 (0.05684)	0.1932 (0.06882)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.4578 (0.1475)	0.4921 (0.1194)
		検出力	0.996 (0.02814)	1 (0)
$n = 500$	提案手法	FDR	0.1982 (0.06126)	0.2061 (0.06083)
		検出力	1 (0)	1 (0)
	BH 法	FDR	0.5095 (0.1062)	0.4782 (0.1138)
		検出力	1 (0)	1 (0)

Table 4: 第 3 主成分における実験結果

			$A = 20$	$A = 50$
$n = 200$	提案手法	FDR	0.5583 (0.1170)	0.5769 (0.1036)
		検出力	0.6598 (0.1583)	0.6778 (0.1339)
	BH 法	FDR	0.4612 (0.1461)	0.5392 (0.1105)
		検出力	0.976 (0.07670)	0.9820 (0.07018)
$n = 500$	提案手法	FDR	0.2155 (0.1085)	0.2074 (0.08062)
		検出力	0.9822 (0.05408)	0.9902 (0.03526)
	BH 法	FDR	0.5709 (0.07207)	0.5813 (0.07957)
		検出力	1 (0)	1 (0)

FDR の右に記載されている括弧は FDP の標準偏差を，検出力の右に記載されている括弧は検出力の標準偏差を表す．

まず，提案手法について述べる．第 1 主成分の FDR はすべての設定において FDR 制御値である 0.2 を下回った．したがって，第 1 主成分については FDR 制御ができているといえる．第 2 主成分の $\{A = 50, n = 500\}$ の設定では FDR が 0.2 をわずかに超え，また，第 3 主成分の FDR はすべての設定において 0.2 を大きく上回った．この結果は，(6.6) 式から，第 1 主成分の固有値と比較して，第 2 主成分と第 3 主成分の固有値の値が小さいことが原因であると見られる．さらに，第 1 主成分と第 2 主成分以降との固有値の差と比較して，第 2 主成分と第 3 主成分以降との固有値の差や，第 3 主成分と第 4 主成分以降との固有値の差の方が小さいことも一因に挙げられる．したがって，固有値の値が小さく，また固有値の差が小さい主成分におい

てはFDR制御が難しいことが考えられる．また，検出力に関して，第1主成分と第2主成分の検出力は1であったが，第3主成分では値が小さくなった．こちらも固有値の値の大きさが関係していると考えられる．第1主成分と第2主成分の検出力が1であるのは，(6.2) 式から (6.4) 式の固有値ベクトルの設定において，非0の値が1といった比較的大きな値であるからだと考えられる．

次に，比較手法であるBH法については，すべての設定においてFDR制御値である0.2を大きく上回った．これは，どの設定においてもFDRの制御が不可能であることを示している．

以上より，第1主成分のような固有値の値が大きく，他の主成分の固有値との差が大きい設定では，提案手法はBH法より正確なFDR制御が可能であると考えられる．

7　まとめ

本論文では，Knockoff 法をスパース主成分分析に拡張することにより，FDR 制御の観点からスパース主成分分析に含まれる調整パラメータの選択方法を提案した．Knockoff 法を実行するにあたり，交換可能性を成立させる必要があるが，その成立条件として重要な Knockoff 変数の作成に関しては，標本相関が t 分布にしたがう条件を利用した．BH 法による実験結果と比較した結果，固有値の値が大きいことや，他の主成分の固有値との差が大きい場合において，提案手法の方が正確に FDR を制御できることがわかった．しかし，固有値の値が小さい場合や，他の主成分の固有値との大小関係により FDR の値が変動する問題が発生した．

今後の課題として，固有値や固有値ベクトルの値の設定を変えて再度実験することで，FDR の値の動向を明確にすることが挙げられる．また，BH 法以外の他手法と比較することも挙げられる．

謝辞

本論文の執筆にあたり，主任指導教員の植野真臣教授，指導教員の宇都雅輝准教授には適切なご指導とご助言をいただきましたこと厚く御礼申し上げます．また，九州大学大学院数理学研究院の川野秀一教授には懇切丁寧な指導と多大なる助言をいただきましたこと深く感謝を申し上げます．さらに，同研究室の皆様，並びに九州大学大学院数理学府の岡崎彰良さんには，日頃の勉強会や研究の相談を通して多くの助言や知見をいただきました．深く感謝いたします．

付録

A　(2.2) 式の $\boldsymbol{v}_k^T S \boldsymbol{v}_k$ の導出

まず，第 k 主成分に関して，主成分得点の平均 $\bar{y}_k$ は

$$\bar{y}_k = \frac{1}{n}\sum_{i=1}^{n} y_{ki} = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{v}_k^T \boldsymbol{x}_i = \boldsymbol{v}_k^T \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{x}_i = 0, \tag{A.1}$$

となる．ここで，$\boldsymbol{x}_i$ はあらかじめ中心化されているため，$\frac{1}{n}\sum_{i=1}^{n} \boldsymbol{x}_i = \boldsymbol{0}$ である．したがって，主成分得点の分散は

$$\begin{aligned}
\frac{1}{n}\sum_{i=1}^{n}(y_{ki} - \bar{y}_k)^2 &= \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{v}_k^T \boldsymbol{x}_i)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{v}_k^T \boldsymbol{x}_i (\boldsymbol{x}_i^T \boldsymbol{v}_k)^T \\
&= \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{v}_k^T \boldsymbol{x}_i \boldsymbol{x}_i^T \boldsymbol{v}_k \\
&= \boldsymbol{v}_k^T \left\{ \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{x}_i \boldsymbol{x}_i^T \right\} \boldsymbol{v}_k \\
&= \boldsymbol{v}_k^T S \boldsymbol{v}_k,
\end{aligned} \tag{A.2}$$

と表されるため，$\boldsymbol{v}_k^T S \boldsymbol{v}_k$ は (2.1) 式の分散と等しい．

B　線形回帰モデルにおける Knockoff 法の証明

ここでは，はじめに (4.23) 式の線形回帰モデルにおける交換可能性の証明を行う．そのあと，(4.22) 式により FDR 制御が実行可能であることを証明する．

i　交換可能性の証明

まず，統計量 $\boldsymbol{W} = (W_1, \ldots, W_p)^T$ は次の 2 つの性質を有する．

- $\boldsymbol{W}$ は $[X, \tilde{X}]^T[X, \tilde{X}]$ と $[X, \tilde{X}]^T\boldsymbol{y}$ にのみ依存する十分性の性質を有する．
  いま，lasso の (4.17) 式を展開すると

$$\frac{1}{2n}\left\{\boldsymbol{y}^T\boldsymbol{y} - 2\boldsymbol{\beta}^T[X, \tilde{X}]^T\boldsymbol{y} + \boldsymbol{\beta}^T[X, \tilde{X}]^T[X, \tilde{X}]\boldsymbol{\beta}\right\} + \lambda \|\boldsymbol{\beta}\|_1 \tag{B.1}$$

  が得られ，このとき，(B.1) 式の最小値を与える $\hat{\boldsymbol{\beta}}$ は $[X, \tilde{X}]^T[X, \tilde{X}]$ と $[X, \tilde{X}]\boldsymbol{y}$ にのみ依存することが分かるため，$\boldsymbol{W}$ も同様に $[X, \tilde{X}]^T[X, \tilde{X}]$ と $[X, \tilde{X}]\boldsymbol{y}$ にのみ依存する．

  本節では，説明の便宜上，$\boldsymbol{W}$ が十分性を持つことを強調したい場合は，$\boldsymbol{W}$ を $\boldsymbol{W}([X, \tilde{X}]^T[X, \tilde{X}], [X, \tilde{X}]\boldsymbol{y})$ と表記することとする．

- $\beta_j = 0$ を満たす添字番号集合 S に関して，X の j 列目と $\tilde{X}$ の j 列目 $(j \in S)$ の位置を交換した上で計算された統計量を $\boldsymbol{W}_{swap(S)}$ とおく．このとき，$\boldsymbol{W}_{swap(S)}$ は W_j の正負が逆になる反対称性の性質を有する．すなわち，$\boldsymbol{W}_{swap(S)}$ は次の式を満たす．

$$\boldsymbol{W}_{swap(S)} = (W_1\epsilon_1, \ldots, W_p\epsilon_p), \quad \epsilon_j = \begin{cases} +1 & j \notin S, \\ -1 & j \in S, \end{cases} \quad j = 1, \ldots, p. \tag{B.2}$$

  $\boldsymbol{W}$ が反対称性をもつように (4.18) 式を設定しているため，この性質は明らかである．

次に，Knockoff 変数を作成することにより次の 2 つの補題が成立する．

Lemma 2. 任意の添字番号集合 $S \subset \{1, \ldots, p\}$ に関して，

$$[X, \tilde{X}]_{swap(S)}^T[X, \tilde{X}]_{swap(S)} = [X, \tilde{X}]^T[X, \tilde{X}], \tag{B.3}$$

が成り立つ．ただし，$[X, \tilde{X}]_{swap(S)}$ は $[X, \tilde{X}]$ の j 列目と $j + p$ 列目 $(j \in S)$ の位置を交換した行列である．

Proof. (B.3) 式の左辺を展開する際に，(4.14)，(4.15) 式や，この 2 式を組み合わせた式を用いると，(B.3) 式の右辺に変形することができる． □

この補題は，オリジナル変数と Knockoff 変数のうち，同じ添字番号の場所を交換しても $[X, \tilde{X}]^T[X, \tilde{X}]$ の値は変わらないことを意味する．

Lemma 3. 帰無仮説が正しい添字番号集合，すなわち $\beta_j = 0$ を満たす添字番号集合 S に関して，

$$[X, \tilde{X}]^T_{swap(S)} \boldsymbol{y} \stackrel{d}{=} [X, \tilde{X}]^T \boldsymbol{y}, \tag{B.4}$$

が成り立つ．

Proof. 線形回帰モデルにおいて，観測誤差 $\boldsymbol{\varepsilon}$ が $N(0, \sigma^2 I)$ にしたがうと仮定した場合，目的変数 $\boldsymbol{y}$ は $N(X\boldsymbol{\beta}, \sigma^2 I)$ にしたがうので，

$$[X, \tilde{X}]^T_{swap(S)} \boldsymbol{y} \sim N\left([X, \tilde{X}]^T_{swap(S)} X\boldsymbol{\beta}, \sigma^2 [X, \tilde{X}]^T_{swap(S)} [X, \tilde{X}]_{swap(S)}\right), \tag{B.5}$$

が成り立つ．ここで，$[X, \tilde{X}]^T_{swap(S)} X\boldsymbol{\beta}$ は，(4.15) 式と，$\beta_j = 0$ の場合に限り $\boldsymbol{x}_j^T X\boldsymbol{\beta} = \tilde{\boldsymbol{x}}_j^T X\boldsymbol{\beta} = 0$ が成立することから，

$$[X, \tilde{X}]^T_{swap(S)} X\boldsymbol{\beta} = [X, \tilde{X}]^T X\boldsymbol{\beta}, \tag{B.6}$$

が成り立つ．また，(B.3) 式を用いることにより，(B.5) 式の正規分布の分散共分散行列は $[X, \tilde{X}]^T [X, \tilde{X}]$ と等しいことが分かる． □

この補題は，オリジナル変数と Knockoff 変数の同じ添字番号の場所を交換しても，$[X, \tilde{X}]^T \boldsymbol{y}$ の分布は変わらないことを意味する．

以上より，$\beta_j = 0$ を満たす添字番号集合 S に関して，

$$\begin{aligned} -\boldsymbol{W} &= \boldsymbol{W}_{swap(S)} \\ &= \boldsymbol{W}([X, \tilde{X}]^T_{swap(S)} [X, \tilde{X}]_{swap(S)}, [X, \tilde{X}]^T_{swap(S)} \boldsymbol{y}) \\ &\stackrel{d}{=} \boldsymbol{W}([X, \tilde{X}]^T [X, \tilde{X}], [X, \tilde{X}]^T \boldsymbol{y}) \\ &= \boldsymbol{W}, \end{aligned} \tag{B.7}$$

が成立する．(B.7) 式の 1 行目の等号は $S = \{j : \epsilon_j = -1\}$ に対する反対称性を表しており，2 行目は十分性を示す．また，3 行目は Lemma 3 を用いている．したがって，$\beta_j = 0$ を満たす添字番号集合 S に関して，

$$\boldsymbol{W} \stackrel{d}{=} -\boldsymbol{W}, \tag{B.8}$$

が成り立つ．これは，$\#\{j : j \in \mathcal{A}^c \text{ and } W_j \geq t\} \stackrel{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } W_j \leq -t\}$ と同じ意味である．

ii　(4.22) 式による FDR 制御の証明

証明の手順は (5.8) 式を証明する場合と同様である．

まず，帰無仮説 $H_{0,j}$ $(j = 1, \ldots, p)$ に関して p 値を p_j $(j = 1, \ldots, p)$ と設定する．帰無仮説が正しい p 値は一様分布にしたがい，これらは互いに独立であるとする．次に，棄却限界値 $\hat{m}$ を次式のように定義する．

$$\hat{m} = \max\left\{m \in M : \frac{1 + \#\{j : j \leq m \text{ and } p_j > c\}}{\#\{j : j \leq m \text{ and } p_j \leq c\} \vee 1} \leq \frac{1-c}{c}\, q\right\}. \tag{B.9}$$

ここで，c $(0 < c < 1)$ は任意の値をとり，$M \subset \{1, \ldots, p\}$ である．$p_j \leq c$ かつ，$j \leq \hat{m}$ を満たす帰無仮説 $H_{0,j}$ を棄却するとき，

$$E\left[\frac{\#\{j : \beta_j = 0 \text{ and } j \leq \hat{m} \text{ and } p_j \leq c\}}{\#\{j : j \leq \hat{m} \text{ and } p_j \leq c\} \vee 1}\right] \leq q, \tag{B.10}$$

が成立する．これは (5.16) 式と同様，あらかじめ設定した値 q で FDR 制御が可能であることを意味する．

次に，値が非 0 である統計量 $\boldsymbol{W}$ の個数を m $(\leq p)$ とし，これを絶対値の降順に並べたものを $W'_1, \ldots, W'_m$ と設定する．すなわち，

$$|W'_1| \geq \ldots \geq |W'_m| > 0, \tag{B.11}$$

である．次に，p 値を以下のように設定する．

$$p_j = \begin{cases} \dfrac{1}{2}, & W'_j > 0, \\ 1, & W'_j < 0, \end{cases} \qquad j = 1, \ldots, m. \tag{B.12}$$

また，帰無仮説が正しい場合において，すなわち，$\beta_j = 0$ において

$$\Pr\left\{p_j = \frac{1}{2}\right\} = \Pr\{p_j = 1\} = \frac{1}{2}, \tag{B.13}$$

が成り立つ．これは，(B.12) 式を用いて (4.23) 式の交換可能性を p 値を含んだ形に言い換えたものである．したがって，帰無仮説が正しい p 値は一様分布にしたがい，互いに独立である．これは統計量 W_j においても同様であるため，Knockoff 法の場合でも FDR 制御が可能である．

最後に，p 値の棄却域の上限を表す (B.9) 式の $\hat{m}$ が，(4.21) 式のしきい値 T と同値であることを示す．まず，(B.9) 式に $c = \frac{1}{2}$ を代入し，統計量 W_j を含む形式で表すと

$$\hat{m} = \max\left\{ m \in M : \frac{1 + \#\{j : j \leq m \text{ and } W'_j < 0\}}{\#\{j : j \leq m \text{ and } W'_j > 0\} \vee 1} \leq q \right\}, \tag{B.14}$$

である．ここで，$j \leq m$ の場合において (B.11) 式を考慮すると，$W'_j < 0$ は $W'_j \leq -|W'_m|$ と同値であり，$W_j > 0$ は $|W'_j| \geq |W'_m|$ と同値であることが分かる．したがって，(B.14) 式は

$$\hat{m} = \max\left\{ m \in M : \frac{1 + \#\{j : W'_j \leq -|W'_m|\}}{\#\{j : W'_j \geq |W'_m|\} \vee 1} \leq q \right\}, \tag{B.15}$$

と書き換えられる．(B.15) 式の不等式を満たす m の最大値を求めることは，(B.15) 式の不等式を満たす $|W'_m|$ の最小値を求めること，すなわち (4.21) 式を計算することである．

C　ガウシアングラフィカルモデルにおける Knockoff 法の交換可能性

ここでは，Yu et al. (2021) が提案したガウシアングラフィカルモデルにおける交換可能性の証明を行う．まず，ガウシアングラフィカルモデルにおける Knockoff 法の手順の概要を述べたあと，交換可能性の証明に移る．

i　Knockoff 手順

ガウシアングラフィカルモデルとは，多変量正規分布 $N(\boldsymbol{\mu}, \Sigma)$ の精度行列 Σ^{-1} のうち，非 0 となる成分を推定することで，変数間の構造をグラフ化しデータの解析

を行う手法である．ガウシアングラフィカルモデルに関する詳細は川野秀一 et al. (2018) を参照されたい．

いま，$N_p(\mathbf{0}_p, \Sigma)$ にしたがう観測データ $\boldsymbol{x}_i = (x_1, \ldots, x_p)^T$ $(i = 1, \ldots, n)$ が得られたとする．このとき，ガウシアングラフィカルモデル $\mathcal{G}$

$$\mathcal{G} = (V, \mathcal{E}), \tag{C.1}$$

を考える．ここで $V = \{1, \ldots, p\}$ は p 個の変数集合であり，$\mathcal{E} = \{(i, j) \in V \times V : i, j = 1, \ldots, p,\ i \neq j\}$ は変数間の関係を表す．V から変数を 2 つ取り出し，それらが条件付き独立であるかを判断するためには，精度行列の値が 0 であるか，非 0 であるかを決定しなければならない．この判断を仮説検定問題の枠組みで捉えるため，帰無仮説を

$$H_{0,ij} : (\Sigma^{-1})_{ij} = 0 \quad i, j = 1, \ldots, p, \tag{C.2}$$

と設定する．この場合，対立仮説は $H_{1,ij} : (\Sigma^{-1})_{ij} \neq 0$ と表せる．以下，Knockoff 法を用いた FDR 制御の方法を述べる．

Knockoff 法による，ガウシアングラフィカルモデルのしきい値パラメータの導出手順は次の通りである．

1. Knockoff 偏相関行列 $\tilde{C}'_{ij}$ の作成
2. 統計量 $\boldsymbol{W}$ の導出
3. しきい値 T の導出
4. 変数の選択，およびしきい値パラメータ t の導出

これらの手順を以下に述べる．

1. Knockoff 偏相関行列 $\tilde{C}'_{ij}$ の作成

   観測データにより得られた標本偏相関行列を

$$C'_{ij} = -\frac{(\hat{\Sigma}^{-1})_{ij}}{\sqrt{(\hat{\Sigma}^{-1})_{ii}(\hat{\Sigma}^{-1})_{jj}}}, \quad i, j = 1, \ldots, p, \tag{C.3}$$

と表す．ここで，$\hat{\Sigma}^{-1}$ は観測された精度行列を表す．母集団の偏相関係数が 0 という仮説の下では，以下の値 R'_{ij}

$$R'_{ij} = -\frac{C'_{ij}}{\sqrt{1-(C'_{ij})^2/(n-p)}}, \quad i,j = 1,\ldots,p, \tag{C.4}$$

が自由度 $n-p$ の t 分布にしたがうことが知られている (Fisher, 1924)．これより，Knockoff 偏相関行列を以下のように設定する．

$$\tilde{C}'_{ij} = \tilde{C}'_{ji} = \begin{cases} 1, & i = j, \\ \frac{R'_{ij}}{\sqrt{n-p+R'^2_{ij}}}, & i \neq j. \end{cases} \tag{C.5}$$

非対角成分は R'_{ij} を標本偏相関行列 $\tilde{C}'_{ij}$ について解いたものであり，また，対角成分の値をすべて 1 に設定する．

2. 統計量 $\boldsymbol{W}$ の導出

まず，以下の罰則付き問題を解く．

$$\begin{aligned} \hat{C}'(t) &= \underset{A\in S}{\operatorname{argmin}} \left\{ \|C' - A\|_F^2 + t^2 \|A\|_0 \right\}, \\ \hat{\tilde{C}}'(t) &= \underset{A\in S}{\operatorname{argmin}} \left\{ \|\tilde{C}' - A\|_F^2 + t^2 \|A\|_0 \right\}. \end{aligned} \tag{C.6}$$

ここで，$t\ (>0)$ はしきい値パラメータである．その後，$(\hat{C}'(t))_{ij}$ の値が非 0 となるしきい値パラメータのうち，最大値を Z_{ij} とする．これを偏相関行列の要素ごとに行う．Knockoff 偏相関行列 $(\hat{\tilde{C}}'(t))_{ij}$ についても同様に行い，$\tilde{Z}_{ij}$ とする．すなわち，Z_{ij}，$\tilde{Z}_{ij}$ は次の式でまとめられる．

$$\begin{aligned} Z_{ij} &= \sup \left\{ t \colon (\hat{C}'(t))_{ij} \neq 0 \right\}, \\ \tilde{Z}_{ij} &= \sup \left\{ t \colon (\hat{\tilde{C}}'(t))_{ij} \neq 0 \right\}, \end{aligned} \quad i,j = 1,\ldots,p. \tag{C.7}$$

次に，Z_{ij} と $\tilde{Z}_{ij}$ を比較し，Z_{ij} の値が大きい場合は $W_{ij} = Z_{ij}$ とし，逆の場合は $W_{ij} = -\tilde{Z}_{ij}$ とする．また，$i = j$ の場合は $W_{ij} = 0$ とする．したがって，W_{ij}

は次式でまとめられる．

$$W_{ij} = W_{ji} = \begin{cases} (Z_{ij} \vee \tilde{Z}_{ij}) \cdot \mathrm{sign}(Z_{ij} - \tilde{Z}_{ij}), & i \neq j, \\ 0, & i = j. \end{cases} \tag{C.8}$$

このとき，統計量 W_{ij} をまとめた行列を

$$\boldsymbol{W} = \begin{bmatrix} W_{11} & \cdots & W_{1p} \\ W_{21} & \cdots & W_{2p} \\ \vdots & \ddots & \vdots \\ W_{p1} & \cdots & W_{pp} \end{bmatrix}, \tag{C.9}$$

で表す．

3. しきい値 T の導出

   $\boldsymbol{W}$ を用いて，次式を満たす T を算出する．

$$T = \min \left\{ t \in \mathcal{W} \colon \frac{\#\{(i,j) \colon W_{ij} \leq -t\}}{\#\{(i,j) \colon W_{ij} \geq t\} \vee 1} \leq q \right\}. \tag{C.10}$$

   ただし，$\mathcal{W} = \{|W_{ij}| : i, j \in \{1, \ldots, p\}\} \setminus \{0\}$ である．(C.10) 式により，あらじめ設定した FDR 値 q $(0 \leq q \leq 1)$ 以下を満たすようなしきい値 T を計算する．

   (C.10) 式は交換可能性が成立した場合に限り，FDR 制御が可能である．ガウシアングラフィカルモデルにおける交換可能性は次式で表される．

$$\#\{j : j \in \mathcal{A}^c \text{ and } W_{ij} \geq t\} \overset{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } W_{ij} \leq -t\}. \tag{C.11}$$

   ここで，$\mathcal{A}$ は，$(\Sigma^{-1})_{ij}$ のうち，非 0 となる精度行列の成分集合である．交換可能性の証明は次項で説明する．

4. 変数の選択，およびしきい値パラメータ t の導出

   最後に，$W_{ij} \geq T$ $(i, j = 1, \ldots, p)$ を満たす精度行列の (i, j) 成分を選択する．これが，FDR 制御を行った際に選択された精度行列の成分番号集合となるため，しきい値パラメータの範囲を算出することができる．

ii　交換可能性の証明

まず，$\boldsymbol{W}$ が持つ性質について述べる．$(\Sigma^{-1})_{ij}=0$ を満たす成分番号集合 S に関して，C'_{ij} と $\tilde{C}'_{ij}$ $((i,j)\in S)$ の位置を交換して計算された統計量を $\boldsymbol{W}_{swap(S)}$ とおく．このとき，$\boldsymbol{W}_{swap(S)}$ は W_{ij} の正負が逆になる反対称性の性質を有する．すなわち，$\boldsymbol{W}_{swap(S)}$ は次の式で表される．

$$\boldsymbol{W}_{swap(S)}=\begin{bmatrix} W_{11}\epsilon_{11} & \cdots & W_{1p}\epsilon_{1p} \\ W_{21}\epsilon_{21} & \cdots & W_{2p}\epsilon_{2p} \\ \vdots & \ddots & \vdots \\ W_{p1}\epsilon_{p1} & \cdots & W_{pp}\epsilon_{pp} \end{bmatrix}, \epsilon_{ij}=\begin{cases} +1 & (i,j)\notin S, \\ -1 & (i,j)\in S, \end{cases} \quad i,j=1,\cdots,p. \tag{C.12}$$

$\boldsymbol{W}$ が反対称性を持つように (C.7) 式を設定しているため，この性質は明らかである．

次に，Knockoff 偏相関行列を作成することにより次の補題が成り立つ．

Lemma 4. $(\Sigma^{-1})_{ij}=0$ を満たす任意の成分番号集合 $S\subset\{(k,l)\in V\times V : k\neq l\}$ に対して，

$$(W_{swap(S)})_{ij}\overset{d}{=}W_{ij}, \tag{C.13}$$

が成り立つ．

Proof. $(\Sigma^{-1})_{ij}=0$ の条件下では，(C.5) 式より，

$$C'_{ij}\overset{d}{=}\tilde{C}'_{ij}, \tag{C.14}$$

であり，この分布の同等性は (C.6) 式の要素ごとのしきい値処理でも成り立つことが分かる．したがって，(C.7) 式においても (C.14) 式の等価性は成り立つため，$Z_{ij}\overset{d}{=}\tilde{Z}_{ij}$ が成立する．同様に，$\mathrm{sign}(Z_{ij}-\tilde{Z}_{ij})\overset{d}{=}\mathrm{sign}(\tilde{Z}_{ij}-Z_{ij})$ であり，$Z_{ij}\vee\tilde{Z}_{ij}$ と $\tilde{Z}_{ij}\vee Z_{ij}$ の値は明らかに等しいので，

$$(W_{swap(S)})_{ij}\overset{d}{=}W_{ij}, \tag{C.15}$$

が成立する． □

この補題は，偏相関行列の要素を交換しても $\boldsymbol{W}$ の分布は変わらないことを意味

している．

以上の $\boldsymbol{W}$ の性質と Lemma4 より，$(\Sigma^{-1})_{ij} = 0$ を満たす任意の要素番号集合 S に関して，

$$W_{ij} = (W_{swap(S)})_{ij} \overset{d}{=} -W_{ij}, \tag{C.16}$$

が成立する．これは，$\#\{j : j \in \mathcal{A}^c \text{ and } W_{ij} \geq t\} \overset{d}{=} \#\{j : j \in \mathcal{A}^c \text{ and } W_{ij} \leq -t\}$ と同じ意味である．

D　モンテカルロ p 値の計算方法

ここでは，6.2 節のモンテカルロ p 値の計算方法を述べる．第 1 主成分から第 3 主成分まで，各主成分ごとに説明する．

- 第 1 主成分のモンテカルロ p 値 $p_{11}, \ldots, p_{1p}$ を求める手順

  1. S_{-j} を $S = \frac{1}{n}X^TX$ から j 行 j 列を取り除いた行列とし，S_{-j} に対して最大固有値 $\hat{\lambda}_1$，そのときの固有ベクトル $\hat{\boldsymbol{P}}_1$ を得る．
  2. 第 j 成分は 0 で，他の成分は $\hat{\boldsymbol{P}}_1$ となる p 次元ベクトル $\hat{\boldsymbol{P}}_1^j$ を作成する．
  3. $S - \hat{\lambda}_1 \hat{\boldsymbol{P}}_1^j \hat{\boldsymbol{P}}_1^{jT}$ に対して $p-1$ 個の固有値を得て，降順に $\hat{\lambda}_2, \ldots, \hat{\lambda}_p$ と設定する．また，そのときの固有ベクトル $\hat{\boldsymbol{P}}_2, \ldots, \hat{\boldsymbol{P}}_p$ を得る．
  4. 行列

  $$\hat{\Sigma}_0 = \hat{\lambda}_1 \hat{\boldsymbol{P}}_1^j \hat{\boldsymbol{P}}_1^{jT} + \hat{\lambda}_2 \hat{\boldsymbol{P}}_2 \hat{\boldsymbol{P}}_p^T + \cdots + \hat{\lambda}_p \hat{\boldsymbol{P}}_p \hat{\boldsymbol{P}}_p^T, \tag{D.1}$$

  を計算する．この行列は帰無仮説の下でデータ $\boldsymbol{x}_i$ が従う分布の分散共分散行列を表している．

  5. 行列

  $$\hat{\Sigma}_1 = \frac{1}{n}X^TX, \tag{D.2}$$

  を計算する．

6. $\hat{\Sigma}_0$，$\hat{\Sigma}_1$ を用いて尤度比検定統計量に対数を施した $-2\log\Gamma$ を次式により計算する．

$$-2\log\Gamma = -2\log\frac{\prod_{i=1}^{n}\frac{1}{(2\pi)^{\frac{p}{2}}|\hat{\Sigma}_0|^{\frac{1}{2}}}\exp[-\frac{1}{2}\boldsymbol{x}_i^T\hat{\Sigma}_0^{-1}\boldsymbol{x}_i]}{\prod_{i=1}^{n}\frac{1}{(2\pi)^{\frac{p}{2}}|\hat{\Sigma}_1|^{\frac{1}{2}}}\exp[-\frac{1}{2}\boldsymbol{x}_i^T\hat{\Sigma}_1^{-1}\boldsymbol{x}_i]}. \tag{D.3}$$

7. 帰無分布 $N_p(\boldsymbol{0},\acute{\Sigma})$ に従う p 次元ベクトルを n 個発生させ，まとめて $X^{(b)} = (\boldsymbol{x}_1^{(b)},\ldots,\boldsymbol{x}_n^{(b)})^T$ と表す．ここで，$\acute{\Sigma}$ は第 j 成分に関する帰無仮説が正しいときの分散共分散行列である．例えば，$j=1$ の場合を例に挙げると，帰無仮説は $H_{0,11}: v_{11}=0$，対立仮説は $H_{1,11}: v_{11}\neq 0$ と表される．このとき，$\acute{\Sigma}$ を

$$\acute{\Sigma} = \acute{P}\Lambda\acute{P}^T, \tag{D.4}$$

と設定する．ここで，$\acute{P}$ は (6.2) 式の第 1 要素を 0 と変更したベクトル

$$\ddot{\boldsymbol{p}}_1 = (0,1,0,1,0,1,1,0,0,0,0,0,0,0,0)^T, \tag{D.5}$$

を用いて構成される $\ddot{\boldsymbol{p}}_1,\dot{\boldsymbol{p}}_2,\ldots,\dot{\boldsymbol{p}}_p$ を，グラムシュミット直交化法により直交ベクトルとした固有ベクトルである．

8. 帰無仮説の下でデータ $\boldsymbol{x}_i^{(b)}$ が従う分布の分散共分散行列 $\hat{\Sigma}_0^{(b)}$ を，手順 1 から 4 と同様の操作により計算する．

9. 行列

$$\hat{\Sigma}_1^{(b)} = \frac{1}{n}X^{(b)T}X^{(b)}, \tag{D.6}$$

を計算する．

10. $\hat{\Sigma}_0^{(b)}$，$\hat{\Sigma}_1^{(b)}$ を用いて尤度比検定統計量に対数を施した $-2\log\Gamma^{(b)}$ を次式により計算する．

$$-2\log\Gamma^{(b)} = -2\log\frac{\prod_{i=1}^{n}\frac{1}{(2\pi)^{\frac{p}{2}}|\hat{\Sigma}_0^{(b)}|^{\frac{1}{2}}}\exp[-\frac{1}{2}\boldsymbol{x}_i^{(b)T}\hat{\Sigma}_0^{(b)-1}\boldsymbol{x}_i^{(b)}]}{\prod_{i=1}^{n}\frac{1}{(2\pi)^{\frac{p}{2}}|\hat{\Sigma}_1^{(b)}|^{\frac{1}{2}}}\exp[-\frac{1}{2}\boldsymbol{x}_i^{(b)T}\hat{\Sigma}_1^{(b)-1}\boldsymbol{x}_i^{(b)}]}. \tag{D.7}$$

11. 手順7から手順10を $B = 10,000$ 回反復することで，$-2\log\Gamma^{(b)}$ を $10,000$ 個作成する．

12. 次式より，モンテカルロ p 値 p_{1j} を得る．

$$p_{1j} = \frac{1}{B+1}\left\{1 + \Sigma_{b=1}^{B}\mathrm{I}(-2\log\Gamma^{(b)} \geq -2\log\Gamma)\right\}. \tag{D.8}$$

ここで，$\mathrm{I}(\cdot)$ は指示関数であり，

$$\mathrm{I}(A) = \begin{cases} 1, & A\text{が成立する}, \\ 0, & A\text{が成立しない}, \end{cases} \tag{D.9}$$

で定義される．

$j = 1, \ldots, p$ に対して手順1から手順12を実行すると第1主成分における p 値 $p_{11}, \ldots, p_{1p}$ が計算される．

- 第2主成分のモンテカルロ p 値 $p_{21}, \ldots, p_{2p}$ を求める手順

1. $S = \frac{1}{n}X^TX$ から最大固有値とそのときの固有ベクトルを得て，それぞれ $\hat{\lambda}_1$，$\hat{\boldsymbol{P}}_1$ とする．
2. S_{-j} を $S - \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T$ から j 行 j 列を抜いた行列とし，S_{-j} に対して最大固有値 $\hat{\lambda}_2$，そのときの固有ベクトル $\hat{\boldsymbol{P}}_2$ を得る．
3. 第 j 成分は0で，他の成分は $\hat{\boldsymbol{P}}_2$ となる p 次元ベクトル $\hat{\boldsymbol{P}}_2^j$ を作成する．
4. $S - \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T - \hat{\lambda}_2\hat{\boldsymbol{P}}_2^j\hat{\boldsymbol{P}}_2^{jT}$ から $p-2$ 個の固有値を得て，降順に $\hat{\lambda}_3, \ldots, \hat{\lambda}_p$ と設定する．また，そのときの固有ベクトル $\hat{\boldsymbol{P}}_3, \ldots, \hat{\boldsymbol{P}}_p$ を得る．
5. 行列

$$\hat{\Sigma}_0 = \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T + \hat{\lambda}_2\hat{\boldsymbol{P}}_2^j\hat{\boldsymbol{P}}_2^{jT} + \cdots + \hat{\lambda}_p\hat{\boldsymbol{P}}_p\hat{\boldsymbol{P}}_p^T, \tag{D.10}$$

を計算する．この行列は帰無仮説の下でデータ $\boldsymbol{x}_i$ が従う分布の分散共分散行列を表している．

これ以降の操作は第1主成分の手順5から手順12と同様である．

- 第3主成分のモンテカルロ p 値 $p_{31}, \ldots, p_{3p}$ を求める手順

1. $S = \frac{1}{n}X^TX$ から最大固有値とそのときの固有ベクトルを得て，それぞれ $\hat{\lambda}_1$，$\hat{\boldsymbol{P}}_1$ とする．
2. $S = \frac{1}{n}X^TX - \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T$ から最大固有値とそのときの固有ベクトルを得て，それぞれ $\hat{\lambda}_2$，$\hat{\boldsymbol{P}}_2$ とする．
3. S_{-j} を $S - \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T - \hat{\lambda}_2\hat{\boldsymbol{P}}_2\hat{\boldsymbol{P}}_2^T$ から j 行 j 列を抜いた行列とし，S_{-j} に対して最大固有値 $\hat{\lambda}_3$，そのときの固有ベクトル $\hat{\boldsymbol{P}}_3$ を得る．
4. 第 j 成分は 0 で，他の成分は $\hat{\boldsymbol{P}}_3$ となる p 次元ベクトル $\hat{\boldsymbol{P}}_3^j$ を作成する．
5. $S - \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T - \hat{\lambda}_2\hat{\boldsymbol{P}}_2\hat{\boldsymbol{P}}_2^T - \hat{\lambda}_3\hat{\boldsymbol{P}}_3^j\hat{\boldsymbol{P}}_3^{jT}$ から $p-3$ 個の固有値を得て，降順に $\hat{\lambda}_4, \ldots, \hat{\lambda}_p$ と設定する．また，そのときの固有ベクトル $\hat{\boldsymbol{P}}_4, \ldots, \hat{\boldsymbol{P}}_p$ を得る．
6. 行列

$$\hat{\Sigma}_0 = \hat{\lambda}_1\hat{\boldsymbol{P}}_1\hat{\boldsymbol{P}}_1^T + \hat{\lambda}_2\hat{\boldsymbol{P}}_2\hat{\boldsymbol{P}}_2^T + \hat{\lambda}_3\hat{\boldsymbol{P}}_3^j\hat{\boldsymbol{P}}_3^{jT} + \cdots + \hat{\lambda}_p\hat{\boldsymbol{P}}_p\hat{\boldsymbol{P}}_p^T, \qquad \text{(D.11)}$$

を計算する．この行列は帰無仮説の下でデータ $\boldsymbol{x}_i$ が従う分布の分散共分散行列を表している．

これ以降の操作は第 1 主成分の手順 5 から手順 12 と同様である．

参考文献

Barber, R. F. and Candès, E. (2015). Controlling the false discovery rate via knockoffs. *The Annals of Statistics*, **43**(5), 2055–2085.

Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society, Series B*, **57**(1), 289–300.

Benjamini, Y. and Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, **29**(4), 1165–1188.

Boyd, S. and Lieven, V. (2004). *Convex Optimization.* Cambridge University Press, New York.

Dai, R. and Zheng, C. (2023). False discovery rate ‐ controlled multiple testing for union null hypotheses: a knockoff ‐ based approach. *Biometrics*, **79**, 3497–3509.

Fisher, R. (1915). Frequency distribution of the values of the correlation coeffcient in samples from an indenitely large population. *Biometrika*, **10**(4), 507–521.

Fisher, R. (1924). On the “probable error“ of a coefcient of correlation deduced from a small sample. *Metron*, **1**, 3–32.

Jolliffe, I. T. (2002). *Principal Component Analysis.* Spriinger, New York.

Jolliffe, I. T., Trendafilov, N. T., and Uddin, M. (2003). A modified principal component technique based on the lasso. *Journal of Computational and Graphical Statistics*, **12**(13), 531–547.

Romano, Y., Sesia, M., and Candès, E. J. (2019). Deep knockoffs. *Journal of the American Statistical Association*, 1–12.

Sesia, M., Sabatti, C., and Candès, E. J. (2019). Gene hunting with hidden markov model knockoffs. *Biometrika*, **106**(1), 1–18.

Storey, J. D., Taylor, J. E., and Siegmund, D. (2004). Strong control, conservative point estimation and simultaneous conservative consistency of false discovery rates: A unified approach. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, **66**(1), 187–205.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society, Series B*, **58**(1), 267–288.

Tibshirani, R., Saunders, M., Rosset, S., Zhu, J., and Knight, K. (2005). Sparsity and smoothness via the fused lasso. *Journal of the Royal Statistical Society, Series B*, **67**(1), 91–108.

Trendafilov, N. T. and Jolliffe, I. T. (2006). Projected gradient approach to the numerical solution of the scotlass. *Computational Statistics and Data Analysis*, **50**(10), 242–253.

Witten, D. M., Tibshirani, R., and Hastie, T. (2009). A penalized matrix decomposition, with applications to sparse principal components and canonical correlation analysis. *Biostatistics*, **10**(3), 515–534.

Yu, L., Kaufmann, T., and Lederer, J. (2021). False discovery rates in biological networks. *Proceedings of International Conference on Artificial Intelligence and Statistics*, 163–171.

Zou, H. and Xue, L. (2018). A selective overview of sparse principal component analysis. *Proceedings of the IEEE*, **106**(8), 1311–1320.

Zou, H., Hastie, T., and Tibshirani, R. (2006). Sparse principal component analysis. *Journal of Computational and Graphical Statistics*, **15**(2), 265–286.

川野秀一, 松井秀俊, and 廣瀬慧. (2018). **スパース推定法による統計モデリング**. 共立出版.

汪金芳 and 桜井裕仁. (2011). R で学ぶデータサイエンス 4 ブートストラップ入門. 共立出版.