令和 6 年 2 月 5 日

情報・ネットワーク工学専攻　修士論文発表会予稿

二重頑健推定法における球共分散に基づく共変量選択

情報数理工学プログラム　2231150　西山悠研究室　武藤大樹

1　はじめに

因果効果を推定することは，医学，経済学や教育学など様々な分野で役立てられている．因果効果値を推定する方法の 1 つとして，Koch et al.（2017）は Group Lasso and Doubly Robust Estimation（GLiDeR）を提案した．しかし，この方法では，真の結果モデルが非線形であるとき，因果効果値の推定の精度が悪くなるという問題がある．この問題を解決するために，球共分散（Pan et al., 2020）に着目し，真の結果モデルが非線形であったとしても，因果効果値の推定を精度良く行う GLiDeR を提案する．

2　二重頑健推定法

因果効果値を推定する方法の 1 つとして，二重頑健推定法（Bang and Robins, 2005; Hoshino, 2007）がある．二重頑健推定法では，割り当て変数と共変量のモデル（傾向スコアモデル）と共変量で結果変数を説明する回帰関数（結果モデル）の 2 つのモデルを求める必要がある．

3　GLiDeR

Koch et al.（2017）は二重頑健推定法により因果効果値を推定する方法として，GLiDeR を提案した．GLiDeR は次の最小化問題として定式化される．

$$\underset{\boldsymbol{\beta}}{\operatorname{argmin}} \frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\boldsymbol{\beta}) + \lambda\sum_{k=1}^{p} W_k\|\beta_k\|_2.$$

ただし，n はデータ数，$\boldsymbol{Y}$ は結果変数，$\boldsymbol{X}$ は割り当て変数，$\boldsymbol{C} = (\boldsymbol{C}_1,\ldots,\boldsymbol{C}_p)$ は共変量，$\boldsymbol{\beta} = (\beta_1,\ldots,\beta_{p+3})^T$ は結果モデルの回帰係数と傾向スコアモデルの回帰係数をグループ化したもの，$\lambda\ (\geq 0)$ は正則化パラメータ，W_k は正の重み，$\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\boldsymbol{\beta})$ は結果モデルにおける誤差 2 乗和と傾向スコアモデルにおける負の対数尤度関数の和である．

4　球共分散

2 変数間の非線形性をとらえることができる尺度として Pan et al.（2020）が提案した球共分散 BCov がある．これに対して，因果効果値の推定に用いるため，Tang et al.（2023）は割り当て変数 $\boldsymbol{X}$ で条件付けたもとで α 番目の共変量 $\boldsymbol{C}_\alpha$ と結果変数 $\boldsymbol{Y}$ の条件付き球共分散 $\mathrm{BCov}^2(\boldsymbol{C}_\alpha,\boldsymbol{Y}\mid\boldsymbol{X})$ を定義している．実際に計算を行うときは経験的条件付き球共分散

$$\begin{aligned}&\mathrm{BCov}_n^2(\boldsymbol{C}_\alpha,\boldsymbol{Y}\mid\boldsymbol{X})\\ &= \frac{\hat{\omega}}{n_1^6}\sum_{(i,j,k,l,s,t):\ X_i,X_j,X_k,X_l,X_s,X_t=1} \xi_{ij,klst}^{\boldsymbol{C}_\alpha}\xi_{ij,klst}^{\boldsymbol{Y}}\\ &+ \frac{1-\hat{\omega}}{n_0^6}\sum_{(i,j,k,l,s,t):\ X_i,X_j,X_k,X_l,X_s,X_t=0} \xi_{ij,klst}^{\boldsymbol{C}_\alpha}\xi_{ij,klst}^{\boldsymbol{Y}}\end{aligned}$$

を用いて条件付き球共分散を求める．ここで，n_1 を処置群に割り当てられる個数，n_0 は処置群に割り当てられない個数，$\hat{\omega} = n_1/(n_1+n_0)$ は処置群に割り当てられる確率 ω の経験的推定量である．また，$\xi_{ij,klst}^{\boldsymbol{C}_\alpha}$ は

$$\begin{aligned}\delta_{ij,k}^{\boldsymbol{C}_\alpha} &= I(C_{k\alpha}\in\bar{B}_\rho(C_{i\alpha},C_{j\alpha})),\\ \delta_{ij,kl}^{\boldsymbol{C}_\alpha} &= \delta_{ij,k}^{\boldsymbol{C}_\alpha}\delta_{ij,l}^{\boldsymbol{C}_\alpha},\\ \xi_{ij,klst}^{\boldsymbol{C}_\alpha} &= (\delta_{ij,kl}^{\boldsymbol{C}_\alpha}+\delta_{ij,st}^{\boldsymbol{C}_\alpha}-\delta_{ij,ks}^{\boldsymbol{C}_\alpha}-\delta_{ij,lt}^{\boldsymbol{C}_\alpha})/2\end{aligned}$$

と定義され，$\xi_{ij,klst}^{\boldsymbol{Y}}$ も同様に定義される．

5　提案手法

まず，結果変数と共変量の 1 次と 2 次の項に対して割り当て変数で条件付けた経験的条件

付き球共分散を計算する．次に，経験的条件付き球共分散が大きい q 個の項を抽出する．続いて，抽出した q 個の項により結果モデルと傾向スコアモデルを作成し，GLiDeR によって回帰係数の推定を行う．最後に，二重頑健推定法により因果効果値の推定を行う．この手法により，1 次の項だけではなく 2 次の項をモデルに含めたとしても，モデルの項の個数は $p(p+3)/2$ 個から q 個に減らすことができ，計算時間を減らすことができる．

6 数値実験

6.1 設定

Koch et al.（2017）の論文をもとに，共変量は $\boldsymbol{C} \sim \mathcal{N}(\mathbf{0}, I_p)$，割り当て変数は $X_i \sim Bernoulli[\text{expit}\{f(\boldsymbol{C}_i)\}]$，結果変数は $Y_i \sim \mathcal{N}(X_i + g(\boldsymbol{C}_i), 1)$ によって発生させた．$f(\boldsymbol{C})$，$g(\boldsymbol{C})$ の組合せは 10 種類考えた．今回の実験において，データ数は $n = 500$，共変量の個数は $p = 10,\ 100$ とした．推定方法は既存手法である GLiDeR と提案手法である球共分散に基づく共変量選択を行った二重頑健推定法の 2 種類とした．また，$p = 10$ のとき $q = 30$，$p = 100$ のとき $q = 100$ とした．

6.2 実験結果

$p = 100$ のときの推定した因果効果値の平均 2 乗誤差と標準偏差を Table 1 にまとめている．設定 6，7，8 は真の結果モデルが非線形であり，真の傾向スコアモデルは線形である．このとき，既存手法よりも提案手法の方が平均 2 乗誤差および標準偏差が小さく，精度良く因果効果値を推定していることがわかる．

7 まとめ

球共分散を GLiDeR に組み込むことにより，共変量の個数が多いときでも，共変量に関する 1 次と 2 次の項をすべて考慮した上で因果効果値の推定を行うことができた．その結果，真の結果モデルが非線形であるときでも因果効果値の推定を精度良く行うことができた．

Table1: 推定した因果効果値の MSE と標準偏差 ($p = 100$)

設定番号	既存手法 MSE (sd)	提案手法 MSE (sd)
1	0.01075 (0.10382)	**0.01037 (0.10227)**
2	**0.00908 (0.09491)**	0.02528 (0.14344)
3	0.00708 (0.08433)	**0.00703 (0.08420)**
4	**0.01701 (0.10415)**	0.25776 (0.23195)
5	**0.04572 (0.11265)**	0.05032 (0.18914)
6	0.53471 (0.73436)	**0.05886 (0.24338)**
7	0.47251 (0.68932)	**0.02552 (0.15870)**
8	0.62878 (0.78963)	**0.16198 (0.40310)**
9	**0.01434** (0.11668)	0.01453 **(0.11433)**
10	0.01153 (0.10778)	**0.01142 (0.10715)**

参考文献

Bang, H. and Robins, J. M. (2005). Doubly robust estimation in missing data and causal inference models. *Biometrics*, **61**, 962–972.

Hoshino, T. (2007). Doubly robust-type estimation for covariate adjustment in latent variable modeling. *Psychometrika*, **72**, 535–549.

Koch, B., Vock, D. M. and Wolfson, J. (2017). Covariate selection with group lasso and doubly robust estimation of causal effects. *Biometrics*, **74**, 8–17.

Pan, W., Wang, X., Zhang, Z., Zhu, H. and Zhu, J. (2020). Ball covariance: A generic measure of dependence in banach space. *J. Am. Stat. Assoc.*, **115**, 307–317.

Tang, D., Kong, D., Pan, W. and Wang, L. (2023). Ultra–high dimensional variable selection for doubly robust causal inference. *Biometrics*, **79**, 903–914.