修 士 論 文 の 和 文 要 旨

研究科・専攻	大学院　情報理工学研究科　　情報・ネットワーク工学専攻　博士前期課程		
氏　　名	武藤　大樹	学籍番号	2231150
論 文 題 目	二重頑健推定法における球共分散に基づく共変量選択		

要　旨

原因となる事柄と結果となる事柄の両方に影響を与える事柄の影響を除去したとき，原因を変化させたことにより結果も変化する場合，この 2 つの間に因果関係があると言い，その効果の大きさを因果効果と呼ぶ．この因果効果の値を推定することにより，治療を行ったときの生存率，広告を見せることの効果や早期英語教育の効果などを予測することができる．このように，因果効果を推定することは，医学，経済学や教育学など様々な分野で役立てられている．

因果効果値を推定する方法の 1 つとして，二重頑健推定法(Bang and Robins, 2005; Hoshino, 2007) が挙げられる．因果効果値を二重頑健推定法により推定するとき，結果モデルと傾向スコアモデルの 2 つのモデルを設定する必要がある．この 2 つのモデルに対してモデル選択および回帰係数の推定を行う方法として，Group Lasso and Doubly Robust Estimation (GLiDeR) (Koch et al., 2017) がある．Koch et al. (2017) による方法では，結果モデルが線形モデルである場合因果効果値の推定を精度良く行うことができるが，結果モデルが非線形モデルである場合因果効果値の推定の精度が悪くなるという問題がある．

本稿では，この問題を解決するために，因果効果値の推定を GLiDeR によって行うとき，結果モデルが非線形モデルであると仮定して推定を行うことを提案する．このとき，共変量の個数が少ないときは 1 次の項と 2 次の項をすべて含めたモデルにより推定を行うことができるが，共変量の個数が多いときは 1 次の項と 2 次の項をすべて含めたモデルにより推定を行うことは計算上不可能になる．これに対して，2 変数間の非線形性をとらえることができる尺度である球共分散 (Pan et al., 2020) を用いることにより，1 次の項と 2 次の項からモデルに含めるべき重要な項を抽出してから，GLiDeR により因果効果値の推定を行うことを提案する． また，人工データおよび実データに対して，提案手法と既存手法の比較を行った．数値実験の結果，1 次の項と 2 次の項をすべて含めて計算が困難であるとき，結果モデルが非線形モデルであるときの因果効果値の推定を精度良く行うことができた．

令和五年度修士論文

二重頑健推定法における球共分散に基づく共変量選択

2024 年 1 月 29 日

電気通信大学 大学院情報理工学研究科

情報・ネットワーク工学専攻

情報数理工学プログラム

学籍番号 2231150

武藤 大樹

主任指導教員 西山 悠 准教授

指導教員 植野 真臣 教授

目 次

1 はじめに **4**

2 因果効果推定 **6**

2.1 傾向スコア 8

2.2 IPW 推定量 10

2.3 二重頑健推定法 10

2.4 共変量の種類 11

3 正則化法 **13**

3.1 ridge 回帰 13

3.2 lasso 14

3.3 適応型 lasso 14

3.4 グループ lasso 15

3.5 GLiDeR 15

4 球共分散 **19**

4.1 経験的球共分散 19

4.2 条件付き球共分散 20

4.3 経験的条件付き球共分散 21

5 提案手法 **22**

6 数値実験 **25**

6.1 人工データ 1 25

6.1.1 データの生成 25

6.1.2 推定方法 25

6.1.3 実験結果 27

6.1.4 高次の項を含む提案手法の結果 34

6.2 人工データ 2 34

6.2.1 データの生成 35

6.2.2 推定方法 35

6.2.3　実験結果 35
6.3　実データへの適用 42
6.3.1　解析データの基本統計量 42
6.3.2　推定方法 42
6.3.3　実験結果 43

7　まとめ **46**

A　結果変数が 2 値のときにおける GLiDeR **48**

B　(4.3)，(4.4) 式の証明 **49**

1　はじめに

原因となる事柄と結果となる事柄の両方に影響を与える事柄の影響を除去したとき，原因を変化させたことにより結果も変化する場合，この 2 つの間に因果関係があると言い，その効果の大きさを因果効果と呼ぶ．この因果効果の値を推定することにより，治療を行ったときの生存率，広告を見せることの効果や早期英語教育の効果などを予測することができる．このように，因果効果を推定することは，医学，経済学や教育学など様々な分野で役立てられている．

前述のとおり，因果効果を推定するとき，原因と結果の両方に影響を与える事柄の影響を考える必要がある．このとき，原因と結果の両方に影響を与える事柄を共変量と呼ぶ．原因となる事柄を行うかどうかがランダムに割り振られる実験を無作為割り当てと言い，このような実験を行うことができるとき，共変量が与える影響を考える必要はない．しかし，実際にこのような実験を行うことが困難である場合が多い．共変量が与える影響を無視できないとき，因果効果値を推定する方法の 1 つとして，二重頑健推定法 (Bang and Robins, 2005; Hoshino, 2007) が挙げられる．因果効果値を二重頑健推定法により推定するとき,「割り当てと共変量のモデル」と「共変量で結果変数を説明するモデル」の 2 つのモデルを設定する必要がある．二重頑健推定法は，この 2 つのうちどちらかが成立していれば，因果効果値を正しく推定できるという性質を有している．

二重頑健推定法により因果効果値を推定するとき,「割り当てと共変量のモデル」と「共変量で結果変数を説明するモデル」においてモデル選択（狭義の意味では変数選択）および回帰係数の推定を行う必要がある．この 2 つのモデルに対してモデル選択および回帰係数の推定を行う方法として，Group Lasso and Doubly Robust Estimation (GLiDeR) (Koch et al., 2017) がある．GLiDeR は適応型 lasso (Zou, 2006) とグループ lasso (Yuan and Lin, 2006) の考えに基づいたスパース推定法であり，二重頑健推定法の変数選択手法として知られている．Koch et al. (2017) による方法では,「共変量で結果変数を説明するモデル」が線形モデルである場合因果効果値の推定を精度良く行うことができるが,「共変量で結果変数を説明するモデル」が非線形モデルである場合因果効果値の推定の精度が悪くなるという問題がある．

この問題を解決するために，本稿では，因果効果値の推定を GLiDeR によって行うとき,「共変量で結果変数を説明するモデル」が非線形モデルであると仮定して推

定を行うことを提案する．このとき，共変量の個数が少ないときは 1 次の項と 2 次の項をすべて含めたモデルにより推定を行うことができるが，共変量の個数が多いときは 1 次の項と 2 次の項をすべて含めたモデルにより推定を行うことは計算上不可能になる．これに対して，1 次の項と 2 次の項からモデルに含めるべき重要な項を抽出してから，GLiDeR により因果効果値の推定を行うことを提案する．このとき，2 変数間の非線形性をとらえることができる尺度である球共分散 (Pan et al., 2020) に着目する．球共分散によりモデルに含めるべき項を抽出して，GLiDeR により計算可能なモデルを作成する．この方法により作成したモデルであれば，共変量の個数が多い場合に対しても非線形性に対応した因果効果値の推定を行うことができる．

本論文の構成は次の通りである．第 2 節では因果効果推定について述べる．第 3 節では正則化法について述べる．第 4 節では球共分散について述べる．第 5 節では提案手法について述べる．第 6 節では人工データと実データに対する数値実験を行う．第 7 節では本論文のまとめと今後の課題について述べる．

2　因果効果推定

変数 X_i を 0 と 1 の 2 値変数とし，$X_i = 1$ のときは介入が行われた群（処置群）に属する対象者，$X_i = 0$ のときは介入が行われていない群（対照群）に属する対象者であるとする．このとき，X_i を割り当て変数と呼ぶ．また，$X_i = 1$ のときの結果変数を Y_{i1}，$X_i = 0$ のときの結果変数を Y_{i0} とする．このとき，$Y_{i1} - Y_{i0}$ は対象者 i の因果効果と定義される．また，Y_{i1} と Y_{i0} は X_i の値によらず潜在的に存在することから，潜在的な結果変数と呼ばれている．

因果効果を求める際に潜在的な結果変数 Y_{i1} と Y_{i0} を使用するが，この 2 つの変数のうち必ず一方は観測できない．そのため，この推定量を観測されたデータから計算することはできない．そこで，2 つの潜在的な結果変数 Y_1 と Y_0 の期待値を求める．このとき，Y_1 と Y_0 の期待値の差

$$E(Y_1 - Y_0) = E(Y_1) - E(Y_0) \tag{2.1}$$

を因果効果として定義する．この潜在的な結果変数の期待値の差をルービンの因果効果 (Rubin, 1974) と呼ぶ．

もし無作為割り当てならば，容易に因果効果を推定することができる．無作為割り当ての場合，割り当て変数 X と結果変数 (Y_1, Y_0) は独立となる．したがって，条件付き分布 $p(Y_1 \mid X)$ は $p(Y_1)$ に，$p(Y_0 \mid X)$ は $p(Y_0)$ に一致するため，期待値も同様に

$$E(Y_1) = E(Y_1 \mid X), \quad E(Y_0) = E(Y_0 \mid X) \quad (X = 0, 1) \tag{2.2}$$

となる．このとき，実際に観測される結果変数を Y としたとき，2 つの潜在的な結果変数 Y_1, Y_0 と割り当て変数 X によって

$$Y = XY_1 + (1 - X)Y_0 \tag{2.3}$$

と表すことができるため，因果効果は

$$E(Y_1) - E(Y_0) = E(Y_1 \mid X = 1) - E(Y_0 \mid X = 0) = E(Y \mid X = 1) - E(Y \mid X = 0) \tag{2.4}$$

と表すことができる．つまり，無作為割り当てならば観測された各群の平均値の差

$$\frac{1}{n_1}\sum_{i:X_i=1}^{n} Y_i + \frac{1}{n_0}\sum_{i:X_i=0}^{n} Y_i \tag{2.5}$$

を用いることで因果効果を偏りなく推定することができる．ただし，n_1，n_0 はそれぞれの群のデータ数，n は $n = n_1 + n_0$ とする．

しかし，実際には無作為割り当ては困難である場合が多く，潜在的な結果変数と割り当て変数の両方に影響を与える変数である共変量について考える必要がある．このとき，共変量の値に依存しない因果効果の推定量を求めるために，共変量の分布について結果変数の期待値をとる必要がある．この操作を共変量調整と呼ぶ．

共変量を用いて因果効果値の推定を行うためには，割り当ては共変量にのみ依存し，結果変数には依存しないという仮定が必要である．この仮定を強く無視できる割り当て条件 (Rosenbaum and Rubin, 1983) と呼ばれている．これは，共変量 $\boldsymbol{C}$ で条件付けたとき，2 つの潜在的な結果変数 Y_1，Y_0 の同時分布 (Y_1, Y_0) と割り当て変数 X が独立であるという条件であり，

$$(Y_1, Y_0) \perp\!\!\!\perp X \mid \boldsymbol{C} \tag{2.6}$$

と表される．これにより，

$$\begin{aligned} E(Y \mid X = 1,\, \boldsymbol{C}) &= E(Y_1 \mid X,\, \boldsymbol{C}) = E(Y_1 \mid \boldsymbol{C}) \\ E(Y \mid X = 0,\, \boldsymbol{C}) &= E(Y_0 \mid X,\, \boldsymbol{C}) = E(Y_0 \mid \boldsymbol{C}) \end{aligned} \tag{2.7}$$

が成り立つ．このとき，因果効果は

$$\begin{aligned} E(Y_1 - Y_0) &= E_{\boldsymbol{C}}\{E(Y_1 - Y_0 \mid \boldsymbol{C})\} \\ &= E_{\boldsymbol{C}}\{E(Y_1 \mid X = 1,\, \boldsymbol{C}) - E(Y_0 \mid X = 0,\, \boldsymbol{C})\} \\ &= E_{\boldsymbol{C}}\{E(Y \mid X = 1,\, \boldsymbol{C}) - E(Y \mid X = 0,\, \boldsymbol{C})\} \end{aligned} \tag{2.8}$$

となり，観測されているデータのみで因果効果値を推定することができる．しかし，共変量が多変量の場合，(2.8) 式を計算することが難しい場合がある．

2.1 傾向スコア

無作為割り当てが困難な場合において，因果効果を推定する方法として，Rosenbaum and Rubin (1983) は傾向スコアを提案した．これにより，複数の共変量を 1 つの変数に集約することができ，共変量が多変量でも共変量調整を行うことができるようになる．

第 i 対象者に対する傾向スコア e_i は，第 i 対象者の共変量を $\boldsymbol{C}_i$，割り当て変数を X_i とするとき，処置群へ割り当てられる確率

$$e_i = p(X_i = 1 \mid \boldsymbol{C}_i) \tag{2.9}$$

として定義される（ただし $0 \leq e_i \leq 1$）．このとき，各対象者の傾向スコアの真値はわからない．したがって，データから傾向スコアの値を推定する必要がある．傾向スコアを推定するときのモデルには一般的にプロビット回帰モデルやロジスティック回帰モデルが使用される．ロジスティック回帰モデルを用いて傾向スコアを推定するとき，(2.9) 式は次のように書き表される．

$$e_i = p(X_i = 1 \mid \boldsymbol{C}_i) = \frac{1}{1 + \exp\{-\boldsymbol{\alpha}^T \boldsymbol{C}_i\}}. \tag{2.10}$$

ここで，$\boldsymbol{\alpha}$ は回帰係数を表すパラメータである．

傾向スコア e，割り当て変数 X および共変量 $\boldsymbol{C}$ に対して，

$$\begin{aligned} p(X = 1 \mid e) &= \int p(X = 1 \mid \boldsymbol{C}, e) p(\boldsymbol{C} \mid e) d\boldsymbol{C} \\ &= E_{\boldsymbol{C}|e}[p(X = 1 \mid \boldsymbol{C})] \\ &= E_{\boldsymbol{C}|e,\ p(X=1|\boldsymbol{C})}[p(X = 1 \mid \boldsymbol{C})] \\ &= p(X = 1 \mid \boldsymbol{C}) \end{aligned} \tag{2.11}$$

が成り立つ．加えて，強く無視できる割り当て条件が成立していれば，傾向スコア

e，割り当て変数 X，共変量 $\boldsymbol{C}$ および潜在的な結果変数 $Y_1,\ Y_0$ に対して，

$$\begin{aligned} p(X=1 \mid Y_1,\ Y_0,\ e) &= \int p(X=1 \mid Y_1,\ Y_0,\ \boldsymbol{C}, e) p(\boldsymbol{C} \mid Y_1,\ Y_0,\ e) d\boldsymbol{C} \\ &= E_{\boldsymbol{C} \mid Y_1,\ Y_0,\ e}[p(X=1 \mid Y_1,\ Y_0,\ \boldsymbol{C})] \\ &= E_{\boldsymbol{C} \mid Y_1,\ Y_0,\ e}[p(X=1 \mid \boldsymbol{C})] \\ &= p(X=1 \mid \boldsymbol{C}) \end{aligned} \tag{2.12}$$

が成り立つ．(2.11)，(2.12) 式より

$$p(X \mid Y_1,\ Y_0,\ e) = p(X \mid e) \tag{2.13}$$

が成り立つ．したがって，

$$(Y_1, Y_0) \perp\!\!\!\perp X \mid e \tag{2.14}$$

となり，傾向スコア e を条件付ければ，割り当て変数 X と潜在的な結果変数 $Y_1,\ Y_0$ は独立になる．

強く無視できる割り当て条件が満たされていれば，傾向スコアを用いた共変量調整を行うことにより，すべての共変量を用いて調整を行ったのと同じだけ偏りを減少させることができる．因果効果は傾向スコアを用いることにより，

$$E(Y_1) - E(Y_0) = E(Y_1 - Y_0) = E_e\{E(Y_1 - Y_0 \mid e)\} \tag{2.15}$$

と表すことができ，(2.14) 式より

$$E(Y_1 \mid e) = E(Y_1 \mid e,\ X=1), \quad E(Y_0 \mid e) = E(Y_0 \mid e,\ X=0) \tag{2.16}$$

となるため，因果効果は

$$E(Y_1) - E(Y_0) = E_e\{E(Y_1 \mid e,\ X=1) - E(Y_0 \mid e,\ X=0)\} \tag{2.17}$$

と表すことができる．このとき，(2.17) 式の右辺において，観測されていない値を用いていないことに注意されたい．したがって，(2.17) 式より，無作為割り当てではない場合でも，傾向スコアと実際に観測される結果変数を用いれば，因果効果値を推定することができることが分かる．

2.2 IPW 推定量

傾向スコアを用いて因果効果値の推定を行う方法の一つとして逆確率による重み付けを用いた IPW 推定量 (inverse probability weighting estimator : IPWE) (Rubin, 1985) がある．いま，e_i は対象者 i の傾向スコア，X_i は対象者 i の割り当て変数，Y_i は実際に観測された対象者 i の結果変数とする．このとき，傾向スコアの逆数による重み付け平均

$$\hat{E}(Y_1) = \frac{\sum_{i=1}^{n} \frac{X_i Y_i}{e_i}}{\sum_{i=1}^{n} \frac{X_i}{e_i}}, \quad \hat{E}(Y_0) = \frac{\sum_{i=1}^{n} \frac{(1-X_i)Y_i}{1-e_i}}{\sum_{i=1}^{n} \frac{(1-X_i)}{1-e_i}} \tag{2.18}$$

によってそれぞれの結果変数の期待値を推定することができる．この方法であれば，因果効果だけでなく各群の周辺期待値を計算することができる．加えて，$\hat{E}(Y_1)$, $\hat{E}(Y_0)$ はそれぞれ $E(Y_1)$, $E(Y_0)$ の一致推定量となる．

2.3 二重頑健推定法

因果効果値を求める推定方式に傾向スコアだけではなく,「対照群における共変量のデータ」を用いた項として「共変量で結果変数を説明する回帰関数」を付加すれば，次の 2 つの条件

条件 A 傾向スコアを計算する際に用いる「割り当て変数 X と共変量 $\boldsymbol{C}$ のモデル」が正しく指定されている

条件 B 「共変量 $\boldsymbol{C}$ で結果変数 Y を説明する回帰関数」が正しく指定されている

のどちらかが成立しているならば，因果効果値の一致推定量が得られる．以降，共変量から傾向スコアを推定するモデルを傾向スコアモデル，共変量から結果変数を推定するモデルを結果モデルと呼ぶこととする．傾向スコアだけではなく「共変量で結果変数を説明する回帰関数」を用いて求めた「拡大された逆確率重み付き推定量」を二重頑健推定法 (Bang and Robins, 2005; Hoshino, 2007) と呼ぶ．

二重頑健推定法の例として

$$E(Y_1 - Y_0) = \frac{1}{n} \sum_{i=1}^{n} \left\{ \frac{Y_i X_i - (X_i - e_i) m_{1i}}{e_i} - \frac{Y_i (1 - X_i) + (X_i - e_i) m_{0i}}{1 - e_i} \right\} \tag{2.19}$$

がある．ただし，n はデータ数，m_{1i}，m_{0i} はそれぞれ共変量で結果変数を説明したときの回帰関数 $E[Y_1 \mid \boldsymbol{C}]$，$E[Y_0 \mid \boldsymbol{C}]$ である．この式において，条件 A または条件 B が成り立てば，因果効果値の一致推定量が得られる．証明は星野崇宏. (2009) を参照されたい．

2.4 共変量の種類

共変量は 4 種類に分類することができる．

- 割り当て変数と結果変数の両方に影響を与える共変量．このような共変量を C^C とする．
- 割り当て変数には影響を与えるが結果変数には影響を与えない共変量．このような共変量を C^I とする．
- 割り当て変数には影響を与えないが結果変数には影響を与える共変量．このような共変量を C^P とする．
- 割り当て変数と結果変数の両方に影響を与えない共変量．このような共変量を C^N とする．

この 4 種類の共変量と結果変数 Y および割り当て変数 X との関係を図式化すると Fig. 1 のようになる．

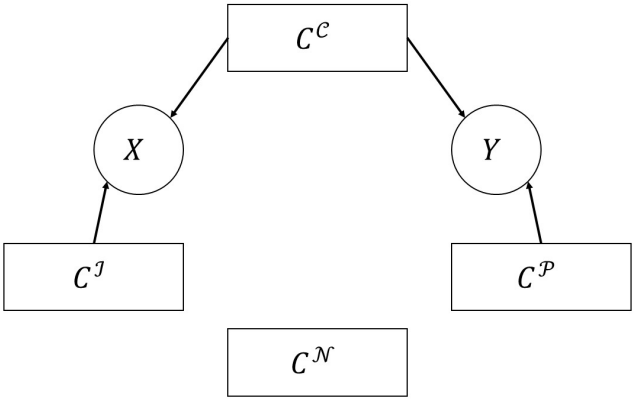


Fig. 1: 共変量の種類

Brookhart et al. (2006) は共変量に関して次の 2 つのことを示している．

- 割り当て変数に影響を与える共変量よりも結果変数に影響を与える共変量を用いて因果効果値の推定を行うほうが因果効果値の推定の偏りが少なく，推定量の分散が小さくなる．

- 割り当て変数に影響を与えるが，結果変数にはあまり影響を与えない共変量を用いて因果効果値の推定を行うと，推定量の分散が大きくなり，平均2乗誤差が大きくなる．

加えて，Lunceford and Davidian (2004) は，IPW 推定量や二重頑健推定法において，割り当て変数には影響を与えないが，結果変数には影響を与えるような共変量を用いて因果効果値の推定を行うと，因果効果値の推定値の漸近分散が低下することを示している．

以上より，因果効果値の推定を精度良く行うためには，C^N や C^I のように結果変数に影響を与えない共変量を用いず，C^C や C^P のように結果変数に影響を与える共変量を用いることが重要となってくる．

3　正則化法

モデルの推定法としてよく用いられる方法として，誤差 2 乗和を最小にする推定方法である最小 2 乗法や，尤度関数を最大にする最尤法がある．しかし，データの構造や性質が次のような場合，最小 2 乗法や最尤法を用いても適切な推定量が得られないときがある．

- 説明変数間の相関が非常に高い場合
- 説明変数の数がデータ数と同じくらい，またはそれ以上の場合

このような問題に対して，正則化法と呼ばれる方法が用いられる．

正則化法とは，誤差 2 乗和や負の対数尤度関数に，モデルが複雑になるにつれて値が大きくなるような罰則項を加えた式の最小化により，パラメータの推定量を得る推定法である．このとき，この罰則項を正則化項と呼ぶ．例として，正則化法は次の最小化問題として書き表すことができる．

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} S(\boldsymbol{\beta}) + \lambda R(\boldsymbol{\beta}) \right\}. \tag{3.1}$$

ただし，$S(\boldsymbol{\beta})$ は $\boldsymbol{\beta}$ をパラメータとした誤差 2 乗和または負の対数尤度関数，$R(\boldsymbol{\beta})$ は正則化項，n はデータ数である．また，$\lambda\ (>0)$ は正則化パラメータと呼ばれる．

3.1　ridge 回帰

(3.1) 式において，正則化項として L_q ノルムを用いる場合がある．このとき，誤差 2 乗和に正則化項として L_2 ノルムを課したときの正則化法は ridge 回帰 (Hoerl and Kennard, 1970) と呼ばれる．

例えば，目的変数 $\boldsymbol{y}$ と説明変数 X に対して，線形回帰モデル

$$\boldsymbol{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon} \tag{3.2}$$

を考える．ただし，$\boldsymbol{\epsilon}$ は観測誤差を表す．このモデルに対して ridge 回帰を適用すると

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \|\boldsymbol{y} - X\boldsymbol{\beta}\|_2^2 + \frac{\lambda}{2} \|\boldsymbol{\beta}\|_2^2 \right\} \tag{3.3}$$

となる．このとき，ridge 回帰によって推定した回帰係数の推定量は $\mathbf{0}$ と最小 2 乗推定量の間になる．

3.2 lasso

(3.1) 式において，正則化項として L_1 ノルムを用いたときの正則化法は lasso (Tibshirani, 1996) と呼ばれる．

例えば，線形回帰モデル (3.2) 式に対する lasso は

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} \|\boldsymbol{y} - X\boldsymbol{\beta}\|_2^2 + \frac{\lambda}{2} \|\boldsymbol{\beta}\|_1 \right\} \tag{3.4}$$

と定式化される．lasso によって線形回帰モデルを推定するとパラメータの一部は完全に 0 と推定され，これはモデルの推定と変数選択を同時に実行することを表している．

3.3 適応型 lasso

lasso に改良を加えた適応型 lasso (Zou, 2006) という推定法がある．適応型 lasso は次の最小化問題として書き表すことができる．

$$\min_{\boldsymbol{\beta}} S_\lambda(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \left\{ \frac{1}{2n} S(\boldsymbol{\beta}) + \lambda \sum_{j=1}^{p} w_j |\beta_j| \right\}. \tag{3.5}$$

このとき，$\boldsymbol{\beta} = (\beta_1, \beta_2, \ldots, \beta_p)^T$ は回帰係数を表す p 次元パラメータ，w_j は正の重みである．正の重み w_j は未知の値であるため，$\hat{w}_j = 1/|\hat{\beta}_j|^\zeta$ と推定して用いることが多い．ここで，$\hat{\beta}_j$ はパラメータ β_j の最小 2 乗推定値や ridge 推定値とし，ζ は調整パラメータである．$|\hat{\beta}_j|$ の値が小さいと $\hat{w}_j$ の値は大きくなる．逆に，$|\hat{\beta}_j|$ の値が大きいと $\hat{w}_j$ の値は小さくなる．つまり，$|\hat{\beta}_j|$ が小さければ，モデルに含む必要がない回帰係数である可能性が高く 0 と推定しやすくなり，$|\hat{\beta}_j|$ が大きければ，モデルに含めるべき回帰係数である可能性が高く非 0 と推定しやすくなる．

3.4 グループ lasso

変数選択をするときに，説明変数が複数のグループに分かれており，グループ単位で選択したいときは Yuan and Lin (2006) によって提案されたグループ lasso を用いる．

いま，p 個の説明変数が J 個のグループに分割されているとする．このとき，各グループ内の説明変数の個数を p_j，第 j 番目のグループに属する説明変数からなる $n \times p_j$ 計画行列を X_j，X_j に関する p_j 次元回帰係数ベクトルを $\boldsymbol{\beta}_j$ とする．このとき，線形回帰モデルは次のように表すことができる．

$$\boldsymbol{y} = \sum_{j=1}^{J} X_j \boldsymbol{\beta}_j + \boldsymbol{\epsilon}. \tag{3.6}$$

ここで，$\boldsymbol{\epsilon}$ は観測誤差を表す．この線形回帰モデルに対して，グループ lasso は次の最小化問題として表すことができる．

$$\min_{\beta} \frac{1}{2n} \left\| \boldsymbol{y} - \sum_{j=1}^{J} X_j \boldsymbol{\beta}_j \right\|_2^2 + \lambda \sum_{j=1}^{J} (\boldsymbol{\beta}_j^T \Omega_j \boldsymbol{\beta}_j)^{1/2}. \tag{3.7}$$

ここで，$\boldsymbol{\beta} = (\boldsymbol{\beta}_1^T, \ldots, \boldsymbol{\beta}_J^T)^T$ とし，Ω_j は非負値定符号行列とする．Ω_j は多くの場合グループごとの要素数 p_j で重み付けした対角行列 $\Omega_j = p_j I_{p_j}$ が用いられる．この最小化問題を解くことにより，同じグループに属するすべての回帰係数は非 0 もしくは 0 と推定される．

3.5 GLiDeR

二重頑健推定法を用いるとき，傾向スコアモデル，結果モデルそれぞれに対して変数選択および回帰係数の推定を行う必要がある．このとき，Koch et al. (2017) は，二重頑健推定法を用いるにあたり変数選択および回帰係数の推定を行う方法として GLiDeR を提案した．

いま，結果変数を $\boldsymbol{Y} = (Y_1, Y_2, \ldots, Y_n)^T$，$p$ 個の共変量からなる $n \times p$ 行列を $\boldsymbol{C} = (\boldsymbol{C}_1, \boldsymbol{C}_2, \ldots, \boldsymbol{C}_p)$（ただし，$\boldsymbol{C}_j = (C_{1j}, C_{2j}, \ldots, C_{nj})^T$ $(j = 1, 2, \ldots, p)$），割り当て変数を $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)^T$ とする．このとき，傾向スコアモデル $\pi(\boldsymbol{C}; \boldsymbol{\gamma})$ をロジスティック

回帰モデル，結果モデル $\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ を線形回帰モデルと仮定すると

$$\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \alpha_1 \boldsymbol{C}_1 + \alpha_2 \boldsymbol{C}_2 + \cdots + \alpha_p \boldsymbol{C}_p + \alpha_{p+1} + \alpha_{p+2} \boldsymbol{X}, \tag{3.8}$$

$$\pi(\boldsymbol{C}; \boldsymbol{\gamma}) = \frac{\exp(\gamma_1 \boldsymbol{C}_1 + \gamma_2 \boldsymbol{C}_2 + \cdots + \gamma_p \boldsymbol{C}_p + \gamma_{p+1})}{1 + \exp(\gamma_1 \boldsymbol{C}_1 + \gamma_2 \boldsymbol{C}_2 + \cdots + \gamma_p \boldsymbol{C}_p + \gamma_{p+1})} \tag{3.9}$$

となる．ここで，$\alpha_1, \ldots, \alpha_p$, α_{p+1}, α_{p+2}, $\gamma_1, \ldots, \gamma_p$, γ_{p+1} は回帰係数を表すパラメータであり，$\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_p, \alpha_{p+1}, \alpha_{p+2})^T$，$\boldsymbol{\gamma} = (\gamma_1, \ldots, \gamma_p, \gamma_{p+1})^T$ とする．

また，$\Phi_{\text{out}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ を結果モデルにおける誤差 2 乗和とし，$\Phi_{\text{trt}}(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\gamma})$ を傾向スコアモデルにおける負の対数尤度関数とする．$\Phi_{\text{out}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ と $\Phi_{\text{trt}}(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\gamma})$ はそれぞれ次のように書き表すことができる．

$$\Phi_{\text{out}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \sum_{i=1}^{n} \left\{ Y_i - \alpha_1 C_{i1} - \alpha_2 C_{i2} - \cdots - \alpha_p C_{ip} - \alpha_{p+1} - \alpha_{p+2} X_i \right\}^2, \tag{3.10}$$

$$\begin{aligned} \Phi_{\text{trt}}(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\gamma}) = &- \sum_{i=1}^{n} \left\{ X_i (\gamma_1 C_{i1} + \gamma_2 C_{i2} + \cdots + \gamma_p C_{ip} + \gamma_{p+1}) \right\} \\ &+ \sum_{i=1}^{n} \log \left\{ 1 + \exp(\gamma_1 C_{i1} + \gamma_2 C_{i2} + \cdots + \gamma_p C_{ip} + \gamma_{p+1}) \right\}. \end{aligned} \tag{3.11}$$

いま，結果モデルと傾向スコアモデルにおける回帰係数を $\beta_1 = (\alpha_1, \gamma_1)$, $\beta_2 = (\alpha_2, \gamma_2), \ldots, \beta_p = (\alpha_p, \gamma_p)$, $\beta_{p+1} = \alpha_{p+1}$, $\beta_{p+2} = \gamma_{p+1}$, $\beta_{p+3} = \alpha_{p+2}$ とおく．これは，$k = 1, \ldots, p$ の場合には β_k がそれぞれ結果モデルと傾向スコアモデルにおける共変量 $\boldsymbol{C}_k$ に対応する回帰係数のグループ，$k = p+1$, $p+2$ の場合には β_k は切片，$k = p+3$ の場合には β_k は (3.8) 式における割り当て変数の回帰係数となっている．このとき，$\boldsymbol{\beta} = (\beta_1, \beta_2, \ldots, \beta_p, \beta_{p+1}, \beta_{p+2}, \beta_{p+3})^T$ とする．

GLiDeR は，次のグループ lasso と適応型 lasso の性質を持った最小化問題として定義される．

$$\hat{\boldsymbol{\beta}}(\lambda) = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \frac{1}{n} \Phi_{\text{sum}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\beta}) + \lambda \sum_{k=1}^{p} W_k \|\beta_k\|_2. \tag{3.12}$$

ただし，λ (> 0) は正則化パラメータ，W_k は正の重みであり，$\Phi_{\text{sum}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\beta})$ は

$$\Phi_{\text{sum}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\beta}) = \Phi_{\text{out}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) + \Phi_{\text{trt}}(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\gamma}) \tag{3.13}$$

である．罰則項において，切片項 β_{p+1}, β_{p+2} と (3.8) 式における割り当て変数 $\boldsymbol{X}$ の係

数β_{p+3}に罰則を課していないことに注意されたい．また，正の重みは$W_k = \frac{\sqrt{2}}{|v_k|}$とする．ここで，$v_k$は，(3.8)式の回帰係数$\alpha_k$のridge推定値である．これにより，共変量と結果変数の関連のみにより重みづけを行うことができ，結果変数のみに影響を与える共変量または結果変数と割り当て変数に影響を与える共変量を選択する可能性が高くなる．

(3.12)式における正則化パラメータλの選択は次の修正した一般化交差検証法(GCV)の最小化により求める．

$$\mathrm{GCV}(\lambda) = \frac{\sum_{i=1}^{n}(Y_i - \hat{\alpha}_1(\lambda)C_{i1} - \cdots - \hat{\alpha}_p(\lambda)C_{ip} - \hat{\alpha}_{p+1}(\lambda) - \hat{\alpha}_{p+2}(\lambda)X_i)^2}{(1 - (2 + \sum_{j=1}^{p} I(\|\hat{\alpha}_j(\lambda)\| > 0) + \sum_{j=1}^{p} \frac{|\hat{\alpha}_j(\lambda)|}{v_j})/n)^2}. \tag{3.14}$$

このとき，$\hat{\boldsymbol{\alpha}}(\lambda) = (\hat{\alpha}_1(\lambda), \hat{\alpha}_2(\lambda), \ldots, \hat{\alpha}_p(\lambda), \hat{\alpha}_{p+1}(\lambda), \hat{\alpha}_{p+2}(\lambda))^T$は(3.12)式における$\boldsymbol{\alpha}$の推定値であり，$I(\|\hat{\alpha}_j(\lambda)\| > 0)$は次のような関数である．

$$I(\|\hat{\alpha}_j(\lambda)\| > 0) = \begin{cases} 1 & (\|\hat{\alpha}_j(\lambda)\| > 0) \\ 0 & (\text{otherwise}) \end{cases}. \tag{3.15}$$

GLiDeRの計算アルゴリズムにはGroupwise Majorization Descent（GMD）アルゴリズム (Yang and Zou, 2015) を採用している．GMDアルゴリズムは，各候補λに対して，次のAlgrithm 1，2から成る．Algorithm 1では，各候補λにおける結果モデルと傾向スコアモデルの回帰係数を求めている．Algorithm 2ではカルーシュ・クーン・タッカー（KKT）条件の考えを用いることにより，Algorithm 1で回帰係数を求める際に用いる共変量の個数を制限している．このことにより，Algorithm 1の計算時間が，すべての共変量を用いるときに比べて短くすることができる．Algorithm1, 2において，τ_k, $U^{(k)}$は次の通りである．

$$\tau_k = \begin{cases} \frac{5}{2n}\boldsymbol{C}_k^T\boldsymbol{C}_k & (1 \le k \le p) \\ \frac{5}{4} & (k = p+1, p+2) \\ \frac{5}{4n}\boldsymbol{X}^T\boldsymbol{X} & (k = p+3) \end{cases}, \tag{3.16}$$

$$U^{(k)} = \begin{cases} \left(-\frac{\partial}{\partial\alpha_k}\frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}), -\frac{\partial}{\partial\gamma_k}\frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}})\right)^T & (1 \le k \le p) \\ -\frac{\partial}{\partial\alpha_{p+1}}\frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}) & (k = p+1) \\ -\frac{\partial}{\partial\gamma_{p+1}}\frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}) & (k = p+2) \\ -\frac{\partial}{\partial\alpha_{p+2}}\frac{1}{n}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}) & (k = p+3) \end{cases}, \tag{3.17}$$

$$-\frac{\partial}{\partial\alpha_k}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}) = \begin{cases} \sum_{i=1}^n 2\left(Y_i - \widetilde{\alpha}_1 C_{i1} - \cdots - \widetilde{\alpha}_p C_{ip} - \widetilde{\alpha}_{p+1} - \widetilde{\alpha}_{p+2} X_i\right) C_{ik} & (1 \le k \le p) \\ \sum_{i=1}^n 2\left(Y_i - \widetilde{\alpha}_1 C_{i1} - \cdots - \widetilde{\alpha}_p C_{ip} - \widetilde{\alpha}_{p+1} - \widetilde{\alpha}_{p+2} X_i\right) & (k = p+1) \\ \sum_{i=1}^n 2\left(Y_i - \widetilde{\alpha}_1 C_{i1} - \cdots - \widetilde{\alpha}_p C_{ip} - \widetilde{\alpha}_{p+1} - \widetilde{\alpha}_{p+2} X_i\right) X_i & (k = p+2) \end{cases}, \tag{3.18}$$

$$-\frac{\partial}{\partial\gamma_k}\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}}) = \begin{cases} \sum_{i=1}^n \left(X_i - \frac{\exp(\widetilde{\gamma}_1 C_{i1} + \cdots + \widetilde{\gamma}_p C_{ip} + \widetilde{\gamma}_{p+1})}{1+\exp(\widetilde{\gamma}_1 C_{i1} + \cdots + \widetilde{\gamma}_p C_{ip} + \widetilde{\gamma}_{p+1})}\right) C_{ik} & (1 \le k \le p) \\ \sum_{i=1}^n \left(X_i - \frac{\exp(\widetilde{\gamma}_1 C_{i1} + \cdots + \widetilde{\gamma}_p C_{ip} + \widetilde{\gamma}_{p+1})}{1+\exp(\widetilde{\gamma}_1 C_{i1} + \cdots + \widetilde{\gamma}_p C_{ip} + \widetilde{\gamma}_{p+1})}\right) & (k = p+1) \end{cases}. \tag{3.19}$$

Algorithm 1 GMD アルゴリズム

1: τ_k $(k = 1, \ldots, p+3)$ を設定する.
2: $\widetilde{\boldsymbol{\beta}}$を初期化.
3: **for** $k = 1, \ldots, p+3$ **do**
4: $\quad U(\widetilde{\boldsymbol{\beta}}) = -\frac{1}{n}\nabla\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\widetilde{\boldsymbol{\beta}})$.
5: $\quad \widetilde{\boldsymbol{\beta}}^{(k)}(new) = \frac{1}{\tau_k}\left(U^{(k)} + \tau_k\widetilde{\boldsymbol{\beta}}^{(k)}\right)\left(1 - \frac{\lambda W_k}{\|U^{(k)}+\tau_k\widetilde{\boldsymbol{\beta}}^{(k)}\|_2}\right)_+$.
6: $\quad \widetilde{\boldsymbol{\beta}}^{(k)} = \widetilde{\boldsymbol{\beta}}^{(k)}(new)$.
7: 収束条件を満たしていなければ step 3 に戻る.

Algorithm 2 回帰係数の次元を制限するアルゴリズム

1: $\widetilde{\boldsymbol{\beta}} = \hat{\boldsymbol{\beta}}(\lambda^{(l)})$ を初期化.
2: $S = \left\{k : \|\frac{1}{n}\nabla\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\hat{\boldsymbol{\beta}}(\lambda^{(l)}))^{(k)}\|_2 \ge W_k\left(2\lambda^{(l+1)} - \lambda^{(l)}\right)\right\}$ を求める.
3: $(Y_i, X_i, C_{Si})_{i=1}^n$に対してAlgorithm 1 を行い，$\hat{\boldsymbol{\beta}}_S$を求める.
4: $V = \left\{k : k \in S^c, \|\frac{1}{n}\nabla\Phi_{\mathrm{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\hat{\boldsymbol{\beta}}(\lambda^{(l+1)}))^{(k)}\|_2 > W_k\lambda^{(l+1)}\right\}$ を求める.
5: **if** $V = \emptyset$ **then**
6: $\quad$ ループを終了し，$\hat{\boldsymbol{\beta}}(\lambda^{(l+1)}) = (\hat{\boldsymbol{\beta}}_S, \boldsymbol{0})$ を返す.
7: **else**
8: $\quad S = S \cup V$ と更新し，step 3 に戻る.

4　球共分散

2 変数間の非線形性をとらえることができる尺度として Pan et al. (2020) が提案した球共分散がある．まず，S, T をバナッハ空間 (S,ρ), (T,ζ) 上の確率変数とする．このとき，ρ, ζ は距離関数である．次に，θ, ι, κ をそれぞれ (S,T), S, T によって誘導される確率測度とする．続いて，$\bar{B}_\rho(s_1,s_2)$ を中心 s_1，半径 $\rho(s_1,s_2)$ とする空間 (S,ρ) 内の閉球とし，$\bar{B}_\zeta(t_1,t_2)$ を中心 t_1，半径 $\zeta(t_1,t_2)$ とする空間 (T,ζ) 内の閉球とする．このとき，球共分散 BCov の 2 乗は次の積分によって定義される．

$$\mathrm{BCov}^2(S,T)=\int(\theta-\iota\otimes\kappa)^2\left\{\bar{B}_\rho(s_1,s_2)\times\bar{B}_\zeta(t_1,t_2)\right\}\theta(ds_1,dt_1)\theta(ds_2,dt_2). \tag{4.1}$$

ただし，

$$(\theta-\iota\otimes\kappa)^2\left\{\bar{B}_\rho(s_1,s_2)\times\bar{B}_\zeta(t_1,t_2)\right\}=\left[\theta\left\{\bar{B}_\rho(s_1,s_2)\times\bar{B}_\zeta(t_1,t_2)\right\}-\iota\left\{\bar{B}_\rho(s_1,s_2)\right\}\kappa\left\{\bar{B}_\zeta(t_1,t_2)\right\}\right]^2 \tag{4.2}$$

であり，$\bar{B}_\rho(s_1,s_2)\times\bar{B}_\zeta(t_1,t_2)$ は $\bar{B}_\rho(s_1,s_2)$ と $\bar{B}_\zeta(t_1,t_2)$ の直積である．球共分散 $\mathrm{BCov}(S,T)$ は $\mathrm{BCov}(S,T)\geq 0$ であり，等号が成り立つ場合 S と T は独立している．加えて，S と T が独立しているならば，$\mathrm{BCov}(S,T)=0$ である．

4.1　経験的球共分散

球共分散は (4.1) 式により求めることができるが，実際に計算することは困難である．それに対して，実際に計算を行うことができる球共分散である経験的球共分散がある．

まず，Y を結果変数，$\boldsymbol{C}=(\boldsymbol{C}_1,\boldsymbol{C}_2,\ldots,\boldsymbol{C}_p)$ を p 個の共変量からなる $n\times p$ 行列とし，α 番目の共変量を $\boldsymbol{C}_\alpha=(C_{1\alpha},C_{2\alpha},\ldots,C_{n\alpha})^T$ とする．いま，$\delta_{ij,k}^{\boldsymbol{C}_\alpha}=I(C_{k\alpha}\in\bar{B}_\rho(C_{i\alpha},C_{j\alpha}))$ とする．このとき，$I(\cdot)$ は指示関数である．次に，$\delta_{ij,kl}^{\boldsymbol{C}_\alpha}=\delta_{ij,k}^{\boldsymbol{C}_\alpha}\delta_{ij,l}^{\boldsymbol{C}_\alpha}$ とし，$\xi_{ij,klst}^{\boldsymbol{C}_\alpha}=(\delta_{ij,kl}^{\boldsymbol{C}_\alpha}+\delta_{ij,st}^{\boldsymbol{C}_\alpha}-\delta_{ij,ks}^{\boldsymbol{C}_\alpha}-\delta_{ij,lt}^{\boldsymbol{C}_\alpha})/2$ とする．同様に，$\delta_{ij,k}^{\boldsymbol{Y}}$, $\delta_{ij,kl}^{\boldsymbol{Y}}$, $\xi_{ij,klst}^{\boldsymbol{Y}}$ を定義する．このとき，$(C_{i\alpha},Y_i)$, $i=1,2,\ldots,6$ が同時分布 $(\boldsymbol{C}_\alpha,\boldsymbol{Y})$ から独立で得られたとすると

$$\mathrm{BCov}^2(\boldsymbol{C}_\alpha,\boldsymbol{Y})=E\left\{\xi_{12,3456}^{\boldsymbol{C}_\alpha}\xi_{12,3456}^{\boldsymbol{Y}}\right\} \tag{4.3}$$

が成り立つ．また，(4.3) 式より

$$\begin{aligned}
&\mathrm{BCov}^2(\boldsymbol{C}_\alpha, \boldsymbol{Y}) \\
&= E\left\{\left[P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}), Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\right.\right. \\
&\quad \left.\left. -P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}) \mid W_1, W_2)P(Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\right]^2\right\}
\end{aligned} \tag{4.4}$$

を求めることができる．(4.3)，(4.4) 式の証明は付録 B を参照されたい．したがって，経験的球共分散 $\mathrm{BCov}_n^2(\boldsymbol{C}_\alpha, \boldsymbol{Y})$ は次のように定義することができる．

$$\mathrm{BCov}_n^2(\boldsymbol{C}_\alpha, \boldsymbol{Y}) = \frac{1}{n^2}\sum_{i,j=1}^{n}\left(\Delta_{ij,n}^{\boldsymbol{C}_\alpha,\boldsymbol{Y}} - \Delta_{ij,n}^{\boldsymbol{C}_\alpha}\Delta_{ij,n}^{\boldsymbol{Y}}\right). \tag{4.5}$$

このとき，

$$\Delta_{ij,n}^{\boldsymbol{C}_\alpha,\boldsymbol{Y}} = \frac{1}{n}\sum_{k=1}^{n}\delta_{ij,k}^{\boldsymbol{C}_\alpha}\delta_{ij,k}^{\boldsymbol{Y}}, \tag{4.6}$$

$$\Delta_{ij,n}^{\boldsymbol{C}_\alpha} = \frac{1}{n}\sum_{k=1}^{n}\delta_{ij,k}^{\boldsymbol{C}_\alpha}, \tag{4.7}$$

$$\Delta_{ij,n}^{\boldsymbol{Y}} = \frac{1}{n}\sum_{k=1}^{n}\delta_{ij,k}^{\boldsymbol{Y}} \tag{4.8}$$

であり，n はデータ数とする．(4.5) 式により，容易に球共分散を計算することができる．

4.2 条件付き球共分散

Tang et al. (2023) は割り当て変数で条件づけた下で共変量と結果変数の球共分散を定義している．

まず，$\omega = P(X = 1)$ を処置群へ割り当てる確率とし，$\boldsymbol{X} = (X_1, X_2, \ldots, X_n)^T$ を割り当て変数とする．次に，$\boldsymbol{C}_\alpha^{(x)}, \boldsymbol{Y}^{(x)}$ を $(\boldsymbol{C}_\alpha^{(x)}, \boldsymbol{Y}^{(x)}) = (\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid X = x)$, $x = 0, 1$ となる確率変数とする．割り当て変数 $\boldsymbol{X}$ が与えられた下で結果変数 $\boldsymbol{Y}$ と α 番目の共変量 $\boldsymbol{C}_\alpha$ の条件付き球共分散 $\mathrm{BCov}(\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid \boldsymbol{X})$ を

$$\mathrm{BCov}^2(\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid \boldsymbol{X}) = \omega\mathrm{BCov}^2(\boldsymbol{C}_\alpha^{(1)}, \boldsymbol{Y}^{(1)}) + (1-\omega)\mathrm{BCov}^2(\boldsymbol{C}_\alpha^{(0)}, \boldsymbol{Y}^{(0)}) \tag{4.9}$$

として定義した．さらに Tang et al. (2023) はこの条件付き球共分散に対し，

$$\mathrm{BCov}(\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid \boldsymbol{X}) = 0 \Longleftrightarrow \boldsymbol{C}_\alpha \perp\!\!\!\perp \boldsymbol{Y} \mid \boldsymbol{X} \tag{4.10}$$

となることを示した．この式により，次のことが言える．

- (4.9) 式の条件付き球共分散の値が大きいとき，共変量 $\boldsymbol{C}_\alpha$ は結果変数 $\boldsymbol{Y}$ に影響を与えていると考えることができる
- (4.9) 式の条件付き球共分散の値が小さいとき，共変量 $\boldsymbol{C}_\alpha$ は結果変数 $\boldsymbol{Y}$ に影響を与えていないと考えることができる

したがって，二重頑健推定法により因果効果値の推定を精度良く行うためには，割り当て変数 $\boldsymbol{X}$ を条件づけた結果変数 $\boldsymbol{Y}$ と α 番目の共変量 $\boldsymbol{C}_\alpha$ に対する条件付き球共分散の値が大きくなるような共変量 $\boldsymbol{C}_\alpha$ を用いて因果効果値の推定を行う必要がある．

4.3 経験的条件付き球共分散

(4.9) 式を容易に求める方法として経験的条件付き球共分散がある．いま，n_1 を処置群に割り当てられた個数，n_0 を処置群に割り当てられていない個数，$\hat{\omega} = n_1/(n_0+n_1)$ を ω の経験的推定量とする．このとき，経験的条件付き球共分散 $\mathrm{BCov}_n^2(\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid \boldsymbol{X})$ は

$$\begin{aligned}
&\mathrm{BCov}_n^2(\boldsymbol{C}_\alpha, \boldsymbol{Y} \mid \boldsymbol{X}) \\
&= \frac{\hat{\omega}}{n_1^6} \sum_{(i,j,k,l,s,t):\ X_i,X_j,X_k,X_l,X_s,X_t=1} \xi^{\boldsymbol{C}_\alpha}_{ij,klst} \xi^{\boldsymbol{Y}}_{ij,klst} \\
&+ \frac{1-\hat{\omega}}{n_0^6} \sum_{(i,j,k,l,s,t):\ X_i,X_j,X_k,X_l,X_s,X_t=0} \xi^{\boldsymbol{C}_\alpha}_{ij,klst} \xi^{\boldsymbol{Y}}_{ij,klst}
\end{aligned} \tag{4.11}$$

となる．

5　提案手法

GLiDeR を用いることにより，傾向スコアモデルと結果モデルの変数選択および回帰係数の推定を行うことができ，二重頑健推定法による因果効果値の推定を行うことができるようになる．しかし，真の結果モデルが非線形である場合，因果効果値の推定の精度は悪くなる．このとき，共変量の個数が少ないときであれば，1 次の項と 2 次の項をすべてモデルに含めて GLiDeR により推定を行うことができ，これにより因果効果値の推定を精度良く行うことができる．しかし，共変量の個数が多くなると，1 次の項と 2 次の項の数の合計は膨大になり，計算を行うことが困難になるという問題点がある．

このような問題に対して，2 変数間の非線形性をとらえることができる尺度である球共分散を GLiDeR に組み込み，因果効果値の推定を行う．具体的には，以下の手順に従って因果効果値の推定を行う．

1. 結果モデル $\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ と傾向スコアモデル $\pi(\boldsymbol{C}; \boldsymbol{\gamma})$ に対して次のようなモデルを考える．

$$\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X}, \tag{5.1}$$

$$\pi(\boldsymbol{C}; \boldsymbol{\gamma}) = \frac{\exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})}{1 + \exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})}. \tag{5.2}$$

ただし，関数 $\psi(\boldsymbol{C}; \boldsymbol{\alpha})$ および $\phi(\boldsymbol{C}; \boldsymbol{\gamma})$ は共変量に関する項のみからなる関数であり，

$$\psi(\boldsymbol{C}; \boldsymbol{\alpha}) = \alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p + \alpha_{1,1}\boldsymbol{C}_1^2 + \alpha_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \alpha_{p,p}\boldsymbol{C}_p^2, \tag{5.3}$$

$$\phi(\boldsymbol{C}; \boldsymbol{\gamma}) = \gamma_1\boldsymbol{C}_1 + \gamma_2\boldsymbol{C}_2 + \cdots + \gamma_p\boldsymbol{C}_p + \gamma_{1,1}\boldsymbol{C}_1^2 + \gamma_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \gamma_{p,p}\boldsymbol{C}_p^2 \tag{5.4}$$

とする．このとき，関数 $\psi(\boldsymbol{C}; \boldsymbol{\alpha})$，$\phi(\boldsymbol{C}; \boldsymbol{\gamma})$ の項の数は $p(p+3)/2$ である．

2. 結果変数と各共変量に関する項 $\boldsymbol{C}_1$, $\boldsymbol{C}_2, \ldots,$ $\boldsymbol{C}_p$, $\boldsymbol{C}_1^2$, $\boldsymbol{C}_1\boldsymbol{C}_2, \ldots,$ $\boldsymbol{C}_p^2$ に対して，割り当て変数で条件付けた経験的条件付き球共分散

$$\mathrm{BCov}_n(\boldsymbol{C}_1, \boldsymbol{Y}|\boldsymbol{X}),\ \mathrm{BCov}_n(\boldsymbol{C}_2, \boldsymbol{Y}|\boldsymbol{X}), \ldots,\ \mathrm{BCov}_n(\boldsymbol{C}_p, \boldsymbol{Y}|\boldsymbol{X}),$$

$$\mathrm{BCov}_n(\boldsymbol{C}_1^2, \boldsymbol{Y}|\boldsymbol{X}),\ \mathrm{BCov}_n(\boldsymbol{C}_1\boldsymbol{C}_2, \boldsymbol{Y}|\boldsymbol{X}), \ldots,\ \mathrm{BCov}_n(\boldsymbol{C}_p^2, \boldsymbol{Y}|\boldsymbol{X})$$

を計算する．

3. 経験的条件付き球共分散が大きい q 個の項を抽出する．

4. 上記ステップ 3 により抽出した q 個の項により関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$, $\phi(\boldsymbol{C};\boldsymbol{\gamma})$ を改めて作成する．例えば，$q = 3$ であり，経験的条件付き球共分散が大きい項が $\boldsymbol{C}_1$, $\boldsymbol{C}_2$, $\boldsymbol{C}_1\boldsymbol{C}_2$ である場合，関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$, $\phi(\boldsymbol{C};\boldsymbol{\gamma})$ は次のようになる．

$$\psi(\boldsymbol{C};\boldsymbol{\alpha}) = \alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \alpha_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2, \tag{5.5}$$

$$\phi(\boldsymbol{C};\boldsymbol{\gamma}) = \gamma_1\boldsymbol{C}_1 + \gamma_2\boldsymbol{C}_2 + \gamma_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2. \tag{5.6}$$

5. 上記ステップ 4 により作成した関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$, $\phi(\boldsymbol{C};\boldsymbol{\gamma})$ によって構成される (5.1), (5.2) 式に対して，GLiDeR により共変量選択および回帰係数の推定を行う．

6. 二重頑健推定法により，因果効果値の推定を行う．

これにより，1 次の項だけではなく 2 次の項をモデルに含めたとしても，項の数は $p(p+3)/2$ 個から q 個に減らすことができ，計算時間を減らすことができる．したがって，球共分散を組み込んだことにより，1 次の項と 2 次の項をすべて考慮したうえで因果効果値の推定を行うことができるようになる．実際，球共分散を計算する時間を計測すると，$p = 10$ のとき，つまり $10(10+3)/2 = 65$ 個の球共分散を計算したときの時間は約 0.13 秒，$p = 100$ のとき，つまり $100(100+3)/2 = 5150$ 個の球共分散を計算したときの時間は約 10 秒となる．また，GLiDeR の計算時間を計測すると，結果モデルや傾向スコアモデルが 10 個の項からなるモデルであるときの計算時間は約 0.17 秒，結果モデルや傾向スコアモデルが 100 個の項からなるモデルであるときの計算時間は約 2.1 秒，結果モデルや傾向スコアモデルが 1000 個の項からなるモデルであるときの計算時間は約 123 秒，結果モデルや傾向スコアモデルが 5000 個の項からなるモデルであるときの計算時間は約 3000 秒となる．したがって，例えば $p = 100$, $q = 100$ のとき，つまり提案手法において 5150 個の球共分散と 100 個の項からなるモデルに対する GLiDeR を考えるとき，計算時間は約 12 秒となり，これは 5150 個の項からなるモデルに対する GLiDeR を考える必要がある既存手法より大幅に短い計算時間となっている．

加えて，球共分散は結果モデルを用いないで求めることができる．したがって，結果モデルが正しく推定できなくても，結果変数に影響を与えるような共変量を選択している可能性が高く，精度良く因果効果値の推定を行うことができる．

6　数値実験

6.1　人工データ 1

Koch et al. (2017) の論文をもとにデータを生成し，数値実験を行った．

6.1.1　データの生成

共変量を $\boldsymbol{C} = (\boldsymbol{C}_1, \boldsymbol{C}_2, \ldots, \boldsymbol{C}_p)$ (ただし，$\boldsymbol{C}_j = (C_{1j}, C_{2j}, \ldots, C_{nj})^T$) ，割り当て変数を $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)^T$ ，結果変数を $\boldsymbol{Y} = (Y_1, Y_2, \ldots, Y_n)^T$ とする．これらの変数の値を

1. $\boldsymbol{C} \sim \mathcal{N}(\boldsymbol{0}, I_p)$
2. $X_i \sim Bernoulli[\mathrm{expit}\{f(\boldsymbol{C}_i)\}]$
3. $Y_i \sim \mathcal{N}(X_i + g(\boldsymbol{C}_i), 1)$

によって発生させた．このとき，$\boldsymbol{0}$ はゼロベクトル，I_p は $p \times p$ 単位行列，関数 expit は

$$\mathrm{expit}(x) = \frac{\exp(x)}{\exp(x) + 1} \tag{6.1}$$

である．$\boldsymbol{Y}, \boldsymbol{X}$ を生成するときに用いる $f(\boldsymbol{C})$, $g(\boldsymbol{C})$ は Table 1 にまとめている．今回の実験において，データ数は $n = 500$，共変量の個数は $p = 10, 100$ とした．実験回数は 100 回とした．

6.1.2　推定方法

2 種類の推定方法によって因果効果値の推定を行った．1 つ目は既存手法である Koch et al. (2017) により提案された GLiDeR，2 つ目は提案手法である球共分散に基づく共変量選択を行った二重頑健推定法で推定を行った．結果モデル $\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ と傾向スコアモデル $\pi(\boldsymbol{C}; \boldsymbol{\gamma})$ は，既存手法，提案手法ともに

$$\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X}, \tag{6.2}$$

$$\pi(\boldsymbol{C}; \boldsymbol{\gamma}) = \frac{\exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})}{1 + \exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})} \tag{6.3}$$

Table 1: 真のモデル設定

設定番号	$f(\boldsymbol{C})$	$g(\boldsymbol{C})$
1	$0.4C_1 + 0.3C_2 + 0.2C_3 + 0.1C_4$	0
2	$0.5C_1 + 0.5C_2 + 0.5C_3 + 0.5C_4$	$0.5C_1 + C_3 + 0.5C_4$
3	$0.1C_1 + 0.1C_2 + C_3 + C_4 + C_5$	$2C_1 + 2C_2$
4	$0.5C_1 + 0.4C_2 + 0.3C_3 + 0.2C_4 + 0.1C_5$	$0.5C_1 + C_2 + 1.5C_3 + 2C_4 + 2.5C_5$
5	$0.2C_1 - 2C_2 + C_5 - C_6 + C_7 - C_8$	$2C_1 + 0.2C_2 + 5C_3 + 5C_4$
6	$0.5C_1 + 0.5C_2 + 0.1C_3$	$C_3 + C_4 + C_5 + \sum_{i=1}^{5}\sum_{j=1}^{5} C_iC_j$
7	$C_1 + C_2 + C_5$	$0.5\sum_{i=1}^{5}\sum_{j=1}^{5} C_iC_j$
8	$0.2C_1 + 0.2C_2 + 0.2C_5$	$0.25C_3 + (C_1 + C_2)^2 - (C_1^2 - C_3)^2$ $+(C_4^2 - 0.5C_5)(C_3 - 0.5C_4)$
9	$C_3 + C_4 + C_5 + \sum_{i=1}^{5}\sum_{j=1}^{5} C_iC_j$	$0.5C_1 + 0.5C_2 + 0.1C_3$
10	$(C_1 + C_2 + 0.5C_3)^2$	$0.5C_1 + 0.5C_3 + 0.5C_4$

とした．ただし，関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$，$\phi(\boldsymbol{C};\boldsymbol{\gamma})$ は，既存手法で共変量の個数が $p = 10$ のときおよび提案手法で共変量の個数が $p = 10, 100$ のときは

$$\psi(\boldsymbol{C};\boldsymbol{\alpha}) = \alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p + \alpha_{1,1}\boldsymbol{C}_1^2 + \alpha_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \alpha_{p,p}\boldsymbol{C}_p^2, \tag{6.4}$$

$$\phi(\boldsymbol{C};\boldsymbol{\gamma}) = \gamma_1\boldsymbol{C}_1 + \gamma_2\boldsymbol{C}_2 + \cdots + \gamma_p\boldsymbol{C}_p + \gamma_{1,1}\boldsymbol{C}_1^2 + \gamma_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \gamma_{p,p}\boldsymbol{C}_p^2 \tag{6.5}$$

とし，既存手法で共変量の個数が $p = 100$ のときは

$$\psi(\boldsymbol{C};\boldsymbol{\alpha}) = \alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p, \tag{6.6}$$

$$\phi(\boldsymbol{C};\boldsymbol{\gamma}) = \gamma_1\boldsymbol{C}_1 + \gamma_2\boldsymbol{C}_2 + \cdots + \gamma_p\boldsymbol{C}_p \tag{6.7}$$

とした．

また，提案手法において，球共分散により抽出する項の数 q は，共変量の個数が $p = 10$ のときは $q = 30$ とし，共変量の個数が $p = 100$ のときは $q = 100$ とした．

6.1.3 実験結果

推定した因果効果値の平均 2 乗誤差 (MSE) と標準偏差 (sd) を Table 2，3 にまとめている．このとき，既存手法と提案手法から得た推定値を比較し，平均 2 乗誤差または標準偏差が小さい値であった方を太字で表している．また，既存手法および提案手法において，100 回行った実験のうち各共変量に関する項が選択された割合を Table 4，5，6，7 にまとめた．このとき，選択すべき項に関しては太字で表している．

Table 2: 推定した因果効果値の MSE と標準偏差 ($p = 10$)

設定番号	既存手法	提案手法
	MSE (sd)	MSE (sd)
1	0.00749 (0.08514)	**0.00734** **(0.08443)**
2	0.00997 (0.09987)	**0.00991** **(0.09966)**
3	**0.00729** **(0.08576)**	0.00734 (0.08605)
4	**0.01235** **(0.09778)**	0.05739 (0.13935)
5	**0.04594** **(0.09572)**	0.04688 (0.09187)
6	**0.00760** **(0.08644)**	0.02854 (0.16611)
7	**0.00935** **(0.09685)**	0.01931 (0.13944)
8	0.28370 (0.53441)	**0.27653** **(0.52716)**
9	0.01528 (0.12305)	**0.01504** **(0.12104)**
10	**0.01229** **(0.11135)**	0.01245 (0.11204)

共変量の個数が少ないときの結果である Table 2 から次のことが分かる．設定 1，2，3，5，8，9，10 において，既存手法と提案手法で因果効果値の推定値に差があまり見られなかった．一方，設定 4，6，7 において，既存手法の方が平均 2 乗誤差および標準偏差の値が小さく，既存手法の方が精度良く因果効果値の推定を行えていると言える．これは，提案手法において球共分散によって共変量に関する項を抽出したときに，重要な共変量を選択していない場合があることが原因であると考えている．因果効果値を推定するにあたって，選択しないでよい共変量を選択して因

Table 3: 推定した因果効果値の MSE と標準偏差 ($p = 100$)

設定番号	既存手法	提案手法
	MSE (sd)	MSE (sd)
1	0.01075 (0.10382)	**0.01037** **(0.10227)**
2	**0.00908** **(0.09491)**	0.02528 (0.14344)
3	0.00708 (0.08433)	**0.00703** **(0.08420)**
4	**0.01701** **(0.10415)**	0.25776 (0.23195)
5	**0.04572** **(0.11265)**	0.05032 (0.18914)
6	0.53471 (0.73436)	**0.05886** **(0.24338)**
7	0.47251 (0.68932)	**0.02552** **(0.15870)**
8	0.62878 (0.78963)	**0.16198** **(0.40310)**
9	**0.01434** (0.11668)	0.01453 **(0.11433)**
10	0.01153 (0.10778)	**0.01142** **(0.10715)**

果効果値を推定するよりも，選択すべき共変量を選択しないで因果効果値を推定するほうが推定の精度が悪くなる．

Table 3 において，設定 4 のとき，既存手法のほうが提案手法と比べて平均 2 乗誤差と標準偏差はかなり小さく，精度良く因果効果値の推定を行えていた．この原因として次のことが考えられる．Table 7 において，設定 2 の回帰係数が 0.5 の項 C_1，C_4 の選択割合は高くなっている．このことから，回帰係数が小さくても正しく選択されることもあると言える．一方，設定 4 の回帰係数が 0.5，1.0 である項 C_1，C_2 の選択割合が低くなっている．これは，回帰係数が小さいだけではなく，回帰係数の値が大きい項である C_3，C_4，C_5 があることが原因であると考えられる．回帰係数の値が大きい項である C_3，C_4，C_5 の球共分散の値だけではなく，C_3，C_4，C_5 を含む 2 次の項の球共分散の値も大きくなり，球共分散の値によって共変量に関する項を抽出するときに C_1，C_2 を抽出しないことが起こり，選択割合が低くなったのではないかと考えられる．その結果，因果効果値の推定の精度が悪くなったと考えられる．また，結果モデルが非線形である設定 6，7，8 において，既存手法に比べて提

案手法のほうが平均2乗誤差と標準偏差はかなり小さく，精度良く因果効果値の推定を行えていた．これは，共変量の個数が多い $p = 100$ のとき，既存手法では2次の項をモデルに含めないで因果効果値の推定を行ったことが原因であると考えられる．このことから，結果モデルが非線形であるとき，推定するときに設定するモデルも非線形であるかどうかで推定結果に大きな差が生じると考えることができる．一方，傾向スコアモデルが非線形である設定9，10において，既存手法，提案手法ともに精度良く推定を行えている，これは，設定9における回帰係数が0.1とかなり小さい C_3 を除いて，選択すべき項を正しく選択していることが原因であると考えられる．以上のことから，真の結果モデルに含まれている項を含めて因果効果値の推定を行えているかどうかにより，因果効果値の推定の精度に大きく影響を与えると考えることができる．

Table 4: 既存手法における選択割合 ($p = 10$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.05	**1.00**	**1.00**	**1.00**	**1.00**	0.02	0.04	0.18	**1.00**	**1.00**
C_2	0.07	0.06	**1.00**	**1.00**	**0.04**	0.02	0.02	0.00	**1.00**	0.05
C_3	0.04	**1.00**	0.01	**1.00**	**1.00**	**1.00**	0.03	**1.00**	**0.56**	**1.00**
C_4	0.01	**1.00**	0.01	**1.00**	**1.00**	**1.00**	0.02	0.93	0.03	**1.00**
C_5	0.04	0.06	0.01	**1.00**	0.04	**1.00**	0.02	0.00	0.05	0.04
C_6	0.02	0.03	0.01	0.01	0.04	0.02	0.02	0.00	0.04	0.05
C_7	0.01	0.04	0.01	0.01	0.04	0.02	0.02	0.01	0.03	0.05
C_1^2	0.04	0.05	0.01	0.01	0.04	**1.00**	**1.00**	**1.00**	0.06	0.04
C_1C_2	0.02	0.03	0.01	0.01	0.04	**1.00**	**1.00**	**0.92**	0.05	0.03
C_1C_3	0.04	0.05	0.01	0.01	0.04	**1.00**	**1.00**	0.14	0.07	0.05
C_1C_4	0.03	0.05	0.01	0.01	0.04	**1.00**	**1.00**	0.20	0.05	0.05
C_1C_5	0.03	0.05	0.01	0.01	0.04	**1.00**	**1.00**	0.14	0.03	0.04
C_1C_6	0.05	0.04	0.01	0.01	0.04	0.02	0.02	0.10	0.06	0.07
C_1C_7	0.07	0.07	0.01	0.01	0.04	0.02	0.02	0.11	0.09	0.05
C_2^2	0.03	0.04	0.01	0.01	0.04	**1.00**	**1.00**	**0.92**	0.05	0.04
C_2C_3	0.02	0.04	0.01	0.01	0.04	**1.00**	**1.00**	0.02	0.03	0.02
C_2C_4	0.03	0.06	0.01	0.01	0.04	**1.00**	**1.00**	0.00	0.05	0.04
C_2C_5	0.02	0.05	0.01	0.01	0.04	**1.00**	**1.00**	0.00	0.05	0.03
C_2C_6	0.02	0.05	0.01	0.01	0.04	0.02	0.02	0.01	0.06	0.05
C_2C_7	0.05	0.06	0.01	0.01	0.04	0.02	0.03	0.01	0.09	0.06
C_3^2	0.02	0.03	0.01	0.01	0.04	**1.00**	**1.00**	**0.92**	0.05	0.03
C_3C_4	0.06	0.07	0.01	0.01	0.04	**1.00**	**1.00**	0.04	0.09	0.07
C_3C_5	0.03	0.04	0.01	0.01	0.04	**1.00**	**1.00**	**0.24**	0.05	0.03
C_3C_6	0.02	0.03	0.01	0.01	0.04	0.02	0.02	0.00	0.04	0.02
C_3C_7	0.03	0.04	0.01	0.01	0.04	0.02	0.02	0.03	0.04	0.05
C_4^2	0.03	0.05	0.01	0.01	0.04	**1.00**	**1.00**	0.13	0.07	0.06
C_4C_5	0.05	0.09	0.01	0.01	0.04	**1.00**	**1.00**	**0.05**	0.07	0.07
C_4C_6	0.04	0.04	0.01	0.01	0.04	0.02	0.02	0.01	0.05	0.02
C_4C_7	0.04	0.05	0.01	0.01	0.04	0.02	0.02	0.01	0.06	0.03
C_5^2	0.04	0.03	0.01	0.01	0.04	**1.00**	**1.00**	0.00	0.08	0.06
C_5C_6	0.04	0.06	0.01	0.01	0.04	0.02	0.02	0.00	0.06	0.06
C_5C_7	0.06	0.08	0.01	0.01	0.04	0.02	0.03	0.00	0.08	0.07
C_6^2	0.01	0.04	0.01	0.01	0.04	0.02	0.02	0.00	0.04	0.04
C_6C_7	0.05	0.04	0.01	0.01	0.04	0.02	0.03	0.00	0.06	0.04
C_7^2	0.05	0.06	0.01	0.01	0.04	0.02	0.02	0.01	0.08	0.06

Table 5: 提案手法における選択割合 ($p = 10$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.04	**1.00**	**1.00**	**0.25**	**0.99**	0.05	0.08	0.19	**1.00**	**1.00**
C_2	0.05	0.01	**1.00**	**0.98**	**0.00**	0.02	0.04	0.02	**1.00**	0.05
C_3	0.04	**1.00**	0.00	**1.00**	**1.00**	**1.00**	0.06	**1.00**	**0.37**	**1.00**
C_4	0.02	**1.00**	0.00	**1.00**	**1.00**	**0.96**	0.04	0.93	0.02	**1.00**
C_5	0.03	0.01	0.00	**1.00**	0.00	**0.96**	0.07	0.02	0.04	0.02
C_6	0.02	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
C_7	0.01	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.01
C_1^2	0.02	0.02	0.00	0.00	0.00	**0.85**	**0.72**	**1.00**	0.03	0.02
C_1C_2	0.04	0.01	0.00	0.00	0.00	**1.00**	**1.00**	**0.93**	0.06	0.03
C_1C_3	0.05	0.01	0.00	0.00	0.00	**1.00**	**0.99**	0.16	0.03	0.05
C_1C_4	0.02	0.03	0.00	0.00	0.00	**0.99**	**1.00**	0.20	0.02	0.05
C_1C_5	0.03	0.02	0.00	0.00	0.00	**0.99**	**1.00**	0.15	0.01	0.01
C_1C_6	0.04	0.01	0.00	0.00	0.00	0.01	0.01	0.11	0.01	0.04
C_1C_7	0.04	0.02	0.00	0.00	0.00	0.01	0.01	0.12	0.02	0.04
C_2^2	0.02	0.00	0.00	0.00	0.00	**0.78**	**0.79**	**0.92**	0.04	0.02
C_2C_3	0.02	0.01	0.00	0.00	0.00	**0.99**	**0.98**	0.03	0.02	0.03
C_2C_4	0.03	0.02	0.00	0.00	0.00	**1.00**	**0.99**	0.02	0.02	0.02
C_2C_5	0.03	0.01	0.00	0.00	0.00	**0.99**	**0.99**	0.01	0.03	0.02
C_2C_6	0.03	0.00	0.00	0.00	0.00	0.02	0.00	0.02	0.02	0.04
C_2C_7	0.03	0.01	0.00	0.00	0.00	0.03	0.01	0.01	0.05	0.03
C_3^2	0.01	0.01	0.00	0.00	0.00	**0.75**	**0.71**	**0.94**	0.01	0.00
C_3C_4	0.01	0.03	0.00	0.00	0.00	**1.00**	**1.00**	0.05	0.03	0.05
C_3C_5	0.02	0.00	0.00	0.00	0.00	**0.99**	**0.99**	**0.21**	0.01	0.01
C_3C_6	0.01	0.01	0.00	0.00	0.00	0.04	0.05	0.02	0.01	0.01
C_3C_7	0.02	0.01	0.00	0.00	0.00	0.02	0.01	0.01	0.01	0.02
C_4^2	0.04	0.01	0.00	0.00	0.00	**0.73**	**0.71**	0.14	0.01	0.05
C_4C_5	0.06	0.01	0.00	0.00	0.00	**1.00**	**1.00**	**0.03**	0.04	0.03
C_4C_6	0.04	0.01	0.00	0.00	0.00	0.02	0.00	0.01	0.01	0.01
C_4C_7	0.04	0.01	0.00	0.00	0.00	0.00	0.02	0.02	0.02	0.04
C_5^2	0.03	0.00	0.00	0.00	0.00	**0.80**	**0.74**	0.00	0.02	0.02
C_5C_6	0.01	0.01	0.00	0.00	0.00	0.01	0.00	0.00	0.02	0.01
C_5C_7	0.04	0.02	0.00	0.00	0.00	0.01	0.01	0.01	0.02	0.01
C_6^2	0.01	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.02	0.02
C_6C_7	0.05	0.01	0.00	0.00	0.00	0.00	0.01	0.00	0.03	0.02
C_7^2	0.04	0.02	0.00	0.00	0.00	0.00	0.00	0.00	0.04	0.02

Table 6: 既存手法における選択割合 ($p = 100$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.12	**1.00**	**1.00**	**1.00**	**1.00**	0.72	0.93	0.54	**1.00**	**1.00**
C_2	0.11	0.05	**1.00**	**1.00**	**0.06**	0.73	0.93	0.31	**1.00**	0.03
C_3	0.10	**1.00**	0.02	**1.00**	**1.00**	**0.95**	0.94	**1.00**	**0.52**	**1.00**
C_4	0.11	**1.00**	0.02	**1.00**	**1.00**	**0.95**	0.94	0.88	0.06	**1.00**
C_5	0.11	0.05	0.02	**1.00**	0.06	**0.93**	0.93	0.31	0.05	0.04
C_6	0.10	0.04	0.02	0.01	0.06	0.69	0.93	0.32	0.04	0.03
C_7	0.11	0.06	0.02	0.01	0.06	0.69	0.93	0.32	0.07	0.04

Table 7: 提案手法における選択割合 (p = 100)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.00	**0.89**	**1.00**	**0.02**	**0.55**	0.11	0.09	0.17	**1.00**	**1.00**
C_2	0.01	0.00	**1.00**	**0.49**	**0.00**	0.04	0.02	0.01	**1.00**	0.03
C_3	0.02	**1.00**	0.00	**0.98**	**1.00**	**0.90**	0.08	**1.00**	**0.05**	**0.99**
C_4	0.00	**0.86**	0.00	**1.00**	**1.00**	**0.87**	0.12	0.50	0.00	**1.00**
C_5	0.00	0.00	0.00	**1.00**	0.00	**0.85**	0.07	0.00	0.01	0.00
C_6	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.00	0.00
C_7	0.00	0.02	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
C_1^2	0.00	0.01	0.02	0.00	0.00	**0.56**	**0.45**	**1.00**	0.00	0.03
C_1C_2	0.00	0.00	0.02	0.00	0.00	**0.99**	**0.92**	**1.00**	0.02	0.00
C_1C_3	0.01	0.09	0.00	0.00	0.02	**0.93**	**0.90**	0.20	0.00	0.03
C_1C_4	0.00	0.03	0.02	0.02	0.03	**0.94**	**0.91**	0.17	0.00	0.05
C_1C_5	0.00	0.01	0.02	0.04	0.00	**0.96**	**0.90**	0.19	0.00	0.00
C_1C_6	0.02	0.02	0.01	0.00	0.00	0.00	0.01	0.14	0.00	0.00
C_1C_7	0.01	0.01	0.00	0.00	0.00	0.01	0.01	0.09	0.00	0.01
C_2^2	0.00	0.00	0.02	0.00	0.00	**0.56**	**0.46**	**0.89**	0.01	0.00
C_2C_3	0.01	0.06	0.01	0.00	0.03	**0.95**	**0.91**	0.01	0.00	0.03
C_2C_4	0.00	0.00	0.02	0.02	0.03	**0.94**	**0.90**	0.05	0.01	0.02
C_2C_5	0.00	0.00	0.02	0.03	0.00	**0.92**	**0.92**	0.00	0.01	0.00
C_2C_6	0.00	0.00	0.01	0.00	0.00	0.01	0.00	0.00	0.00	0.00
C_2C_7	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.02	0.00
C_3^2	0.00	0.07	0.00	0.00	0.03	**0.46**	**0.44**	**0.62**	0.00	0.00
C_3C_4	0.00	0.07	0.00	0.03	0.03	**0.98**	**0.91**	0.12	0.00	0.04
C_3C_5	0.00	0.09	0.00	0.04	0.03	**0.96**	**0.89**	**0.02**	0.00	0.01
C_3C_6	0.00	0.05	0.00	0.00	0.02	0.01	0.00	0.00	0.00	0.01
C_3C_7	0.01	0.03	0.00	0.00	0.01	0.00	0.00	0.01	0.00	0.00
C_4^2	0.01	0.00	0.00	0.01	0.03	**0.52**	**0.48**	0.04	0.01	0.03
C_4C_5	0.00	0.00	0.00	0.04	0.03	**0.99**	**0.95**	**0.00**	0.00	0.01
C_4C_6	0.00	0.01	0.00	0.00	0.02	0.01	0.00	0.00	0.00	0.03
C_4C_7	0.00	0.01	0.00	0.00	0.02	0.02	0.02	0.00	0.00	0.00
C_5^2	0.01	0.00	0.00	0.04	0.00	**0.46**	**0.34**	0.00	0.00	0.01
C_5C_6	0.01	0.00	0.00	0.04	0.00	0.00	0.00	0.00	0.00	0.01
C_5C_7	0.00	0.00	0.01	0.02	0.00	0.01	0.03	0.00	0.00	0.00
C_6^2	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.01
C_6C_7	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.00	0.00
C_7^2	0.01	0.01	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00

6.1.4　高次の項を含む提案手法の結果

6.1.3 節では，提案手法において，結果モデルおよび傾向スコアモデルである (6.2), (6.3) 式に対して共変量に関する関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$，$\phi(\boldsymbol{C};\boldsymbol{\gamma})$ は 2 次の項まで含めた関数として推定を行った．本節では，(6.2), (6.3) 式に対して，共変量に関する関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$, $\phi(\boldsymbol{C};\boldsymbol{\gamma})$ を 2 次の項まで含めた関数から d ($d = 2, 3, 4, 5, 6$) 次の項まで含めた関数に変更して，提案手法により因果効果値の推定を行った．このモデル設定による推定を，真の結果モデルにおいて共変量に関する項が 4 次の項まで含まれている設定 8 に対して行った．また，共変量の個数は $p = 10$，球共分散の値により抽出する項の数は $q = 30$ とした．

推定結果は Table 8 となった．実験結果より，設定 8 における結果モデルの次数と同じである 4 次の項まで含めて推定したとき，もっとも精度良く因果効果値の推定を行うことができることが分かる．これは，2 次の項または 3 次の項まで含めて因果効果値の推定を行ったときは，選択すべき項である $C_3C_4^2$，C_4^3，$C_1^2C_3$ や C_1^4 を選択できなかったため推定の精度が悪くなり，5 次の項または 6 次の項まで含めて因果効果値の推定を行ったときは，選択する必要がない項が余分に含まれていたため因果効果値の推定の精度が悪くなったと考えられる．したがって，この結果から，因果効果値の推定を行うにあたり，次数にかかわらず，モデルに含めるべき項を正しくモデルに含めてから因果効果値の推定を行うことが重要であると言える．

Table 8: 次元を変更して推定した因果効果値

次元	2	3	4	5	6
MSE	0.27653	0.22941	**0.07818**	0.17629	0.21418
(sd)	(0.52716)	(0.47844)	**(0.28071)**	(0.42185)	(0.46490)

6.2　人工データ 2

Koch et al. (2017) の論文をもとにデータを生成し，数値実験を行った．このとき，結果変数は連続変数ではなく，2 値変数とした．

6.2.1　データの生成

共変量を $\boldsymbol{C} = (\boldsymbol{C}_1, \boldsymbol{C}_2, \ldots, \boldsymbol{C}_p)$ (ただし，$\boldsymbol{C}_j = (C_{1j}, C_{2j}, \ldots, C_{nj})^T$) ，割り当て変数を $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)^T$ ，結果変数を $\boldsymbol{Y} = (Y_1, Y_2, \ldots, Y_n)^T$ とする．これらの変数の値を

1. $\boldsymbol{C} \sim \mathcal{N}(\boldsymbol{0}, I_p)$
2. $X_i \sim Bernoulli[\text{expit}\{f(\boldsymbol{C}_i)\}]$
3. $Y_i \sim Bernoulli[\text{expit}\{X_i + g(\boldsymbol{C}_i)\}]$

によって発生させた．本節では，結果変数 Y_i を 2 値変数とするため，ベルヌーイ分布によって発生させた．$\boldsymbol{Y}, \boldsymbol{X}$ を生成するときに用いる $f(\boldsymbol{C})$, $g(\boldsymbol{C})$ の組合わせは 6.1.1 節のときと同様に Table 1 にまとめている．今回の実験において，データ数は $n = 500$, 共変量の個数は $p = 10, 100$ とした．実験回数は 100 回とした．

6.2.2　推定方法

6.1 節と同様に，既存手法である Koch et al. (2017) により提案された GLiDeR と提案手法である球共分散に基づく共変量選択を行った二重頑健推定法で推定を行った．結果モデル $\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha})$ と傾向スコアモデル $\pi(\boldsymbol{C}; \boldsymbol{\gamma})$ は，既存手法，提案手法ともに

$$\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \frac{\exp(\psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X})}{1 + \exp(\psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X}))}, \tag{6.8}$$

$$\pi(\boldsymbol{C}; \boldsymbol{\gamma}) = \frac{\exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})}{1 + \exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})} \tag{6.9}$$

とした．ただし，関数 $\psi(\boldsymbol{C}; \boldsymbol{\alpha})$, $\phi(\boldsymbol{C}; \boldsymbol{\gamma})$ は 6.1 節と同じとした．結果変数が 2 値変数であるため，それに伴い 3.5 節で説明した GLiDeR の推定方法を変更する必要がある．変更の詳細は付録 A を参照されたい．

また，提案手法において，球共分散により抽出する項の数 q は，共変量の個数が $p = 10$ のときは $q = 30$ とし，共変量の個数が $p = 100$ のときは $q = 100$ とした．

6.2.3　実験結果

推定した因果効果値の平均 2 乗誤差 (MSE) と標準偏差 (sd) を Table 9 にまとめている．このとき，既存手法と提案手法から得た推定値を比較し，平均 2 乗誤差または

標準偏差が小さい値であった方を太字で表している．また，既存手法および提案手法において，100 回行った実験のうち各共変量に関する項が選択された割合を Table 11，12，13，14 にまとめた．このとき，選択すべき項に関しては太字で表している．

Table 9: 推定した因果効果値の MSE と標準偏差 ($p = 10$)

設定番号	既存手法	提案手法
	MSE (sd)	MSE (sd)
1	0.00273 (0.05249)	**0.00238** **(0.04873)**
2	**0.00247** **(0.04948)**	0.00259 (0.05076)
3	0.00112 (0.03282)	**0.00107** **(0.03202)**
4	**0.00095** **(0.03045)**	0.00124 (0.03311)
5	0.00057 (0.02404)	**0.00055** **(0.02314)**
6	**0.00131** **(0.03624)**	0.00161 (0.04027)
7	0.00198 (0.04461)	**0.00216** **(0.04624)**
8	**0.00138** **(0.03716)**	0.00146 (0.03830)
9	0.00334 (0.05722)	**0.00313** **(0.05565)**
10	**0.00229** **(0.04788)**	0.00243 (0.04924)

Table 9，10 より，全体的に推定した因果効果値は真の因果効果値に近い値であることが見て取れる．一方，共変量に関する項の選択割合をみると，結果変数が連続変数であるときの実験結果である Table 4，5，6，7 と比較すると，選択すべきではない項を選択している割合が高くなっていることがわかる．加えて，設定 6，7 において，選択すべき 2 次の項の選択割合が結果変数が連続変数であるときに比べて低くなっていることがわかる．しかし，結果変数が連続変数である Table 2，3 と比べて，設定平均 2 乗誤差および標準偏差は小さくなっていた．これは，次のことが原因であると考えられる．もし，真の結果モデルが

$$\frac{\exp(\psi(\boldsymbol{C};\boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X})}{1 + \exp(\psi(\boldsymbol{C};\boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X}))} \tag{6.10}$$

Table 10: 推定した因果効果値の MSE と標準偏差 ($p = 100$)

設定番号	既存手法	提案手法
	MSE (sd)	MSE (sd)
1	0.00326 (0.05558)	**0.00224** **(0.04571)**
2	**0.00175** **(0.04185)**	0.00445 (0.05449)
3	0.00125 (0.03482)	**0.00095** **(0.03070)**
4	**0.00104** **(0.03205)**	0.00276 (0.04147)
5	**0.00046** (0.02136)	0.00049 **(0.02078)**
6	**0.00201** (0.04467)	0.00214 **(0.03920)**
7	0.00610 (0.07842)	**0.00179** **(0.04254)**
8	0.00191 (0.04337)	**0.00168** **(0.04086)**
9	**0.00531** **(0.07248)**	0.01064 (0.10354)
10	**0.00265** **(0.05174)**	0.00274 (0.05259)

であるとき，$\psi(\boldsymbol{C};\boldsymbol{\alpha}) + \alpha_{p+1}$ の値が大きいもしくは小さいと，$\alpha_{p+2}X$ の値にかかわらず，1 もしくは 0 に限りなく近づく．その結果，処置群に割り当てられたときの結果と処置群に割り当てられなかったときの結果の差は 0 となる可能性がある．したがって，真の因果効果値にかかわらず，推定した因果効果値は 0 に近づくと考えられる．このことが原因で，共変量に関する項の選択割合が悪いにもかかわらず，平均 2 乗誤差や標準偏差は小さかったのではないかと考えられる．

Table 11: 既存手法における選択割合 ($p = 10$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.83	**0.99**	**1.00**	**0.95**	**1.00**	0.96	0.57	0.18	**0.98**	**0.98**
C_2	0.83	0.19	**1.00**	**1.00**	**0.84**	0.95	0.55	0.18	**0.99**	0.09
C_3	0.83	**1.00**	0.40	**1.00**	**1.00**	**0.99**	0.10	**1.00**	**0.15**	**0.98**
C_4	0.83	**1.00**	0.43	**1.00**	**1.00**	**0.97**	0.07	1.00	0.12	**1.00**
C_5	0.83	0.07	0.44	**1.00**	0.58	**0.99**	0.51	0.18	0.14	0.11
C_6	0.83	0.07	0.01	0.08	0.68	0.26	0.10	0.11	0.13	0.11
C_7	0.83	0.07	0.01	0.08	0.74	0.30	0.11	0.17	0.12	0.09
C_1^2	0.83	0.07	0.00	0.07	0.01	**0.94**	**0.45**	**1.00**	0.12	0.10
C_1C_2	0.83	0.06	0.02	0.07	0.06	**0.99**	**0.66**	**1.00**	0.13	0.15
C_1C_3	0.83	0.07	0.00	0.11	0.07	**0.97**	**0.60**	0.12	0.12	0.08
C_1C_4	0.83	0.08	0.02	0.09	0.01	**1.00**	**0.71**	0.13	0.12	0.09
C_1C_5	0.83	0.09	0.03	0.07	0.07	**0.99**	**0.63**	0.03	0.13	0.09
C_1C_6	0.83	0.01	0.02	0.10	0.10	0.21	0.08	0.06	0.12	0.08
C_1C_7	0.83	0.07	0.03	0.12	0.10	0.33	0.12	0.06	0.13	0.08
C_2^2	0.83	0.07	0.01	0.03	0.11	**0.95**	**0.44**	**1.00**	0.13	0.10
C_2C_3	0.83	0.09	0.01	0.07	0.05	**0.97**	**0.60**	0.08	0.14	0.09
C_2C_4	0.83	0.11	0.01	0.08	0.05	**0.95**	**0.68**	0.09	0.12	0.13
C_2C_5	0.83	0.10	0.02	0.05	0.11	**0.98**	**0.62**	0.07	0.13	0.10
C_2C_6	0.83	0.07	0.03	0.07	0.05	0.27	0.08	0.09	0.12	0.09
C_2C_7	0.83	0.07	0.01	0.12	0.08	0.33	0.12	0.08	0.12	0.09
C_3^2	0.83	0.07	0.01	0.07	0.04	**0.93**	**0.50**	**1.00**	0.12	0.09
C_3C_4	0.83	0.08	0.01	0.07	0.04	**0.99**	**0.62**	0.12	0.13	0.09
C_3C_5	0.83	0.09	0.01	0.05	0.07	**0.94**	**0.65**	**0.61**	0.13	0.12
C_3C_6	0.83	0.06	0.02	0.11	0.04	0.24	0.12	0.09	0.12	0.10
C_3C_7	0.83	0.06	0.05	0.06	0.04	0.26	0.12	0.10	0.12	0.10
C_4^2	0.83	0.08	0.03	0.04	0.07	**0.90**	**0.48**	0.08	0.12	0.09
C_4C_5	0.83	0.06	0.03	0.05	0.09	**0.94**	**0.66**	**0.21**	0.12	0.09
C_4C_6	0.83	0.07	0.02	0.09	0.08	0.33	0.07	0.10	0.12	0.09
C_4C_7	0.83	0.07	0.02	0.10	0.05	0.37	0.07	0.07	0.12	0.09
C_5^2	0.83	0.07	0.02	0.02	0.11	**0.97**	**0.46**	0.09	0.12	0.11
C_5C_6	0.83	0.09	0.01	0.07	0.10	0.24	0.10	0.07	0.13	0.10
C_5C_7	0.83	0.08	0.02	0.05	0.08	0.25	0.12	0.10	0.13	0.08
C_6^2	0.83	0.09	0.04	0.13	0.11	0.25	0.12	0.11	0.13	0.09
C_6C_7	0.83	0.07	0.04	0.12	0.07	0.36	0.13	0.08	0.13	0.11
C_7^2	0.83	0.07	0.01	0.08	0.10	0.20	0.12	0.13	0.13	0.08

Table 12: 提案手法における選択割合 ($p = 10$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.14	**0.97**	**1.00**	**0.68**	**0.98**	0.86	0.37	0.23	**0.98**	**0.99**
C_2	0.16	0.18	**1.00**	**0.96**	**0.24**	0.92	0.26	0.26	**1.00**	0.03
C_3	0.18	**1.00**	0.17	**1.00**	**1.00**	**0.88**	0.12	**1.00**	**0.10**	**1.00**
C_4	0.18	**0.96**	0.24	**1.00**	**1.00**	**0.88**	0.05	0.87	0.02	**1.00**
C_5	0.15	0.04	0.21	**1.00**	0.25	**0.92**	0.37	0.07	0.04	0.03
C_6	0.14	0.03	0.04	0.05	0.26	0.13	0.05	0.02	0.01	0.05
C_7	0.22	0.03	0.01	0.05	0.28	0.08	0.03	0.08	0.01	0.02
C_1^2	0.17	0.02	0.00	0.05	0.04	**0.53**	**0.29**	**1.00**	0.03	0.08
C_1C_2	0.21	0.01	0.03	0.03	0.02	**0.79**	**0.48**	**0.97**	0.04	0.04
C_1C_3	0.18	0.04	0.04	0.07	0.07	**0.72**	**0.60**	0.14	0.00	0.03
C_1C_4	0.18	0.05	0.06	0.07	0.02	**0.66**	**0.52**	0.08	0.01	0.02
C_1C_5	0.20	0.03	0.05	0.07	0.03	**0.78**	**0.48**	0.02	0.02	0.03
C_1C_6	0.22	0.01	0.02	0.05	0.05	0.06	0.06	0.05	0.01	0.01
C_1C_7	0.15	0.03	0.05	0.10	0.00	0.09	0.02	0.07	0.02	0.01
C_2^2	0.23	0.02	0.01	0.03	0.04	**0.51**	**0.26**	**1.00**	0.05	0.04
C_2C_3	0.17	0.02	0.03	0.08	0.02	**0.74**	**0.49**	0.03	0.03	0.03
C_2C_4	0.14	0.06	0.01	0.07	0.04	**0.74**	**0.56**	0.09	0.01	0.04
C_2C_5	0.18	0.03	0.05	0.02	0.04	**0.72**	**0.44**	0.07	0.05	0.01
C_2C_6	0.11	0.01	0.03	0.07	0.00	0.09	0.05	0.10	0.02	0.00
C_2C_7	0.17	0.02	0.02	0.09	0.01	0.10	0.02	0.02	0.00	0.01
C_3^2	0.18	0.02	0.02	0.08	0.00	**0.42**	**0.34**	**0.95**	0.01	0.03
C_3C_4	0.14	0.03	0.02	0.02	0.01	**0.47**	**0.57**	0.06	0.03	0.00
C_3C_5	0.18	0.02	0.02	0.04	0.06	**0.49**	**0.50**	**0.43**	0.04	0.03
C_3C_6	0.15	0.03	0.03	0.07	0.01	0.10	0.06	0.05	0.01	0.02
C_3C_7	0.18	0.02	0.03	0.08	0.01	0.05	0.02	0.06	0.03	0.02
C_4^2	0.15	0.02	0.03	0.03	0.02	**0.32**	**0.36**	0.04	0.03	0.00
C_4C_5	0.15	0.01	0.01	0.03	0.03	**0.54**	**0.55**	**0.03**	0.01	0.03
C_4C_6	0.14	0.01	0.03	0.03	0.03	0.09	0.05	0.03	0.03	0.01
C_4C_7	0.18	0.02	0.01	0.02	0.00	0.07	0.01	0.01	0.02	0.00
C_5^2	0.18	0.04	0.06	0.04	0.04	**0.39**	**0.38**	0.05	0.03	0.06
C_5C_6	0.16	0.03	0.07	0.09	0.02	0.07	0.04	0.03	0.02	0.03
C_5C_7	0.18	0.03	0.04	0.03	0.04	0.07	0.05	0.03	0.01	0.01
C_6^2	0.16	0.02	0.04	0.05	0.05	0.07	0.03	0.02	0.02	0.03
C_6C_7	0.21	0.04	0.05	0.09	0.01	0.12	0.06	0.02	0.01	0.04
C_7^2	0.18	0.01	0.00	0.05	0.03	0.07	0.04	0.02	0.03	0.01

Table 13: 既存手法における選択割合 ($p = 100$)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	1.00	**1.00**	**1.00**	**0.99**	**1.00**	0.98	1.00	0.17	**1.00**	**1.00**
C_2	1.00	0.19	**1.00**	**1.00**	**0.83**	0.97	1.00	0.15	**1.00**	0.38
C_3	1.00	**1.00**	0.43	**1.00**	**1.00**	**0.88**	1.00	**1.00**	**0.49**	**1.00**
C_4	1.00	**1.00**	0.48	**1.00**	**1.00**	**0.89**	1.00	0.95	0.47	**1.00**
C_5	1.00	0.12	0.46	**1.00**	0.67	**0.83**	1.00	0.15	0.47	0.40
C_6	1.00	0.11	0.07	0.17	0.61	0.59	1.00	0.15	0.47	0.38
C_7	1.00	0.11	0.07	0.15	0.62	0.59	1.00	0.17	0.47	0.37

Table 14: 提案手法における選択割合 (p = 100)

共変量	設定番号									
	1	2	3	4	5	6	7	8	9	10
C_1	0.01	**0.61**	**1.00**	**0.09**	**0.86**	0.42	0.07	0.14	**0.80**	**0.74**
C_2	0.02	0.03	**1.00**	**0.70**	**0.01**	0.42	0.09	0.10	**0.72**	0.05
C_3	0.00	**1.00**	0.02	**1.00**	**1.00**	**0.58**	0.08	**1.00**	**0.01**	**0.79**
C_4	0.00	**0.54**	0.01	**1.00**	**1.00**	**0.47**	0.13	0.36	0.01	**0.82**
C_5	0.00	0.01	0.03	**1.00**	0.02	**0.41**	0.08	0.02	0.00	0.01
C_6	0.02	0.01	0.01	0.00	0.03	0.00	0.01	0.00	0.01	0.00
C_7	0.01	0.00	0.00	0.00	0.00	0.01	0.01	0.01	0.00	0.00
C_1^2	0.01	0.01	0.00	0.00	0.01	**0.03**	**0.02**	**0.94**	0.01	0.01
C_1C_2	0.01	0.00	0.00	0.00	0.02	**0.10**	**0.08**	**0.81**	0.00	0.01
C_1C_3	0.00	0.01	0.03	0.00	0.00	**0.12**	**0.08**	0.03	0.01	0.00
C_1C_4	0.01	0.00	0.00	0.01	0.00	**0.15**	**0.14**	0.00	0.01	0.00
C_1C_5	0.00	0.01	0.04	0.02	0.00	**0.06**	**0.06**	0.03	0.01	0.00
C_1C_6	0.01	0.01	0.01	0.00	0.01	0.00	0.00	0.00	0.01	0.00
C_1C_7	0.00	0.01	0.00	0.00	0.00	0.02	0.01	0.01	0.00	0.01
C_2^2	0.01	0.00	0.00	0.00	0.00	**0.06**	**0.03**	**0.88**	0.00	0.02
C_2C_3	0.00	0.01	0.03	0.00	0.02	**0.15**	**0.07**	0.00	0.02	0.00
C_2C_4	0.01	0.00	0.02	0.01	0.06	**0.09**	**0.12**	0.05	0.00	0.00
C_2C_5	0.02	0.00	0.03	0.00	0.01	**0.13**	**0.12**	0.02	0.01	0.01
C_2C_6	0.01	0.00	0.01	0.00	0.01	0.01	0.01	0.02	0.00	0.01
C_2C_7	0.00	0.00	0.00	0.01	0.01	0.02	0.01	0.01	0.00	0.00
C_3^2	0.00	0.00	0.00	0.00	0.00	**0.04**	**0.08**	**0.33**	0.01	0.01
C_3C_4	0.00	0.01	0.00	0.01	0.00	**0.04**	**0.10**	0.00	0.00	0.01
C_3C_5	0.01	0.00	0.00	0.00	0.00	**0.05**	**0.07**	**0.10**	0.01	0.00
C_3C_6	0.00	0.00	0.00	0.02	0.01	0.03	0,99	0.03	0.01	0.00
C_3C_7	0.01	0.01	0.01	0.00	0.02	0.01	0.01	0.00	0.00	0.00
C_4^2	0.01	0.00	0.01	0.00	0.00	**0.02**	**0.05**	0.00	0.00	0.00
C_4C_5	0.00	0.00	0.00	0.00	0.00	**0.05**	**0.05**	**0.01**	0.01	0.02
C_4C_6	0.01	0.00	0.00	0.00	0.00	0.00	0.00	0.01	0.01	0.02
C_4C_7	0.01	0.00	0.00	0.00	0.01	0.00	0.01	0.00	0.01	0.01
C_5^2	0.00	0.02	0.02	0.00	0.01	**0.04**	**0.04**	0.00	0.01	0.01
C_5C_6	0.00	0.00	0.00	0.00	0.00	0.01	0.01	0.00	0.00	0.01
C_5C_7	0.00	0.00	0.00	0.02	0.00	0.00	0.01	0.01	0.00	0.00
C_6^2	0.02	0.00	0.00	0.00	0.01	0.03	0.00	0.00	0.00	0.00
C_6C_7	0.00	0.00	0.01	0.01	0.03	0.00	0.02	0.00	0.00	0.00
C_7^2	0.01	0.00	0.01	0.00	0.00	0.00	0.00	0.00	0.02	0.00

6.3 実データへの適用

6.3.1 解析データの基本統計量

腎結石に対する内視鏡治療患者データ (Komeya et al., 2018) に対して提案手法を適用した．提案手法および GLiDeR を考え，データ数は $n = 256$，共変量の個数は $p = 16$ であった．各共変量の基本統計量は Table 15 の通りである．割り当て変数 X として術後尿管ステントの留置・非留置群を考え，$X = 0$ ならば術後尿管ステント留置群，$X = 1$ ならば非留置群とした．結果変数として，残石の有無 $Y_{Rs} = 1$，$Y_{Rs} = 0$，術後急性憎悪有無 $Y_{TA} = 1$，$Y_{TA} = 0$ の 2 種類を考えた．

Table 15: 実データの説明

変数名	情報
sex	1：60%，0：40%
height	平均：162.4，分散 9.872
body weight	平均：62.69，分散：15.44
body mass index	平均：23.60，分散：4.920
age	平均：57.92，分散 14.20
right or left (right:0 , left:1)	1：54%，0：46%
the sum of the volume volume	平均：1.664，分散：2.207
stone number	1：50%，0：50%
CT value	平均：932.9，分散：343.8
preoperative stenting(none:0 , yes:1)	1：57%，0：43%
stenosis of ureter(none:0 , yes:1)	1：24%，0：76%
pretreatment(none:0 , yes:1)	1：23%，0：77%
preoperative white blood cell count	平均：6539，分散：1847
preoperative C-reactive protein	平均：0.4498，分散：1.043
Preoperative creatinine	平均：0.8482，分散：0.3031
ope time	平均：88.64，分散：31.03

6.3.2 推定方法

提案手法および GLiDeR を考え，モデルは

$$\mu(\boldsymbol{X}, \boldsymbol{C}; \boldsymbol{\alpha}) = \frac{\exp(\psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X})}{1 + \exp(\psi(\boldsymbol{C}; \boldsymbol{\alpha}) + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X}))}, \tag{6.11}$$

$$\pi(\boldsymbol{C}; \boldsymbol{\gamma}) = \frac{\exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})}{1 + \exp(\phi(\boldsymbol{C}; \boldsymbol{\gamma}) + \gamma_{p+1})} \tag{6.12}$$

とした．ただし，関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$，$\phi(\boldsymbol{C};\boldsymbol{\gamma})$ は

$$\psi(\boldsymbol{C};\boldsymbol{\alpha}) = \alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p + \alpha_{1,1}\boldsymbol{C}_1^2 + \alpha_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \alpha_{p,p}\boldsymbol{C}_p^2, \tag{6.13}$$

$$\phi(\boldsymbol{C};\boldsymbol{\gamma}) = \gamma_1\boldsymbol{C}_1 + \gamma_2\boldsymbol{C}_2 + \cdots + \gamma_p\boldsymbol{C}_p + \gamma_{1,1}\boldsymbol{C}_1^2 + \gamma_{1,2}\boldsymbol{C}_1\boldsymbol{C}_2 + \cdots + \gamma_{p,p}\boldsymbol{C}_p^2 \tag{6.14}$$

とした．提案手法においては，関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$，$\phi(\boldsymbol{C};\boldsymbol{\gamma})$ は (6.13)，(6.14) 式だけではなく，共変量に関する項を d ($d = 2, 3, 4, 5, 6, 7, 8$) 次の項まで含めた関数に変更した場合に対しても，因果効果値の推定を行った．結果変数が 2 値であるため，付録 A の方法を用いた．また，提案手法において，球共分散により抽出する項の数 q は $q = 30$ とした．

6.3.3 実験結果

推定した因果効果値を Table 16 にまとめている．Komeya et al. (2018) は，術後尿管ステント留置群と非留置群での患者の残石および術後急性憎悪の結果に差がないことを示している．このとき，既存手法，提案手法ともに 0 に近い因果効果値を推定しているため，適切に因果効果値の推定を行っていると言える．

Table 16: 推定した因果効果値

	既存手法	提案手法
残石	0.02107	0.03389
術後急性憎悪	−0.01157	−0.04768

また，既存手法および提案手法に対してブートストラップ法を用いて因果効果推定値に対する 95%信頼区間を求めた．このときブートストラップ法の反復回数は 2000 回とした．それぞれの推定法の信頼区間を Fig. 2，3 にまとめた．このとき，赤色は既存手法の信頼区間，青色は提案手法の信頼区間である．

Fig. 2，3 より，既存手法および提案手法両方とも，信頼区間が 0 を含んでいることがわかる．このことからも，既存手法と提案手法ともに因果効果値の推定を適切に行えていると言うことができる．また，既存手法と提案手法を比較したとき，提案手法のほうが信頼区間が広いという結果となった．したがって，提案手法の方が誤った因果効果値を推定しにくいと言える．Komeya et al. (2018) は，術後尿管ステント留置群と非留置群での患者の残石および術後急性憎悪の結果に差がないことを

示したが，もし実際には差があった場合，提案手法の方が 95%信頼区間に真の因果効果値が含まれている可能性が高いと考えられる．

提案手法において関数 $\psi(\boldsymbol{C};\boldsymbol{\alpha})$，$\phi(\boldsymbol{C};\boldsymbol{\gamma})$ に含める共変量に関する項の次元を変更したときの実験結果は Table 17 となった．結果変数が残石の場合は 2 次の項までモデルに含めて推定したときよりも，モデルに含める項の次元を増やして推定したときの方が 0 に近い推定値となった．特に，6 次の項までモデルに含めて推定したときもっとも 0 に近い推定値となった．このことから，共変量と残石の関係性は次数が 6 のモデルで構成されている可能性が高いと考えられる．一方，結果変数が術後急性憎悪の場合は 2 次の項までモデルに含めて推定したときよりも，モデルに含める項の次元を増やして推定したときの方が 0 から遠い推定値となった．このことから，共変量と術後急性憎悪の関係性は次数が 2 のモデルで構成されている可能性が高いと考えられる．

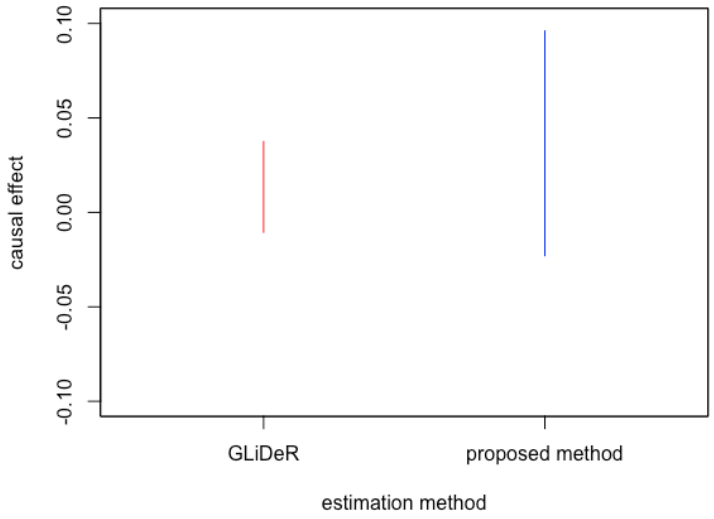


Fig. 2: 結果変数が残石のときのブートストラップ信頼区間

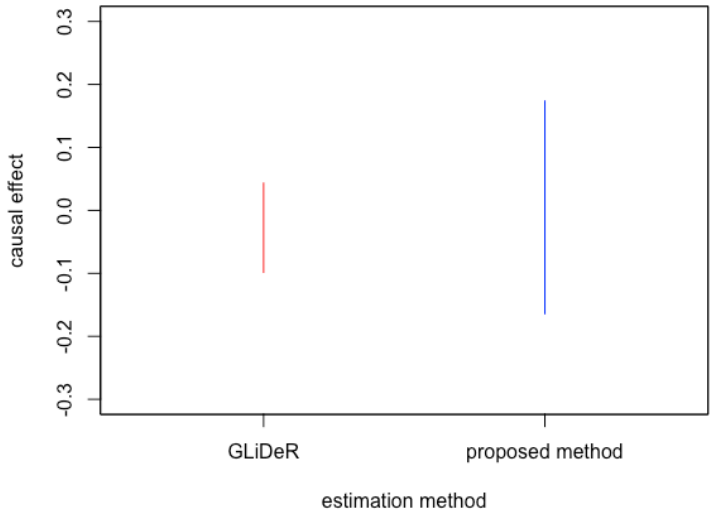


Fig. 3: 結果変数が術後急性憎悪のときのブートストラップ信頼区間

Table 17: 次元を変更して推定した因果効果値

次元	残石	術後急性憎悪
2	0.03389	−0.04768
3	0.03064	0.22250
4	0.01272	0.18808
5	0.01845	0.06448
6	0.01267	−0.05312
7	0.01336	−0.07922
8	0.01526	−0.10199

7　まとめ

本論文では，結果モデルが非線形であるときに因果効果値の推定精度向上を目指し，球共分散を組み込んだ GLiDeR を提案した．数値実験では，共変量に関する 1 次と 2 次の項をすべて含めて計算を行うことが困難であるとき，既存手法よりも提案手法の方が，結果モデルが非線形であるときの因果効果値の推定を精度良く行うことができることを示した．

今後の課題として，真の結果モデルに 2 乗の項が含まれているとき，2 乗の項の選択割合が低くなってしまうことが挙げられる．また，本稿で行った数値実験において，結果変数が 2 値であるときの因果効果値の推定を，処置群に割り当てられたときの結果と処置群に割り当てられなかったときの結果の差

$$E(Y_1 - Y_0) = \frac{1}{n}\sum_{i=1}^{n}\left\{\frac{Y_i X_i - (X_i - e_i)m_{1i}}{e_i} - \frac{Y_i(1 - X_i) + (X_i - e_i)m_{0i}}{1 - e_i}\right\} \tag{7.1}$$

を見ることによって行った．しかし，この方法では，因果効果の推定値は過剰に 0 に近づく恐れがあり，たとえ真の因果効果値が非 0 であったとしても，推定した因果効果値が 0 になりやすい可能性があるという問題点がある．そのため，結果変数が 2 値であるときに対応した二重頑健推定法を検討する必要がある．

謝辞

本研究を進めるにあたり，主任指導教員の西山悠准教授，指導教員の植野真臣教授，九州大学大学院数理学研究院の川野秀一教授から丁寧な指導と助言を頂き深謝いたします．また，同研究室の皆様には，相談に乗っていただいたことや研究の助言を頂いたことに心より感謝申し上げます.

付録

A　結果変数が2値のときにおけるGLiDeR

結果変数が連続変数のときと同様に，傾向スコアモデル $\pi(\boldsymbol{C};\boldsymbol{\gamma})$ にはロジスティック回帰モデルを仮定し，(3.9) 式を用いる．一方，結果モデル $\mu(\boldsymbol{X},\boldsymbol{C};\boldsymbol{\alpha})$ には，結果変数が連続変数であるときは線形回帰モデルを仮定したが，結果変数が 2 値変数であるときはロジスティック回帰モデル

$$\mu(\boldsymbol{X},\boldsymbol{C};\boldsymbol{\alpha}) = \frac{\exp(\alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X})}{1 + \exp(\alpha_1\boldsymbol{C}_1 + \alpha_2\boldsymbol{C}_2 + \cdots + \alpha_p\boldsymbol{C}_p + \alpha_{p+1} + \alpha_{p+2}\boldsymbol{X})} \tag{A.1}$$

を仮定する．ここで，$\alpha_1, \ldots, \alpha_p, \alpha_{p+1}, \alpha_{p+2}$ は回帰係数を表すパラメータであり，$\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_p, \alpha_{p+1}, \alpha_{p+2})^T$ とする．

いま，結果モデルと傾向スコアモデルにおける回帰係数を $\beta_1 = (\alpha_1, \gamma_1)$, $\beta_2 = (\alpha_2, \gamma_2), \ldots, \beta_p = (\alpha_p, \gamma_p)$, $\beta_{p+1} = \alpha_{p+1}$, $\beta_{p+2} = \gamma_{p+1}$, $\beta_{p+3} = \alpha_{p+2}$ とおき，$\boldsymbol{\beta} = (\beta_1, \beta_2, \ldots, \beta_p, \beta_{p+1}, \beta_{p+2}, \beta_{p+3})^T$ とする．GLiDeR は (3.12) 式の最小化問題として定義されている．このとき，結果変数が連続変数であるならば，$\Phi_{\text{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\boldsymbol{\beta})$ は傾向スコアモデルにおける負の対数尤度関数と結果モデルの誤差 2 乗和の和であったが，結果変数が 2 値変数であるならば，$\Phi_{\text{sum}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\boldsymbol{\beta})$ は傾向スコアモデルにおける負の対数尤度関数と結果モデルの負の対数尤度関数

$$\begin{aligned}\Phi_{\text{out}}(\boldsymbol{Y},\boldsymbol{X},\boldsymbol{C};\boldsymbol{\alpha}) = &-\sum_{i=1}^{n}\left\{Y_i(\alpha_1 C_{i1} + \alpha_2 C_{i2} + \cdots + \alpha_p C_{ip} + \alpha_{p+1} + \alpha_{p+2}X_i)\right\} \\ &+ \sum_{i=1}^{n}\log\left\{1 + \exp(\alpha_1 C_{i1} + \alpha_2 C_{i2} + \cdots + \alpha_p C_{ip} + \alpha_{p+1} + \alpha_{p+2}X_i)\right\}\end{aligned} \tag{A.2}$$

の和である．

また，正の重みは $W_k = \frac{\sqrt{2}}{|\nu_k|}$ であるが，ν_k は，ridge 回帰を用いて求めた (A.1) 式の回帰係数 α_k の推定値とする．このとき，ridge 回帰を用いて (A.1) 式の回帰係数を求めることが難しい場合は，ridge 回帰を用いて求めた (3.8) 式の回帰係数 α_k の推定値で代用する．

(3.12) 式における正則化パラメータ λ の選択は次の修正した一般化交差検証法

(GCV) の最小化により求める．

$$\mathrm{GCV}(\lambda) = \frac{\Phi_{\mathrm{out}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \hat{\boldsymbol{\alpha}}(\lambda))}{(1 - (2 + \sum_{j=1}^{p} I(\|\hat{\alpha}_j(\lambda)\| > 0) + \sum_{j=1}^{p} \frac{|\hat{\alpha}_j(\lambda)|}{v_j})/n)^2}. \tag{A.3}$$

このとき，$\hat{\boldsymbol{\alpha}}(\lambda) = (\hat{\alpha}_1(\lambda), \hat{\alpha}_2(\lambda), \cdots, \hat{\alpha}_p(\lambda), \hat{\alpha}_{p+1}(\lambda), \hat{\alpha}_{p+2}(\lambda))^T$ は (3.12) 式における $\boldsymbol{\alpha}$ の推定値である．結果変数が連続変数であるときは，分子は結果モデルの誤差 2 乗和としたが，結果変数が 2 値であるときは，分子は結果モデルの負の対数尤度関数としている．

計算アルゴリズムには結果変数が連続変数のときと同様に Algrithm 1，2 を用いる．ただし，Algorithm1，2 で用いる関数 $U^{(k)}$ において，(3.18) 式で求められた $\frac{\partial}{\partial \alpha_k}\Phi_{\mathrm{sum}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \widetilde{\boldsymbol{\beta}})$ は次のように変更する．

$$-\frac{\partial}{\partial \alpha_k}\Phi_{\mathrm{sum}}(\boldsymbol{Y}, \boldsymbol{X}, \boldsymbol{C}; \widetilde{\boldsymbol{\beta}}) = \begin{cases} \sum_{i=1}^{n} \left(Y_i - \frac{\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}{1+\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}\right) C_{ik} & (1 \leq k \leq p) \\ \sum_{i=1}^{n} \left(Y_i - \frac{\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}{1+\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}\right) & (k = p+1) \\ \sum_{i=1}^{n} \left(Y_i - \frac{\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}{1+\exp(\widetilde{\alpha}_1 C_{i1} + \cdots + \widetilde{\alpha}_p C_{ip} + \widetilde{\alpha}_{p+1} + \widetilde{\alpha}_{p+2} X_i)}\right) X_i & (k = p+2) \end{cases}. \tag{A.4}$$

B (4.3)，(4.4) 式の証明

(4.3)，(4.4) 式は次のようにして証明することができる．まず，$W_1 = (C_{1\alpha}, Y_1)$，$W_2 = (C_{2\alpha}, Y_2)$ とする．次に，$E\left\{\xi^{\boldsymbol{C}_\alpha}_{12,3456}\xi^{\boldsymbol{Y}}_{12,3456}\right\}$ は

$$E\left\{\xi^{\boldsymbol{C}_\alpha}_{12,3456}\xi^{\boldsymbol{Y}}_{12,3456}\right\} = E(\delta^{\boldsymbol{C}_\alpha}_{12,34}\delta^{\boldsymbol{Y}}_{12,34}) + E(\delta^{\boldsymbol{C}_\alpha}_{12,34}\delta^{\boldsymbol{Y}}_{12,56}) - 2E(\delta^{\boldsymbol{C}_\alpha}_{12,34}\delta^{\boldsymbol{Y}}_{12,35}) \tag{B.1}$$

と書き換えることができる．このとき，以下の式が成り立つ．

$$\begin{aligned} E(\delta^{\boldsymbol{C}_\alpha}_{12,34}\delta^{\boldsymbol{Y}}_{12,34}) &= E\left\{E(\delta^{\boldsymbol{C}_\alpha}_{12,34}\delta^{\boldsymbol{Y}}_{12,34} \mid W_1, W_2)\right\} \\ &= E\left\{E(\delta^{\boldsymbol{C}_\alpha}_{12,3}\delta^{\boldsymbol{C}_\alpha}_{12,4}\delta^{\boldsymbol{Y}}_{12,3}\delta^{\boldsymbol{Y}}_{12,4} \mid W_1, W_2)\right\} \\ &= E\left\{E^2(\delta^{\boldsymbol{C}_\alpha}_{12,3}\delta^{\boldsymbol{Y}}_{12,3} \mid W_1, W_2)\right\}, \end{aligned} \tag{B.2}$$

$$
\begin{aligned}
E(\delta_{12,34}^{\boldsymbol{C}_\alpha}\delta_{12,56}^{\boldsymbol{Y}}) &= E\left\{E(\delta_{12,34}^{\boldsymbol{C}_\alpha}\delta_{12,56}^{\boldsymbol{Y}} \mid W_1, W_2)\right\} \\
&= E\left\{E(\delta_{12,3}^{\boldsymbol{C}_\alpha}\delta_{12,4}^{\boldsymbol{C}_\alpha}\delta_{12,5}^{\boldsymbol{Y}}\delta_{12,6}^{\boldsymbol{Y}} \mid W_1, W_2)\right\} \\
&= E\left\{E^2(\delta_{12,3}^{\boldsymbol{C}_\alpha} \mid W_1, W_2)E^2(\delta_{12,3}^{\boldsymbol{Y}} \mid W_1, W_2)\right\},
\end{aligned} \tag{B.3}
$$

$$
\begin{aligned}
E(\delta_{12,34}^{\boldsymbol{C}_\alpha}\delta_{12,35}^{\boldsymbol{Y}}) &= E\left\{E(\delta_{12,34}^{\boldsymbol{C}_\alpha}\delta_{12,35}^{\boldsymbol{Y}} \mid W_1, W_2)\right\} \\
&= E\left\{E(\delta_{12,3}^{\boldsymbol{C}_\alpha}\delta_{12,4}^{\boldsymbol{C}_\alpha}\delta_{12,3}^{\boldsymbol{Y}}\delta_{12,5}^{\boldsymbol{Y}} \mid W_1, W_2)\right\} \\
&= E\left\{E(\delta_{12,3}^{\boldsymbol{C}_\alpha}\delta_{12,3}^{\boldsymbol{Y}} \mid W_1, W_2)E(\delta_{12,3}^{\boldsymbol{C}_\alpha} \mid W_1, W_2)E(\delta_{12,3}^{\boldsymbol{Y}} \mid W_1, W_2)\right\}.
\end{aligned} \tag{B.4}
$$

以上より，次が成り立つ．

$$
\begin{aligned}
&E\left\{\xi_{12,3456}^{\boldsymbol{C}_\alpha}\xi_{12,3456}^{\boldsymbol{Y}}\right\} \\
&= E\left\{\left[E(\delta_{12,3}^{\boldsymbol{C}_\alpha}\delta_{12,3}^{\boldsymbol{Y}} \mid W_1, W_2) - E(\delta_{12,3}^{\boldsymbol{C}_\alpha} \mid W_1, W_2)E(\delta_{12,3}^{\boldsymbol{Y}} \mid W_1, W_2)\right]^2\right\} \\
&= E\left\{\Big[P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}), Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\right. \\
&\quad \left.-P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}) \mid W_1, W_2)P(Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\Big]^2\right\} \\
&= \int (\theta - \iota \otimes \kappa)^2 \left\{\bar{B}_\rho(C_{1\alpha}, C_{2\alpha}) \times \bar{B}_\zeta(Y_1, Y_2)\right\}\theta(dC_{1\alpha}, dY_1)\theta(dC_{2\alpha}, dY_2) \\
&= \mathrm{BCov}^2(\boldsymbol{C}_\alpha, \boldsymbol{Y}).
\end{aligned} \tag{B.5}
$$

このとき，θ, ι, κ はそれぞれ $(\boldsymbol{C}_\alpha, \boldsymbol{Y})$, $\boldsymbol{C}_\alpha$, $\boldsymbol{Y}$ によって誘導される確率測度である．したがって，

$$
\mathrm{BCov}^2(\boldsymbol{C}_\alpha, \boldsymbol{Y}) = E\left\{\xi_{12,3456}^{\boldsymbol{C}_\alpha}\xi_{12,3456}^{\boldsymbol{Y}}\right\} \tag{B.6}
$$

となり，(4.3) 式が証明される．加えて，

$$
\begin{aligned}
&\mathrm{BCov}^2(\boldsymbol{C}_\alpha, \boldsymbol{Y}) \\
&= E\left\{\Big[\, P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}), Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\right. \\
&\quad \left.- P(C_{3\alpha} \in \bar{B}_\rho(C_{1\alpha}, C_{2\alpha}) \mid W_1, W_2)P(Y_3 \in \bar{B}_\zeta(Y_1, Y_2) \mid W_1, W_2)\,\Big]^2\right\}.
\end{aligned} \tag{B.7}
$$

となり，(4.4) 式が証明される．

参考文献

Bang, H. and Robins, J. M. (2005). Doubly robust estimation in missing data and causal inference models. *Biometrics*, **61**, 962–972.

Brookhart, M. A., Schneeweiss, S., Rothman, K. J., Glynn, R. J., Avorn, J. and Stürmer, T. (2006). Variable selection for propensity score models. *American Journal of Epidemiology*, **163**, 1149–1156.

Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, **12**, 55–67.

Hoshino, T. (2007). Doubly robust-type estimation for covariate adjustment in latent variable modeling. *Psychometrika*, **72**, 535–549.

Koch, B., Vock, D. M. and Wolfson, J. (2017). Covariate selection with group lasso and doubly robust estimation of causal effects. *Biometrics*, **74**, 8–17.

Komeya, M., Usui, K., Asai, T., Ogawa, T., Taguri, M., Kataoka, K., Yao, M. and Matsuzaki, J. (2018). Outcome of flexible ureteroscopy for renal stone with overnight ureteral catheterization: a propensity score-matching analysis. *World Journal of Urology*, **36**, 1871–1876.

Lunceford, J. K. and Davidian, M. (2004). Stratification and weighting via the propensity score in estimation of causal treatment effects: a comparative study. *Statistics in medicine*, **23**, 2937–2960.

Pan, W., Wang, X., Zhang, Z., Zhu, H. and Zhu, J. (2020). Ball covariance: A generic measure of dependence in banach space. *Journal of the American Statistical Association*, **115**, 307–317.

Rosenbaum, P. R. and Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, **70**, 41–55.

Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, **66**, 688–701.

Rubin, D. B. (1985). The use of propensity scores in applied bayesian inference. In J.M. Bernardo, M.H. De Groot, D.V. Lindley, and A.F.M. Smith (eds.), *Bayesian Statistics*, **2**, 463–472. Elsevier Science Publisher B.V., North–Holland.

Tang, D., Kong, D., Pan, W. and Wang, L. (2023). Ultra–high dimensional variable selection for doubly robust causal inference. *Biometrics*, **79**, 903–914.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, **58**, 267–288.

Yang, Y. and Zou, H. (2015). A fast unified algorithm for solving group–lasso penalized learning problems. *Statistics and Computing*, **25**, 1129–1141.

Yuan, M. and Lin, Y. (2006). Model selection and estimation in regression with grouped variables. *Journal of the Royal Statistical Society: Series B*, **68**, 49–67.

Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, **101**, 1418–1429.

星野崇宏. (2009). 調査観察データの統計科学 – 因果推論・選択バイアス・データ融合. 岩波書店.